

## CH.2 - Régression linéaire Simple (RLS)

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

termes d'erreur de l'ind.  $i$   
 $1 \leq i \leq n$

observation de la  
variable réponse  
de l'individu  $i$

ordonnée à l'origine

obs. de la var. explicative de l'ind.  $i$

pente de la droite de régression

paramètres (coefficients) du modèle de rég.


Quelles sont les variables aléatoires / constantes ? Connues / inconnues ?

$\varepsilon_i$  : v.a. , inconnues

$Y_i$  : v.a. , connues

$X_i$  : valeurs constantes , connues

$\beta_0, \beta_1$  : constantes , inconnues



## POSTULATS

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

1°  $E(\varepsilon_i) = 0$  pour  $1 \leq i \leq n$

$$E(Y_i) = E(\beta_0 + \beta_1 x_i + \varepsilon_i) = \beta_0 + \beta_1 x_i + E(\varepsilon_i) = \beta_0 + \beta_1 x_i$$

2°  $\text{Var}(\varepsilon_i) = \sigma^2$  pour  $1 \leq i \leq n$

3°  $\text{COV}(\varepsilon_i, \varepsilon_j) = 0$  pour  $i \neq j$ ,  $1 \leq i, j \leq n$

4°  $\varepsilon_i \sim N(0, \sigma^2)$  pour  $1 \leq i \leq n$

$$\left[ \varepsilon_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2) \text{ pour } 1 \leq i \leq n \right]$$

Que représente  $\beta_0$ ?

- la valeur moyenne de  $Y$  quand  $x=0$
- si  $\beta_0=0$  : en moyenne,  $Y$  vaut 0 lorsque  $x=0$ .

Que représente  $\beta_1$ ?

- l'augmentation moyenne de  $Y$  quand  $x$  augmente de 1 unité

## Modèle centré

On peut centrer le modèle pour interpréter l'ordonnée à l'origine.

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$


$$= \beta_0 + \beta_1 \bar{x} + \beta_1 x_i - \beta_1 \bar{x} + \varepsilon_i$$

$$= (\beta_0 + \beta_1 \bar{x}) + \beta_1 (x_i - \bar{x}) + \varepsilon_i$$

$$= \beta_0^* + \beta_1 (x_i - \bar{x}) + \varepsilon_i$$

$\beta_0^* = \beta_0 + \beta_1 \bar{x}$  est la valeur moyenne de  $Y$  quand  $x = \bar{x}$

## Estimation des paramètres : Méthode des moindres carrés



Minimiser la distance  
entre la droite et les  
observations

On veut choisir les coef. qui permettent de minimiser la somme des erreurs au carré

$$\sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n \left[ \underbrace{y_i - (\beta_0 + \beta_1 x_i)}_{\varepsilon_i} \right]^2$$

On cherche à minimiser

$$g(\beta_0, \beta_1) = \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2$$

• Dérivons

$$\begin{aligned} \frac{\partial g(\beta_0, \beta_1)}{\partial \beta_0} &= \sum_{i=1}^n 2[y_i - (\beta_0 + \beta_1 x_i)](-1) \\ &= -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) \end{aligned}$$

$$\begin{aligned} \frac{\partial g(\beta_0, \beta_1)}{\partial \beta_1} &= \sum_{i=1}^n 2[y_i - (\beta_0 + \beta_1 x_i)](-x_i) \\ &= -2 \sum_{i=1}^n (y_i x_i - \beta_0 x_i - \beta_1 x_i^2) \end{aligned}$$

• Posons = 0 et évaluons en  $\hat{\beta}_0$  et  $\hat{\beta}_1$

$$-2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \Rightarrow \sum_{i=1}^n y_i - \sum_{i=1}^n \hat{\beta}_0 - \sum_{i=1}^n \hat{\beta}_1 x_i = 0$$

$$n\bar{y} - n\hat{\beta}_0 - n\hat{\beta}_1 \bar{x} = 0 \Rightarrow \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$-2 \sum_{i=1}^n (y_i x_i - \hat{\beta}_0 x_i - \hat{\beta}_1 x_i^2) = 0 \Rightarrow \sum_{i=1}^n x_i y_i - \sum_{i=1}^n \hat{\beta}_0 x_i - \sum_{i=1}^n \hat{\beta}_1 x_i^2 = 0$$

$$\sum_{i=1}^n x_i y_i - n\hat{\beta}_0 \bar{x} - \hat{\beta}_1 \sum_{i=1}^n x_i^2 = 0$$

$$\sum_{i=1}^n x_i y_i - n(\bar{y} - \hat{\beta}_1 \bar{x}) \bar{x} - \hat{\beta}_1 \sum_{i=1}^n x_i^2 = 0$$

$$\sum_{i=1}^n x_i y_i - n \bar{y} \bar{x} + n \hat{\beta}_1 \bar{x}^2 - \hat{\beta}_1 \sum_{i=1}^n x_i^2 = 0$$

$$S_{xy} + \hat{\beta}_1 \left( n \bar{x}^2 - \sum_{i=1}^n x_i^2 \right) = 0$$

$$S_{xy} - \hat{\beta}_1 \left( \sum_{i=1}^n x_i^2 - n \bar{x}^2 \right) = 0$$

$$S_{xy} - \hat{\beta}_1 S_{xx} = 0$$

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} \quad \text{or} \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$


---

$$\begin{aligned} S_{xy} &= \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \\ &= \sum_{i=1}^n x_i y_i - \frac{1}{n} \sum_{i=1}^n x_i \sum_{j=1}^n y_j \\ &= \sum_{i=1}^n x_i y_i - n \bar{x} \bar{y} \end{aligned}$$

$$\begin{aligned} S_{xx} &= \sum_{i=1}^n (x_i - \bar{x})^2 \\ &= \sum_{i=1}^n x_i^2 - \frac{1}{n} \left( \sum_{i=1}^n x_i \right)^2 \\ &= \sum_{i=1}^n x_i^2 - n \bar{x}^2 \end{aligned}$$

modèle:  $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$

estimations:  $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}$  et  $\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$

Prédictions:  $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$

Residus:  $\hat{\varepsilon}_i = Y_i - \hat{Y}_i$   
 $= Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$

