

Chapitre 2

Ajustement d'un modèle de régression linéaire simple (RLS)

Sommaire

2.1	Le modèle de régression linéaire simple	11
2.1.1	Postulats du modèle de RLS	12
2.1.2	Interprétation de β_0 et β_1	13
2.2	Estimation des paramètres	14
2.2.1	Méthode des moindres carrés	14
2.2.2	Méthode du maximum de vraisemblance	16
2.3	Exemple	17

Figures

2.1	Illustration du modèle de régression linéaire simple	13
2.2	Diagramme de dispersion du rendement en fonction de la température	18
2.3	Diagramme de dispersion du rendement en fonction de la température avec la droite de régression estimée superposée	19

2.1 Le modèle de régression linéaire simple

Le modèle de régression linéaire simple est un modèle dans lequel on cherche à expliquer une variable endogène Y en fonction d'une seule variable exogène x . Il s'exprime comme suit

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad (2.1)$$

où

- Y_i est une variable aléatoire représentant la réponse de l'unité i ;
- x_i est la valeur (connue) de la variable explicative de l'unité i ;
- β_0 est le paramètre associé à l'ordonnée à l'origine de la droite ;
- β_1 est le paramètre associé à la pente de la droite ;
- ε_i est une variable aléatoire représentant le terme d'erreur de l'unité i .

Il est important de comprendre quelles quantités sont supposées constantes ou aléatoires dans le modèle (2.1), à savoir

- $Y_1, \dots, Y_n$ sont des variables aléatoires ;
- $x_1, \dots, x_n$ sont des valeurs considérées constantes ;
- β_0 et β_1 , les paramètres du modèle, sont constants ;
- $\varepsilon_1, \dots, \varepsilon_n$ sont des variables aléatoires.

Les paramètres du modèle (2.1) sont inconnus et doivent être estimés. Pour les estimer, nous disposons de n réalisations, soit les couples (x_i, y_i) , pour $i = 1, \dots, n$. À noter que y_i est la réalisation de la variable aléatoire Y_i , pour $i = 1, \dots, n$.

2.1.1 Postulats du modèle de RLS

Pour développer la théorie de la régression linéaire, il est nécessaire de formuler certains postulats sur le modèle défini en (2.1). Ces postulats peuvent être énoncés mathématiquement en termes d'hypothèses sur les termes d'erreur ε_i du modèle :

$\mathcal{P}_1$. La linéarité de la relation entre la variable réponse et la variable explicative :

$$\mathbb{E}[\varepsilon_i] = 0 \text{ pour } 1 \leq i \leq n.$$

$\mathcal{P}_2$. L'homoscédasticité (variance constante) des observations de la variable réponse :

$$\mathbb{V}\text{ar}[\varepsilon_i] = \sigma^2 \text{ pour } 1 \leq i \leq n.$$

$\mathcal{P}_3$. L'indépendance des observations de la variable réponse :

$$\mathbb{C}\text{ov}(\varepsilon_i, \varepsilon_j) = 0 \text{ pour } i \neq j.$$

$\mathcal{P}_4$. La normalité des termes d'erreur :

$$\varepsilon_1, \dots, \varepsilon_n \sim \mathcal{N}(0, \sigma^2).$$

Le premier postulat est nécessaire pour l'interprétation des paramètres du modèle, et indique simplement que le modèle linéaire est approprié pour modéliser la relation entre les variables d'intérêt. Les deux postulats suivants permettent d'estimer la variance des estimateurs de β_0 et β_1 . Obtenir une telle mesure de précision des estimateurs ponctuels est très important en pratique. À ces trois postulats, on doit souvent ajouter le quatrième postulat sur l'hypothèse de normalité des termes d'erreur. Il s'agit d'un postulat plus fort généralement utilisé parce qu'il permet de construire des intervalles de confiance et de

faire des tests d'hypothèses aisément¹. On verra également que ce postulat est nécessaire à la mise en œuvre de la méthode du maximum de vraisemblance pour l'estimation des paramètres.

Il est évidemment possible que ces 4 postulats ne soient pas vérifiés en pratique. Nous verrons dans ce cours comment tester si chacun des postulats est vérifié et comment modifier le modèle au besoin. Nous verrons aussi brièvement d'autres modèles de régression qui peuvent être utilisés si une ou plusieurs des conditions d'application de la RLS ne sont pas vérifiées.

2.1.2 Interprétation de β_0 et β_1

La figure 2.1 illustre le modèle de régression linéaire simple. La ligne droite représente la valeur moyenne de Y en fonction de la valeur de x . Les variables Y_i sont distribuées de façon aléatoire autour de cette droite. Les termes d'erreur sont les différences entre les Y_i et la droite. Comme la variance de ces termes est constante en x , la distance moyenne des points à la droite est la même pour toute valeur de x . Finalement, l'absence de corrélation entre les termes d'erreur signifie que la valeur d'un terme d'erreur n'est pas influencée par la valeur des autres termes d'erreur.




FIGURE 2.1 – Illustration du modèle de régression linéaire simple.

On interprète β_0 comme la valeur moyenne de Y lorsque x vaut zéro et β_1 comme l'accroissement moyen de Y lorsque x augmente d'une unité. Si $\beta_0 = 0$, l'espérance de Y est nulle lorsque x vaut zéro, et le modèle ne comporte pas d'ordonnée à l'origine. Si $\beta_1 = 0$, l'espérance de Y ne dépend pas de x , du moins pas de façon linéaire.

1. Il est également possible d'obtenir des intervalles de confiance et des tests d'hypothèses sans poser le postulat de normalité des erreurs, en utilisant par exemple la méthode du bootstrap.

Modèle centré

Il arrive que la valeur moyenne de Y lorsque x vaut zéro soit difficile ou inutile à interpréter. On peut alors utiliser une version centrée du modèle,

$$\begin{aligned} Y_i &= \beta_0 + \beta_1 x_i + \varepsilon_i \\ &= \beta_0^* + \beta_1 (x_i - \bar{x}) + \varepsilon_i \text{ (version centrée).} \end{aligned}$$

Dans la version centrée du modèle, l'interprétation de β_1 est inchangée, mais β_0^* s'interprète comme étant la valeur moyenne de Y lorsque x vaut $\bar{x}$. On remarque que $\beta_0^* = \beta_0 + \beta_1 \bar{x}$.

2.2 Estimation des paramètres

Dans le modèle de régression linéaire simple, on doit estimer trois paramètres : β_0 et β_1 , qui décrivent la droite de régression, ainsi que σ^2 , la variance des termes d'erreur. Deux approches communes pour estimer les paramètres d'un modèle de régression sont la méthode des moindres carrés et celle du maximum de vraisemblance. Dans les sections suivantes, on explique comment estimer les paramètres de régression à l'aide de ces deux approches, et on démontre qu'elles sont équivalentes sous le postulat de normalité $\mathcal{P}_4$.

2.2.1 Méthode des moindres carrés

Tel que mentionné au [chapitre 1](#), on attribue généralement la méthode des moindres carrés au mathématicien français Adrien-Marie Legendre (1752-1833). Plusieurs autres mathématiciens de l'époque ont aussi publié des travaux sur le sujet, notamment Carl Friedrich Gauss (1777-1855) et Robert Adrain (1775-1843).

Soit $\hat{Y}_i$ la prévision du modèle pour l'observation i . On appelle résidu la différence entre Y_i , la variable réponse, et cette prévision $\hat{Y}_i$. On le dénote $\hat{\varepsilon}_i$, puisque c'est une estimation du terme d'erreur ε_i .

Avec la méthode des moindres carrés, on cherche à choisir les estimateurs $\hat{\beta}_0$ et $\hat{\beta}_1$ de façon à minimiser la somme des carrés des erreurs. On veut donc minimiser la fonction

$$g(\beta_0, \beta_1) = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n \{Y_i - (\beta_0 + \beta_1 x_i)\}^2. \quad (2.2)$$

Puisque la fonction à minimiser possède de bonnes propriétés (entre autres lisse et convexe), elle peut être minimisée en la dérivant par rapport à β_0 et β_1 , puis en posant ces dérivées égales à zéro. On doit donc résoudre le système d'équations à deux inconnues suivant :

$$\begin{cases} \frac{\partial}{\partial \beta_0} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2 = 0, \\ \frac{\partial}{\partial \beta_1} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2 = 0. \end{cases} \quad (2.3)$$

Estimation de β_0

On dérive d'abord par rapport à β_0 :

$$\begin{aligned} \frac{\partial}{\partial \beta_0} \left\{ \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2 \right\} &= \sum_{i=1}^n 2(Y_i - \beta_0 - \beta_1 x_i)(-1) \\ &= -2(n\bar{Y} - n\beta_0 - n\beta_1 \bar{x}). \end{aligned}$$

On pose ensuite cette dérivée égale à zéro, et elle est évaluée au point $(\hat{\beta}_0, \hat{\beta}_1)$. Il s'agit du point critique de la fonction $g(\beta_0, \beta_1)$:

$$\begin{aligned} -2(n\bar{Y} - n\hat{\beta}_0 - n\hat{\beta}_1 \bar{x}) &= 0, \\ \bar{Y} - \hat{\beta}_0 - \hat{\beta}_1 \bar{x} &= 0, \\ \hat{\beta}_0 &= \bar{Y} - \hat{\beta}_1 \bar{x}. \end{aligned} \tag{2.4}$$

Remarque 1. Il est à noter que l'équation (2.4) signifie que la droite de régression passe nécessairement par le point de coordonnées $(\bar{x}, \bar{Y})$:

$$\bar{Y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}. \tag{2.5}$$

Estimation de β_1

On dérive ensuite par rapport à β_1 :

$$\begin{aligned} \frac{\partial}{\partial \beta_1} \left\{ \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2 \right\} &= \sum_{i=1}^n 2(Y_i - \beta_0 - \beta_1 x_i)(-x_i) \\ &= -2 \left(\sum_{i=1}^n x_i Y_i - \sum_{i=1}^n \beta_0 x_i - \sum_{i=1}^n \beta_1 x_i^2 \right). \end{aligned}$$

En posant cette dérivée égale à zéro, en l'évaluant au point $(\hat{\beta}_0, \hat{\beta}_1)$ et en utilisant (2.4), on a

$$\begin{aligned} -2 \left(\sum_{i=1}^n x_i Y_i - \sum_{i=1}^n \hat{\beta}_0 x_i - \sum_{i=1}^n \hat{\beta}_1 x_i^2 \right) &= 0 \\ \sum_{i=1}^n x_i Y_i &= \hat{\beta}_0 \sum_{i=1}^n x_i + \hat{\beta}_1 \sum_{i=1}^n x_i^2 \\ \sum_{i=1}^n x_i Y_i &= (\bar{Y} - \hat{\beta}_1 \bar{x}) \sum_{i=1}^n x_i + \hat{\beta}_1 \sum_{i=1}^n x_i^2 \\ \sum_{i=1}^n x_i Y_i &= \bar{Y} \sum_{i=1}^n x_i + \hat{\beta}_1 \left(\sum_{i=1}^n x_i^2 - \bar{x} \sum_{i=1}^n x_i \right). \end{aligned}$$

On obtient l'estimateur

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i Y_i - \bar{Y} \sum_{i=1}^n x_i}{\sum_{i=1}^n x_i^2 - \bar{x} \sum_{i=1}^n x_i}. \tag{2.6}$$

Il est possible de réécrire $\hat{\beta}_1$ sous les formes équivalentes suivantes :

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i Y_i - n\bar{x}\bar{Y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})Y_i}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

Ces différentes formes peuvent être utiles pour calculer $\hat{\beta}_1$ selon le type d'information que nous avons sur les données. On simplifie parfois davantage la notation en écrivant

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}, \quad (2.7)$$

où

$$S_{xy} = \sum_{i=1}^n (x_i - \bar{x}) Y_i = \sum_{i=1}^n x_i Y_i - \frac{1}{n} \left(\sum_{i=1}^n x_i \right) \left(\sum_{i=1}^n Y_i \right), \quad (2.8)$$

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2. \quad (2.9)$$

Il est à noter que S_{xy} et S_{xx} sont appelés respectivement la somme des produits croisés corrigée de x et Y et la somme des carrés corrigée de x . En somme, les estimateurs des moindres carrés pour la RLS sont

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}, \quad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}. \quad (2.10)$$

2.2.2 Méthode du maximum de vraisemblance

La méthode du maximum de vraisemblance nécessite de spécifier la distribution exacte de $Y_1, \dots, Y_n$. Celle-ci est connue sous l'hypothèse des quatre postulats établis à la section 2.1.1. Avec ceux-ci, on peut écrire le modèle sous la forme

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2),$$

ou, de façon équivalente,

$$Y_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2), \quad (2.11)$$

pour $i = 1, \dots, n$. La vraisemblance s'exprime donc

$$\begin{aligned} L(\beta_0, \beta_1, \sigma^2) &= \prod_{i=1}^n f(Y_i) \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{1}{2} \left(\frac{Y_i - \beta_0 - \beta_1 x_i}{\sigma} \right)^2 \right\}. \end{aligned}$$

Pour simplifier les calculs, plutôt que de maximiser la vraisemblance $L(\beta_0, \beta_1)$, il est possible de maximiser son logarithme

$$\begin{aligned} l(\beta_0, \beta_1, \sigma^2) &= \sum_{i=1}^n \left\{ -\frac{1}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} (Y_i - \beta_0 - \beta_1 x_i)^2 \right\} \\ &= -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2. \end{aligned} \quad (2.12)$$

Les estimateurs $\hat{\beta}_0$, $\hat{\beta}_1$ et $\hat{\sigma}^2$ sont les valeurs qui minimisent $l(\beta_0, \beta_1, \sigma^2)$ obtenues en dérivant respectivement par rapport à β_0 , β_1 et σ^2 puis en posant les dérivées égales à zéro.

Dans l'équation (2.12), on remarque que le premier terme ne contient ni β_0 , ni β_1 . Maximiser la log-vraisemblance par rapport à β_0 et β_1 revient donc à maximiser le second terme. Ce dernier étant négatif, cela équivaut à minimiser $\sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2$, ce qui correspond exactement à la méthode des moindres carrés de Legendre. Ainsi, les estimateurs de la méthode du maximum de vraisemblance de β_0 et β_1 sont les mêmes que ceux obtenus avec la méthode des moindres carrés.

La méthode du maximum de vraisemblance présente toutefois certains avantages par rapport à la méthode des moindres carrés. Elle permet notamment d'estimer σ^2 de façon directe. Ceci permet de trouver la distribution des paramètres et des prévisions et de faire des tests d'hypothèse, comme on verra dans les sections suivantes.

Estimation de σ^2

On estime σ^2 de la même manière que β_0 et β_1 en dérivant le logarithme de la vraisemblance par rapport à σ^2 ,

$$\begin{aligned} \frac{\partial}{\partial \sigma^2} \left\{ -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2 \right\} &= -\frac{n}{2} \frac{1}{2\pi\sigma^2} 2\pi + \frac{1}{\sigma^4} \frac{1}{2} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2 \\ &= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2. \end{aligned}$$

En posant la dérivée égale à zéro et en évaluant au point $(\hat{\beta}_0, \hat{\beta}_1, \hat{\sigma}_{MV}^2)$, on a

$$\hat{\sigma}_{MV}^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 = \frac{1}{n} \sum_{i=1}^n \hat{\varepsilon}_i^2. \quad (2.13)$$

Rappelons que $\hat{\varepsilon}_i$ désigne la différence entre la prédiction $\hat{Y}_i$ et la variable Y_i .

2.3 Exemple

Le petit exemple qui va servir de fil conducteur pour les chapitres sur la régression linéaire simple est tiré de [Hines et coll. \(2012\)](#). Un ingénieur chimiste a analysé l'effet de la température de fonctionnement d'un procédé sur le rendement du produit. Les valeurs obtenues sont résumées ci-dessous.

TABLE 2.1 – 10 mesures du rendement en % en fonction de la température en °C

Température [°C]	100	110	120	130	140	150	160	170	180	190
Rendement [%]	45	51	54	61	66	70	74	78	85	89




FIGURE 2.2 – Diagramme de dispersion du rendement en fonction de la température

On peut constater sur la figure 2.2 qu'il existe une relation forte entre le rendement et la température. Supposons que cette relation est linéaire, il est possible de modéliser ces données à l'aide de l'équation (2.1). On calcule d'abord

$$\begin{aligned} \sum_{i=1}^{10} x_i &= 1450, & \bar{x} &= \frac{1}{10} \sum_{i=1}^{10} x_i = 145, & \sum_{i=1}^{10} x_i^2 &= 218\,500, \\ \sum_{i=1}^{10} y_i &= 673, & \bar{y} &= \frac{1}{10} \sum_{i=1}^{10} y_i = 67,3, & \sum_{i=1}^{10} Y_i x_i &= 101\,570. \end{aligned}$$

On obtient

$$\begin{aligned} S_{xx} &= 218\,500 - (1450)^2/10 = 8250, \\ S_{xy} &= 101\,570 - 1450 \times 673/10 = 3985. \end{aligned}$$

Et donc

$$\begin{aligned} \hat{\beta}_1 &= 3985/8250 = 0,483, \\ \hat{\beta}_0 &= 67,3 - 0,483 \times 145 = -2,739. \end{aligned}$$

Le modèle de régression linéaire simple ajusté est $\hat{Y}_i = -2,739 + 0,483x_i$. Ainsi, une augmentation de un degré Celsius de la température du procédé est associée à une augmentation moyenne de 0,483

point de pourcentage du rendement du produit. Le modèle indique aussi qu'à une température nulle, le rendement attendu est de $-2,739\%$.

La figure 2.3 montre l'ajustement obtenu sous forme d'une droite. Dans ce cas-ci la relation linéaire semble très appropriée pour modéliser la relation entre les variables.




FIGURE 2.3 – Diagramme de dispersion du rendement en fonction de la température avec la droite de régression estimée superposée

On peut également estimer σ^2 à partir des données. Il faut d'abord calculer la valeur prédite et le résidu pour chacune des observations, comme au Tableau 2.2. L'équation (2.13) mène à

$$\hat{\sigma}_{MV}^2 = \frac{1}{10} \{(-0,561)^2 + \dots + (-0,0301)^2\} = \frac{7,224}{10} = 0,7224.$$

TABLE 2.2 – Tableau résumant x_i , Y_i , $\hat{Y}_i$ et $\hat{\varepsilon}_i$, $i = 1, \dots, 10$ pour le calcul de $\hat{\sigma}_{MV}^2$ dans l'exemple de la section 2.3

i	x_i	Y_i	$\hat{Y}_i$	$\hat{\varepsilon}_i$
1	100	45	45,561	-0,561
2	110	51	50,391	0,609
3	120	54	55,221	-1,221
4	130	61	60,051	0,949
5	140	66	64,881	1,119
6	150	70	69,711	0,289
7	160	74	74,541	-0,541
8	170	78	79,371	-1,371
9	180	85	84,201	0,799
10	190	89	89,031	-0,031