

CHAPITRE 3 — INFÉRENCE

• modèle : $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$

• $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$

• $\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x}) y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} = 0$

→ $\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n (x_i - \bar{x}) y_i - \underbrace{\left(\sum_{i=1}^n (x_i - \bar{x}) \bar{y} \right)}_{=0}$

$$\bar{y} \sum_{i=1}^n (x_i - \bar{x})$$

$$\bar{y} \left(\sum_{i=1}^n x_i - \sum_{i=1}^n \bar{x} \right)$$

$$\bar{y} \left(\sum_{i=1}^n x_i - n \bar{x} \right) = \bar{y} \left(\sum_{i=1}^n x_i - n \frac{1}{n} \sum_{i=1}^n x_i \right) = 0$$

$$\bullet \hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x}) y_i}{S_{xx}} = \frac{\sum_{i=1}^n \frac{(x_i - \bar{x})}{S_{xx}} y_i}{1} = \sum_{i=1}^n a_i y_i \quad \text{ou} \quad a_i = \frac{x_i - \bar{x}}{S_{xx}}$$

$$\bullet \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = \frac{1}{n} \sum_{i=1}^n y_i - \bar{x} \sum_{i=1}^n a_i y_i = \sum_{i=1}^n \left(\frac{1}{n} - \bar{x} a_i \right) y_i = \sum_{i=1}^n b_i y_i$$

$$\text{ou} \quad b_i = \frac{1}{n} - \bar{x} a_i = \frac{1}{n} - \bar{x} \frac{x_i - \bar{x}}{S_{xx}}$$

→ $\hat{\beta}_0$ et $\hat{\beta}_1$ sont des combinaisons linéaires des y_i , $i=1, \dots, n$
 de v.a. normalement distribuées

⇒ $\hat{\beta}_0$ et $\hat{\beta}_1$ sont normalement distribués

- $\hat{\beta}_1 = \sum_{i=1}^n a_i Y_i$ avec $a_i = \frac{X_i - \bar{X}}{S_{XX}}$

- $E(\hat{\beta}_1) = E\left(\sum_{i=1}^n a_i Y_i\right) = \sum_{i=1}^n a_i E(Y_i) = \sum_{i=1}^n a_i E(\beta_0 + \beta_1 X_i + \varepsilon_i)$

$$= \sum_{i=1}^n a_i \left[\beta_0 + \beta_1 X_i + E(\varepsilon_i) \right]$$

$$= \sum_{i=1}^n a_i (\beta_0 + \beta_1 X_i) + 0 = \beta_0 \sum_{i=1}^n a_i + \beta_1 \sum_{i=1}^n a_i X_i$$

$P1 : E(\varepsilon_i) = 0 \quad \forall i=1, \dots, n$

$$= \beta_0 \underbrace{\sum_{i=1}^n \frac{X_i - \bar{X}}{S_{XX}}}_{\sum_{i=1}^n (X_i - \bar{X})} + \beta_1 \underbrace{\sum_{i=1}^n \frac{(X_i - \bar{X}) X_i}{S_{XX}}}_{\sum_{i=1}^n (X_i - \bar{X}) X_i} = \beta_0 \cdot 0 + \beta_1 \cdot 1 = \beta_1$$

$$\Rightarrow E(\hat{\beta}_1) = \beta_1$$

$\Rightarrow \hat{\beta}_1$ est un estimateur sans biais de β_1

$$\frac{\sum_{i=1}^n X_i - \sum_{i=1}^n \bar{X}}{S_{XX}} = 0$$

$$\frac{S_{XX}}{S_{XX}} = 1$$

- $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$

- $E(\hat{\beta}_0) = E(\bar{Y} - \hat{\beta}_1 \bar{X}) = E(\bar{Y}) - E(\hat{\beta}_1) \bar{X}$

$$= E\left(\frac{1}{n} \sum_{i=1}^n Y_i\right) - \beta_1 \bar{X} = \frac{1}{n} \sum_{i=1}^n E(Y_i) - \beta_1 \bar{X}$$

$$= \frac{1}{n} \sum_{i=1}^n E(\beta_0 + \beta_1 x_i + \varepsilon_i) - \beta_1 \bar{X}$$

$$= \frac{1}{n} \sum_{i=1}^n (\beta_0 + \beta_1 x_i) - \beta_1 \bar{X}$$

$$P1: E(\varepsilon_i) = 0 \quad \forall i=1, \dots, n$$

$$= \frac{1}{n} \sum_{i=1}^n \beta_0 + \beta_1 \frac{1}{n} \sum_{i=1}^n x_i - \beta_1 \bar{X} \rightarrow 0$$

$$= \frac{1}{n} n \beta_0 = \beta_0 \quad \Rightarrow \quad E(\hat{\beta}_0) = \beta_0$$

$$\Rightarrow \hat{\beta}_0 \text{ E.S.B de } \beta_0$$

$$\hat{\beta}_1 = \sum_{i=1}^n a_i Y_i \quad \text{on} \quad a_i = \frac{x_i - \bar{x}}{S_{xx}}$$

$$\text{var}(\hat{\beta}_1) = \text{var}\left(\sum_{i=1}^n a_i Y_i\right) = \sum_{i=1}^n \text{var}(a_i Y_i) \quad \text{P3: independence}$$

$$= \sum_{i=1}^n a_i^2 \text{var}(Y_i)$$

$$= \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{(S_{xx})^2} \text{var}(\beta_0 + \beta_1 x_i + \varepsilon_i)$$

$$= \frac{1}{S_{xx}^2} \sum_{i=1}^n (x_i - \bar{x})^2 \underbrace{\text{var}(\varepsilon_i)}_{\sigma^2}$$

$$\text{P2: } \text{var}(\varepsilon_i) = \sigma^2 \quad \forall i=1, \dots, n$$

$$= \frac{1}{S_{xx}^2} \sigma^2 \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{S_{xx}^2} \sigma^2 S_{xx} = \frac{\sigma^2}{S_{xx}}$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X} = \sum_{i=1}^n b_i Y_i \quad \text{on} \quad b_i = \frac{1}{n} - \bar{X} \frac{X_i - \bar{X}}{S_{XX}}$$

$$\text{Var}(\hat{\beta}_0) = \text{Var}\left(\sum_{i=1}^n b_i Y_i\right) = \sum_{i=1}^n \text{Var}(b_i Y_i) \quad \text{P3: indep.}$$

$$= \sum_{i=1}^n b_i^2 \text{Var}(Y_i) = \sigma^2 \sum_{i=1}^n b_i^2$$

$$\text{P2: } \text{Var}(\varepsilon_i) = \sigma^2 = \text{Var}(Y_i) \quad \forall i=1, \dots, n$$

$$= \sigma^2 \sum_{i=1}^n \left(\frac{1}{n} - \bar{X} \frac{X_i - \bar{X}}{S_{XX}} \right)^2$$

$$= \sigma^2 \sum_{i=1}^n \left[\frac{1}{n^2} - 2 \frac{\bar{X}}{n} \frac{1}{S_{XX}} (X_i - \bar{X}) + \frac{\bar{X}^2}{S_{XX}^2} (X_i - \bar{X})^2 \right]$$

$$= \frac{\sigma^2}{n^2} \sum_{i=1}^n 1 - \sigma^2 \frac{2\bar{X}}{n S_{XX}} \underbrace{\sum_{i=1}^n (X_i - \bar{X})}_0 + \sigma^2 \frac{\bar{X}^2}{S_{XX}^2} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$= \frac{\sigma^2}{n} - 0 + \frac{\sigma^2 \bar{X}^2}{S_{XX}^2} S_{XX} = \frac{\sigma^2}{n} + \sigma^2 \frac{\bar{X}^2}{S_{XX}} = \sigma^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{S_{XX}} \right)$$

$$\hat{\beta}_1 \sim N \left(\beta_1 ; \frac{\sigma^2}{S_{xx}} \right)$$

$$\hat{\beta}_0 \sim N \left(\beta_0 ; \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right] \right)$$

$$\frac{\hat{\beta}_1 - \beta_1}{\sqrt{\sigma^2 / S_{xx}}} \sim N(0, 1)$$

$$\text{et } \frac{\hat{\beta}_0 - \beta_0}{\sqrt{\sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)}} \sim N(0, 1)$$

RAPPEL

Soit W une v.a. tq $W \sim N(\mu_w, \sigma_w^2)$

Alors $\frac{W - \mu_w}{\sigma_w} \sim N(0, 1)$.

Si on ne connaît pas σ_w^2 , on l'estime par S_w^2 .

On a que $K = \frac{\nu S_w^2}{\sigma_w^2} \sim \chi_\nu^2$


et $\frac{Z}{\sqrt{K/\nu}} \sim t_\nu$

avec $Z \sim N(0, 1)$

Done

$$\frac{\frac{W - \mu_w}{\sigma_w}}{\sqrt{\frac{\cancel{\sigma_w^2}}{\cancel{\sigma_w^2}}}} = \frac{W - \mu_w}{\cancel{\sigma_w}} \sqrt{\frac{\cancel{\sigma_w^2}}{S_w^2}} = \frac{W - \mu_w}{\sqrt{S_w^2}} \sim t_v$$

IC: $P\left(-t_{v;1-\alpha/2} \leq \frac{W - \mu_w}{\sqrt{S_w^2}} \leq t_{v;1-\alpha/2}\right) = 1 - \alpha$




$$P\left(W - t_{v;1-\alpha/2}\sqrt{S_w^2} \leq \mu_w \leq W + t_{v;1-\alpha/2}\sqrt{S_w^2}\right) = 1 - \alpha$$

$$IC_{1-\alpha}(\mu_w) : \left[W - t_{v;1-\alpha/2}\sqrt{S_w^2} ; W + t_{v;1-\alpha/2}\sqrt{S_w^2} \right]$$

Test d'hypothèse : $\begin{cases} H_0 : \mu_w = C \\ H_1 : \mu_w \neq C \end{cases}$

seuil $\alpha = P(\text{Rejeter } H_0 \mid H_0 \text{ est vraie})$
 $= P\left(\left|\frac{W - C}{\sqrt{S_w^2}}\right| > t_{v; 1-\alpha/2} \mid \mu_w = C\right)$



$\Rightarrow$ on rejette H_0 au seuil α si $\left|\frac{W - C}{\sqrt{S_w^2}}\right| > t_{v; 1-\alpha/2}$

$\Rightarrow$ on rejette H_0 au seuil α si:

$\alpha^* = \text{valeur } -p = \text{seuil observé}$

$$= P \left(T > \left| \frac{W - c}{\sqrt{S_W^2}} \right| \right) \quad \text{avec } T \sim t_\nu$$
$$< \alpha$$

$\Rightarrow$ on rejette H_0 au seuil α si $C \notin IC_{1-\alpha}(\mu_W)$

On connaît les distributions de $\hat{\beta}_0$ et $\hat{\beta}_1$.

- IC (associer une marge d'erreur aux estimateurs)

- Tests d'hyp $\begin{cases} H_0: \beta_j = c \\ H_1: \beta_j \neq c \end{cases}$

- ANOVA

RLS

σ^2 est une quantité inconnue, on l'estime par $\hat{\sigma}^2$.

Par EMV, on a obtenu $\hat{\sigma}_{MV}^2 = \frac{1}{n} \sum_{i=1}^n \hat{\epsilon}_i^2$ qui est biaisé.

On utilise plutôt $\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n \hat{\epsilon}_i^2$ qui est un ESB.

$$\Rightarrow \frac{\hat{\beta}_0 - \beta_0}{\sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)}} \sim t_{n-2} \quad \text{et} \quad \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\hat{\sigma}^2 / S_{xx}}} \sim t_{n-2}$$

IC


$$IC_{1-\alpha}(\beta_0) : \hat{\beta}_0 \pm t_{n-2; 1-\alpha/2} \sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)}$$

$$IC_{1-\alpha}(\beta_1) : \hat{\beta}_1 \pm t_{n-2; 1-\alpha/2} \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}$$

Tests d'hypothèses

- test bilatéral $\begin{cases} H_0 : \beta_j = C \\ H_1 : \beta_j \neq C \end{cases}$ au seuil α

sous H_0 : $\frac{\hat{\beta}_j - C}{\sqrt{\hat{\text{var}}(\hat{\beta}_j)}} \sim t_{n-2}$



→ on rejette H_0 au seuil α si

$$\bullet |T_{obs}| = \left| \frac{\hat{\beta}_j - C}{\sqrt{\widehat{\text{var}}(\hat{\beta}_j)}} \right| > t_{n-2; 1-\alpha/2}$$

ou

$$\bullet C \notin IC_{1-\alpha}(\hat{\beta}_j)$$

ou


$$\bullet \alpha^* < \alpha \quad \text{on} \quad \alpha^* = P(t_{n-2} > |T_{obs}|) + P(t_{n-2} < -|T_{obs}|) \\ = 2 P(t_{n-2} > |T_{obs}|)$$

$$\bullet \text{test unilatéral à droite: } \begin{cases} H_0: \beta_j = C \\ H_1: \beta_j > C \end{cases}$$

On rej. H_0 au seuil α si $\alpha^* < \alpha$, $\alpha^* = P(t_{n-2} > t_{obs})$
ou si $T_{obs} > t_{n-2; 1-\alpha}$


• Test unilatéral à gauche: $\begin{cases} H_0: \beta_j = C \\ H_1: \beta_j < C \end{cases}$

On rejette H_0 au seuil α si $\alpha^* < \alpha$, $\alpha^* = P(t_{n-2} < t_{obs})$
 ou si $T_{obs} < -t_{n-2; 1-\alpha}$



Dans R et SAS: $\begin{cases} H_0: \beta_j = 0 \\ H_1: \beta_j \neq 0 \end{cases}$


Pour β_1 :
$$T_{obs} = \frac{\hat{\beta}_1 - C}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_1)}} = \frac{\hat{\beta}_1 - 0}{\sqrt{\hat{\sigma}^2 / S_{xx}}} = \frac{\hat{\beta}_1}{\sqrt{\hat{\sigma}^2 / S_{xx}}}$$



↓

$$Y_i = \beta_0 + \beta_1 x_i + \epsilon_i$$

sous $H_0 : \beta_1 = 0 \Rightarrow Y_i = \beta_0 + 0 \cdot x_i + \epsilon_i$
 $= \beta_0 + \epsilon_i$



sous $H_0 : \beta_0 = 0 \Rightarrow Y_i = 0 + \beta_1 x_i + \epsilon_i$
 $= \beta_1 x_i + \epsilon_i$




TEST GLOBAL - ANOVA

Est-ce qu'il y a un lien linéaire entre X et Y ?

$$\begin{cases} H_0: \beta_1 = 0 \\ H_1: \beta_1 \neq 0 \end{cases}$$

$$\Leftrightarrow \begin{cases} H_0: Y_i = \beta_0 + \varepsilon_i \\ H_1: Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \beta_1 \neq 0 \end{cases}$$



Décomposition de la variabilité totale de y

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n ((y_i - \hat{y}_i) + (\hat{y}_i - \bar{y}))^2$$

SC_{TOT}


$$= \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + 2 \sum_{i=1}^n (y_i - \hat{y}_i)(\hat{y}_i - \bar{y})$$

exercice
= 0

$$= \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$


SC_{res}

SC_{reg} faible



SC_{reg}

SC_{reg} ↑



Source	DDL	SC	CM	F
SC _{reg}	1	$SC_{reg} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$	$CM_{reg} = \frac{SC_{reg}}{1}$ $= SC_{reg}$	$F_{obs} = \frac{CM_{reg}}{CM_{res}}$
SC _{res}	n-2	$SC_{res} = \sum_{i=1}^n (y_i - \hat{y}_i)^2$	$CM_{res} = \frac{SC_{res}}{n-2}$ $= \hat{\sigma}^2$	
SC _{TOT}	n-1 (=n-2+1)	$SC_{TOT} = \sum_{i=1}^n (y_i - \bar{y})^2$ $= SC_{reg} + SC_{res}$		

$$SC_{res} = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$


$$= \sum_{i=1}^n \hat{\epsilon}_i^2$$

$$CM_{res} = \frac{SC_{res}}{n-2} = \frac{\sum_{i=1}^n \hat{\epsilon}_i^2}{n-2} = \hat{\sigma}^2$$

Test global $\left\{ \begin{array}{l} H_0 : \beta_1 = 0 \\ H_1 : \beta_1 \neq 0 \end{array} \right.$

Sous H_0 , $F_{obs} = \frac{CM_{reg}}{CM_{res}} \sim F_{1; n-2}$

$$= \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2 / 1}{\sum_{i=1}^n (y_i - \hat{y}_i)^2 / (n-2)}$$



Au seuil α , on rejette H_0

$$\text{Si } F_{obs} > F_{1; n-2; \alpha}$$

ou

$$\text{Si } \alpha^* < \alpha$$

avec $\alpha^* = P(F_{1; n-2} > F_{obs})$

Coefficient de détermination R^2

$$R^2 = \frac{SC_{\text{reg}}}{SC_{\text{TOT}}} = \frac{SC_{\text{TOT}} - SC_{\text{res}}}{SC_{\text{TOT}}} = 1 - \frac{SC_{\text{res}}}{SC_{\text{TOT}}}$$

$$R^2 \in [0, 1]$$

R^2 est la proportion de la variabilité totale de Y qui est expliquée par la régression linéaire avec x .

Prévisions

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

Pour prédire la valeur de Y pour un certain $x = x_0$,
on utilise

$$\hat{Y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0$$

$$\hat{Y}_0 = \sum_{i=1}^n c_i Y_i \quad \text{avec} \quad c_i = \frac{1}{n} + a_i (x_0 - \bar{x})$$

$$\text{et } a_i = \frac{(x_i - \bar{x})}{S_{xx}}$$

on peut déduire que $\hat{Y}_0 \sim N \left(\beta_0 + \beta_1 x_0 ; \sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right] \right)$

- $E(\hat{Y}_0) = E(\hat{\beta}_0 + \hat{\beta}_1 x_0) = E(\hat{\beta}_0) + E(\hat{\beta}_1 x_0) = \beta_0 + \beta_1 x_0$

- $$\begin{aligned} \text{Var}(\hat{Y}_0) &= \text{Var}\left(\sum_{i=1}^n C_i Y_i\right) = \sum_{i=1}^n C_i^2 \text{Var}(Y_i) = \sigma^2 \sum_{i=1}^n C_i^2 \\ &= \dots = \sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right] \end{aligned}$$

si σ^2 est inconnue, on l'estime par $\hat{\sigma}^2$

~~$IC_{1-\alpha}(Y_0)$~~ : $\hat{\beta}_0 + \hat{\beta}_1 x_0 \pm t_{n-2; 1-\alpha/2} \sqrt{\hat{\sigma}^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]}$

$IC_{1-\alpha}[E(Y|x=x_0)]$

Si on s'intéresse à prédire UNE observation en x_0

$$\hat{y}_0^* = \hat{\beta}_0 + \hat{\beta}_1 x_0 + \varepsilon \quad \varepsilon \sim N(0, \sigma^2)$$

$$\bullet E(\hat{y}_0^*) = E(\hat{\beta}_0 + \hat{\beta}_1 x_0 + \varepsilon) = \beta_0 + \beta_1 x_0 + 0$$

$$\bullet \text{Var}(\hat{y}_0^*) = \text{Var}(\hat{\beta}_0 + \hat{\beta}_1 x_0 + \varepsilon)$$

$$= \text{Var}(\hat{y}_0 + \varepsilon)$$

$$= \text{Var}(\hat{y}_0) + \text{Var}(\varepsilon)$$

$$= \sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right] + \sigma^2$$

$$= \sigma^2 \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]$$

Intervalle de prévision pour une observation de Y en x_0

$$\pm P_{1-\alpha}(Y_0) : \hat{\beta}_0 + \hat{\beta}_1 x_0 \pm t_{n-2; 1-\alpha/2} \sqrt{\hat{\sigma}^2 \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]}$$

Test global vs test t pour β_1

$$CM_{RES} = \frac{SC_{RES}}{n-2} = \frac{\sum_{i=1}^n \hat{\epsilon}_i^2}{n-2} = \hat{\sigma}^2$$

Test global : $\begin{cases} H_0 : \beta_1 = 0 \\ H_1 : \beta_1 \neq 0 \end{cases}$

Test t pour β_1 : $\begin{cases} H_0 : \beta_1 = c \\ H_1 : \beta_1 \neq c \end{cases}$
bilateral

R et SAS
(cas on $c=0$) $\begin{cases} H_0 : \beta_1 = 0 \\ H_1 : \beta_1 \neq 0 \end{cases} T_{obs}$

$$F_{obs} : \frac{CM_{REG}}{CM_{RES}} = \frac{SC_{REG}}{\hat{\sigma}^2} / 1 = \frac{SC_{REG}}{\hat{\sigma}^2} = \frac{S_{xy}^2 / S_{xx}}{\hat{\sigma}^2} = \frac{\hat{\beta}_1^2 S_{xx}}{\hat{\sigma}^2} = \frac{\hat{\beta}_1^2}{\hat{\sigma}^2 / S_{xx}}$$

Sans H_0
 $\sim F_{1, n-2}$

$$= \left(\frac{\hat{\beta}_1}{\hat{\sigma} / \sqrt{S_{xx}}} \right)^2 = \left(\frac{\hat{\beta}_1 - 0}{\sqrt{\text{Var}(\hat{\beta}_1)}} \right)^2 = (T_{obs})^2$$

Sans H_0
 $T_{obs} \sim t_{n-2}$
 $(t_{n-2})^2 \sim F_{1, n-2}$

$$SC_{REG} = \frac{S_{xy}^2}{S_{xx}}$$

en exo

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} \rightarrow \hat{\beta}_1^2 = \frac{S_{xy}^2}{S_{xx}^2} \rightarrow \hat{\beta}_1^2 S_{xx} = \frac{S_{xy}^2}{S_{xx}}$$

Bonferroni

Exemple: On veut tester 2 paramètres avec des tests de niveau $\alpha = 0,05 = P(\text{rejeter } H_0 \mid H_0 \text{ est vraie})$

$E_1 =$ on fait une erreur de type 1 pour le 1er para.
 $E_2 =$ " " " " 2ième para.

$$P(E_1 \cup E_2) = P(E_1) + P(E_2) - P(E_1 \cap E_2)$$

$$= 0,05 + 0,05 - P(E_1 \cap E_2)$$

$$? < 0,05$$

correction de Bonferroni : pour chaque test individuel, on prend un seul α/m , où m est le nb de tests

$$P(E_1) = 0,05/2 \quad \text{et} \quad P(E_2) = 0,05/2 \quad (\text{faire des tests au seuil } 0,025)$$

$$P(E_1 \cup E_2) = P(E_1) + P(E_2) - P(E_1 \cap E_2) = \frac{0,05}{2} + \frac{0,05}{2} - P(E_1 \cap E_2) \\ = 0,05 - P(E_1 \cap E_2) \leq 0,05$$

