

Chapitre 3

Inférence pour la RLS

Sommaire

3.1	Inférence sur les paramètres	21
3.1.1	Distribution des estimateurs	21
3.1.2	Intervalle de confiance pour β_0 et β_1	24
3.1.3	Tests d'hypothèses	26
3.2	Prévision	27
3.2.1	Prévision de la valeur moyenne $\mathbb{E}[Y x = x_0]$	27
3.2.2	Prévision d'une observation Y_0^* lorsque $x = x_0$	28
3.3	Décomposition de la variance	30
3.3.1	Coefficient de détermination	31

3.1 Inférence sur les paramètres

On a montré comment obtenir des estimations pour les différents paramètres du modèle de régression linéaire simple. Généralement, on souhaite également faire de l'inférence sur les vraies valeurs des paramètres β_0 , β_1 et σ^2 . Pour ce faire, on utilise la distribution des estimateurs.

3.1.1 Distribution des estimateurs

Distribution de $\hat{\beta}_1$

On note d'abord que $\hat{\beta}_1$ est une combinaison linéaire des Y_i . En effet,

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x}) Y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} = \sum_{i=1}^n a_i Y_i,$$

où

$$a_i = \frac{x_i - \bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{x_i - \bar{x}}{S_{xx}}.$$

Étant donné qu'une combinaison linéaire de variables aléatoires normales suit également une distribution normale, il s'ensuit que $\hat{\beta}_1$ est distribué selon une loi normale. Il faut déterminer l'espérance et la variance de $\hat{\beta}_1$. Notons d'abord que

$$\begin{aligned} \sum_{i=1}^n a_i &= \frac{\sum_{i=1}^n (x_i - \bar{x})}{S_{xx}} = 0, \\ \sum_{i=1}^n a_i x_i &= \frac{\sum_{i=1}^n (x_i - \bar{x}) x_i}{S_{xx}} = \frac{\sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})}{S_{xx}} = \frac{S_{xx}}{S_{xx}} = 1. \end{aligned}$$

Calculons l'espérance de β_1 ,

$$\begin{aligned} \mathbb{E}(\hat{\beta}_1) &= \sum_{i=1}^n a_i \mathbb{E}(Y_i) \\ &= \sum_{i=1}^n a_i (\beta_0 + \beta_1 x_i) \\ &= \beta_0 \sum_{i=1}^n a_i + \beta_1 \sum_{i=1}^n a_i x_i \\ &= \beta_1. \end{aligned}$$

Ainsi, l'estimateur $\hat{\beta}_1$ est un estimateur sans biais de β_1 puisque $\mathbb{E}(\hat{\beta}_1) - \beta_1 = 0$. Calculons la variance de $\hat{\beta}_1$,

$$\begin{aligned} \text{Var}(\hat{\beta}_1) &= \text{Var}\left(\sum_{i=1}^n a_i Y_i\right) \\ &= \sum_{i=1}^n a_i^2 \text{Var}(Y_i) \\ &= \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{S_{xx}^2} \text{Var}(Y_i) \\ &= \frac{1}{S_{xx}^2} \sum_{i=1}^n (x_i - \bar{x})^2 \text{Var}(Y_i) \\ &= \frac{S_{xx}}{S_{xx}^2} \sigma^2 \\ &= \frac{\sigma^2}{S_{xx}}. \end{aligned}$$

Ainsi, la distribution de $\hat{\beta}_1$ est

$$\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{S_{xx}}\right). \quad (3.1)$$

Remarque 2. *Seulement certaines hypothèses de la RLS ont été nécessaires pour calculer cette distribution. Lesquelles ? Et que nous indique la forme de cette distribution sur l'estimation de la pente dans un modèle de régression linéaire simple ?*

Distribution de $\hat{\beta}_0$

L'estimateur $\hat{\beta}_0$ peut également s'exprimer comme une combinaison linéaire des Y_i ,

$$\begin{aligned} \hat{\beta}_0 &= \bar{Y} - \hat{\beta}_1 \bar{x} \\ &= \sum_{i=1}^n \frac{Y_i}{n} - \bar{x} \sum_{i=1}^n a_i Y_i \\ &= \sum_{i=1}^n \left(\frac{1}{n} - a_i \bar{x} \right) Y_i. \end{aligned}$$

Par le même raisonnement que pour $\hat{\beta}_1$, on a donc que $\hat{\beta}_0$ est distribué selon une loi normale. On peut calculer l'espérance et la variance de $\hat{\beta}_1$. Pour l'espérance, on a que

$$\begin{aligned} \mathbb{E}(\hat{\beta}_0) &= \mathbb{E}(\bar{Y} - \hat{\beta}_1 \bar{x}) \\ &= \frac{1}{n} \sum_{i=1}^n \mathbb{E}(Y_i) - \bar{x} \mathbb{E}(\hat{\beta}_1) \\ &= \frac{1}{n} \sum_{i=1}^n (\beta_0 + \beta_1 x_i) - \bar{x} \beta_1 \\ &= \beta_0 + \beta_1 \bar{x} - \beta_1 \bar{x} \\ &= \beta_0. \end{aligned}$$

Pour la variance, on a

$$\begin{aligned} \text{Var}(\hat{\beta}_0) &= \text{Var}(\bar{Y} - \hat{\beta}_1 \bar{x}) \\ &= \text{Var}\left(\frac{1}{n} \sum_{i=1}^n Y_i\right) + \bar{x}^2 \text{Var}(\hat{\beta}_1) - 2\bar{x} \text{Cov}(\bar{Y}, \hat{\beta}_1) \\ &= \frac{\sigma^2}{n} + \bar{x}^2 \frac{\sigma^2}{S_{xx}} \\ &= \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right). \end{aligned}$$

Pour obtenir l'expression finale pour cette variance, il faut démontrer que $\text{Cov}[\bar{Y}, \hat{\beta}_1] = 0$, ce qui est laissé en exercice. On obtient ainsi la loi pour $\hat{\beta}_0$,

$$\hat{\beta}_0 \sim \mathcal{N}\left\{\beta_0, \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right) \sigma^2\right\}. \quad (3.2)$$

Exemple 3.1. Calculons la variance de $\hat{\beta}_0$ et $\hat{\beta}_1$ de l'exemple de la section 2.3. On doit pour ce faire connaître la valeur de la variance des termes d'erreur. Supposons ici que $\sigma^2 = 1$. On sait déjà que $n = 10$, $\bar{x} = 145$ et $S_{xx} = 8250$. Par conséquent on a

$$\begin{aligned}\text{Var}[\hat{\beta}_0] &= \left(\frac{1}{10} + \frac{145^2}{8250} \right) (1) = 2,648, \\ \text{Var}[\hat{\beta}_1] &= \frac{1^2}{8250} = 1,212 \times 10^{-4}.\end{aligned}$$

3.1.2 Intervalles de confiance pour β_0 et β_1

On peut utiliser les distributions de $\hat{\beta}_0$ et $\hat{\beta}_1$ pour construire des intervalles de confiance pour β_0 et β_1 . Pour déterminer l'intervalle de confiance pour β_1 , on centre et réduit la variable aléatoire pour obtenir

$$\frac{\hat{\beta}_1 - \beta_1}{\sqrt{\sigma^2/S_{xx}}} \sim \mathcal{N}(0, 1). \quad (3.3)$$

Si σ^2 était connue, un intervalle de confiance de niveau $100(1 - \alpha)\%$ serait donné par

$$\left[\hat{\beta}_1 \pm z_{1-\alpha/2} \frac{\sigma}{\sqrt{S_{xx}}} \right].$$

Or, σ^2 n'est généralement pas connue et on doit l'estimer. L'estimateur du maximum de vraisemblance de cette quantité est

$$\hat{\sigma}_{MV}^2 = \sum_{i=1}^n \frac{\hat{\varepsilon}_i^2}{n},$$

mais ce dernier est biaisé. On utilisera donc plutôt l'estimateur non biaisé défini par

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n \hat{\varepsilon}_i^2.$$

Remplacer σ^2 par $\hat{\sigma}^2$ dans le terme de gauche de (3.3) a toutefois pour conséquence que cette variable aléatoire ne suit plus une loi normale. On peut néanmoins montrer, en utilisant des notions de statistique mathématique, que

$$\frac{\frac{\hat{\beta}_1 - \beta_1}{\sigma/\sqrt{S_{xx}}}}{\sqrt{\frac{\hat{\sigma}^2}{\sigma^2}}} \sim \mathcal{T}_{n-2}. \quad (3.4)$$

On peut alors déduire un intervalle de confiance de niveau $100(1 - \alpha)\%$ pour β_1 ,

$$\left[\hat{\beta}_1 \pm t_{n-2; 1-\alpha/2} \left(\frac{\hat{\sigma}}{\sqrt{S_{xx}}} \right) \right], \quad (3.5)$$

où $t_{n-2; 1-\alpha/2}$ dénote le $(1 - \alpha/2)$ -ième quantile d'une loi $\mathcal{T}$ à $(n - 2)$ degrés de liberté.

Il est possible de construire de la même manière un intervalle de confiance pour β_0 . On obtient l'intervalle de confiance

$$\left[\hat{\beta}_0 \pm t_{n-2; 1-\alpha/2} \hat{\sigma} \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}} \right]. \quad (3.6)$$

Remarque 3. Pour arriver à (3.4), on note que

$$\frac{\frac{\hat{\beta}_1 - \beta_1}{\sigma / \sqrt{S_{xx}}}}{\sqrt{\frac{\sum_{i=1}^n \hat{\varepsilon}_i^2}{\sigma^2(n-2)}}} = \frac{U}{\sqrt{V/\nu}},$$

où $U = (\hat{\beta}_1 - \beta_1) / (\sigma / \sqrt{S_{xx}})$ est distribué selon une loi normale centrée réduite et $V = (\sum_{i=1}^n \hat{\varepsilon}_i^2) / \sigma^2$ suit une loi du khi-carré à $\nu = (n-2)$ degrés de liberté, puisque c'est une somme du carré de variables aléatoires normales. Comme il s'agit d'un rapport entre une variable aléatoire normale centrée réduite et la racine carrée d'une variable khi-carré divisée par son degré de liberté $(n-2)$, on obtient la distribution d'une loi $\mathcal{T}$ de Student à $(n-2)$ degrés de liberté ($\mathcal{T}_{n-2}$),

$$\frac{\frac{\hat{\beta}_1 - \beta_1}{\sigma / \sqrt{S_{xx}}}}{\sqrt{\frac{\sum_{i=1}^n \hat{\varepsilon}_i^2}{\sigma^2(n-2)}}} \sim \frac{\mathcal{N}(0, 1)}{\sqrt{\chi_{n-2}^2/(n-2)}} \sim \mathcal{T}_{n-2}.$$

Exemple 3.2. Calculons un intervalle de confiance pour β_0 et β_1 de l'exemple 2.3. La plupart des quantités nécessaires ont déjà été calculées. Il ne manque que

$$\hat{\sigma} = \sqrt{\frac{1}{10-2} \sum_{i=1}^{10} \hat{\varepsilon}_i^2} = \sqrt{\frac{7,224}{8}} = 0,950.$$

Si on fixe $\alpha = 5\%$, il faut calculer $t_{n-2; 0,975}$. On peut trouver dans une table que ce quantile est $t_{8; 0,975} = 2,306$. On obtient alors les intervalles suivants :

$$\left[\hat{\beta}_0 \pm 2,306 \times 0,950 \sqrt{1/10 + 145^2/8250} \right] = \left[\hat{\beta}_0 \pm 3,566 \right] = [-6,305; 0,827],$$

$$\left[\hat{\beta}_1 \pm 2,306 \times 0,950 / \sqrt{8250} \right] = \left[\hat{\beta}_1 \pm 0,024 \right] = [0,459; 0,507].$$

3.1.3 Tests d'hypothèses

On peut également se baser sur les distributions déterminées à la section 3.1.1 pour mettre en œuvre des tests d'hypothèses sur la valeur des coefficients. Considérons le test bilatéral

$$\mathcal{H}_0 : \beta_j = c,$$

$$\mathcal{H}_1 : \beta_j \neq c.$$

Notons

$$\widehat{\text{Var}}(\hat{\beta}_0) = \hat{\sigma}^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right),$$

$$\widehat{\text{Var}}(\hat{\beta}_1) = \frac{\hat{\sigma}^2}{S_{xx}}.$$

Sous $\mathcal{H}_0$,

$$\frac{\hat{\beta}_j - c}{\widehat{\text{Var}}(\hat{\beta}_j)} \sim \mathcal{T}_{n-2}.$$

Soit $t_{obs} = (\hat{\beta}_j - c) / \widehat{\text{Var}}(\hat{\beta}_j)$ la statistique observée du test. La décision du test d'hypothèses au seuil α peut être prise de trois façons.

- (i) Valeur critique : Soit le quantile théorique $t_{n-2;1-\alpha/2}$. Si $|t_{obs}| > t_{n-2;1-\alpha/2}$, l'hypothèse nulle $\mathcal{H}_0 : \beta_j = c$ est rejetée.
- (ii) Valeur-p : Soit $\alpha^* = \mathbb{P}(|t_{n-2}| > |t_{obs}|) = 2\mathbb{P}(t_{n-2} > |t_{obs}|)$ la valeur-p. Si $\alpha^* < \alpha$, l'hypothèse nulle $\mathcal{H}_0 : \beta_j = c$ est rejetée.
- (iii) Intervalle de confiance : Si la valeur c n'est pas comprise dans l'intervalle de confiance pour β_j de niveau $1 - \alpha$, l'hypothèse nulle $\mathcal{H}_0 : \beta_j = c$ est rejetée.

Il est aussi possible de faire des test unilatéraux. Pour le test

$$\mathcal{H}_0 : \beta_j = c,$$

$$\mathcal{H}_1 : \beta_j < c,$$

les règles de décisions sont

- (i) Valeur critique : Si $t_{obs} < -t_{n-2;1-\alpha}$, l'hypothèse nulle $\mathcal{H}_0 : \beta_j = c$ est rejetée.
- (ii) Valeur-p : Si $\alpha^* = \mathbb{P}(t_{n-2} < t_{obs}) < \alpha$, l'hypothèse nulle $\mathcal{H}_0 : \beta_j = c$ est rejetée.

Pour le test

$$\mathcal{H}_0 : \beta_j = c,$$

$$\mathcal{H}_1 : \beta_j > c,$$

les règles de décisions sont

- (i) Valeur critique : Si $t_{obs} > t_{n-2;1-\alpha}$, l'hypothèse nulle $\mathcal{H}_0 : \beta_j = c$ est rejetée.
- (ii) Valeur-p : Si $\alpha^* = \mathbb{P}(t_{n-2} > t_{obs}) < \alpha$, l'hypothèse nulle $\mathcal{H}_0 : \beta_j = c$ est rejetée.

Un cas particulier, souvent d'intérêt, est le test bilatéral avec $c = 0$. Pour la pente, ceci correspond aux hypothèses $\mathcal{H}_0 : \beta_1 = 0$, $\mathcal{H}_1 : \beta_1 \neq 0$. Si l'hypothèse nulle de ce test est rejetée, le lien linéaire entre Y et x n'est pas significatif et le modèle se réduit à $Y_i = \beta_0 + \varepsilon_i$. Pour l'ordonnée à l'origine, on a $\mathcal{H}_0 : \beta_0 = 0$, $\mathcal{H}_1 : \beta_0 \neq 0$. Si l'hypothèse nulle de ce test est rejetée, l'ordonnée à l'origine n'est pas significativement différente de 0 et le modèle se réduit à $Y_i = \beta_1 x_i + \varepsilon_i$.

Exemple 3.3. Toujours avec les données de la section 2.3, on a

$$t_{obs} = \frac{\hat{\beta}_1}{\hat{\sigma}/\sqrt{S_{xx}}} = \frac{0,483}{0,950/\sqrt{8250}} = 46,17.$$

Un logiciel nous permet d'obtenir 5.35×10^{-11} comme valeur de p correspondante. On rejette donc l'hypothèse d'une pente nulle au seuil $\alpha = 0,05$. Notez qu'on aurait pu arriver à la même conclusion simplement à l'aide de l'intervalle de confiance construit à l'exemple 3.2. En effet, l'intervalle de confiance à 95% pour β_1 ne contient pas la valeur 0, ce qui permet de rejeter l'hypothèse que $\beta_1 = 0$ au seuil $\alpha = 0,05$.

3.2 Prévision

On a déjà défini $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$, la prévision du modèle en x_i . Avant de définir un intervalle de confiance, deux intérêts doivent être distingués :

- (i) l'estimation de $\mathbb{E}[Y|x = x_0]$, la valeur moyenne de Y pour une valeur $x = x_0$ de la variable indépendante.
- (ii) l'estimation de Y_0^* , soit la valeur d'une observation/réalisation de Y lorsque la variable réponse prend la valeur x_0 .

Dans le premier cas, on souhaite estimer la valeur de la droite en x_0 , alors que dans le deuxième cas, on s'intéresse à une réalisation de la variable réponse, qui n'est pas nécessairement sur la droite. L'intervalle de confiance sera plus grand dans le deuxième cas, pour tenir compte de la variabilité additionnelle causée par la fluctuation aléatoire autour de la droite.

3.2.1 Prévision de la valeur moyenne $\mathbb{E}[Y|x = x_0]$

Soit $\mathbb{E}[Y|x = x_0]$, la valeur moyenne de Y lorsque $x = x_0$. Cette quantité est estimée par $\hat{Y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0$. On utilise le fait que $Y_i \sim \mathcal{N}(\beta_0 + \beta_1 x_i, \sigma^2)$ pour déterminer la distribution de $\hat{Y}_0$. On exprime

d'abord $\hat{Y}_0$ sous la forme d'une combinaison linéaire des Y_i ,

$$\begin{aligned}\hat{Y}_0 &= \hat{\beta}_0 + \hat{\beta}_1 x_0 \\ &= \sum_{i=1}^n \left(\frac{1}{n} - a_i \bar{x} \right) Y_i + \left(\sum_{i=1}^n a_i Y_i \right) x_0 \\ &= \sum_{i=1}^n \left(\frac{1}{n} - a_i \bar{x} + a_i x_0 \right) Y_i \\ &= \sum_{i=1}^n c_i Y_i,\end{aligned}$$

où

$$c_i = \frac{1}{n} - a_i \bar{x} + a_i x_0.$$

On peut montrer que $\sum_{i=1}^n c_i = 1$, que $\sum_{i=1}^n c_i x_i = x_0$ et que $\sum_{i=1}^n c_i^2 = 1/n + (\bar{x} - x_0)^2 / S_{xx}$. On peut ensuite en déduire que

$$\mathbb{E}(\hat{Y}_0) = \sum_{i=1}^n c_i \mathbb{E}(Y_i) = \sum_{i=1}^n c_i (\beta_0 + \beta_1 x_i) = \beta_0 + \beta_1 x_0, \quad (3.7)$$

$$\text{Var}(\hat{Y}_0) = \sum_{i=1}^n c_i^2 \text{Var}(Y_i) = \left\{ \frac{1}{n} + \frac{(\bar{x} - x_0)^2}{S_{xx}} \right\} \sigma^2. \quad (3.8)$$

Puisque $\hat{Y}_0$ est une combinaison linéaire des Y_i , qui suivent une loi normale, $\hat{Y}_0$ suit aussi une loi normale. On a donc

$$\hat{Y}_0 \sim \mathcal{N} \left\{ \beta_0 + \beta_1 x_0, \left(\frac{1}{n} + \frac{(\bar{x} - x_0)^2}{S_{xx}} \right) \sigma^2 \right\}. \quad (3.9)$$

À partir de ce résultat, il est possible de calculer un intervalle de confiance autour de la valeur moyenne de Y en $x = x_0$ en remplaçant σ^2 par son estimateur $\hat{\sigma}^2$. En utilisant le même raisonnement qu'à la section 3.1.2, on obtient l'intervalle de confiance de niveau $1 - \alpha$ pour $\mathbb{E}[Y|x = x_0]$,

$$\left[\left(\hat{\beta}_0 + \hat{\beta}_1 x_0 \right) \pm t_{n-2; 1-\alpha/2} \hat{\sigma} \sqrt{\frac{1}{n} + \frac{(\bar{x} - x_0)^2}{S_{xx}}} \right]. \quad (3.10)$$

3.2.2 Prédiction d'une observation Y_0^* lorsque $x = x_0$

Il est important de comprendre que l'intervalle de confiance défini à l'équation (3.10) concerne la moyenne de Y au point $x = x_0$. Pour construire ce qu'on appelle un intervalle de prédiction, il faut considérer à la fois la variance liée à l'estimation des paramètres et la variance liée à la variabilité naturelle du phénomène, c'est-à-dire la variance du terme d'erreur ε . Or, l'équation (3.8) ne tient pas compte de la variance du terme d'erreur σ^2 .

Désignons la prévision de la moyenne de Y en x_0 par $\hat{Y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0$ et la prévision d'une observation individuelle par $\hat{Y}_0^* = \hat{\beta}_0 + \hat{\beta}_1 x_0 + \varepsilon$. L'espérance de $\hat{Y}_0$ et celle de $\hat{Y}_0^*$ sont égales parce que l'espérance des termes d'erreur est nulle. Ce n'est pas le cas des variances. On a que

$$\begin{aligned}\text{Var}(\hat{Y}_0^*) &= \text{Var}(\hat{Y}_0) + \text{Var}(\varepsilon) \\ &= \left\{ \frac{1}{n} + \frac{(\bar{x} - x_0)^2}{S_{xx}} \right\} \sigma^2 + \sigma^2 \\ &= \left\{ 1 + \frac{1}{n} + \frac{(\bar{x} - x_0)^2}{S_{xx}} \right\} \sigma^2.\end{aligned}\quad (3.11)$$

Le méthode de calcul de l'intervalle de prévision de niveau $1 - \alpha$ pour Y_0^* est similaire à celle de l'intervalle de confiance pour $\mathbb{E}[Y|x = x_0]$. On obtient donc

$$\left[(\hat{\beta}_0 + \hat{\beta}_1 x_0) \pm t_{n-2; 1-\alpha/2} \hat{\sigma} \sqrt{1 + \frac{1}{n} + \frac{(\bar{x} - x_0)^2}{S_{xx}}} \right]. \quad (3.12)$$

En analysant les expressions (3.8) et (3.11), nous constatons que les variances diminuent lorsque n augmente ou que S_{xx} augmente. Cela signifie que plus la taille de l'échantillon est grande et/ou plus il y a de la variabilité dans les valeurs de la variable indépendante, plus les estimations seront précises. Au contraire, plus le point x_0 pour lequel une prévision est requise est éloigné du centre de la variable explicative ($\bar{x}$), plus la prévision sera imprécise. Il est important de prendre ces remarques en considération lors de la planification des expériences.

Remarque 4. *L'intervalle de prévision pour Y_0^* sera toujours plus large que l'intervalle de confiance pour $\mathbb{E}[Y|x = x_0]$. Pour cette raison, il peut arriver dans la pratique qu'un client préfère présenter l'intervalle de confiance plutôt que l'intervalle de prévision. Il est important de bien comprendre et de bien expliquer la distinction entre les deux intervalles pour éviter une mauvaise interprétation des résultats.*

Exemple 3.4. *On désire calculer un intervalle de confiance au niveau 95 % pour le rendement moyen du produit ($\mathbb{E}[Y|x = x_0]$) lorsque la température de fonctionnement est de 150 °C et pour le rendement d'un produit spécifique (Y_0^*) lorsque la température est de 150 °C. Dans les deux cas, la prévision est $\hat{Y}_0 = \hat{\beta}_0 + \hat{\beta}_1 \times 150 = -2,739 + 0,483 \times 150 = 69,711\%$.*

La plupart des quantités nécessaires au calcul des deux intervalles ont été déjà calculées auparavant. On tire de la section 2.3 que $\bar{x} = 145$, $S_{xx} = 8250$ et de l'exemple 3.2 que $\hat{\sigma} = 0,950$ et que $t_{8;0,975} = 2,306$. Il nous reste seulement à calculer $(x_0 - \bar{x})^2 = (150 - 145)^2 = 25$. En utilisant l'équation (3.10), on obtient l'intervalle de confiance du rendement moyen :

$$\left[69,711 \pm 2,306 \times 0,950 \times \sqrt{1/10 + 25/8250} \right] = [69,711 \pm 0,703] = [69,008; 70,414].$$

L'intervalle de prévision du rendement d'un produit quelconque, appelé également intervalle de

prévision, se calcule à l'aide de l'équation (3.12) :

$$\left[69,711 \pm 2,306 \times 0,950 \times \sqrt{1 + 1/10 + 25/8250} \right] = [69,711 \pm 2,301] = [67,410; 72,012].$$

Comme mentionné, l'intervalle de prévision est plus large que l'intervalle de confiance pour $\mathbb{E}[Y|x = 150]$.

3.3 Décomposition de la variance

Une partie de la différence entre les Y_i peut être expliquée par la différence entre les x_i , puisque selon le modèle de régression la variable réponse est expliquée en partie par la variable explicative. Il reste une partie de la variabilité des Y_i qui n'est pas expliquée par les différences dans les valeurs de x_i . On peut écrire

$$Y_i - \bar{Y} = (\hat{Y}_i - \bar{Y}) + (Y_i - \hat{Y}_i).$$

On a aussi que

$$\begin{aligned} \sum_{i=1}^n (Y_i - \bar{Y})^2 &= \sum_{i=1}^n (Y_i - \hat{Y}_i + \hat{Y}_i - \bar{Y})^2 \\ &= \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 + \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 + 2 \sum_{i=1}^n (Y_i - \hat{Y}_i) (\hat{Y}_i - \bar{Y}) \\ &= \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 + \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2. \end{aligned}$$

Notons

$$SC_{tot} = SC_{reg} + SC_{res}, \quad (3.13)$$

où

- $SC_{tot} = \sum_{i=1}^n (Y_i - \bar{Y})^2$, la somme des carrés totale, quantifie la variabilité des Y_i autour de leur valeur moyenne ;
- $SC_{reg} = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$, la somme des carrés de la régression, quantifie la variabilité des prévisions $\hat{Y}_i$. Les $\hat{Y}_i$ ne varient qu'avec les x_i , cette somme de carrés est donc la partie de la variabilité des Y_i expliquée par le fait que toutes les observations n'ont pas la même valeur de x_i ;
- $SC_{res} = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$, la somme des carrés résiduelle, quantifie la variabilité dans les $(Y_i - \hat{Y}_i)$. Cette variabilité est induite par le fait que la valeur de Y_i n'est pas expliquée parfaitement par le modèle de régression.

Exemple 3.5. *Toujours dans l'exemple du rendement d'un produit en fonction de la température de fonctionnement du procédé, on peut calculer*

$$\begin{aligned} SC_{tot} &= \sum_{i=1}^n (Y_i - \bar{Y})^2 = 1931,2, \\ SC_{res} &= \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = (n - 2) * \hat{\sigma}^2 = 7,224, \\ SC_{reg} &= \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 = 1924,876. \end{aligned}$$

On vérifie alors que $SC_{tot} = SC_{reg} + SC_{res}$. On note que la température à elle seule ne peut pas expliquer en totalité le fait que toutes les expériences ne possèdent pas le même rendement.

3.3.1 Coefficient de détermination

La décomposition de la variance permet de quantifier la qualité du modèle de régression linéaire à l'aide du coefficient de détermination,

$$R^2 = \frac{SC_{reg}}{SC_{tot}}. \quad (3.14)$$

Notons que $0 \leq R^2 \leq 1$. Le coefficient de détermination s'interprète comme la proportion de la variance des Y_i expliquée par le modèle. Lorsque $R^2 = 0$, le modèle n'explique absolument pas la variabilité des Y_i . Quand $R^2 = 1$, tous les points sont alignés sur la droite de régression, c'est-à-dire que l'ajustement du modèle est parfait et que la valeur de Y_i est une fonction exacte de x_i . Ainsi, une valeur élevée de R^2 indique que le modèle est bon. Le seuil à partir duquel on considère que le R^2 est élevé est très variable et assez subjectif. Il dépend notamment des objectifs de la régression et du domaine d'application.

Le coefficient de détermination correspond au carré de la corrélation entre les valeurs observées et les valeurs prédites

$$R^2 = \frac{SC_{reg}}{SC_{tot}} = \text{Corr}^2(Y, \hat{Y}) = \left(\frac{\sum_{i=1}^n (Y_i - \bar{Y})(\hat{Y}_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2 \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}} \right)^2.$$

Exemple 3.6. *Dans notre exemple,*

$$R^2 = \frac{1924,876}{1931,2} = 0,9967,$$

ce qui indique que la température prédit presque parfaitement le rendement de l'expérience. Des valeurs aussi grandes sont plutôt rares en pratique.

