

CHAPTER 5 - REGRESSION LINEAR MULTIPLE

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip} + \varepsilon_i \quad i=1, \dots, n$$

$$\begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & \dots & x_{1p} \\ \vdots & \vdots & & \vdots \\ 1 & x_{n1} & \dots & x_{np} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

$n \times 1$ $n \times (p+1)$ $(p+1) \times 1$ $n \times 1$
 $n \times 1$

Y X β ε

$$\underline{Y} = \underline{X} \underline{\beta} + \underline{\varepsilon}$$

$$\underline{Y} = \underline{X} \underline{\beta} + \underline{\varepsilon}$$

- Comment appelle-t-on le lieu géométrique défini par $\underline{X}\underline{\beta}$?
 Si $p=1$: une droite (RLS)
 Si $p=2$: un plan
 Si $p>2$: un hyperplan
- À quoi correspond la colonne de 1 dans $\underline{X}$?
 associée à β_0 (constante)
- Comment interprète-t-on la valeur de β_0 ?
 Espérance de Y quand $X_{i1} = X_{i2} = \dots = X_{ip} = 0$
- Comment interprète-t-on les valeurs $\beta_1, \dots, \beta_p$?
 β_j est la variation de $E(Y)$ quand x_j augmente d'une unité ET que toutes les autres variables explicatives restent constantes.
 (β_0 est la pente de l'hyperplan dans la direction de $\underline{x}_j$)

Postulats

$$P.1 \quad E(\varepsilon_i) = 0$$

$$P.2 \quad \text{Var}(\varepsilon_i) = \sigma^2$$

$$P.3 \quad \text{Cov}(\varepsilon_i, \varepsilon_j) = 0, \quad \text{pour } i \neq j$$

P.4 ε_i distribuée normalement

} pour $i=1, \dots, n$
 $j=1, \dots, n$

$$\Rightarrow P.1 \sim P.4 \quad \varepsilon_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2), \quad i=1, \dots, n$$

On veut estimer les β_j

1. Principe des moindres carrés

- (a) Moindres carrés (optimisation)
- (b) approche géométrique

2. Méthode du maximum de vraisemblance
- basée sur la distribution multivariée de Y

1.(a) on cherche à minimiser $\sum_{i=1}^n \epsilon_i^2$

$$\epsilon_i = y_i - (\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip})$$

$$\underline{y} = \underline{x} \underline{\beta} + \underline{\epsilon} \rightarrow \underline{\epsilon} = \underline{y} - \underline{x} \underline{\beta}$$

$$\underline{\epsilon}^T \underline{\epsilon} = (\epsilon_1 \quad \epsilon_2 \quad \dots \quad \epsilon_n) \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix} = \epsilon_1^2 + \epsilon_2^2 + \dots + \epsilon_n^2 = \sum_{i=1}^n \epsilon_i^2$$

On cherche à minimiser $\underline{\epsilon}^T \underline{\epsilon}$

$$\begin{aligned} \underline{\epsilon}^T \underline{\epsilon} &= (\underline{y} - \underline{x} \underline{\beta})^T (\underline{y} - \underline{x} \underline{\beta}) = (\underline{y}^T - \underline{\beta}^T \underline{x}^T) (\underline{y} - \underline{x} \underline{\beta}) \\ &= \underline{y}^T \underline{y} - (\underline{y}^T \underline{x} \underline{\beta}) - \underline{\beta}^T \underline{x}^T \underline{y} + \underline{\beta}^T \underline{x}^T \underline{x} \underline{\beta} \\ &= \underline{y}^T \underline{y} - 2 \underline{\beta}^T \underline{x}^T \underline{y} + \underline{\beta}^T \underline{x}^T \underline{x} \underline{\beta} \end{aligned}$$

on veut dériver $\underline{\varepsilon}^T \underline{\varepsilon}$ par rapport à $\underline{\beta}$

- $\underline{\beta}^T \underline{X}^T \underline{Y} = (\beta_0 \quad \beta_1) \begin{pmatrix} 1 & 1 \\ x_{11} & x_{21} \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \end{pmatrix}$
 $= (\beta_0(1) + \beta_1 x_{11} \quad (1)\beta_0 + \beta_1 x_{21}) \begin{pmatrix} y_1 \\ y_2 \end{pmatrix}$
 $= \beta_0(1) y_1 + \beta_1 x_{11} y_1 + \beta_0(1) y_2 + \beta_1 x_{21} y_2$
- $\frac{\partial \underline{\beta}^T \underline{X}^T \underline{Y}}{\partial \beta_0} = (1) y_1 + (1) y_2 = (1 \quad 1) \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} = \underline{1}^T \underline{Y}$
- $\frac{\partial \underline{\beta}^T \underline{X}^T \underline{Y}}{\partial \beta_1} = x_{11} y_1 + x_{21} y_2 = (x_{11} \quad x_{21}) \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} = \underline{x}_1^T \underline{Y}$
- $\frac{\partial \underline{\beta}^T \underline{X}^T \underline{Y}}{\partial \underline{\beta}} = \begin{pmatrix} \frac{\partial \underline{\beta}^T \underline{X}^T \underline{Y}}{\partial \beta_0} \\ \frac{\partial \underline{\beta}^T \underline{X}^T \underline{Y}}{\partial \beta_1} \end{pmatrix} = \begin{pmatrix} \underline{1}^T \underline{Y} \\ \underline{x}_1^T \underline{Y} \end{pmatrix} = \underline{X}^T \underline{Y}$

on veut minimiser $\underline{\varepsilon}^T \underline{\varepsilon}$, on dérive p/r à $\underline{\beta}$

$$\underline{\varepsilon}^T \underline{\varepsilon} = \underline{y}^T \underline{y} - 2 \underline{\beta}^T \underline{x}^T \underline{y} + \underline{\beta}^T \underline{x}^T \underline{x} \underline{\beta}$$

$$\frac{\partial \underline{\varepsilon}^T \underline{\varepsilon}}{\partial \underline{\beta}} = 0 - 2 \underline{x}^T \underline{y} + 2 \underline{x}^T \underline{x} \underline{\beta}$$

Dérivée = 0 évalué en $\hat{\underline{\beta}}$

$$- \cancel{2} \underline{x}^T \underline{y} + \cancel{2} \underline{x}^T \underline{x} \hat{\underline{\beta}} = 0$$

$$\underline{x}^T \underline{x} \hat{\underline{\beta}} = \underline{x}^T \underline{y}$$

$$\hat{\underline{\beta}} = (\underline{x}^T \underline{x})^{-1} \underline{x}^T \underline{y}$$

1(b) approche géométrique

- on peut écrire y comme une combinaison linéaire des colonnes de X plus une erreur


$$\underline{y} = \underline{X}\underline{\beta} + \underline{\varepsilon}$$

$$= \begin{pmatrix} 1 & x_{11} & \dots & x_{1p} \\ \vdots & \vdots & & \vdots \\ 1 & x_{n1} & \dots & x_{np} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix} + \underline{\varepsilon}$$

$$= \begin{pmatrix} \underline{1} & \underline{x}_1 & \dots & \underline{x}_p \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix} + \underline{\varepsilon}$$

$$= \beta_0 \underline{1} + \beta_1 \underline{x}_1 + \dots + \beta_p \underline{x}_p + \underline{\varepsilon}$$

- Les vecteurs $\underline{1}, \underline{x}_1, \dots, \underline{x}_p$ forment un sous-espace vectoriel
- On veut projeter $\underline{y}$ dans le sous-espace vectoriel engendré par les colonnes de $\underline{X}$
- Si on appelle H la matrice de projection,
 - les valeurs prédites : $\hat{\underline{y}} = \underline{H} \underline{y}$
 - les résidus : $\hat{\underline{e}} = \underline{y} - \hat{\underline{y}} = \underline{I}_n \underline{y} - \underline{H} \underline{y} = (\underline{I}_n - \underline{H}) \underline{y}$



$$\begin{aligned}\underline{y} &= \underline{\hat{y}} + \underline{\hat{\varepsilon}} \\ &= \underline{H}\underline{y} + (\underline{I}_n - \underline{H})\underline{y}\end{aligned}$$

→ $\underline{\hat{y}}$ et $\underline{\hat{\varepsilon}}$ sont orthogonaux

$$\rightarrow \text{cov}(\underline{\hat{y}}, \underline{\hat{\varepsilon}}) = 0$$

$$\rightarrow \underline{\hat{y}}^T \underline{\hat{\varepsilon}} = 0$$

Si on prend $\hat{\underline{y}} = \underline{X} \hat{\underline{\beta}}$

on a $\hat{\underline{y}}^T \hat{\underline{\varepsilon}} = 0$

$$(\underline{X} \hat{\underline{\beta}})^T \hat{\underline{\varepsilon}} = 0$$

$$\hat{\underline{\beta}}^T \underline{X}^T \hat{\underline{\varepsilon}} = 0$$

$$\underline{X}^T \hat{\underline{\varepsilon}} = 0$$

$$\underline{X}^T (\underline{y} - \underline{X} \hat{\underline{\beta}}) = 0$$

$$\underline{X}^T \underline{y} - \underline{X}^T \underline{X} \hat{\underline{\beta}} = 0$$

$$\underline{X}^T \underline{y} = \underline{X}^T \underline{X} \hat{\underline{\beta}}$$

$$(\underline{X}^T \underline{X})^{-1} \underline{X}^T \underline{y} = \hat{\underline{\beta}}$$

$$\hat{\underline{y}} = \underline{X} \hat{\underline{\beta}}$$

$$\hat{\underline{y}} = \underline{X} (\underline{X}^T \underline{X})^{-1} \underline{X}^T \underline{y}$$

on écrit $\hat{\underline{y}} = \underline{H} \underline{y}$

$$\rightarrow \underline{H} = \underline{X} (\underline{X}^T \underline{X})^{-1} \underline{X}^T$$

Pour calculer $\hat{\underline{\beta}}$, il faut de $\underline{x}^T \underline{x}$ soit inversible

$$\hat{\underline{\beta}} = (\underline{x}^T \underline{x})^{-1} \underline{x}^T \underline{y}$$

$\rightarrow \underline{x}^T \underline{x}$ doit être de plein rang. $\rightarrow$ Rang doit être $p+1$

$\underline{x}^T \underline{x}$ est de dimension $(p+1) \times (p+1)$

$\Rightarrow$ il faut que $p+1 < n$

$\Rightarrow$ on ne veut pas de colonnes de $\underline{x}$ parfaitement linéaires

Lien RLS et RLM

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i \quad \text{vs} \quad \underline{Y} = \underline{X}\beta + \underline{\varepsilon}$$

$$\text{on } \underline{X} = \begin{pmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix} \quad \text{et} \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}$$

$$\hat{\beta} = (\underline{X}^T \underline{X})^{-1} \underline{X}^T \underline{Y}$$

$$\begin{aligned} \cdot \underline{X}^T \underline{X} &= \begin{pmatrix} 1 & \dots & 1 \\ x_1 & \dots & x_n \end{pmatrix} \begin{pmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n 1 & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{pmatrix} \\ &= \begin{pmatrix} n & n\bar{x} \\ n\bar{x} & \sum_{i=1}^n x_i^2 \end{pmatrix} \end{aligned}$$

$$\cdot \det(\underline{X}^T \underline{X}) = n \sum x_i^2 - n^2 \bar{x}^2 = n \left[\sum x_i^2 - n\bar{x}^2 \right] = n S_{xx}$$

$$\cdot (\underline{X}^T \underline{X})^{-1} = \frac{1}{n S_{xx}} \begin{pmatrix} \sum x_i^2 & -n\bar{x} \\ -n\bar{x} & n \end{pmatrix}$$

$$\cdot \underline{X}^T \underline{Y} = \begin{pmatrix} 1 & \dots & 1 \\ x_1 & \dots & x_n \end{pmatrix} \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} \sum y_i \\ \sum x_i y_i \end{pmatrix}$$

$$\hat{\beta} = (X^T X)^{-1} X^T Y = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{pmatrix} = \begin{pmatrix} \bar{Y} - \frac{S_{xy}}{S_{xx}} \bar{X} \\ S_{xy}/S_{xx} \end{pmatrix}$$

$$= \frac{1}{n S_{xx}} \begin{pmatrix} \sum x_i^2 & -n \bar{X} \\ -n \bar{X} & n \end{pmatrix} \begin{pmatrix} \sum y_i \\ \sum x_i y_i \end{pmatrix}$$

$$= \frac{1}{n S_{xx}} \begin{pmatrix} \sum x_i^2 \sum y_i - n \bar{X} \sum x_i y_i \\ -n \bar{X} \sum y_i + n \sum x_i y_i \end{pmatrix}$$

$$= \begin{pmatrix} \frac{n \bar{Y} \sum x_i^2 - n \bar{X} \sum x_i y_i}{n S_{xx}} \\ \frac{n \sum x_i y_i - n \bar{X} \bar{Y}}{n S_{xx}} \end{pmatrix} = \begin{pmatrix} \frac{\bar{Y} \sum x_i^2 - \bar{X} \sum x_i y_i}{S_{xx}} \\ \frac{S_{xy}}{S_{xx}} \end{pmatrix}$$

$$= \begin{pmatrix} \frac{\bar{Y} (\sum x_i^2 - n \bar{X}^2) - (\bar{X} \sum x_i y_i - n \bar{X}^2 \bar{Y})}{S_{xx}} \\ \hat{\beta}_1 \end{pmatrix}$$

$$= \begin{pmatrix} \frac{\bar{Y} S_{xx} - \bar{X} (\sum x_i y_i - n \bar{X} \bar{Y})}{S_{xx}} \\ \hat{\beta}_1 \end{pmatrix}$$

$$= \begin{pmatrix} \bar{Y} - \frac{\bar{X} S_{xy}}{S_{xx}} \\ \hat{\beta}_1 \end{pmatrix} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{pmatrix} = \begin{pmatrix} \bar{Y} - \hat{\beta}_1 \bar{X} \\ S_{xy}/S_{xx} \end{pmatrix}$$