Chapitre 6

Inférence pour la RLM

Sommaire

6.1 Distribution de l'estimateur 49
6.2 Matrice chapeau et implications 50
6.2.1 La matrice chapeau 50
6.2.2 Distribution de $\widehat{\boldsymbol{Y}}$ et $\widehat{\boldsymbol{\varepsilon}}$ 51
6.2.3 Estimation de σ^2 51
6.3 Intervalle de confiance et test d'hypothèse pour un coefficient 52
6.4 Prévision 53
6.4.1 Inférence pour $\boldsymbol{a}^\top \boldsymbol{\beta}$ 54
6.4.2 Inférence sur $\mathbb{E}(Y|\boldsymbol{x})$ 54
6.4.3 Inférence sur une valeur de Y étant donné $\boldsymbol{x}$ 55
6.4.4 Théorème de Gauss-Markov 56
6.5 Analyse de la variance 57
6.5.1 Test global de la régression 57
6.6 Test de réduction du modèle 59
6.6.1 Cas particuliers simples 60
6.6.2 Point de vue géométrique 62
6.7 Test d'une hypothèse linéaire générale 63

Figures

6.1 Illustration de l'analyse de la variance généralisée 57
6.2 Illustration de l'analyse de la variance généralisée 62

6.1 Distribution de l'estimateur

Déterminons la distribution des estimateurs pour faire de l'inférence sur les paramètres. Pour trouver la loi des estimateurs, on doit faire l'hypothèse que le vecteur des termes d'erreurs $\boldsymbol{\varepsilon}$ est distribuée selon une loi normale multivariée de dimension égale au nombre d'observations n. On peut écrire cette hypothèse sous la forme

$$\boldsymbol{\varepsilon} = (\varepsilon_1, \varepsilon_2, ..., \varepsilon_n)^\top \sim \mathcal{N}_n(\mathbf{0}, \sigma^2 \mathbf{I}_n)$$

où $\mathbf{I}_n$ dénote la matrice identité de dimension $n \times n$. On a donc que

$$\boldsymbol{Y} \sim \mathcal{N}_n(\boldsymbol{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n).$$

Afin de déterminer l'espérance et la variance de $\widehat{\boldsymbol{\beta}}$, on suit la même approche que pour la régression linéaire simple et on exprime $\widehat{\boldsymbol{\beta}}$ comme une combinaison linéaire des Y_i. On a vu que

$$\widehat{\boldsymbol{\beta}} = (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \boldsymbol{Y}.$$

On a donc que $\widehat{\boldsymbol{\beta}} \sim \mathcal{N}_{p'}\left(\mathbb{E}[\widehat{\boldsymbol{\beta}}], \mathbb{V}\text{ar}[\widehat{\boldsymbol{\beta}}]\right)$ car une combinaison linéaire de variables aléatoires normales est également normalement distribuée. Il reste à calculer $\mathbb{E}[\widehat{\boldsymbol{\beta}}]$ et $\mathbb{V}\text{ar}[\widehat{\boldsymbol{\beta}}]$ afin de déterminer la loi complètement. On peut d'abord montrer que l'estimateur est non biaisé :

$$\begin{aligned}
\mathbb{E}\left[\widehat{\boldsymbol{\beta}}\right] &= \mathbb{E}\left[(\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \boldsymbol{Y}\right] \\
&= (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \mathbb{E}\left[\boldsymbol{Y}\right] \\
&= (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{\beta} \\
&= \boldsymbol{\beta}
\end{aligned}$$

On calcule ensuite la variance :

$$\begin{aligned}
\mathbb{V}\text{ar}\left[\widehat{\boldsymbol{\beta}}\right] &= \mathbb{V}\text{ar}\left[(\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \boldsymbol{Y}\right] \\
&= (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \mathbb{V}\text{ar}\left[\boldsymbol{Y}\right] \left\{(\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top\right\}^\top \\
&= (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \sigma^2 \mathbf{I}_n \left\{(\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top\right\}^\top \\
&= \sigma^2 (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \boldsymbol{X} (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \\
&= \sigma^2 (\boldsymbol{X}^\top \boldsymbol{X})^{-1}
\end{aligned}$$

Ainsi,

$$\widehat{\boldsymbol{\beta}} \sim \mathcal{N}_{p'}\{\boldsymbol{\beta}, \sigma^2 (\boldsymbol{X}^\top \boldsymbol{X})^{-1}\}. \tag{6.1}$$

Exemple 6.1. Application au cas $p = 1$

On a déjà vu que dans le cas où $p = 1$,

$$(\boldsymbol{X}^\top \boldsymbol{X})^{-1} = \frac{1}{nS_{xx}} \begin{pmatrix} \sum_{i=1}^{n} x_i^2 & -n\overline{x} \\ -n\overline{x} & n \end{pmatrix}. \tag{6.2}$$

À partir de (6.1) et (6.2), on peut calculer les variances et la covariance de $\widehat{\beta}_0$ et de $\widehat{\beta}_1$,

$$\begin{aligned} \mathbb{V}ar\left(\widehat{\beta}_1\right) &= \frac{\sigma^2 n}{nS_{xx}} = \frac{\sigma^2}{S_{xx}} \\ \mathbb{V}ar\left(\widehat{\beta}_0\right) &= \frac{\sigma^2 \sum_{i=1}^{n} x_i^2}{nS_{xx}} = \frac{S_{xx} + n\overline{x}^2}{nS_{xx}}\sigma^2 \\ \mathbb{C}ov\left(\widehat{\beta}_1, \widehat{\beta}_0\right) &= \frac{-n\overline{x}\sigma^2}{nS_{xx}} = \frac{-\overline{x}\sigma^2}{S_{xx}} \end{aligned}$$

On obtient les quantités déjà connues. Remarquez que la covariance entre $\widehat{\beta}_0$ et $\widehat{\beta}_1$ est de signe contraire de $\overline{x}$ et que cette covariance est nulle si $\overline{x} = 0$.

6.2 Matrice chapeau et implications

On a introduit la matrice chapeau, à la section 5.2.2. Dans cette section, on explore plus en détails la matrice chapeau, et on obtient quelques résultats utiles pour l'inférence à partir de ses propriétés.

6.2.1 La matrice chapeau

La matrice chapeau $\boldsymbol{H}$ (ńhat matrixż) tire son nom du fait qu'elle permet de transformer $\boldsymbol{Y}$ en $\widehat{\boldsymbol{Y}}$ ("Y chapeau"). Selon l'équation (5.2), la régression linéaire multiple s'exprime sous format matriciel comme $\boldsymbol{Y} = \boldsymbol{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$. L'estimateur de $\boldsymbol{\beta}$ peut s'écrire selon l'équation (5.3) comme $\widehat{\boldsymbol{\beta}} = (\boldsymbol{X}^\top \boldsymbol{X})^{-1}\boldsymbol{X}^\top \boldsymbol{Y}$. On peut écrire

$$\begin{aligned} \widehat{\boldsymbol{Y}} &= \boldsymbol{X}\widehat{\boldsymbol{\beta}} \\ &= \boldsymbol{X}(\boldsymbol{X}^\top \boldsymbol{X})^{-1}\boldsymbol{X}^\top \boldsymbol{Y} \\ &= \boldsymbol{H}\boldsymbol{Y} \end{aligned}$$

La matrice chapeau correspond donc à la matrice $\boldsymbol{H} = \boldsymbol{X}(\boldsymbol{X}^\top \boldsymbol{X})^{-1}\boldsymbol{X}^\top$. Il est également possible d'exprimer les résidus en fonction de la matrice chapeau,

$$\widehat{\boldsymbol{\varepsilon}} = \boldsymbol{Y} - \widehat{\boldsymbol{Y}} = \left[\mathbf{I}_n - \boldsymbol{X}(\boldsymbol{X}^\top \boldsymbol{X})^{-1}\boldsymbol{X}^\top\right] \boldsymbol{Y} = (\mathbf{I}_n - \boldsymbol{H})\boldsymbol{Y}.$$

La matrice chapeau peut être vue comme une matrice de transformation. Il s'agit d'un opérateur linéaire, de même que $(\mathbf{I}_n - \boldsymbol{H})$. Ces deux opérateurs possèdent plusieurs propriétés intéressantes, à savoir :

1. $\boldsymbol{H}^\top = \boldsymbol{H}$ (symétrie) ;
2. $\boldsymbol{H}\boldsymbol{H} = \boldsymbol{H}$ (idempotence) ;
3. $\boldsymbol{H}\boldsymbol{X} = \boldsymbol{X}$;
4. $(\mathbf{I}_n - \boldsymbol{H})^\top = (\mathbf{I}_n - \boldsymbol{H})$ (symétrie) ;
5. $(\mathbf{I}_n - \boldsymbol{H})(\mathbf{I}_n - \boldsymbol{H}) = (\mathbf{I}_n - \boldsymbol{H})$ (idempotence) ;
6. $(\mathbf{I}_n - \boldsymbol{H})\boldsymbol{X} = 0$.

De plus, tous les éléments de la matrice ont une interprétation précise et utile pour étudier la robustesse d'un modèle de RLM. Nous y reviendrons à la section 10.

6.2.2 Distribution de $\widehat{\boldsymbol{Y}}$ et $\widehat{\boldsymbol{\varepsilon}}$

Les propriétés de la matrice chapeau permettent de calculer la variance de $\widehat{\boldsymbol{Y}}$ et $\widehat{\boldsymbol{\varepsilon}}$. En effet,

$$\mathbb{V}\text{ar}\left(\widehat{\boldsymbol{Y}}\right) = \mathbb{V}\text{ar}\left(\boldsymbol{H}\boldsymbol{Y}\right) = \boldsymbol{H}\mathbb{V}\text{ar}\left(\boldsymbol{Y}\right)\boldsymbol{H}^\top = \boldsymbol{H}\boldsymbol{H}^\top\sigma^2 = \boldsymbol{H}\sigma^2$$

et

$$\mathbb{V}\text{ar}\left(\widehat{\boldsymbol{\varepsilon}}\right) = \mathbb{V}\text{ar}\left((\mathbf{I}_n - \boldsymbol{H})\boldsymbol{Y}\right) = (\mathbf{I}_n - \boldsymbol{H})\sigma^2.$$

On a donc que les lois de $\widehat{\boldsymbol{Y}}$ et $\widehat{\boldsymbol{\varepsilon}}$ sont respectivement

$$\widehat{\boldsymbol{Y}} \sim \mathcal{N}_n(\boldsymbol{X}\boldsymbol{\beta}, \sigma^2\boldsymbol{H})$$

$$\widehat{\boldsymbol{\varepsilon}} \sim \mathcal{N}_n(\mathbf{0}, \sigma^2(\mathbf{I}_n - \boldsymbol{H})). \tag{6.3}$$

6.2.3 Estimation de σ^2

La méthode du maximum de vraisemblance permet de trouver un estimateur pour σ^2, mais celui-ci est biaisé. On utilise plutôt l'estimateur suivant :

$$\widehat{\sigma}^2 = \frac{\widehat{\boldsymbol{\varepsilon}}^\top\widehat{\boldsymbol{\varepsilon}}}{n - p'}, \tag{6.4}$$

où $p' = p + 1$. Montrons que l'estimateur donné en (6.4) est sans biais pour σ^2, c'est-à-dire, montrons que

$$E\left(\frac{\widehat{\boldsymbol{\varepsilon}}^\top\widehat{\boldsymbol{\varepsilon}}}{n - p'}\right) = \sigma^2.$$

Commençons par étudier $\widehat{\boldsymbol{\varepsilon}}$ et $\widehat{\boldsymbol{\varepsilon}}^\top\widehat{\boldsymbol{\varepsilon}}$. Par le résultat (6.3), $\widehat{\boldsymbol{\varepsilon}} \sim \mathcal{N}_n\left(\mathbf{0}, \sigma^2(\mathbf{I}_n - \boldsymbol{H})\right)$, et on peut écrire

$$\frac{\widehat{\boldsymbol{\varepsilon}}}{\sigma} \sim \mathcal{N}_n\left(\mathbf{0}, (\mathbf{I}_n - \boldsymbol{H})\right).$$

Soit un vecteur $\boldsymbol{Z} \sim \mathcal{N}_n(\mathbf{0}, \mathbf{I}_n)$. On a que $(\mathbf{I}_n - \boldsymbol{H})\boldsymbol{Z} \sim \mathcal{N}_n\left(\mathbf{0}, (\mathbf{I}_n - \boldsymbol{H})\right)$. Ainsi, on peut écrire

$$\frac{\widehat{\boldsymbol{\varepsilon}}}{\sigma} = (\mathbf{I}_n - \boldsymbol{H})\boldsymbol{Z} \sim \mathcal{N}_n\left(\mathbf{0}, (\mathbf{I}_n - \boldsymbol{H})\right).$$

Cette forme nous permet d'utiliser le théorème 1 du Chapitre 4. On a

- $\boldsymbol{Z} \sim \mathcal{N}_n(\mathbf{0}, \mathbf{I}_n)$,
- $(\mathbf{I}_n - \boldsymbol{H})$ une matrice symétrique,
- $(\mathbf{I}_n - \boldsymbol{H})$ une matrice idempotente idempotente.

Avec le Théorème 1,

$$\boldsymbol{Z}^\top(\mathbf{I}_n - \boldsymbol{H})\boldsymbol{Z} \sim \chi^2_r,$$

avec $r = \text{rang}(\mathbf{I}_n - \boldsymbol{H}) = n - p'$. Or,

$$\begin{aligned}
\boldsymbol{Z}^\top(\mathbf{I}_n - \boldsymbol{H})\boldsymbol{Z} &= \boldsymbol{Z}^\top(\mathbf{I}_n - \boldsymbol{H})^\top(\mathbf{I}_n - \boldsymbol{H})\boldsymbol{Z} \\
&= ((\mathbf{I}_n - \boldsymbol{H})\boldsymbol{Z})^\top(\mathbf{I}_n - \boldsymbol{H})\boldsymbol{Z} \\
&= \frac{\widehat{\boldsymbol{\varepsilon}}^\top}{\sigma}\frac{\widehat{\boldsymbol{\varepsilon}}}{\sigma} \\
&= \frac{\widehat{\boldsymbol{\varepsilon}}^\top\widehat{\boldsymbol{\varepsilon}}}{\sigma^2}.
\end{aligned}$$

Ainsi,

$$\frac{\widehat{\boldsymbol{\varepsilon}}^\top\widehat{\boldsymbol{\varepsilon}}}{\sigma^2} \sim \chi^2_{n-p'}.$$

On peut finalement montrer que l'estimateur donné en (6.4) est sans biais pour σ^2,

$$\begin{aligned}
E\left(\frac{\widehat{\boldsymbol{\varepsilon}}^\top\widehat{\boldsymbol{\varepsilon}}}{\sigma^2}\right) &= n - p' \\
E\left(\widehat{\boldsymbol{\varepsilon}}^\top\widehat{\boldsymbol{\varepsilon}}\right) &= \sigma^2(n - p') \\
E\left(\frac{\widehat{\boldsymbol{\varepsilon}}^\top\widehat{\boldsymbol{\varepsilon}}}{n - p'}\right) &= \sigma^2.
\end{aligned}$$

6.3 Intervalle de confiance et test d'hypothèse pour un coefficient

On a utilisé le postulat de normalité $\boldsymbol{\varepsilon} \sim \mathcal{N}_n(0, \sigma^2\mathbf{I}_n)$, pour montrer que $\widehat{\boldsymbol{\beta}} \sim \mathcal{N}_{p'}\left(\boldsymbol{\beta}, \sigma^2(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\right)$. Si on s'intéresse à un β_j en particulier, on a alors que

$$\frac{\widehat{\beta}_j - \beta_j}{\sigma\sqrt{v_{j+1,j=1}}} \sim \mathcal{N}(0, 1),$$

où $v_{j+1,j=1}$ est l'élément $(j+1, j+1)$ de la matrice $(\boldsymbol{X}^\top \boldsymbol{X})^{-1}$, pour $j = 0, \ldots, p$.

On a montré que $\widehat{\sigma}^2 = \widehat{\boldsymbol{\varepsilon}}^\top \widehat{\boldsymbol{\varepsilon}}/(n-p')$ est un estimateur sans biais de σ^2. Par conséquent,

$$\frac{\dfrac{\widehat{\beta}_j - \beta_j}{\sigma\sqrt{v_{j+1,j+1}}}}{\sqrt{\dfrac{\widehat{\boldsymbol{\varepsilon}}^\top \widehat{\boldsymbol{\varepsilon}}}{\sigma^2(n-p')}}} \sim \frac{\mathcal{N}(0,1)}{\sqrt{\chi^2_{n-p'}/(n-p')}} \sim \mathcal{T}_{n-p'}, \tag{6.5}$$

où $\mathcal{T}_{n-p'}$ note la loi de Student à $n-p'$ degrés de liberté. On peut alors utiliser (6.5) pour construire un intervalle de confiance pour β_j ou pour effectuer des tests d'hypothèses. L'intervalle de confiance de niveau $(1-\alpha)$ pour β_j s'exprime comme

$$\left[\widehat{\beta}_j \pm t_{n-p';1-\alpha/2}\sqrt{\widehat{\sigma}^2 v_{j+1,j+1}}\right] \tag{6.6}$$

Exemple 6.2. *Construisons un intervalle de confiance à 95 % pour le paramètre β_1 de l'exemple de la section 5.1. Nous avons déjà calculé que $\widehat{\beta}_1 = 0,01314$. L'élément diagonal de la matrice $(\boldsymbol{X}^\top \boldsymbol{X})^{-1}$ correspondant à β_1 est $v_{22} = 0,0000077$. L'estimation non biaisée de σ^2 est $\widehat{\sigma}^2 = 2,247$. Le quantile à 97,5 % d'une loi $\mathcal{T}$ de Student à $n-p' = 20-3 = 17$ degrés de liberté est égal à 2,110. On obtient donc selon (6.6) l'intervalle de confiance suivant :*

$$\begin{aligned}\left[\widehat{\beta}_1 \pm t_{n-p';1-\alpha/2}\sqrt{\widehat{\sigma}^2 v_{22}}\right] &= \left[0,01314 \pm 2,110\sqrt{2,247 \times 0,0000077}\right] \\ &= [0,00436; 0,0219]\end{aligned}$$

On note que l'intervalle n'inclut pas la valeur 0. On peut donc rejeter l'hypothèse nulle $H_0 : \beta_1 = 0$ et conclure que la hauteur de la chute est significativement associée au diamètre moyen des meurtrissures, en tenant compte de la présence des autres variables explicatives dans le modèle.

6.4 Prévision

Quand on veut faire une prévision, on s'intéresse à une combinaison linéaire des coefficients. Considérons donc le problème général d'estimer une combinaison linéaire de $\boldsymbol{\beta}$:

$$\sum_{i=0}^{p} a_i \beta_i = \boldsymbol{a}^\top \boldsymbol{\beta}, \qquad \text{où} \quad \boldsymbol{a}^\top = (a_0 \; a_1 \; \ldots \; a_p)\,. \tag{6.7}$$

On peut utiliser $\boldsymbol{a}^\top \widehat{\boldsymbol{\beta}}$ pour estimer $\boldsymbol{a}^\top \boldsymbol{\beta}$, puisque

$$\boldsymbol{a}^\top \widehat{\boldsymbol{\beta}} \sim \mathcal{N}(\boldsymbol{a}^\top \boldsymbol{\beta}, \quad \sigma^2 \boldsymbol{a}^\top (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{a}). \tag{6.8}$$

6.4.1 Inférence pour $\boldsymbol{a}^\top\boldsymbol{\beta}$

On peut utiliser (6.8) pour faire de l'inférence sur une combinaison linéaire des coefficients. Si on connaissait σ^2, on pourrait construire des intervalles de confiance et des tests d'hypothèses pour $\boldsymbol{a}^\top\boldsymbol{\beta}$ à partir de

$$\frac{\boldsymbol{a}^\top\widehat{\boldsymbol{\beta}} - \boldsymbol{a}^\top\boldsymbol{\beta}}{\sqrt{\sigma^2\boldsymbol{a}^\top(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{a}}} \sim \mathcal{N}(0,1). \tag{6.9}$$

Toutefois, comme on ne connaît pas σ^2, on l'estime par $\widehat{\sigma}^2 = \widehat{\boldsymbol{\varepsilon}}^\top\widehat{\boldsymbol{\varepsilon}}/(n-p')$ et on a que

$$\frac{\boldsymbol{a}^\top\widehat{\boldsymbol{\beta}} - \boldsymbol{a}^\top\boldsymbol{\beta}}{\sqrt{\widehat{\sigma}^2\boldsymbol{a}^\top(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{a}}} \sim \mathcal{T}_{n-p'}. \tag{6.10}$$

On peut utiliser ce résultat pour construire un intervalle de confiance ou pour faire un test pour $\boldsymbol{a}^\top\boldsymbol{\beta}$.

Remarque 8. *Il y a plusieurs circonstances dans lesquelles on voudrait faire de l'inférence sur une combinaison linéaire des coefficients. On pourrait se demander si une variable a un effet aussi grand qu'une autre (on s'intéresse alors à $\beta_i - \beta_j$), ou si une variable a un effet deux fois plus grand qu'une autre ($\beta_i - 2\beta_j$), par exemple. Dans les prochaines sections, le résultat (6.10) est appliqué au cas de la prévision pour de nouvelles observations.*

6.4.2 Inférence sur $\mathbb{E}(Y|\boldsymbol{x})$

On désire dans ce cas estimer la valeur moyenne de la variable réponse pour une combinaison de valeurs $\mathbf{x}^{*\top} = (1, x_1^*, \ldots, x_p^*)$ spécifiées des variables explicatives. On veut donc estimer $\mathbb{E}(Y|\mathbf{x}^*) = \mathbb{E}\left(\mathbf{x}^{*\top}\boldsymbol{\beta} + \varepsilon\right) = \mathbf{x}^{*\top}\boldsymbol{\beta}$. Cela revient à estimer une combinaison linéaire de $\boldsymbol{\beta}$ et il suffit de remplacer $\mathbf{x}^{*\top}$ par $\boldsymbol{a}^\top$ dans la section précédente afin d'obtenir un intervalle de confiance au niveau $100(1-\alpha)\%$ pour $\mathbb{E}(Y|\mathbf{x}^*)$. Celui-ci est donné par

$$\left[\mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}} \pm t_{n-p';1-\alpha/2}\sqrt{\widehat{\sigma}^2\mathbf{x}^{*\top}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\mathbf{x}^*}\right]. \tag{6.11}$$

Exemple 6.3. *Les scientifiques œuvrant sur l'expérimentation des pêches meurtries de l'exemple 5.1 désirent construire un intervalle de confiance à 95 % pour la moyenne des meurtrissures d'une pêche qui tombe d'une hauteur de $x_1 = 325$ mm et qui possède une masse volumique de $x_2 = 0,98$ g/cm^3. On a dans ce cas que*

$$\mathbf{x}^* = \begin{pmatrix} 1 \\ 325 \\ 0,98 \end{pmatrix}.$$

Notre estimation est

$$\mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}} = \begin{pmatrix} 1 & 325 & 0,98 \end{pmatrix} \begin{pmatrix} -33,831 \\ 0,01314 \\ 34,890 \end{pmatrix} = 4,63.$$

La variance de $\mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}}$ *est estimée par*

$$\begin{aligned} &\widehat{\sigma}^2 \mathbf{x}^{*\top}(\boldsymbol{X}^\top \boldsymbol{X})^{-1}\mathbf{x}^* \\ &\quad = 2,247 \begin{pmatrix} 1 & 325 & 0,98 \end{pmatrix} \begin{pmatrix} 24,63666 & 0,005321 & -26,74679 \\ 0,005321 & 0,0000077 & -0,008353 \\ -26,74679 & -0,008353 & 30,096389 \end{pmatrix} \begin{pmatrix} 1 \\ 325 \\ 0,98 \end{pmatrix} \\ &\quad = 2,247 \times 0,0718 \\ &\quad = 0,1613. \end{aligned}$$

Avec l'équation (6.11)*, l'intervalle de confiance à 95 % pour la moyenne des meurtrissures au point* $\mathbf{x}^*$ *est donné par*

$$\left[4,63 \pm 2,110\sqrt{0,1613}\right] = [3,78; 5,48]\,.$$

6.4.3 Inférence sur une valeur de Y étant donné x

Nous cherchons maintenant à prédire la valeur même d'une réalisation de la variable réponse pour une combinaison de valeurs $\mathbf{x}^*$ fixées des variables explicatives. On cherche donc à estimer $Y = \mathbf{x}^{*\top}\boldsymbol{\beta} + \varepsilon$. On estime de nouveau $\mathbf{x}^{*\top}\boldsymbol{\beta}$ par $\mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}}$. Comme $\mathbb{E}(\varepsilon) = 0$, la meilleure estimation d'une réalisation de ε est 0. L'estimateur ponctuel de Y pour une valeur $\mathbf{x}^*$ donnée est donc $\mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}} + 0 = \mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}}$.

Afin d'utiliser un résultat similaire à (6.5), nous devons calculer

$$\begin{aligned} \mathbb{V}\text{ar}[\widehat{Y} - Y] = \mathbb{V}\text{ar}[\mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}} - (\mathbf{x}^{*\top}\boldsymbol{\beta} + \varepsilon)] &= \mathbb{V}\text{ar}[\mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}}] + \mathbb{V}\text{ar}[\varepsilon] \\ &= \sigma^2 \mathbf{x}^{*\top}(\boldsymbol{X}^\top \boldsymbol{X})^{-1}\mathbf{x}^* + \sigma^2 \\ &= \sigma^2 \left(1 + \mathbf{x}^{*\top}(\boldsymbol{X}^\top \boldsymbol{X})^{-1}\mathbf{x}^*\right). \end{aligned}$$

On a donc que

$$\frac{\mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}} - (\mathbf{x}^{*\top}\boldsymbol{\beta} + \varepsilon)}{\sqrt{\widehat{\sigma}^2\left(1 + \mathbf{x}^{*\top}(\boldsymbol{X}^\top \boldsymbol{X})^{-1}\mathbf{x}^*\right)}} \sim \mathcal{T}_{n-p'}. \tag{6.12}$$

Un intervalle de prévision à $100(1-\alpha)\%$ pour une observation de Y étant donné $\mathbf{x}^*$ est donc donné par

$$\left[\mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}} \pm t_{n-p';1-\alpha/2}\sqrt{\widehat{\sigma}^2\left(1 + \mathbf{x}^{*\top}(\boldsymbol{X}^\top \boldsymbol{X})^{-1}\mathbf{x}^*\right)}\right]. \tag{6.13}$$

Comme on a déjà remarqué pour la RLS, l'intervalle de prévision pour une valeur précise sera plus grand que celui pour $\mathbb{E}[Y|\boldsymbol{x}]$.

Exemple 6.4. *Supposons que les scientifiques de l'exemple 5.1 désirent construire un intervalle de prévision à 95 % sur les meurtrissures subies par une pêche tombant d'une hauteur $x_1 = 325$ mm et de masse volumique $x_2 = 0,98$ g/cm^3. Comme dans l'exemple 6.3 on a que $\mathbf{x}^{*\top} = \begin{pmatrix} 1 & 325 & 0,98 \end{pmatrix}$ et que l'estimation ponctuelle des meurtrissures est égale à $\mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}} = 4,63$ mm. De plus on a que $\mathbf{x}^{*\top}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\mathbf{x}^* = 0,0718$. Donc, selon l'équation (6.13), l'intervalle de prévision s'obtient comme*

$$\left[4,63 \pm 2,110\sqrt{2,247(1+0,0718)}\right] = [1,36; 7,90]\,.$$

6.4.4 Théorème de Gauss-Markov

On conclut cette section en présentant un théorème important qui montre que l'inférence présentée aux sections 6.4.1, 6.4.2 et 6.4.3 est optimale.

Théorème 2. ***(Théorème de Gauss-Markov)***
Le théorème de Gauss-Markov stipule que $\boldsymbol{a}^\top\widehat{\boldsymbol{\beta}} = \boldsymbol{a}^\top(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{X}^\top\boldsymbol{Y}$ est le meilleur estimateur linéaire non biaisé de $\boldsymbol{a}^\top\boldsymbol{\beta}$, c'est-à-dire qu'il est l'estimateur linéaire sans biais dont la variance est la plus petite.

Démonstration. Supposons que $\boldsymbol{c}^\top\boldsymbol{Y}$ est un autre estimateur linéaire quelconque sans biais de $\boldsymbol{a}^\top\boldsymbol{\beta}$. Nous montrerons que $\mathbb{V}\text{ar}[\boldsymbol{c}^\top\boldsymbol{Y}] \geq \mathbb{V}\text{ar}[\boldsymbol{a}^\top\widehat{\boldsymbol{\beta}}]$.

On a que

$$\mathbb{E}[\boldsymbol{c}^\top\boldsymbol{Y}] = \boldsymbol{c}^\top\mathbb{E}[\boldsymbol{Y}] = \boldsymbol{c}^\top\boldsymbol{X}\boldsymbol{\beta} = \boldsymbol{a}^\top\boldsymbol{\beta},$$

la dernière égalité provenant du fait qu'on veut un estimateur sans biais. On a donc que $\boldsymbol{a}^\top = \boldsymbol{c}^\top\boldsymbol{X}$.

Si on calcule la variance de $\boldsymbol{c}^\top\boldsymbol{Y}$, on obtient

$$\mathbb{V}\text{ar}[\boldsymbol{c}^\top\boldsymbol{Y}] = \boldsymbol{c}^\top\mathbb{V}\text{ar}[\boldsymbol{Y}]\boldsymbol{c} = \boldsymbol{c}^\top\sigma^2\mathbb{I}_n\boldsymbol{c} = \sigma^2\boldsymbol{c}^\top\boldsymbol{c}.$$

La variance de $\boldsymbol{a}^\top\widehat{\boldsymbol{\beta}}$ est

$$\mathbb{V}\text{ar}[\boldsymbol{a}^\top\widehat{\boldsymbol{\beta}}] = \boldsymbol{a}^\top\mathbb{V}\text{ar}[\widehat{\boldsymbol{\beta}}]\boldsymbol{a} = \sigma^2\boldsymbol{a}^\top(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{a}.$$

Si on calcule $\mathbb{V}\text{ar}[\boldsymbol{c}^\top\boldsymbol{Y}] - \mathbb{V}\text{ar}[\boldsymbol{a}^\top\widehat{\boldsymbol{\beta}}]$, on obtient un terme nécessairement positif. En effet

$$\begin{aligned}
\mathbb{V}\text{ar}[\boldsymbol{c}^\top\boldsymbol{Y}] - \mathbb{V}\text{ar}[\boldsymbol{a}^\top\widehat{\boldsymbol{\beta}}] &= \sigma^2[\boldsymbol{c}^\top\boldsymbol{c} - \boldsymbol{a}^\top(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{a}] \\
&= \sigma^2[\boldsymbol{c}^\top\boldsymbol{c} - \boldsymbol{c}^\top\boldsymbol{X}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{X}^\top\boldsymbol{c}] \\
&= \sigma^2\boldsymbol{c}^\top[\mathbf{1}_n - \boldsymbol{X}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{X}^\top]\boldsymbol{c} \\
&= \sigma^2\boldsymbol{c}^\top[\mathbf{1}_n - \boldsymbol{H}]\boldsymbol{c},
\end{aligned}$$

où $\boldsymbol{H}$ désigne la matrice chapeau. D'après les propriétés de cette matrice, $\mathbf{1}_n - \boldsymbol{H}$ est une matrice semi-définie positive, ce qui implique que $\sigma^2\boldsymbol{c}^\top(\mathbb{I}_n - \boldsymbol{H})\boldsymbol{c} \geq 0$. Ainsi, $\mathbb{V}\text{ar}[\boldsymbol{c}^\top\boldsymbol{Y}] \geq \mathbb{V}\text{ar}[\boldsymbol{a}^\top\widehat{\boldsymbol{\beta}}]$. □

6.5 Analyse de la variance

Tout comme pour la RLS, on peut décomposer la variabilité de la variable réponse en une part expliquée linéairement par les variables explicatives et une part résiduelle. On peut écrire la décomposition sous forme matricielle,

$$\begin{aligned}
\sum_{i=1}^{n}(Y_i-\overline{Y})^2 &= \sum_{i=1}^{n}(\widehat{Y}_i-\overline{Y})^2+\sum_{i=1}^{n}(Y_i-\widehat{Y}_i)^2\\
\boldsymbol{Y}^\top\boldsymbol{Y}-n\overline{Y}^2 &= \widehat{\boldsymbol{Y}}^\top\widehat{\boldsymbol{Y}}-n\overline{Y}^2+(\boldsymbol{Y}-\widehat{\boldsymbol{Y}})^\top(\boldsymbol{Y}-\widehat{\boldsymbol{Y}})\\
&= \left(\widehat{\boldsymbol{\beta}}^\top\boldsymbol{X}^\top\boldsymbol{X}\widehat{\boldsymbol{\beta}}-n\overline{Y}^2\right)+\widehat{\boldsymbol{\varepsilon}}^\top\widehat{\boldsymbol{\varepsilon}}\\
SC_{tot} &= SC_{reg}+SC_{res}.
\end{aligned}$$

Cette décomposition peut également être obtenue par un argument géométrique. La figure 6.1 montre cette géométrie.

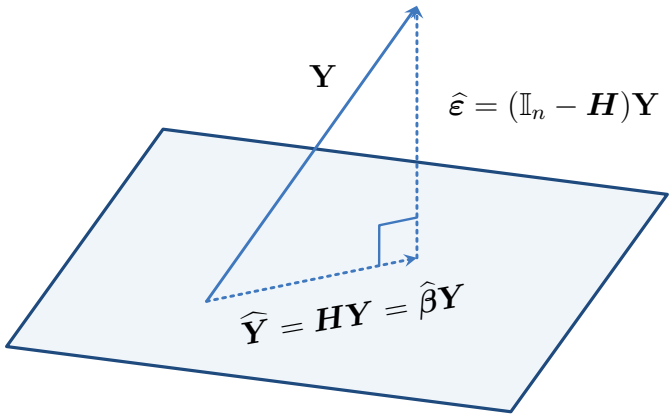


FIGURE 6.1 – Illustration de l'analyse de la variance généralisée

Le théorème de Pythagore donne

$$||\boldsymbol{Y}||^2 = ||\boldsymbol{X}\widehat{\boldsymbol{\beta}}||^2 + ||\widehat{\boldsymbol{\varepsilon}}||^2,$$

où $||\cdot||$ représente la norme (longueur) du vecteur. Ainsi on retrouve la décomposition,

$$\begin{aligned}
\boldsymbol{Y}^\top\boldsymbol{Y} &= (\boldsymbol{X}\widehat{\boldsymbol{\beta}})^\top\boldsymbol{X}\widehat{\boldsymbol{\beta}}+\widehat{\boldsymbol{\varepsilon}}^\top\widehat{\boldsymbol{\varepsilon}}\\
\Rightarrow \boldsymbol{Y}^\top\boldsymbol{Y}-n\overline{Y}^2 &= \widehat{\boldsymbol{\beta}}^\top\boldsymbol{X}^\top\boldsymbol{X}\widehat{\boldsymbol{\beta}}+\widehat{\boldsymbol{\varepsilon}}^\top\widehat{\boldsymbol{\varepsilon}}-n\overline{Y}_n^2\\
&= \widehat{\boldsymbol{\beta}}^\top\boldsymbol{X}^\top\boldsymbol{X}\widehat{\boldsymbol{\beta}}-n\overline{Y}^2+\widehat{\boldsymbol{\varepsilon}}^\top\widehat{\boldsymbol{\varepsilon}}.
\end{aligned}$$

6.5.1 Test global de la régression

La somme des carrés de la régression (SC_{reg}) constitue la portion de la variance expliquée par le modèle, alors que la somme des carrés résiduelle (SC_{res}) représente la partie que le modèle n'explique pas.

Intuitivement, on comprend que si la proportion de la variance expliquée par le modèle (SC_{reg}/SC_{tot}) est élevée, le modèle est bon.

L'analyse de la variance utilise cette idée pour effectuer un test global de la régression. On désire tester les hypothèses suivantes

$$\begin{aligned} H_0 : &\quad \beta_1 = \beta_2 = \cdots = \beta_p = 0 \\ H_1 : &\quad \text{au moins un des coefficients n'est pas nul.} \end{aligned} \tag{6.14}$$

L'idée consiste à comparer SC_{reg} à SC_{res} pour évaluer si les variables explicatives explique une partie significative de SC_{tot}. Afin de construire un test, il faut en premier lieu déterminer la statistique à utiliser et sa distribution sous H_0. Il se trouve qu'il est plus simple de trouver cette distribution si on standardise les sommes des carrés pour construire la statistique de test. On obtient alors

— CM_{res}, le carré moyen pour les résidus,

— CM_{reg}, le carré moyen pour la régression.

La statistique de test des hypothèses 6.14 est le rapport $F_{obs} = CM_{reg}/CM_{res}$. Le tableau 6.1 présente les principaux éléments de l'analyse de la variance et montre comment calculer cette statistique de test.

TABLE 6.1 – Tableau d'analyse de la variance dans le cas de la régression linéaire multiple

Source	Degrés de liberté	Sommes des carrés	Carrés moyens	F_{obs}	$\alpha*$
Modèle	$ddl_1 = p$	$SC_{reg} = \sum_{i=1}^{n} (\widehat{Y}_i - \overline{Y})^2$	$CM_{reg} = \frac{SC_{reg}}{ddl_1}$	$\frac{CM_{reg}}{CM_{res}}$	$P(F > F_{obs})$
Erreur	$ddl_2 = n - p'$	$SC_{res} = \sum_{i=1}^{n} (Y_i - \widehat{Y}_i)^2$	$CM_{res} = \frac{SC_{res}}{ddl_2}$		
Totale	$n - 1 = p + n - p'$	$SC_{tot} = \sum_{i=1}^{n} (Y_i - \overline{Y})^2$			

Une grande valeur de la statistique F_{obs} indique que la régression explique une bonne partie de la variabilité, et suggère de rejeter l'hypothèse nulle. Sous H_0, la statistique F_{obs} suit une loi $\mathcal{F}$ de Fisher-Snedecor avec p degrés de liberté au numérateur et $n-p'$ degrés de liberté au dénominateur. On rejette donc H_0 au seuil α lorsque la statistique $F_{obs} > F_{p,n-p';1-\alpha}$. On peut rejeter H_0 au seuil α si la valeur p du test est inférieure au seuil,

$$\alpha^* = P\left(F > F_{obs}\right),$$

avec F une variable de loi $\mathcal{F}_{p,n-p'}$.

Remarque 9. *Il est à souligner que le carré moyen de l'erreur résiduelle (CM_{res}) correspond à l'estimation de la variance des termes d'erreur. En effet*

$$CM_{res} = \frac{SC_{res}}{ddl_2} = \frac{\sum_{i=1}^{n} (Y_i - \widehat{Y}_i)^2}{n - p'} = \frac{\sum_{i=1}^{n} \widehat{\varepsilon}_i^2}{n - p'} = \widehat{\sigma}^2.$$

Exemple 6.5. *Pour l'exemple 5.1, on peut calculer* $SC_{res} = \widehat{\boldsymbol{\varepsilon}}^\top \widehat{\boldsymbol{\varepsilon}} = \widehat{\sigma}^2(n-p') = 38,21$, $SC_{tot} = \boldsymbol{Y}'\boldsymbol{Y} - n\overline{Y}^2 = 904,60 - 20\left(\frac{120,79}{20}\right)^2 = 175,089$ *et* $SC_{reg} = SC_{tot} - SC_{res} = 136,88$. *On obtient donc le tableau d'analyse de la variance 6.2.*

Pour tester $H_0 : \beta_1 = \beta_2 = 0$, *on compare* $F = 30,46$ *au quantile* $F_{p,n-p'}(1-\alpha) = F_{2,17}(0,95) = 3,59$. *Comme* $30,46 > 3,59$, *on rejette l'hypothèse nulle. On en conclut donc que les meurtrissures de pêche sont liées soit à la hauteur de chute, soit à la masse volumique, soit aux deux.*

TABLE 6.2 – Tableau d'analyse de la variance pour l'exemple 5.1

Source	Degrés de liberté	Sommes des carrés	Carrés moyens	F
Modèle	$ddl_1 = 2$	$136,88$	$136,88/2 = 68,44$	$68,44/2,247 = 30,46$
Erreur résiduelle	$ddl_2 = 17$	$38,21$	$38,21/17 = 2,247$	
Totale	19	$175,09$		

6.6 Test de réduction du modèle

Il est plutôt rare en pratique que le test $\mathcal{F}$ de Fisher global ne rejette pas l'hypothèse H_0 donnée par (6.14) que le modèle de régression est totalement inutile. Cependant, on veut souvent tester si le modèle peut être réduit. Cela revient à tester si un sous-modèle plus simple explique une partie suffisamment grande de la variabilité dans les Y_i pour qu'il ne soit pas nécessaire d'utiliser le modèle plus complexe. Il s'agit donc de mesurer si la différence entre les sommes de carrés résiduels des deux modèles est faible ou élevée.

Cette idée se traduit mathématiquement de la manière suivante. Supposons le modèle de régression multiple standard

$$Y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i.$$

On désire tester si un modèle comprenant seulement $k < p$ variables exogènes suffit à expliquer la variabilité dans les Y_i. Par souci de simplicité, on suppose que les k variables explicatives en question sont $x_1, \ldots, x_k$. Alors on veut tester

$$\begin{aligned} H_0 : \ Y_i &= \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik} + \varepsilon_i \\ H_1 : \ Y_i &= \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik} + \beta_{k+1} x_{i,k+1} + \cdots + \beta_p x_{ip} + \varepsilon_i. \end{aligned} \tag{6.15}$$

Le modèle donné par H_0 est appelé modèle réduit, alors que le modèle présenté en H_1 se nomme modèle complet.

Soit $SC_{res}^{(0)}$ la somme des carrés résiduels obtenue avec le modèle réduit et $SC_{res}^{(1)}$ la somme des carrés résiduels obtenue avec le modèle complet. Alors il est toujours vrai que $SC_{res}^{(1)} \leq SC_{res}^{(0)}$. Cependant, sous H_0, la différence entre $SC_{res}^{(0)}$ et $SC_{res}^{(1)}$ est faible, alors que cette même différence est élevée sous H_1.

On standardise le rapport $(SC_{res}^{(0)} - SC_{res}^{(1)})/SC_{res}^{(1)}$ afin d'obtenir une statistique avec une distribution connue sous H_0. On obtient

$$F = \frac{SC_{res}^{(0)} - SC_{res}^{(1)}}{\Delta_{dl}\widehat{\sigma}^2_{H_1}}, \tag{6.16}$$

où Δ_{dl} note la différence entre les degrés de liberté de $SC_{res}^{(0)}$ et les degrés de liberté de $SC_{res}^{(1)}$. Sous l'hypothèse nulle H_0 donnée par (6.15), la statistique F en (6.16) suit une distribution $\mathcal{F}$ de Fisher avec Δ_{dl} degrés de liberté au numérateur et $n - p'$ degrés de liberté au dénominateur. On rejette donc H_0 au niveau de confiance α lorsque $F \geq F_{\Delta_{dl}, n-p'}(1-\alpha)$.

On note qu'il existe plusieurs manières de calculer Δ_{dl} :

1. $\Delta_{dl} = dl(SC_{res}^{(0)}) - dl(SC_{res}^{(1)})$;
2. Δ_{dl} =(nbr de paramètres du modèle H_1)- (nbr de paramètres du modèle H_0) ;
3. Δ_{dl} = nbr de contraintes sur les paramètres du modèle complet pour arriver au modèle réduit.

Ainsi, dans le cas présenté en (6.15), on aurait

1. $dl(SC_{res}^{(0)}) = n - (k+1) = n - k - 1$
   $dl(SC_{res}^{(1)}) = n - p'$
   Donc, $\Delta_{dl} = n - k - 1 - n + p' = p' - k - 1 = p - k$.
2. Paramètres sous H_1 : $p' = p + 1$
   Paramètres sous H_0 : $k + 1$
   Donc, $\Delta_{dl} = p + 1 - k - 1 = p - k$.
3. Les contraintes pour réduire le modèle H_1 au modèle H_0 sont

$$\beta_{k+1} = 0, \ldots, \beta_p = 0,$$

   c'est-à-dire $p - k$ égalités (contraintes) sur les paramètres du modèle complet afin d'obtenir le modèle réduit. Donc $\Delta_{dl} = p - k$.

6.6.1 Cas particuliers simples

La très grande majorité des tests d'hypothèses que nous aurons à effectuer dans ce cours pourrons être exprimés sous la forme H_0 : modèle réduit contre H_1 : modèle complet. Trois cas particuliers ont des noms spécifiques et méritent d'être étudiés.

Test global de la régression

La statistique F_{obs} de la table 6.1 d'ANOVA constitue en fait un test de réduction de modèle dans lequel le modèle complet contient toutes les variables explicatives disponibles et le modèle réduit s'écrit simplement comme $Y_i = \beta_0 + \varepsilon_i$. Dans ce cas, on peut facilement voir que la statistique F donnée en (6.16) est égale à la statistique F_{obs} de la table d'ANOVA. De plus, on déduit aussi facilement que $\Delta_{dl} = p$.

Tests de F séquentiels

Il s'agit de tests de réduction de modèles séquentiels pour toutes les variables du jeu de données. On commence avec le modèle nul comme modèle simple et on ajoute séquentiellement chaque variable en testant si elle permet de réduire significativement la somme des carrés résiduelle.

On présente souvent les valeurs de F et valeurs de p associées pour les tests de F séquentiels de toutes les variables d'un jeu de données dans un seul tableau. Les résultats dépendront de l'ordre dans lequel on ajoute les variables.

Remarque 10. *Dans certains livres et logiciels on parle dans ce cas de sommes de carrés de type I.*

Tests de F ajustés

On parle de tests de F ajustés quand on teste l'effet de l'ajout de chaque variable, en tenant compte de toutes les autres variables présentes dans le modèle. On dit qu'on ajuste pour toutes les autres variables présentes dans le modèle.

Un test de F ajusté pour la variable j teste donc

$$\begin{aligned} H_0 : Y_i &= \beta_0 + \beta_1 x_{i1} + \cdots + \beta_{j-1} x_{i(j-1)} + \beta_{j+1} x_{i(j+1)} + \beta_k x_{ik} + \varepsilon_i, \\ H_1 : Y_i &= \beta_0 + \beta_1 x_{i1} + \cdots + \beta_{j-1} x_{i(j-1)} + \beta_j x_{ij} + \beta_{j+1} x_{i(j+1)} + \beta_k x_{ik} + \varepsilon_i. \end{aligned}$$

Ici aussi on présente souvent dans un seul tableau les résultats des tests de F ajustés de toutes les variables d'un jeu de données. Puisqu'on ajuste à chaque fois sur toutes les variables disponibles, les résultats ne dépendront pas de l'ordre dans lequel les variables sont testées.

Remarque 11. *On parle parfois dans ce cas de sommes de carrés de type II.*

Remarque 12. *Dans un test de F ajusté pour la variable j, on teste en fait $H_0 : \beta_j = 0$ vs $H_1 : \beta_j \neq 0$. On peut d'ailleurs montrer que ce test est équivalent au test t de l'hypothèse $H_0 : \beta_j = 0$ basé sur la distribution de $\widehat{\beta}$ et mentionné à la section 6.3.*

6.6.2 Point de vue géométrique

On peut également comprendre les tests de réduction de modèle d'un point de vue géométrique. La statistique F du test est alors construite en standardisant les longueurs des vecteurs appropriés en les divisant par la dimension de l'espace dans lesquels ils vivent (leurs degrés de liberté). La figure 6.2 montre toutes les quantités impliquées.

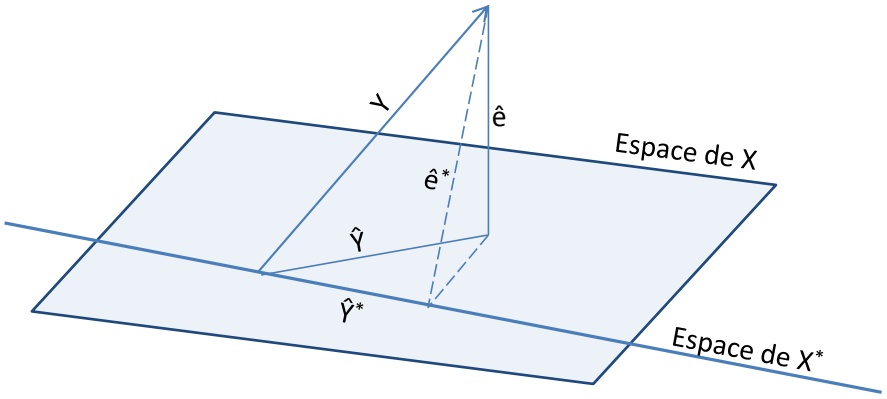


FIGURE 6.2 – Illustration de l'analyse de la variance généralisée

- Le plan Espace de X est l'espace colonne de la matrice d'incidence sous H_1.
- La droite Espace de X^* est l'espace colonne de la matrice d'incidence sous H_0.
- Le vecteur $\widehat{\boldsymbol{Y}}$ est $\boldsymbol{X}\widehat{\boldsymbol{\beta}}$ sous le modèle complet et se situe dans un espace de dimension p'. Ce vecteur constitue la projection orthogonale du vecteur $\boldsymbol{Y}$ sur le plan nommé Espace de X.
- Le vecteur $\boldsymbol{\varepsilon}$ est constitué des résidus sous le modèle complet et vit dans un espace de dimension $n - p'$.
- Le vecteur $\widehat{\boldsymbol{Y}}^*$ représente le vecteur $\mathbf{x}^*\widehat{\boldsymbol{\beta}}$ sous le modèle réduit et évolue dans un espace de dimension $p' - \Delta_{dl}$. Ce vecteur est la projection orthogonale du vecteur $\boldsymbol{Y}$ sur la droite Espace de X.
- Le vecteur $\boldsymbol{\varepsilon}^*$ est formé des résidus sous le modèle réduit et vit dans un espace de dimension $n - p' + \Delta_{dl}$.

Le vecteur égal à la différence entre les vecteurs de résidus des deux modèles est important. Notons C sa longueur. C^2 est donc la différence entre les sommes de carrés résiduels. Ce vecteur vit dans un espace de dimension Δ_{dl}. La statistique du test F du principe de somme de carrés résiduels additionnelle est tout simplement égale à $(C^2/\Delta_{dl})/(B^2/(n-p'))$ où B dénote la longueur du vecteur des résidus sous le modèle complet.

6.7 Test d'une hypothèse linéaire générale

Plusieurs tests en régression linéaire peuvent être exprimés comme une liste de contraintes linéaires sur les valeurs des paramètres. Soit $\boldsymbol{C}$, une matrice de dimension $r \times p'$, et $\boldsymbol{d}$, un vecteur de dimension $r \times 1$. Un test d'hypothèse linéaire générale s'écrit comme

$$\begin{aligned} H_0 : \boldsymbol{C\beta} &= \boldsymbol{d} \\ H_1 : \boldsymbol{C\beta} &\neq \boldsymbol{d}. \end{aligned} \tag{6.17}$$

On peut ré-écrire ce test d'hypothèse sous la forme d'un modèle réduit et d'un modèle complet de la manière suivante :

$$\begin{aligned} H_0 : \boldsymbol{Y} &= \boldsymbol{Z\alpha} + \boldsymbol{\varepsilon} \\ H_1 : \boldsymbol{Y} &= \boldsymbol{X\beta} + \boldsymbol{\varepsilon}, \end{aligned}$$

où l'équation en H_0 est obtenue en (i) résolvant le système d'équations $\boldsymbol{C\beta} = \boldsymbol{d}$ pour β et (ii) en substituant la solution trouvée en (i) dans le modèle $\boldsymbol{Y} = \boldsymbol{X\beta} + \boldsymbol{\varepsilon}$.

Il est possible de montrer (voir par e.g. Sen et Srivastava, 1990, pp. 44–45 et pp. 60–64) que

$$SC_{res}^{(0)} - SC_{res}^{(1)} = (\boldsymbol{C}\widehat{\boldsymbol{\beta}} - \boldsymbol{d})'[\boldsymbol{C}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{C}^\top]^{-1}(\boldsymbol{C}\widehat{\boldsymbol{\beta}} - \boldsymbol{d}).$$

Notez que $\sigma^2[\boldsymbol{C}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{C}^\top]$ est la variance de $\boldsymbol{C}\widehat{\boldsymbol{\beta}} - \boldsymbol{d}$. Donc la différence des sommes de carrés résiduels peut être vue comme la longueur du vecteur qui sépare $\boldsymbol{C}\widehat{\boldsymbol{\beta}}$ et $\boldsymbol{d}$, standardisée par sa variance. Si la distance entre $\boldsymbol{C}\widehat{\boldsymbol{\beta}}$ et $\boldsymbol{d}$ est faible, alors H_0 constitue une hypothèse raisonnable, $SC_{res}^{(0)} - SC_{res}^{(1)}$ prend une petite valeur et on ne rejette donc pas H_0. Si H_0 n'est pas réaliste, alors $\boldsymbol{C}\widehat{\boldsymbol{\beta}}$ sera éloignée de $\boldsymbol{d}$, $SC_{res}^{(0)} - SC_{res}^{(1)}$ prendra une grande valeur et on rejettera l'hypothèse nulle H_0.

On peut maintenant construire la statistique F en utilisant l'équation (6.16) :

$$F = \frac{(\boldsymbol{C}\widehat{\boldsymbol{\beta}} - \boldsymbol{d})^\top[\boldsymbol{C}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{C}^\top]^{-1}(\boldsymbol{C}\widehat{\boldsymbol{\beta}} - \boldsymbol{d})/r}{SC_{res}^{(1)}/(n-p')} = \frac{(\boldsymbol{C}\widehat{\boldsymbol{\beta}} - \boldsymbol{d})^\top[\boldsymbol{C}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{C}^\top]^{-1}(\boldsymbol{C}\widehat{\boldsymbol{\beta}} - \boldsymbol{d})}{r\widehat{\sigma}^2_{H_1}},$$

où r note le nombre de lignes de la matrice $\boldsymbol{C}$. Le fait que $\Delta_{dl} = r$ dans ce cas est facile à comprendre si on utilise la troisième manière de le calculer, soit le nombre de contraintes sur les paramètres du modèle complet pour obtenir le modèle réduit. Sous l'hypothèse H_0, F suit une loi de Fisher $\mathcal{F}_{r,n-p'}$.