Variables catégoriques et interactions avec R

Cette fiche accompagne les notes du chapitre 7. Les noms des objets peuvent être adaptés à vos données. Les exemples utilisent des données incluses dans R ou des données simulées ; aucun fichier externe nest requis.

Choisir le niveau de référence

La fonction factor() traite une variable comme catégorique ; relevel() choisit la référence. Avec les contrastes de traitement habituels, une variable à C catégories produit C-1 colonnes indicatrices en présence d'une constante.

```
donnees <- iris
donnees$Species <- relevel(factor(donnees$Species),
                           ref = "setosa")
mod_add <- lm(Sepal.Length ~ Petal.Length + Species,
              data = donnees)
contrasts(donnees$Species)
head(model.matrix(mod_add))
summary(mod_add)
```

Inclure et tester les interactions

L'opérateur * inclut les deux effets principaux et leur interaction. L'opérateur : inclut uniquement l'interaction. Un coefficient de Species représente ici une différence à Petal.Length=0, profil souvent peu réaliste.

```
mod_int <- lm(Sepal.Length ~ Petal.Length * Species,
              data = donnees)
summary(mod_int)
# Test conjoint des deux interactions : pentes paralleles
anova(mod_add, mod_int, test = "F")
# Utilite globale de Species dans le modele additif
mod_sans <- lm(Sepal.Length ~ Petal.Length, data = donnees)
anova(mod_sans, mod_add, test = "F")
```

Centrer et interpréter les pentes

Le centrage change la référence des coefficients sans changer les ajustements. Choisissez une référence pertinente et examinez le domaine de chaque espèce avant d'interpréter une différence entre groupes.

```
donnees$petale_c <- donnees$Petal.Length - 4
mod_c <- lm(Sepal.Length ~ petale_c * Species,
            data = donnees)
summary(mod_c)
b <- coef(mod_int)
c(setosa = unname(b["Petal.Length"]),
  versicolor = unname(b["Petal.Length"] +
                      b["Petal.Length:Speciesversicolor"]),
  virginica = unname(b["Petal.Length"] +
                     b["Petal.Length:Speciesvirginica"]))
```

Prédire avec les mêmes niveaux

Chaque profil ci-dessous utilise une longueur de pétale plausible pour son espèce. La variable catégorique de newdata doit reprendre les niveaux du modèle ; une catégorie inconnue ne peut être prédite.

```
profils <- data.frame(
  Petal.Length = c(1.5, 4, 5.5),
  Species = factor(c("setosa", "versicolor", "virginica"),
                   levels = levels(donnees$Species)))
predict(mod_int, newdata = profils, interval = "confidence")
```

Aide

Dans R, utilisez `?lm` et laide des fonctions présentées.