Chapitre 7

Variables catégoriques et interactions

Sommaire

7.1 Variables exogènes catégoriques 64

7.1.1 Inférence avec des variables catégoriques 69

7.2 Interactions 69

Figures

7.1 Espérance de la variable endogène Y en fonction de la variable exogène x_2 pour chacun des groupes 1 à 4. 68

7.2 Espérance de la variable endogène Y en fonction de la variable exogène x_2 pour chacune des valeurs de x_{1i}. 70

Une grande différence quand on utilise un modèle de RLM au lieu de la RLS, c'est qu'on peut créer des modèles plus complexes. On verra ici deux façons pour ce faire, soit inclure des variables catégoriques et inclure des interactions.

7.1 Variables exogènes catégoriques

Jusqu'à maintenant, nous n'avons considéré que des variables exogènes continues. Il arrive pourtant souvent en pratique que les variables exogènes ne puissent prendre des valeurs que dans un ensemble de

valeurs possibles, et que ces valeurs n'impliquent pas un ordre entre les mesures. Quelques exemples :

$$x_{1i} = \begin{cases} H, & \text{si } i \text{ est un homme} \\ F, & \text{si } i \text{ est une femme} \end{cases}$$

$$x_{1i} = \begin{cases} 1, & \text{si } i \text{ est une ville} \\ -1, & \text{si } i \text{ est un village} \end{cases}$$

$$x_{1i} = \begin{cases} 1, & \text{si } i \text{ est à ON} \\ 0, & \text{si } i \text{ est à OFF} \end{cases}$$

On peut simplement ajouter une variable catégorique linéairement dans le modèle de RLM. La valeur de cette variable modifiera l'ordonnée à l'origine de la régression. Il faut toutefois faire attention à la façon avec laquelle on code les variables catégoriques pour s'assurer que le modèle soit facile à interpréter.

Variable dichotomique

Dans le cas d'une variable dichotomique, il est toujours plus prudent de coder x_i sous la forme d'une variable indicatrice, c'est-à-dire sous la forme

$$x_i = \begin{cases} 1, & \text{si ...} \\ 0, & \text{sinon} \end{cases}$$

Si ce type de codage n'est pas utilisé, alors les β peuvent être difficiles à interpréter.

Par exemple si

$$x_i = \begin{cases} -5, & \text{si } i \text{ est un homme} \\ 5, & \text{si } i \text{ est une femme} \end{cases}$$

Alors le modèle $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ nous donne

$$\begin{aligned} \mathbb{E}[Y_i | i \text{ est un homme}] &= \beta_0 - 5\beta_1 \\ \mathbb{E}[Y_i | i \text{ est une femme}] &= \beta_0 + 5\beta_1 \end{aligned}$$

On a donc que β_0 est la moyenne des espérances de Y pour les hommes et les femmes, et β_1 représente 0.1 fois la différence entre la valeur moyenne de Y pour les hommes et celle pour les femmes.

Si on prend plutôt

$$x_i = \begin{cases} 1, & \text{si } i \text{ est un homme} \\ 0, & \text{si } i \text{ est une femme} \end{cases}$$

alors on a

$$\begin{aligned} \mathbb{E}[Y_i | i \text{ est un homme}] &= \beta_0 + \beta_1 \\ \mathbb{E}[Y_i | i \text{ est une femme}] &= \beta_0 \end{aligned}$$

et maintenant β_0 est simplement la valeur moyenne de Y pour les femmes et β_1 représente exactement la différence entre la valeur moyenne de Y pour les hommes et celle pour les femmes.

Un autre codage souvent utilisé durant la collecte de données est de la forme

$$x_i = \begin{cases} 1, & \text{si } i \text{ est un homme} \\ 2, & \text{si } i \text{ est une femme} \end{cases}$$

Dans ce cas, β_1 s'interprète de la même façon qu'avec la variable indicatrice, mais β_0 est plus complexe à interpréter.

Variable polytomique

Si x est une variable polytomique, c'est-à-dire que x_i peut prendre une parmi $C \geq 2$ valeurs possibles, la façon prudente de procéder est de définir $C - 1$ variables indicatrices. Ainsi, si

$$x_{1i} = \begin{cases} 1, & \text{si } i \text{ est bleu} \\ 2, & \text{si } i \text{ est rouge} \\ 3, & \text{si } i \text{ est jaune} \\ 4, & \text{si } i \text{ est vert} \end{cases}$$

alors on définit

$$x_{Bi} = \begin{cases} 1, & \text{si } i \text{ est bleu} \\ 0, & \text{sinon} \end{cases} \qquad x_{Ri} = \begin{cases} 1, & \text{si } i \text{ est rouge} \\ 0, & \text{sinon} \end{cases}$$

$$x_{Ji} = \begin{cases} 1, & \text{si } i \text{ est jaune} \\ 0, & \text{sinon} \end{cases}$$

Dans ce cas

$$\begin{aligned} x_{1i} = \text{bleu} &\Rightarrow (x_{Bi}, x_{Ri}, x_{Ji}) = (1,0,0) \\ x_{1i} = \text{rouge} &\Rightarrow (x_{Bi}, x_{Ri}, x_{Ji}) = (0,1,0) \\ x_{1i} = \text{jaune} &\Rightarrow (x_{Bi}, x_{Ri}, x_{Ji}) = (0,0,1) \\ x_{1i} = \text{vert} &\Rightarrow (x_{Bi}, x_{Ri}, x_{Ji}) = (0,0,0) \end{aligned}$$

Ainsi, si $Y_i = \beta_0 + \beta_B x_{Bi} + \beta_R x_{Ri} + \beta_J x_{Ji} + \varepsilon_i$,

$$\begin{aligned} \mathbb{E}[Y_i | i \text{ est bleu}] &= \beta_0 + \beta_B \\ \mathbb{E}[Y_i | i \text{ est rouge}] &= \beta_0 + \beta_R \\ \mathbb{E}[Y_i | i \text{ est jaune}] &= \beta_0 + \beta_J \\ \mathbb{E}[Y_i | i \text{ est vert}] &= \beta_0. \end{aligned}$$

Remarque 13. *Si une variable exogène ne prend que très peu de valeurs différentes, il est important de déterminer s'il s'agit d'une variable continue pour laquelle on a peu de mesures ou s'il s'agit d'une variable polytomique. Selon la façon avec laquelle la variable est incluse dans le modèle, l'interprétation sera différente, ainsi que l'information qu'on pourra retirer du modèle.*

Exemple 7.1. *Soit x_{1i}, le numéro de lot du produit i, x_{2i}, la concentration de sel dans le produit i et Y_i, l'indice de qualité du produit i. Les variables Y_i et x_{2i} sont des variables continues, alors que x_{1i} est un variable polytomique prenant une des valeurs $\{1, 2, 3, 4\}$.*

On ajuste le modèle

$$Y_i = \beta_0 + \beta_{11}x_{11i} + \beta_{12}x_{12i} + \beta_{13}x_{13i} + \beta_2 x_{2i} + \varepsilon_i,$$

où

$$x_{11i} = \begin{cases} 1, & x_{1i} = 1 \\ 0, & x_{1i} \neq 1 \end{cases} \qquad x_{12i} = \begin{cases} 1, & x_{1i} = 2 \\ 0, & x_{1i} \neq 2 \end{cases}$$

$$x_{13i} = \begin{cases} 1, & x_{1i} = 3 \\ 0, & x_{1i} \neq 3. \end{cases}$$

La figure 7.1 illustre graphiquement ce modèle. Notez qu'on suppose dans la figure que tous les coefficients sont positifs, mais ce n'est absolument pas nécessaire en pratique.

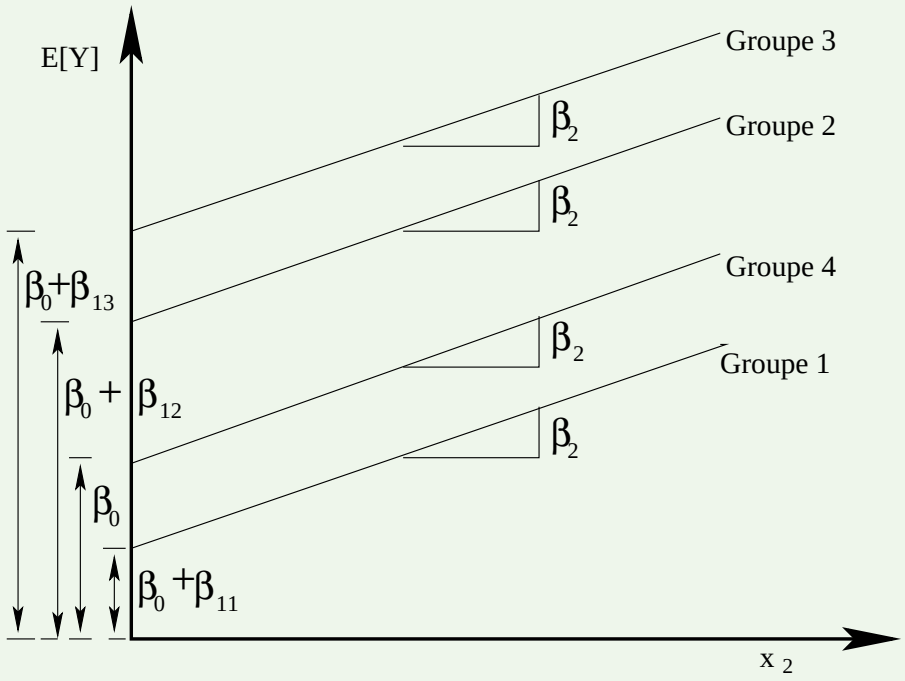


FIGURE 7.1 – Espérance de la variable endogène Y en fonction de la variable exogène x_2 pour chacun des groupes 1 à 4. Comme on peut le voir, les β_0 et β_{1j} déterminent les ordonnées à l'origine, tandis que β_2 détermine la pente des droites de régression.

7.1.1 Inférence avec des variables catégoriques

On peut en général faire de l'inférence sur les coefficients des variables indicatrices exactement comme pour les coefficients des variables continues.

Tester l'utilité globale d'une variable polytomique

Il faut toutefois faire attention si on veut tester si une variable polytomique possède un effet significatif sur la valeur moyenne de la variable endogène. On doit alors tester si plusieurs coefficients sont simultanément égaux à zéro à l'aide d'un test F de réduction de modèle. En général, pour tester si une variable polytomique prenant C valeurs possibles a un effet significatif, il faut tester si $C-1$ coefficients sont simultanément égaux à zéro.

Exemple 7.2. *Supposons que dans le modèle de l'exemple 7.1 on souhaite tester si le groupe d'où provient l'item i a un effet sur la variable dépendante. Il faut alors tester $H_0 : \beta_{11} = \beta_{12} = \beta_{13} = 0$. Notez que ceci revient à tester si la droite de régression est la même pour les 4 groupes, c'est-à-dire que sur la figure 7.1, les 4 lignes sont superposées.*

Tester une hypothèse plus complexe sur les différents niveaux d'une variable

Notons aussi que plusieurs hypothèses intéressantes dans un modèle avec variables polytomiques peuvent être vues comme des hypothèses linéaires sur les β, ce qui nous permet d'utiliser nos résultats de la section 6.7.

Exemple 7.3. *Toujours pour le modèle de l'exemple 7.1, supposons qu'on veut tester que la valeur moyenne de Y_i est la même pour les lots 1 et 3. Ceci revient à tester si $\beta_{11} = \beta_{13}$. On peut donc utiliser un test d'hypothèse linéaire générale avec*

$$\boldsymbol{C} = (0, 1, 0, -1, 0).$$

On pourrait aussi vouloir tester si on peut diviser les lots en deux : les lots 1 et 3 ayant la même moyenne, et les lots 2 et 4 ayant la même moyenne. Ici encore, c'est un test d'hypothèse linéaire générale, mais avec deux contraintes simultanées. La matrice C appropriée est alors :

$$\boldsymbol{C} = \begin{bmatrix} 0 & 1 & 0 & -1 & 0 \\ 0 & 0 & 1 & 0 & 0 \end{bmatrix}.$$

7.2 Interactions

Une interaction entre deux variables exogènes x_{1i} et x_{2i} est un terme de la forme

$$\beta_{12} x_{1i} x_{2i}.$$

On inclut une interaction dans un modèle lorsque l'effet d'une des variables sur la moyenne de Y dépend de la valeur d'une autre variable. En effet, supposons le modèle

$$Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_{12} x_{1i} x_{2i} + \varepsilon_i.$$

On a alors

$$\mathbb{E}[Y_i | x_{1i} + 1] = \beta_0 + \beta_1 (x_{1i} + 1) + \beta_2 x_{2i} + \beta_{12} (x_{1i} + 1) x_{2i} \quad (7.1)$$

$$\mathbb{E}[Y_i | x_{1i}] = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_{12} x_{1i} x_{2i}. \quad (7.2)$$

L'effet d'une augmentation d'une unité de x_{1i} sur $\mathbb{E}[Y_i]$ est $\beta_1 + \beta_{12} x_{2i}$, c'est-à-dire que l'effet d'une augmentation de x_{1i} d'une unité sur $\mathbb{E}[Y_i]$ **dépend de la valeur de** x_{2i}.

Exemple 7.4. *Soit x_{1i} une variable polytomique pouvant prendre les valeurs $\{1, 2, 3\}$ et soient x_{11i} l'indicatrice que $x_{1i} = 1$ et x_{12i} l'indicatrice que $x_{1i} = 2$. Le modèle*

$$Y_i = \beta_0 + \beta_{11} x_{11i} + \beta_{12} x_{12i} + \beta_2 x_{2i} + \beta_{112} x_{11i} x_{2i} + \beta_{122} x_{12i} x_{2i} + \varepsilon_i.$$

est illustré à la figure 7.2.

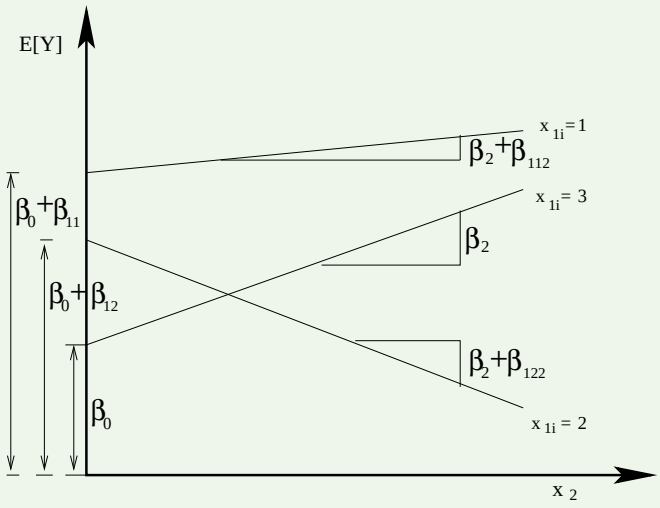


FIGURE 7.2 – Espérance de la variable endogène Y en fonction de la variable exogène x_2 pour chacune des valeurs de x_{1i}.

L'exemple 7.4 illustre une interaction entre une variable catégorique et une variable continue, ce qui s'illustre aisément. On peut également inclure une interaction entre deux variables catégoriques, ce qui crée en quelque sorte une nouvelle variable catégorique avec plus de catégories. Ou entre deux variables continues, ce qui implique une pente de régression pour une première variable qui diffère pour chaque valeur d'une autre variable.

De plus, les termes d'interaction ne sont pas limités à seulement deux variables. En effet, si nous mesurons 4 variables $x_1, \ldots, x_4$ il se pourrait que le modèle approprié soit

$$\begin{aligned} Y_i &= \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_{12} x_{1i} x_{2i} + \beta_{13} x_{1i} x_{3i} \\ &\quad + \beta_{14} x_{1i} x_{4i} + \beta_{23} x_{2i} x_{3i} + \beta_{24} x_{2i} x_{4i} + \beta_{34} x_{3i} x_{4i} \\ &\quad + \beta_{123} x_{1i} x_{2i} x_{3i} + \cdots + \beta_{1234} x_{1i} x_{2i} x_{3i} x_{4i} + \varepsilon_i. \end{aligned}$$

Mais à moins de posséder vraiment beaucoup de données, les interactions impliquant plus de deux variables sont rarement utilisées. Elles sont en outre plus complexes à interpréter.

Test de linéarité

Pour tester si un modèle est adéquat, on peut y ajouter des termes d'interaction et tester si ces termes sont significatifs.

Exemple 7.5. *Soit le modèle*

$$Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \varepsilon_i.$$

Nous pouvons tester si $H_0 : \ \beta_{12} = 0$ *contre* $H_1 : \ \beta_{12} \neq 0$ *à partir du modèle*

$$Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_{12} x_{1i} x_{2i} + \varepsilon_i.$$

Si nous ne rejetons pas H_0*, les données ne fournissent pas de preuve suffisante en faveur de cette interaction ; cela ne démontre pas que le modèle est adéquat. Si nous rejetons* H_0*, alors le modèle sans interaction n'est pas adéquat.*

Remarque 14. *Un cas particulier d'interaction est si on inclut une interaction entre une variable* x_j *et elle-même, ce qui crée un terme de la forme* x_j^2 *dans l'équation de régression. Ce peut être utile si la relation entre les variables est quadratique plutôt que linéaire. On y reviendra à la section 11.1.*