Chapitre 8

Choix de modèle pour la RLM

Sommaire

8.1 Vérification des postulats et transformations 73
8.1.1 Les résidus 73
8.1.2 Vérification de la linéarité 73
8.1.3 Homogénéité des variances 75
8.1.4 Normalité des erreurs 75
8.1.5 Transformation de Box-Cox 75
8.1.6 Indépendance des erreurs 75
8.1.7 Test pour manque d'ajustement (lack-of-fit) 76
8.2 Importance de la sélection de variables 78
8.3 Critères basés sur l'ajustement du modèle 80
8.3.1 Coefficient de détermination 80
8.3.2 Coefficient de détermination ajusté 80
8.3.3 Critère d'information d'Akaike (AIC) 80
8.3.4 Critère BIC ou SBC 81
8.4 Méthodes basées sur la puissance de prévision 81
8.4.1 Utilisation d'un jeu de validation 82
8.4.2 La validation croisée 82
8.4.3 Le C_p de Mallows 83
8.5 Méthodes algorithmiques 85
8.6 Régularisation (ou régression pénalisée) 89
8.6.1 La régression « ridge » 89
8.6.2 Le LASSO 90
8.7 Le cas des variables catégoriques et interactions 93
8.7.1 Sélection de modèle avec variables catégoriques 93
8.7.2 Sélection de modèle en présence d'interactions 93

Figures

8.1 Illustration de la différence entre le LASSO et la régression ridge. 91

Comme pour la RLS, il est important lors du choix de modèle de s'assurer que les postulats sont bien respectés. Une autre difficulté de la RLM est qu'il faut choisir les variables à inclure dans le modèle parmi toutes celles à notre disposition. Nous abordons ces deux étapes dans ce chapitre.

8.1 Vérification des postulats et transformations

L'analyse des résidus pour la RLM est très similaire à celle des résidus pour la RLS. Nous révisons ici brièvement les diagnostics de régression, et introduisons quelques nouvelles procédures.

8.1.1 Les résidus

Comme pour la RLS, le résidu est l'outil de base pour la vérification des postulats. On a déjà vu à la section 6.2.2 que $\widehat{\boldsymbol{\varepsilon}} = \boldsymbol{Y} - \widehat{\boldsymbol{Y}} = (\mathbb{I}_n - \boldsymbol{H})\boldsymbol{Y}$ et que

$$\widehat{\boldsymbol{\varepsilon}} \sim \mathcal{N}_n(0, \sigma^2(\mathbb{I}_n - \boldsymbol{H})).$$

Tout comme pour la RLS, les résidus suivent une loi normale de moyenne $\mathbf{0}$, mais ne sont pas indépendants et n'ont pas des variances homogènes.

Les résidus standardisés et studentisés sont définis exactement comme pour la RLS :

$$r_i = \frac{\hat{\varepsilon}_i}{\sqrt{\hat{\sigma}^2(1-h_{ii})}} \qquad t_i = \frac{\hat{\varepsilon}_i}{\hat{\sigma}_{(i)}\sqrt{1-h_{ii}}}$$

8.1.2 Vérification de la linéarité

On peut utiliser les mêmes graphiques que pour la RLS. On doit notamment observer le graphique de $\widehat{\boldsymbol{\varepsilon}}$ *versus* x_j pour toutes les variables explicatives. On pourra alors identifier la ou les variables pour lesquelles la relation avec Y n'est pas linéaire, et corriger le problème par une transformation appropriée.

Toutefois, **les graphiques à variable ajoutée** sont mieux adaptés au contexte de la régression multiple pour détecter le manque de linéarité. Un graphique à variable ajoutée est un nuage de points de $\widehat{\boldsymbol{\varepsilon}}_{\boldsymbol{Y}|\boldsymbol{X}_{-j}}$ vs $\widehat{\boldsymbol{\varepsilon}}_{x_j|\boldsymbol{X}_{-j}}$. Ici $\widehat{\boldsymbol{\varepsilon}}_{\boldsymbol{Y}|\boldsymbol{X}_{-j}}$ représente le vecteur des résidus obtenu en régressant $\boldsymbol{Y}$ sur toutes les variables exogènes du modèle **excepté** x_j. Il s'agit donc de la partie des Y_i qui n'est pas expliquée par l'ensemble des variables exogènes, sauf la variable d'intérêt. On veut ensuite savoir si ajouter la variable x_j permet d'expliquer davantage les Y_i. On pourrait tout simplement regarder la relation entre x_j et $\widehat{\boldsymbol{\varepsilon}}_{\boldsymbol{Y}|\boldsymbol{X}_{-j}}$, mais puisque x_j peut lui-même être expliqué par les autres variables exogènes, il faut être un peu plus rusé. On utilise donc $\widehat{\boldsymbol{\varepsilon}}_{x_j|\boldsymbol{X}_{-j}}$, soit le vecteur des résidus de la régression avec x_j comme

variable endogène et toutes les variables explicatives sauf x_j comme variables exogènes. On l'obtient en ajustant le modèle suivant :

$$x_{ij} = \delta_0 + \delta_1 x_{i1} + ... + \delta_p x_{ip} + \varepsilon_{i\,[x_j|\boldsymbol{X}_{-j}]}.$$

Plus les résidus de cette régression sont grands, plus x_j ajoute de l'information importante au modèle.

Le nuage de points de $\widehat{\boldsymbol{\varepsilon}}_{\boldsymbol{Y}|\boldsymbol{X}_{-j}}$ vs $\widehat{\boldsymbol{\varepsilon}}_{x_j|\boldsymbol{X}_{-j}}$ tombera dans un des trois cas suivants :

— Si x_j est vraiment une variable qui entre linéairement dans le modèle,
le graphique devrait donner une droite de pente β_j passant par l'origine.

— Si x_j est « inutile »,
le graphique devrait ressembler à un graphique de résidus ordinaires.

— Si x_j est utile mais entre dans le modèle de façon non linéaire,
le graphique devrait avoir l'allure d'une courbe plutôt que d'une droite. On pourra donc détecter le manque de linéarité en x_j de la moyenne de $\boldsymbol{Y}$.

Dans certains cas, il est également possible de tester la linéarité d'un modèle à l'aide d'un test de manque d'ajustement. Nous présentons celui-ci à la section 8.1.7.

8.1.3 Homogénéité des variances

On teste l'homogénéité des variances avec le graphique r_i vs $\hat{Y}_i$ comme pour la RLS. S'il y a un problème, on tentera souvent de le régler en transformant la variable endogène.

Notons également qu'il existe un test formel de l'homogénéité des variances, soit le test de White (1980). La statistique du test de White s'exprime comme suit

$$\chi^2_{\text{White}} = nR^2 \overset{a}{\sim} \chi^2_{p(p+3)/2}$$

où R^2 est le coefficient de détermination (R^2) de la régression de $\hat{\varepsilon}_i^2$ sur toutes les variables explicatives x_j, de même que sur tous les produits croisés entre ces variables, incluant le carré de chacune des variables. On rejette l'hypothèse d'homogénéité des variances au seuil α lorsque $\chi^2_{\text{White}} > \chi^2_{p(p+3)/2;1-\alpha}$.

8.1.4 Normalité des erreurs

Les mêmes outils que pour la RLS peuvent être utilisés pour tester la normalité des erreurs. Quand le postulat de normalité n'est pas rencontré, il peut être souhaitable d'utiliser la technique de transformation de Box-Cox (voir section 8.1.5) pour déterminer la meilleure transformation de la variable endogène.

Il vaut la peine de noter que le test de Shapiro-Wilk est très puissant et que pour de gros échantillons, il rejettera très souvent la normalité. Comme les seuils des tests t de Student et F de Fisher ne sont pas sérieusement affectés si la distribution des résidus est près de la normalité sans l'atteindre exactement, alors il est toujours bon d'accompagner le test de normalité d'un diagramme quantile-quantile pour s'assurer que la non-normalité est vraiment sérieuse.

8.1.5 Transformation de Box-Cox

Pour une réponse strictement positive, on peut considérer la famille

$$g_\lambda(Y) = \begin{cases} (Y^\lambda - 1)/\lambda, & \lambda \neq 0, \\ \log(Y), & \lambda = 0. \end{cases}$$

On choisit une transformation en tenant compte de la vraisemblance avec son jacobien, de l'interprétation et des diagnostics du modèle transformé. Une transformation ne corrige pas automatiquement tous les problèmes. L'inverse de la moyenne prédite sur l'échelle transformée n'est généralement pas la moyenne sur l'échelle originale. Il faut tenir compte de ce biais lorsqu'on souhaite prédire une moyenne sur l'échelle originale.

8.1.6 Indépendance des erreurs

On vérifie l'indépendance des erreurs exactement de la même façon que pour la RLS. Si les données sont chronologiques, on peut utiliser un graphique des résidus versus le temps. Sinon, il faut se fier à la description de la collecte de données.

8.1.7 Test pour manque d'ajustement (lack-of-fit)

Ce test permet de vérifier si le modèle proposé s'ajuste bien aux données. Il constitue un bon complément à l'analyse des résidus. Toutefois, ce test ne peut être utilisé que lorsque nous avons plusieurs observations dont la (les) variable(s) exogène(s) a (ont) exactement la (les) même(s) valeur(s).

Exemple 8.1. *Le tableau 8.1 montre un jeu de données où les observations 2 et 3, 4 et 5 et 7 et 8 ont les mêmes combinaisons de valeurs pour leurs variables exogènes. Un test de manque d'ajustement est donc possible dans ce cas.*

Obs	Y_i	x_1	x_2	Obs	Y_i	x_1	x_2
1	8.74	2	1				
2	7.10	2	0	3	9.85	2	0
4	12.1	5	1	5	13.1	5	1
6	14.1	5	0				
7	18.6	8	1	8	15.0	8	1
9	16.9	8	0				

TABLE 8.1 – Jeu de données pour lequel le test de manque d'ajustement s'applique.

Le test de manque d'ajustement se base sur le fait qu'on peut estimer σ^2 (l'erreur pure) grâce à la variabilité de la variable endogène parmi les observations ayant une même combinaison de variables exogènes. On peut ainsi séparer notre somme de carrés résiduels en une partie due à l'erreur pure et une partie due au manque d'ajustement du modèle. Mathématiquement, on écrira

$$\underbrace{\sum_{k=1}^{m}\sum_{j=1}^{n_k}(Y_{kj}-\hat{Y}_k)^2}_{SC_{res}} = \underbrace{\sum_{k=1}^{m}\sum_{j=1}^{n_k}(Y_{kj}-\overline{Y}_k)^2}_{SC_{pure}} + \underbrace{\sum_{k=1}^{m} n_k(\overline{Y}_k-\hat{Y}_k)^2}_{SC_{ajust.}}.$$

où

- m est le nombre de combinaisons distinctes des valeurs des variables exogènes
- n_k, le nombre d'observations de la k^e combinaison de variables exogènes
- Y_{kj} la j^e observation de la variable endogène pour la k^e combinaison de variables exogènes
- $\overline{Y}_k = \sum_j Y_{kj}/n_k$, la valeur moyenne de la variable endogène pour la k^e combinaison de variables exogènes

Si le modèle de régression est adéquat, alors $\hat{Y}_k$ sera une bonne estimation de la vraie moyenne de Y pour la k^e combinaison de variables exogènes. Dans ce cas, $\overline{Y}_k$ sera proche de la valeur prédite $\hat{Y}_k$ et la $SC_{ajust.}$ sera petite. On compare $SC_{ajust.}$ à SC_{pure} pour tester l'adéquation du modèle.

On teste donc les hypothèses

$H_0 : E(Y_i) = \beta_0 + \beta_1 x_1 + \ldots \beta_p x_p$

$H_1 : E(Y_i) \neq \beta_0 + \beta_1 x_1 + \ldots \beta_p x_p$

On procède alors à une analyse de variance, résumée au tableau 8.2.

	dl	SC	CM	F
Manque d'ajustement	$m - p'$	$SC_{ajust.}$	$\frac{SC_{ajust.}}{m-p'}$	$\frac{SC_{ajust.}/(m-p')}{SC_{pure}/(n-m)}$
Erreur pure	$n - m$	SC_{pure}	$\frac{SC_{pure}}{n-m}$	
Erreur totale	$n - p'$	SC_{res}		

TABLE 8.2 – Table d'ANOVA pour un test de manque d'ajustement

On rejette H_0 si $F \geq F_{m-p',n-m,\,1-\alpha}$. On peut également obtenir une valeur de p en comparant notre statistique F à la distribution $F_{m-p',n-m}$.

Exemple 8.2. *Dans les données de l'exemple 8.1, on a $m = 6$ combinaisons de valeurs différentes pour (x_{1i}, x_{2i}) : $\{(2,1),(2,0),(5,1),(5,0),(8,1),(8,0)\}$.*
On a par exemple $n_2 = 2$ observations avec $(x_{1i}, x_{2i}) = (2,0)$, et $\overline{Y}_2 = 8.475$.
On peut calculer les 5 autres moyennes pour obtenir SC_{pure}.

On ajuste également le modèle $Y_{ij} = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \varepsilon_{ij}$, et on obtient alors $\hat{Y}_1, \ldots, \hat{Y}_6$, ce qui permet de calculer SC_{res} et $SC_{ajust.}$. On trouve :

	dl	*SC*	*CM*	*F*	$Pr > F$
Manque ajustement	*3*	*1.598029*	*0.53267*	*0.1484*	*0.9242*
Erreur pure	*3*	*10.76125*	*3.58708*		
Erreur totale	*6*	*12.3598*	*2.0599*		

Il ne semble pas y avoir de problème de manque d'ajustement dans notre exemple. Bien entendu, avec le très petit nombre de données observé, très peu d'hypothèses peuvent être rejetées !

8.2 Importance de la sélection de variables

Pour la RLM, la vérification des postulats n'est pas le seul élément important dans le choix du modèle. Il faut aussi sélectionner les variables à inclure dans le modèle.

En effet, il se peut que certaines variables dans notre jeu de données de soient pas associées à la variable réponse. En présence d'un grand nombre de variables exogènes, on court deux dangers : enlever une variable qui est utile pour expliquer la variable endogène, et conserver dans le modèle une variable qui n'est pas utile.

Conserver une variable inutile

Si on conserve trop de variables, on va augmenter inutilement la variance des estimations. Par conséquent, certains effets importants risquent d'être jugés non significatifs.

Plus précisément, supposons que le bon modèle soit :

$$Y_i = \beta_0 + \beta_1 x_{1i} + ... + \beta_k x_{ki} + \varepsilon_i. \tag{8.1}$$

Si on ajoute la variable x_{k+1} et qu'on ajuste le modèle :

$$Y_i = \beta_0^* + \beta_1^* x_{1i} + ... + \beta_k^* x_{ki} + \beta_{k+1}^* x_{(k+1)i} + \varepsilon_i \tag{8.2}$$

on obtiendra que

$$\mathbb{V}\text{ar}[\hat{\beta}_j^*] \geq \mathbb{V}\text{ar}[\hat{\beta}_j], \qquad \text{pour } \; j = 1, ..., k.$$

De plus, la prévision faite pour Y en un $\boldsymbol{x}^*$ donné sera moins précise avec le modèle superflu de l'équation (8.2) qu'avec le modèle simple de l'équation (8.1).

Enlever une variable utile

À l'opposé, si on enlève trop de variables, le modèle sera biaisé. Pour illustrer le biais, prenons par exemple les deux modèles suivants exprimés sous forme matricielle :

$$\boldsymbol{Y} = \boldsymbol{X}_1\boldsymbol{\beta}_1 + \boldsymbol{\varepsilon}, \tag{8.3}$$

$$\boldsymbol{Y} = \boldsymbol{X}_1\boldsymbol{\beta}_1 + \boldsymbol{X}_2\boldsymbol{\beta}_2 + \boldsymbol{\varepsilon}, \tag{8.4}$$

où $\boldsymbol{\beta}_1$ comporte $p' = p + 1$ paramètres et $\boldsymbol{\beta}_2$ inclut $m - p'$ paramètres.

Supposons que le bon modèle soit celui de l'équation (8.4) et qu'on choisisse plutôt le modèle de l'équation (8.3), on aura alors

$$\begin{aligned}
\mathbb{E}[\widehat{\boldsymbol{\beta}}_1] &= (\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{X}_1'\mathbb{E}[\boldsymbol{Y}] \\
&= (\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{X}_1'(\boldsymbol{X}_1\boldsymbol{\beta}_1 + \boldsymbol{X}_2\boldsymbol{\beta}_2) \\
&= \boldsymbol{\beta}_1 + (\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{X}_1'\boldsymbol{X}_2\boldsymbol{\beta}_2.
\end{aligned}$$

On a donc que $\widehat{\boldsymbol{\beta}}_1$ est un estimateur biaisé.

Si l'on s'intéresse plutôt à la prévision au point $\boldsymbol{x}^* = \begin{bmatrix} \boldsymbol{x}_1^* \\ \boldsymbol{x}_2^* \end{bmatrix}$, le modèle à p' paramètres nous donnerait

$$\begin{aligned} \widehat{\boldsymbol{Y}}(\boldsymbol{x}_1^*) &= \boldsymbol{x}_1^{*'}\widehat{\boldsymbol{\beta}}_1 \\ \mathbb{E}[\widehat{\boldsymbol{Y}}(\boldsymbol{x}_1^*)] &= \boldsymbol{x}_1^{*'}\mathbb{E}[\widehat{\boldsymbol{\beta}}_1] \\ &= \boldsymbol{x}_1^{*'}\{\boldsymbol{\beta}_1 + (\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{X}_1'\boldsymbol{X}_2\boldsymbol{\beta}_2\} \end{aligned}$$

alors que le modèle à m paramètres conduirait à

$$\begin{aligned} \widehat{\boldsymbol{Y}}(\boldsymbol{x}^*) &= \boldsymbol{x}_1^{*'}\widehat{\boldsymbol{\beta}}_1^* + \boldsymbol{x}_2^{*'}\widehat{\boldsymbol{\beta}}_2^* \\ \mathbb{E}[\widehat{\boldsymbol{Y}}(\boldsymbol{x}^*)] &= \boldsymbol{x}_1^{*'}\boldsymbol{\beta}_1 + \boldsymbol{x}_2^{*'}\boldsymbol{\beta}_2. \end{aligned}$$

Le biais dans la prévision serait donc

$$\begin{aligned} \text{biais}[\widehat{\boldsymbol{Y}}(\boldsymbol{x}^*)] &= \mathbb{E}[\widehat{\boldsymbol{Y}}(\boldsymbol{x}_1^*)] - \mathbb{E}[\widehat{\boldsymbol{Y}}(\boldsymbol{x}^*)] \\ &= \boldsymbol{x}_1^{*'}\{\boldsymbol{\beta}_1 + (\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{X}_1'\boldsymbol{X}_2\boldsymbol{\beta}_2\} - \boldsymbol{x}_1^{*'}\boldsymbol{\beta}_1 - \boldsymbol{x}_2^{*'}\boldsymbol{\beta}_2 \\ &= [\boldsymbol{x}_1^{*'}(\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{X}_1'\boldsymbol{X}_2 - \boldsymbol{x}_2^{*'}]\boldsymbol{\beta}_2. \end{aligned}$$

En somme

En résumé, un trop grand nombre de variables mène à une variance trop grande et un trop petit nombre de variables conduit à une estimation biaisée. Il est donc important de chercher un ensemble de variables permettant d'atteindre un compromis entre ces deux critères. Pour ce faire, on a souvent recours à l'une des techniques de sélection de variables pour choisir un sous-ensemble raisonnable de variables.

8.3 Critères basés sur l'ajustement du modèle

Pour sélectionner les bonnes variables dans le modèle, plusieurs techniques sont disponibles. Voyons d'abord quelques critères basés sur l'ajustement du modèle.

8.3.1 Coefficient de détermination

Comme pour la RLS, le coefficient de détermination est défini comme

$$R^2 = \frac{SC_{reg}}{SC_{tot}} = 1 - \frac{SC_{res}}{SC_{tot}}. \tag{8.5}$$

C'est une mesure d'ajustement du modèle facile à calculer et à interpréter, mais il est problématique pour la RLM puisque sa valeur ne peut jamais diminuer si on ajoute une variable dans le modèle, même si celle-ci est inutile.

En effet, si on ajoute un terme à un modèle de régression, SC_{reg} ne peut pas diminuer. Comme SC_{tot} ne dépend pas du modèle, elle reste inchangée. Donc l'ajout d'un terme au modèle se traduit forcément par un R^2 plus grand. L'ajout de termes superflus réduit en général la précision dans les prévisions, ce qu'on souhaite éviter. Le coefficient de détermination n'est donc pas utile pour la RLM.

8.3.2 Coefficient de détermination ajusté

Il s'agit d'un coefficient de détermination qui pénalise pour l'ajout d'un trop grand nombre de variables. Plus précisément, il est défini comme :

$$R_a^2 = 1 - \frac{CM_{res}}{CM_{tot}} = 1 - \frac{SC_{res}/(n-p')}{SC_{tot}/(n-1)} = 1 - \frac{(n-1)\hat{\sigma}^2}{SC_{tot}}. \tag{8.6}$$

Avec R_a^2, l'ajout d'une variable exogène peut aussi résulter en une diminution de la statistique. Comme on peut le voir dans la dernière égalité de l'équation (8.6), comparer deux modèles sur la base de leur R_a^2 est équivalent à comparer deux modèles sur la base de leur estimation de la variance des termes d'erreur $\hat{\sigma}^2$, puisque SC_{tot} et n ne dépendent pas du modèle choisi.

Notez que peu importe si on utilise R^2 ou R_a^2, on ne peut pas vraiment se fier sur ces statistiques pour comparer des modèles employant des transformations différentes de la variable endogène, ou un modèle avec et un modèle sans ordonnée à l'origine.

8.3.3 Critère d'information d'Akaike (AIC)

Le critère d'information d'Akaike a été proposé par Hirotsugu Akaike (1974), un statisticien japonais. Ce critère est assez utilisé dans la pratique et permet d'évaluer la qualité de l'ajustement d'un modèle. Il est défini de plusieurs façons dans la littérature, mais il est toujours basé sur la log-vraisemblance

maximisée :

$$\begin{aligned} -2\ln L(\widehat{\boldsymbol{\beta}}, \hat{\sigma}^2_{\mathsf{ML}}) &= \sum_{i=1}^{n} \frac{(Y_i - \hat{Y}_i)^2}{\hat{\sigma}^2_{\mathsf{ML}}} + n\ln(2\pi\hat{\sigma}^2_{\mathsf{ML}}) \\ &= n + n\ln(2\pi\hat{\sigma}^2_{\mathsf{ML}}) \\ &= n + n\ln(2\pi) + n\ln(SC_{res}/n), \end{aligned}$$

car $\hat{\sigma}^2_{\mathsf{ML}} = \sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2/n = SC_{res}/n$.

Les différentes définitions du AIC varient par une constante additive dépendant de n. Puisque tous les modèles sont basés sur les mêmes observations (donc le même n), on sélectionnera les mêmes variables avec n'importe laquelle de ces versions :

Critère	Procédure SAS	Fonction R
$AIC_1 = n\ln(SC_{res}/n) + 2p'$	REG	`extractAIC, stepAIC`
$AIC_2 = n\ln(SC_{res}/n) + 2p' + n + 2$	GLMSELECT	
$AIC_3 = n\ln(SC_{res}/n) + 2(p'+1) + n + n\ln(2\pi)$		`AIC`

L'AIC prend en compte à la fois la qualité des prédictions du modèle et sa complexité. En effet, un modèle qui s'ajuste bien sur les observations est associé à une faible valeur de SC_{res} et donc à une faible valeur de $n\ln(SC_{res}/n)$. La complexité du modèle est prise en compte en ajoutant le double du nombre de paramètres ($2p'$) à cette dernière quantité. Un bon modèle est donc associé à une faible valeur d'AIC.

8.3.4 Critère BIC ou SBC

Le BIC, pour Bayesian Information Criterion, souvent appelé SBC pour Schwarz Bayesian Criterion, est un critère semblable à l'AIC. Il est aussi défini de différentes façons :

Critère	Procédure SAS	Fonction R
$BIC_1 = n\ln(SC_{res}/n) + \ln(n)p'$	REG	`extractAIC(...,k=log(n))`
	GLMSELECT	`stepAIC(...,k=log(n))`
$BIC_2 = n\ln(SC_{res}/n) + \ln(n)(p'+1) + n + n\ln(2\pi)$		`BIC`
		`AIC(...,k=log(n))`

La seule différence avec l'AIC est que la pénalité pour le nombre de variables grandit avec le nombre d'observations. En général, la pénalité du BIC sera supérieure à celle de l'AIC. Le BIC tend donc à sélectionner des modèles moins complexes que l'AIC.

8.4 Méthodes basées sur la puissance de prévision

Si on se préoccupe beaucoup de la capacité prédictive de notre modèle, on peut utiliser certains critères qui mesurent directement la prévision du modèle plutôt que son ajustement. On pourrait simple-

ment regarder la taille des résidus du modèle puisqu'un meilleur modèle devrait mener à de plus petits résidus. Toutefois, on risque de sous-estimer l'erreur de prévision du modèle puisqu'on triche en quelque sorte en testant la prévision de notre modèle sur les données qui ont été utilisées pour l'estimer. On présente ici quelques alternatives.

8.4.1 Utilisation d'un jeu de validation

Une méthode simple et efficace pour mesurer la capacité de prévision d'un modèle est de séparer notre jeu de données en deux au tout début de l'analyse. Avec la première partie, nommée jeu de données d'entraînement, on estime les paramètres du modèle. On prédit ensuite la valeur de la variable dépendante pour les observations dans la deuxième partie du jeu de données, appelé jeu de validation. On choisit le modèle pour lequel l'erreur quadratique moyenne de prévision, soit la moyenne des carrés des erreurs sur le jeu de validation, est la plus petite.

L'avantage ici est que puisque les observations du jeu de validation n'ont pas été utilisées pour estimer les paramètres du modèle, on a une meilleure estimation de l'erreur de prévision réelle. Toutefois, cela fait moins d'observations pour ajuster le modèle, et donc des estimations moins précises. L'utilisation d'un jeu de validation est donc en général limité aux situations où la taille du jeu de données originale est très grande.

8.4.2 La validation croisée

Si notre jeu de données n'est pas assez grand pour utiliser un jeu de validation, on peut avoir recours à la validation croisée. L'idée est la même que pour le jeu de validation, soit de tester le modèle sur des données qui n'ont pas été utilisées pour l'ajuster, mais ici les données font tour à tour partie du jeu de données d'entraînement et du jeu de données de validation. L'algorithme est le suivant :

1. Diviser les données en k échantillons.
2. Ajuster un modèle sur $k-1$ des échantillons et l'utiliser pour prédire les valeurs dans le dernier échantillon. Calculer l'erreur quadratique moyenne.
3. Répéter k fois l'étape 2 avec un échantillon différent pour le test à chaque fois.
4. Calculer la moyenne des k erreurs quadratiques moyennes.

Cet algorithme permet de bien estimer l'erreur de prévision du modèle pour un choix approprié de k, mais peut être assez demandant en temps de calcul.

Critère PRESS

Une alternative efficace pour la RLM consiste à utiliser la validation croisée avec $k = n$ échantillons de validation, c'est-à-dire à enlever chacune des observations une à une du jeu d'entraînement.

Soit $\hat{Y}_{i,-i}$ la prévision pour l'observation i obtenue à l'aide d'un modèle de régression estimé sans l'observation i. On définit alors le i^e résidu $PRESS$ (pour PREdiction Sum of Squares) comme étant

$$\hat{\varepsilon}_{i,-i} = Y_i - \hat{Y}_{i,-i}.$$

À première vue, cela semble allonger le temps de calcul, mais il est en fait possible de calculer l'erreur quadratique moyenne de façon analytique dans ce cas.

Théorème 3. *Le i^e résidu $PRESS$ peut être obtenu à l'aide du i^e résidu ordinaire et de l'élément en position i, i de la matrice chapeau grâce à la relation*

$$\hat{\varepsilon}_{i,-i} = \frac{\hat{\varepsilon}_i}{1 - h_{ii}}.$$

Pour comparer des modèles, on peut donc calculer le critère

$$PRESS = \sum_{i=1}^{n} \hat{\varepsilon}_{i,-i}^2 = \sum_{i=1}^{n} (Y_i - \hat{Y}_{i,-i})^2 = \sum_{i=1}^{n} \left(\frac{\hat{\varepsilon}_i}{1 - h_{ii}} \right)^2.$$

Le critère $PRESS$ permet de comparer entre eux tous les modèles utilisant la même transformation pour la variable endogène. Évidemment, plus le critère $PRESS$ est faible, plus le modèle prédit bien.

Le critère $PRESS$ peut aussi servir à définir un *coefficient de détermination de prévision* de la manière suivante :

$$R_p^2 = 1 - \frac{PRESS}{SC_{tot}} = 1 - \frac{\sum_{i=1}^{n} (Y_i - \hat{Y}_{i,-i})^2}{\sum_{i=1}^{n} (Y_i - \overline{Y})^2}. \tag{8.7}$$

Encore une fois, une valeur de R_p^2 approchant 1 est signe d'un modèle qui prédit bien, tandis qu'une valeur approchant 0 indique un modèle qui prédit mal.

Remarque 15. *Il est bon d'examiner également chaque résidu $PRESS$ de façon individuelle. En effet, un modèle précis dont une seule des prévisions est mauvaise pourrait être indûment pénalisé par la somme $PRESS$.*

8.4.3 Le C_p de Mallows

Il existe également un autre critère de comparaison de modèle basé sur la prévision du modèle, soit le C_p de Mallows. Il est maintenant peu utilisé en pratique, mais nous le décrivons tout de même ici car il s'agit d'un critère classique de sélection de modèle.

Idée

On a vu précédemment qu'un trop grand nombre de variables cause un problème de variance et qu'un nombre insuffisant de variables induit un problème de biais. Un compromis serait de tenter de minimiser

l'erreur quadratique moyenne (EQM) de prévision d'un modèle à p variables lorsque m variables sont disponibles.

$$\begin{aligned}\mathsf{EQM}[\hat{Y}(\boldsymbol{x}^*)] &= \mathbb{V}\mathsf{ar}[\hat{Y}(\boldsymbol{x}^*)] + \mathsf{biais}^2[\hat{Y}(\boldsymbol{x}^*)] \\ &= \sigma^2 \boldsymbol{x}_{\boldsymbol{1}}^{*\prime}(\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{x}_{\boldsymbol{1}}^* + \left\{[\boldsymbol{x}_{\boldsymbol{1}}^{*\prime}(\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{X}_1'\boldsymbol{X}_2 - \boldsymbol{x}_{\boldsymbol{2}}^{*\prime}]\boldsymbol{\beta}_2\right\}^2\end{aligned}$$

Pour minimiser l'EQM, on fait face à deux difficultés : premièrement, on ne sait pas quel $\boldsymbol{x}^*$ choisir ; deuxièmement, l'EQM dépend de $\boldsymbol{\beta}_2$, que l'on ne connaît pas. Mallows a donc proposé un autre critère, qui permet de régler le premier problème : on minimise

$$\sum_{i=1}^{n} \frac{\mathsf{EQM}[\hat{Y}(x_i)]}{\sigma^2}.$$

La division par σ^2 permettra une simplification commode.

Calcul de la portion variance de l'EQM

$$\begin{aligned}\sum_{i=1}^{n} \frac{\mathbb{V}\mathsf{ar}[\hat{Y}(\boldsymbol{x}_i)]}{\sigma^2} &= \sum_{i=1}^{n} \frac{\boldsymbol{x}_{1i}'\mathbb{V}\mathsf{ar}[\widehat{\boldsymbol{\beta}}_1]\boldsymbol{x}_{1i}}{\sigma^2} \\ &= \sum_{i=1}^{n} \boldsymbol{x}_{1i}'(\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{x}_{1i} \\ &= \sum_{i=1}^{n} \mathsf{tr}[\boldsymbol{x}_{1i}'(\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{x}_{1i}] \\ &= \sum_{i=1}^{n} \mathsf{tr}[\boldsymbol{x}_{1i}\boldsymbol{x}_{1i}'(\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}] \\ &= \mathsf{tr}\left[(\sum_{i=1}^{n} \boldsymbol{x}_{1i}\boldsymbol{x}_{1i}')(\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\right] \\ &= \mathsf{tr}\left[(\boldsymbol{X}_1'\boldsymbol{X}_1)(\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\right] \\ &= \mathsf{tr}(I_p') = p'\end{aligned}$$

Dans le développement ci-dessus, nous avons utilisé le fait que la trace d'un nombre réel est le nombre lui-même et que $\mathsf{tr}(AB) = \mathsf{tr}(BA)$.

Calcul de la portion biais de l'EQM La portion biais peut être estimée facilement une fois que l'on réalise que

$$\mathbb{E}[\hat{\sigma}_p^2] = \sigma^2 + \frac{\sum_{i=1}^{n} \mathsf{biais}[\hat{Y}(x_i)]^2}{n - p'}$$

où $\hat{\sigma}_p^2$ est la variance calculée dans le modèle à p variables. Si σ^2 était connu, on pourrait estimer $\sum_{i=1}^{n} \mathsf{biais}[\hat{Y}(x_i)]^2$ par $(\hat{\sigma}_p^2 - \sigma^2)(n - p')$. Puisque σ^2 est inconnu, on l'estime par $\hat{\sigma}_{toutes}^2$, la variance

calculée dans le modèle incluant toutes les variables disponibles. Le critère proposé par Mallows est donc le suivant :

$$C_p \quad = \quad p' + \frac{(\hat{\sigma}_p^2 - \hat{\sigma}_{toutes}^2)(n-p')}{\hat{\sigma^2}_{toutes}}.$$

En pratique, un modèle pour lequel $C_p \approx p'$ (ou $C_p - p' \approx 0$) est un bon modèle. Une façon simple de choisir un modèle lorsque k variables exogènes sont disponibles est de calculer le C_p des 2^{k+1} modèles possibles et de prendre celui pour lequel $C_p - p'$ est le plus faible. Mais en général, on utilise C_p pour cerner un petit ensemble de modèles raisonnables, et ensuite on utilise d'autres critères ($PRESS$, R_a^2, etc.) pour départager ces modèles. On peut réécrire le C_p de la façon suivante, où SC_{res} est associée au modèle à p variables :

$$C_p \quad = \quad \frac{SC_{res}}{\hat{\sigma^2}_{toutes}} + 2p' - n$$

8.5 Méthodes algorithmiques

On a beau avoir des critères pour comparer les modèles 2 à 2, encore faut-il savoir quels modèles comparer. En effet, le nombre de modèles possibles à comparer augmente très rapidement avec le nombre de variables et si p est grand il peut être impossible de tester tous les modèles possibles. Certaines méthodes algorithmiques ont été proposées pour tenter de trouver le meilleur modèle par une série d'optimisations.

L'utilisation de ces méthodes est toutefois de moins en moins conseillée, pour plusieurs raisons

- Il n'y a aucune garantie de trouver le modèle optimal. Le modèle final est un peu trop adapté à l'échantillon.
- Les procédures sont difficiles à appliquer en présence d'interactions.
- L'inférence à partir du modèle final n'est pas exacte. Les valeurs p sont sous-estimées, car on fait de l'inférence conditionnelle et de multiples tests non indépendants.
- Les données dictent la théorie, alors qu'on voudrait confronter la théorie à des données.

Nous décrivons toutefois les 3 méthodes algorithmiques les plus connues. :

— **Méthode d'inclusion** : on entre les variables une à une tant qu'elles sont significatives.

— **Méthode d'exclusion** : on entre toutes les variables, puis on les retire une à une tant qu'il reste des coefficients non significatifs.

— **Méthode pas-à-pas** : On entre une variable, puis à chaque étape on vérifie s'il est justifié d'ajouter ou de retirer une variable.

À chaque étape de ces méthodes, il faut choisir un critère objectif qui déterminera s'il est utile d'entrer ou de retirer une variable du modèle. Ce peut être un seuil de test si on procède par statistique de Fisher, ou encore un des critères d'ajustement de modèle vus précédemment.

Méthode d'inclusion (*forward*)

1. Commencer avec $Y_i = \beta_0 + \varepsilon_i$.
2. Identifier la variable j qui améliore le plus le modèle d'après le critère de sélection.
3. Si elle est significative (ou si le critère est amélioré), ajouter cette variable au modèle : $Y_i = \beta_0 + \beta_j X_{ij} + \varepsilon_i$
4. Répéter les étapes 2 et 3 jusqu'à qu'aucune variable n'améliore le modèle.

On peut utiliser tout critère de notre choix : R^2_a, $PRESS$, C_p, AIC, BIC ou test F de réduction de modèle (puisqu'on compare des modèles emboîtés).

Méthode d'exclusion (*backward*)

1. Commencer avec le modèle complet (toutes les variables).
2. Identifier, si elle existe, la variable j qui améliore le plus le modèle si on l'enlève (ou qui apporte un gain non significatif une fois les autres prises en compte)
3. Enlever cette variable du modèle.
4. Répéter les étapes 2 et 3 jusqu'à ce qu'aucune variable ne puisse être enlevée pour améliorer le modèle.

Méthode pas à pas (*stepwise*)

Cette méthode combine les deux premières.

1. Commencer avec uniquement l'ordonnée à l'origine : $Y_i = \beta_0 + \varepsilon_i$.
2. Faire un pas avec la méthode d'inclusion.
3. Faire un pas avec la méthode d'exclusion.
4. Répéter les étapes 2 et 3 jusqu'à ce qu'aucune variable ne puisse être enlevée ou ajoutée pour améliorer le modèle.

On peut spécifier des seuils différents pour l'inclusion et l'exclusion des variables.

Exemple 8.3. *Prenons un cas avec trois variables et $n = 10$ observations pour illustrer les méthodes de sélection de variables dites algorithmiques (inclusion, exclusion et pas à pas). On utilisera ici le test F de réduction de modèle comme critère d'inclusion et d'exclusion, à l'aide de l'information dans le tableau ci-dessous.*

Variables du modèle	SC_{res}
aucune	*30*
x_1	*25*
x_2	*24*
x_3	*20*
x_1, x_2	*6*
x_1, x_3	*15*
x_2, x_3	*12*
x_1, x_2, x_3	*4*

- *Si on procède par inclusion, avec un seuil d'entrée de $\alpha_E = 0,25$:*

1. *On commence avec la variable x_3 (la plus importante baisse de SC_{res}). On compare le modèle nul et (x_3) avec un test F. On obtient $F = \frac{30-20}{20/(10-2)} = 4 > F_{0,25;1;8} = 1,54$ donc on inclut la variable x_3.*
2. *On essaie ensuite d'inclure la variable x_2 (la plus importante baisse de SC_{res} une fois que x_3 est prise en compte). On compare les modèles (x_3) et (x_2, x_3). On obtient $F = \frac{20-12}{12/(10-3)} = 4,67 > F_{0,25;1;7} = 1,57$ donc on inclut la variable x_2.*
3. *Enfin on essaie la variable x_1. On compare les modèles (x_2, x_3) et (x_1, x_2, x_3). On obtient $F = \frac{12-4}{4/(10-4)} = 12 > F_{0,25;1;6} = 1,62$ donc on inclut la variable x_1.*

Le modèle final avec la méthode d'inclusion est $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \varepsilon$.

- *Si on procède par exclusion, avec un seuil de sortie de $\alpha_S = 0,10$:*

1. *On retire x_3 (son retrait cause la plus petite hausse de SC_{res}) et on compare les modèles (x_1, x_2) et (x_1, x_2, x_3). On obtient $F = \frac{6-4}{4/(10-4)} = 3 < F_{0,10;1;6} = 3,78$. On rejette la variable x_3 du modèle.*
2. *On retire x_1 et on compare les modèles (x_1, x_2) et (x_2). On obtient $F = \frac{24-6}{6/(10-3)} = 21 > F_{0,10;1;7} = 3,58$. On ne rejette pas la variable x_1.*

Le modèle final avec la méthode d'exclusion est $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$.

• *Si on utilise la méthode pas à pas avec* $\alpha_E = 0,25$ *et* $\alpha_S = 0,10$*, on vérifie à chaque étape si une des variables peut entrer, puis si une des variables doit sortir :*

1. • *La meilleure candidate pour entrer est la variable* x_3*. Comme dans la méthode d'inclusion, on obtient* $F = \frac{30-20}{20/(10-2)} = 4 > F_{0,25;1;8} = 1,54$ *donc on inclut la variable* x_3*.*

   • *Comme* x_3 *est la seule dans le modèle, c'est la seule candidate pour sortir. Puisque* $F = 4 > F_{0.10,1,8} = 3,46$*, on la garde dans le modèle.*

   Le modèle à cette étape est $Y = \beta_0 + \beta_3\, x_3 + \varepsilon$*.*

2. • *La meilleure candidate pour entrer est la variable* x_2*. On compare les modèles* (x_3) *et* $(x_2,\, x_3)$*. On obtient* $F = \frac{20-12}{12/(10-3)} = 4,67 > F_{0,25;1;7} = 1,57$ *donc on inclut la variable* x_2*.*

   • *On vérifie si* x_2 *et* x_3 *sont toujours pertinentes avec l'arrivée de* x_2*. Comme retirer* x_2 *mène au* SC_{res} *le plus bas, on compare les modèles* (x_3) *et* $(x_2,\, x_3)$ *au seuil de 10%. Puisque* $F = 4,67 > F_{0,10;1;7} = 3,58$ *, on garde* x_2 *dans le modèle.*

   Le modèle à cette étape est $Y = \beta_0 + \beta_2\, x_2 + \beta_3\, x_3 + \varepsilon$*.*

3. • *Enfin on essaie la variable* x_1*. On compare les modèles* $(x_2,\, x_3)$ *et* $(x_1,\, x_2,\, x_3)$*. On obtient* $F = \frac{12-4}{4/(10-4)} = 12 > F_{0,25;1;6} = 1,62$ *donc on inclut la variable* x_1*.*

   • *On vérifie si les 3 variables sont toujours pertinentes individuellement. Comme retirer* x_3 *mène au* SC_{res} *le plus bas à deux variables, on compare les modèles* $(x_1,\, x_2)$ *et* $(x_1,\, x_2,\, x_3)$ *au seuil de 10%.* $F = \frac{6-4}{4/(10-4)} = 3 < F_{0,10;1;6} = 3,78$*. On rejette la variable* x_3 *du modèle.*

Le modèle final avec la méthode pas à pas est $Y = \beta_0 + \beta_1\, x_1 + \beta_2\, x_2 + \varepsilon$*.*

8.6 Régularisation (ou régression pénalisée)

La régularisation est une technique statistique très générale qui fait référence au fait d'ajouter une pénalité à un modèle pour pénaliser les modèles trop complexes et éviter le sur-ajustement, particulièrement en présence d'un grand nombre de variables explicatives. La méthode de régularisation qui nous intéresse dans cette section est le LASSO, qui peut être utilisé pour la sélection de variables. Nous présentons d'abord la régression ridge, qui est une méthode de régularisation voisine du LASSO. On introduit un biais dans les estimateurs dans le but de diminuer la variance des prédictions.

8.6.1 La régression « ridge »

La régression ridge fut très populaire dans les années 1970-80. Elle consiste à estimer les paramètres de régression en ajoutant une petite constante $k > 0$ à la diagonale de la matrice $\boldsymbol{X}'\boldsymbol{X}$ avant de calculer son inverse. Dans les formules suivantes, les prédicteurs sont centrés et réduits, la réponse est centrée, et $\boldsymbol{X}$ ne contient pas de colonne de 1. La constante est récupérée séparément et n'est pas pénalisée. On obtient alors

$$\begin{aligned}
\widehat{\boldsymbol{\beta}}(k) &= (\boldsymbol{X}'\boldsymbol{X} + k\mathbb{I})^{-1}\boldsymbol{X}'\boldsymbol{Y} \\
&= \{(\boldsymbol{X}'\boldsymbol{X})\left[\mathbb{I} + k(\boldsymbol{X}'\boldsymbol{X})^{-1}\right]\}^{-1}\boldsymbol{X}'\boldsymbol{Y} \\
&= \{\mathbb{I} + k(\boldsymbol{X}'\boldsymbol{X})^{-1}\}^{-1}(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{Y} \\
&= \{\mathbb{I} + k(\boldsymbol{X}'\boldsymbol{X})^{-1}\}^{-1}\widehat{\boldsymbol{\beta}}.
\end{aligned}$$

L'estimateur $\widehat{\boldsymbol{\beta}}(k)$ est un estimateur biaisé pour β, ce qui peut sembler problématique. L'intérêt de l'estimateur réside dans sa variance, qui est donnée par

$$\mathbb{V}\text{ar}[\widehat{\boldsymbol{\beta}}(k)] = (\boldsymbol{X}'\boldsymbol{X} + k\mathbb{I})^{-1}(\boldsymbol{X}'\boldsymbol{X})(\boldsymbol{X}'\boldsymbol{X} + k\mathbb{I})^{-1}\sigma^2.$$

Dans certains cas, $\widehat{\boldsymbol{\beta}}(k)$ a une variance largement inférieure à celle de $\widehat{\boldsymbol{\beta}}$, ce qui compense le gain en biais en terme d'erreur quadratique moyenne. On peut d'ailleurs choisir k dans le but de minimiser cette erreur quadratique moyenne.

La régression ridge peut être utile en particulier en présence de multicolinéarité (voir la section 9.3) ou lorsque $p > n$.

Il est dur d'interpréter la valeur de k dans l'estimateur ridge, mais elle est reliée à une contrainte fixée sur la longueur du vecteur $\widehat{\boldsymbol{\beta}}(k)$, i.e. sur $\widehat{\boldsymbol{\beta}}(k)'\widehat{\boldsymbol{\beta}}(k)$. Une formulation équivalente de l'estimateur met en évidence cette interprétation.

Formulation équivalente

On peut voir la régression ridge autrement. Elle est équivalente à ajuster une régression linéaire normale mais en ajoutant une pénalité à la somme des carrés. On minimise ainsi

$$Q_{Ridge}(\beta) = \sum_{i=1}^{n}(Y_i - (\beta_1 x_{i1} + ... + \beta_p x_{ip}))^2 + \lambda \sum_{j=1}^{p} \beta_j^2$$

Nous n'irons pas dans ces détails ici, mais notez qu'on peut écrire le k de la formulation précédente en fonction du λ de cette formulation.

En comparaison avec la méthode des moindres carrés originale, cette pénalité force les coefficients estimés à être plus proches de 0 qu'avec le critère des moindres carrés. L'estimateur est toutefois une fonction de λ, qu'on doit choisir. On choisit en général λ à l'aide d'un estimateur du risque de prévision, par exemple la validation croisée.

L'idée d'ajouter une pénalité au critère des moindres carrés pour faire un compromis entre le biais et la variance de l'estimateur est plus générale que la simple régression ridge. En particulier, différentes pénalités peuvent être utilisées pour régulariser. La méthode LASSO utilise une pénalité particulièrement utile pour la sélection de variables.

8.6.2 Le LASSO

Le LASSO (*Least Absolute Shrinkage and Selection Operator*) a été proposé par Tibshirani en 1995. On minimise dans ce cas

$$Q_{Lasso}(\beta) = \sum_{i=1}^{n}(Y_i - (\beta_1 x_{i1} + ... + \beta_p x_{ip}))^2 + \lambda \sum_{i=1}^{p} |\beta_j|$$

Notez que la seule différence avec la régression ridge est qu'on somme les valeurs absolues des coefficients estimés dans la pénalité, et non les carrés de ces mêmes coefficients. L'avantage du LASSO est que cette pénalité ne fait pas que biaiser les estimations vers 0, elle force certains coefficients à valoir exactement 0. On a donc directement une sélection de modèle ! La figure 8.1 illustre pourquoi c'est le cas.

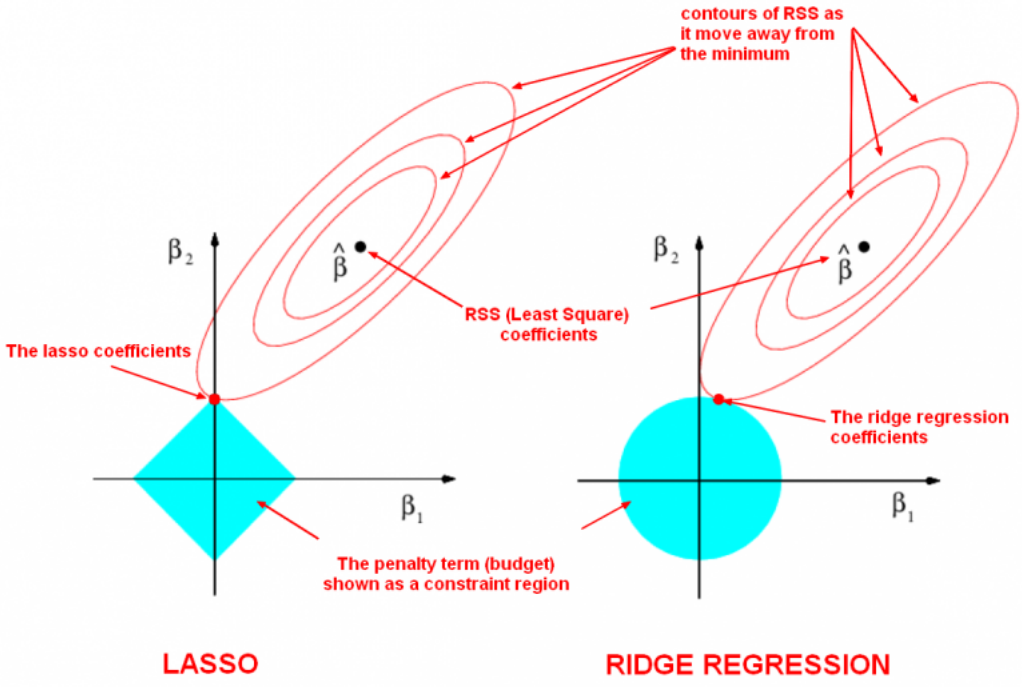


FIGURE 8.1 – Illustration de la différence entre le LASSO et la régression ridge.

Source : http://gerardnico.com/wiki/data_mining/lasso

Tel qu'indiqué plus haut, il faut choisir le paramètre λ pour obtenir une estimation avec le LASSO. Celui-ci est généralement choisi pour minimiser l'erreur de prévision, telle qu'estimée par une méthode comme la validation croisée.

Notons que sous certaines hypothèses, on peut montrer que le LASSO identifie correctement les coefficients qui ne valent pas 0 avec une grande probabilité. Toutefois, les estimateurs sont en général biaisés vers 0, et pas nécessairement convergents. En pratique, on utilise donc parfois le LASSO pour faire une sélection de variables, et on estime ensuite les coefficients avec la méthode des moindres carrés sans pénalité.

Enfin, un autre avantage de la régression LASSO est qu'elle permet d'ajuster un modèle dans le cas où le nombre de paramètres à estimer p' est supérieur au nombre d'observations n.

8.7 Le cas des variables catégoriques et interactions

Dans le cas de modèles de régression contenant des variables catégoriques et des interactions, il faut être un peu plus prudent dans la sélection de modèle.

8.7.1 Sélection de modèle avec variables catégoriques

La sélection se fait comme à l'habitude en présence de variables dichotomiques.

Avec des variables polytomiques, la règle utilisée en sélection de modèle, quel que soit le critère de sélection, est que les β correspondant à une même variable polytomique soient ou bien tous exclus du modèle, ou bien tous inclus dans le modèle. On peut aussi décider de fusionner certaines catégories de la variable polytomique si c'est suggéré par la forme du modèle sélectionné.

Exemple 8.4. *Considérons de nouveau l'exemple 7.1. Si un critère de sélection indique que le meilleur modèle est* $Y_i = \beta_0 + \beta_{11}x_{11i} + \beta_{13}x_{13i} + \varepsilon_i$*, alors on ajoutera* $\beta_{12}x_{12i}$ *à ce modèle car* β_{11}*,* β_{12} *et* β_{13} *sont tous reliés à la variable « lot »et doivent donc ou tous être inclus dans le modèle, ou tous être exclus du modèle, et comme au moins un de ces* β *semble important, nous les incluons tous. On pourrait aussi décider de fusionner les lots 1 et 2 pour créer une nouvelle variable à trois catégories.*

8.7.2 Sélection de modèle en présence d'interactions

Si une interaction entre plusieurs variables exogènes est incluse dans un modèle, on laisse en général les effets plus simples correspondants dans le modèle. Ceci facilitera l'interprétation des différents coefficients du modèle.

Exemple 8.5. *Supposons que le modèle complet est*

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_{12} x_1 x_2 + \beta_{13} x_1 x_3 + \beta_{23} x_2 x_3 + \varepsilon,$$

mais que les procédures de sélection de variables indiquent que seulement les coefficients β_1 *et* β_{23} *semblent importants. Nous utiliserions alors le modèle*

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_{23} x_2 x_3 + \varepsilon$$

car avec la présence de β_{23} *dans le modèle, il est recommandé d'y inclure* β_2 *et* β_3*.*