Diagnostiquer la multicolinéarité avec R

Cette fiche accompagne les notes du chapitre 9. Les noms des objets peuvent être adaptés à vos données. Les exemples utilisent des données incluses dans R ou des données simulées ; aucun fichier externe nest requis.

Dépendance exacte et rang

Une corrélation par paire ne suffit pas à dépister les dépendances entre plusieurs colonnes. alias() et le rang QR révèlent une dépendance exacte.

```
donnees <- mtcars
donnees$double_wt <- 2 * donnees$wt
mod_exact <- lm(mpg ~ wt + double_wt + hp, data = donnees)
coef(mod_exact)
alias(mod_exact)
X <- model.matrix(mod_exact)
c(rang = qr(X)$rank, colonnes = ncol(X))
```

VIF par régressions auxiliaires

Cette formule concerne des prédicteurs numériques à une colonne, dans un modèle avec constante, sans interaction et de plein rang. Pour un facteur à plusieurs colonnes, un diagnostic par terme tel que le GVIF exige une autre formule.

```
variables <- c("wt", "hp", "disp")
cor(donnees[variables])
vif <- sapply(variables, function(v) {
  f <- reformulate(setdiff(variables, v), response = v)
  auxiliaire <- lm(f, data = donnees)
  1 / (1 - summary(auxiliaire)$r.squared)
})
vif
```

Indices de conditionnement

On normalise ici toutes les colonnes, constante comprise, à une norme euclidienne de 1. Les indices sont les racines des rapports de valeurs propres. Le maximum est le conditionnement spectral de cette matrice de modèle normalisée.

```
mod <- lm(mpg ~ wt + hp + disp, data = donnees)
X <- model.matrix(mod)
Xs <- sweep(X, 2, sqrt(colSums(X^2)), "/")
decomp <- eigen(crossprod(Xs), symmetric = TRUE)
if (min(decomp$values) <= 0) stop("Matrice singuliere")
indices <- sqrt(max(decomp$values) / decomp$values)
contributions <- sweep(decomp$vectors^2, 2,
                       decomp$values, "/")
proportions <- contributions / rowSums(contributions)
rownames(proportions) <- colnames(X)
indices
proportions
```

Une pénalisation ridge illustrative

Les prédicteurs sont centrés et réduits ; la constante n'est pas pénalisée. lambda=10 est choisi pour illustrer le calcul, sans prétendre être optimal. Une validation croisée est nécessaire pour le choisir selon la prévision.

```
Z <- scale(as.matrix(donnees[variables]))
y <- donnees$mpg
lambda <- 10
beta_ridge <- solve(crossprod(Z) + lambda * diag(ncol(Z)),
                    crossprod(Z, y - mean(y)))
beta_ridge
pred_ridge <- drop(mean(y) + Z %*% beta_ridge)
```

Aide

Dans R, utilisez `?lm` et laide des fonctions présentées.