Chapitre 9

Multicolinéarité

Sommaire

9.1 Introduction et définition 94
9.2 Détection de la multicolinéarité 95
9.2.1 La matrice de corrélations 95
9.2.2 Le facteur d'inflation de la variance (VIF) 96
9.2.3 L'indice de conditionnement 97
9.3 Les solutions possibles à la multicolinéarité 99
9.3.1 La régression « ridge » 99
9.3.2 La régression basée sur les composantes principales 99

9.1 Introduction et définition

Depuis le début du cours, nous avons supposé que la matrice $\boldsymbol{X}$ est une matrice de plein rang, c'est-à-dire qu'il existe une unique inverse à la matrice $\boldsymbol{X}'\boldsymbol{X}$, et donc qu'il n'existe qu'un seul vecteur $\widehat{\boldsymbol{\beta}}$ qui minimise la somme des carrés résiduels SC_{res}. Toutefois, en pratique certaines colonnes de $\boldsymbol{X}$ peuvent être reliées linéairement entre elles. C'est ce qu'on nomme la multicolinéarité.

La définition mathématique formelle de la multicolinéarité est la suivante.

Définition 9.1. *Il y a **multicolinéarité exacte** lorsqu'une variable est la combinaison linéaire d'une ou de plusieurs autres variables, c'est-à-dire lorsqu'il existe une combinaison de constantes $d_1, \ldots, d_p$ (pas toutes égales à zéro) telle que*

$$\sum_{j=1}^{p} d_j X_j = \mathbf{0}.$$

Définition 9.2. *La **multicolinéarité** au sens large se produit lorsqu'il existe une combinaison de*

constantes $d_1, \ldots, d_p$ (pas toutes égales à zéro) telle que

$$\sum_{j=1}^{p} d_j X_j \approx \mathbf{0}.$$

Dans le cas de multicolinéarité exacte, la matrice $\boldsymbol{X}'\boldsymbol{X}$ n'est pas inversible et les coefficients ne sont pas tous identifiables de façon unique. Les valeurs ajustées restent définies comme la projection de $\boldsymbol{Y}$ sur l'espace engendré par les colonnes de $\boldsymbol{X}$. La multicolinéarité exacte ne représente pas un problème : elle se détecte facilement et il suffit d'enlever la ou les variables en cause pour régler le problème. La multicolinéarité au sens large est plus fréquente et plus difficile à détecter.

La multicolinéarité au sens large pose plusieurs problèmes :

1. Instabilité de $(\boldsymbol{X}'\boldsymbol{X})^{-1}$, ce qui entraîne qu'une petite variation en $\boldsymbol{Y}$ peut se traduire par de très grands changements en $\widehat{\boldsymbol{\beta}}$. Les valeurs ajustées aux profils observés peuvent toutefois rester stables.
2. On observe des $\hat{\beta}_i$ de signe inattendu ou contre-intuitif.
3. Les variances de certains $\hat{\beta}_i$ peuvent être grandes. Les prédictions à des profils éloignés du domaine observé peuvent également être peu précises.
4. Les méthodes de sélection de variables ne concordent pas.
5. Certains paramètres peuvent se révéler non-significatifs alors que la corrélation des variables correspondantes avec Y est très grande.

Le problème, au fond, est que les variables s'expliquent entre elles. Si on s'imagine l'espace d'une régression à deux variables, c'est comme si les points étaient alignés en ńpiquets de clôtureż. Ce phénomène n'est pas facile à détecter dans un espace à haute dimension. Nous présenterons ici quelques outils de détection de la multicolinéarité.

9.2 Détection de la multicolinéarité

9.2.1 La matrice de corrélations

À première vue, on pourrait être tenté de calculer la matrice des corrélations entre les variables exogènes pour détecter la multicolinéarité.

Le coefficient de corrélation échantillonnal entre la variable x_j et la variable x_k est donné par

$$r_{jk} = \frac{1}{n-1} \sum_{i=1}^{n} \frac{(x_{ji} - \overline{x}_j)(x_{ki} - \overline{x}_k)}{s_j s_k},\ j \in \{1, \ldots, p\}, k \in \{1, \ldots, p\}$$

où $\overline{x}_j = \sum_{i=1}^{n} x_{ji}/n$ et $s_j = \sqrt{\sum_{i=1}^{n}(x_{ji} - \overline{x}_j)^2/(n-1)}$, et de même pour $\overline{x}_k$ et s_k.

On peut aussi écrire la matrice des coefficients de corrélation échantillonnaux (en excluant la colonne de 1) comme

$$\boldsymbol{X}_c^{*'}\boldsymbol{X}_c^* = \begin{pmatrix} 1 & r_{12} & \cdots & r_{1p} \\ r_{21} & 1 & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & 1 \end{pmatrix}$$

où

$$\boldsymbol{X}_c^* = \left(\frac{\boldsymbol{x}_1 - \overline{\boldsymbol{x}}_1}{\sqrt{\sum_i (x_{1i} - \overline{x}_1)^2}} \quad \frac{\boldsymbol{x}_2 - \overline{\boldsymbol{x}}_2}{\sqrt{\sum_i (x_{2i} - \overline{x}_2)^2}} \ldots \frac{\boldsymbol{x}_p - \overline{\boldsymbol{x}}_p}{\sqrt{\sum_i (x_{pi} - \overline{x}_p)^2}} \right) \quad \text{et} \quad \overline{\boldsymbol{x}}_j = (\overline{x}_j, \ldots, \overline{x}_j)'.$$

Si deux variables exogènes sont linéairement reliées, leur coefficient de corrélation devrait être élevé. Cependant deux problèmes majeurs empêchent les coefficients de corrélation d'être des bons outils de diagnostic :

(i) il est difficile de dire ce qu'est une grande valeur de la corrélation

(ii) la multicolinéarité est souvent induite par une dépendance linéaire entre plus de deux variables.

Pour voir que le point (ii) constitue un problème, il est possible de créer des exemples où p variables sont parfaitement linéairement dépendantes, mais où les coefficients de corrélation de toutes les paires de variables sont égaux en valeur absolue à $1/(p-1)$. Ainsi, même si la corrélation entre deux variables est indésirable, cela ne représente qu'un cas particulier de la multicolinéarité.

9.2.2 Le facteur d'inflation de la variance (VIF)

Une approche plus sensible consiste à évaluer le degré de dépendance linéaire de chaque variable exogène sur les autres variables exogènes. Ainsi pour la j^e variable exogène, on peut mesurer ce niveau de dépendance en effectuant une régression linéaire avec la j^e variable exogène comme variable réponse et les $p-1$ variables exogènes restantes comme variables explicatives. Le coefficient de détermination de cette régression, noté R_j^2, mesurera la proportion de la variabilité de la j^e variable exogène qui est expliquée de façon linéaire par les autres variables exogènes. Si R_j^2 est grand, on a vraisemblablement un problème.

Cette idée se matérialise dans le facteur d'inflation de la variance (en anglais, VIF pour Variance Inflation Factor). Celui-ci est défini de la façon suivante :

$$\text{VIF}_j \quad = \quad \frac{1}{1 - R_j^2} \tag{9.1}$$

Si $R_j^2 \to 1$, alors $VIF_j \to \infty$. Ainsi, une grande valeur de VIF_j signifie une valeur proche de 1 de R_j^2, et donc une forte dépendance linéaire des variables exogènes.

Le nom « facteur d'inflation de la variance » vient du fait que la variance de $\hat{\beta}_j$ s'exprime en fonction du VIF comme suit :

$$\mathbb{V}\text{ar}[\hat{\beta}_j] \quad = \quad \frac{\sigma^2}{(\boldsymbol{X}'\boldsymbol{X})_{jj}}\text{VIF}_j$$

On voit donc l'effet de cette multicolinéarité sur la variance des estimateurs des coefficients.

Plusieurs auteurs suggèrent un VIF > 10 comme point où l'on doit commencer à considérer la présence de multicolinéarité aux conséquences importantes. Cependant, les VIF à eux seuls ne sont pas un diagnostic complet. Parmi les points faibles des VIF on dénote

(i) l'incapacité de détecter des multicolinéarités impliquant la colonne de 1 de la matrice d'incidence

(ii) l'incapacité de cerner le nombre de quasi dépendances linéaires présentes dans les données

(iii) le fait qu'on a jamais réussi à cerner une valeur précise pour le VIF où l'on doit vraiment commencer à s'inquiéter (10 est une valeur *ad hoc*).

Remarque 16. *Une mesure équivalente au facteur d'inflation de la variance est la tolérance définie comme suit :*

$$TOL_j = 1 - R_j^2 = 1/VIF_j.$$

La tolérance TOL_j est donc la partie de la variabilité dans la $j^{ème}$ variable exogène qui n'est pas expliquée par les autres variables exogènes. Ainsi, si on définit un cas problématique comme un cas où $VIF > 10$, ceci est équivalent à définir les cas problématiques comme ceux ayant une $TOL < 10\%$, c'est-à-dire ceux pour qui au moins 90 % de la variabilité est expliquée par les autres variables exogènes.

9.2.3 L'indice de conditionnement

L'approche la plus efficace afin de détecter les causes de multicolinéarité est basée sur les valeurs propres de la matrice des coefficients de corrélation échantillonnaux $\boldsymbol{X}_c^{*'}\boldsymbol{X}_c^*$, ou sur la matrice des valeurs réduites, mais non centrées $\boldsymbol{X}^*$ (qui permet l'inclusion de la colonne de 1), où

$$\boldsymbol{X}^* = \left(\frac{\boldsymbol{x}_1}{\sqrt{\sum_i x_{1i}^2}} \quad \frac{\boldsymbol{x}_2}{\sqrt{\sum_i x_{2i}^2}} \cdots \frac{\boldsymbol{x}_p}{\sqrt{\sum_i x_{pi}^2}} \right).$$

En se servant de la décomposition en valeurs propres de $\boldsymbol{X}^{*'}\boldsymbol{X}^*$, i.e.

$$\boldsymbol{X}^{*'}\boldsymbol{X}^* = \boldsymbol{P}\boldsymbol{\Lambda}\boldsymbol{P}'$$

avec $\boldsymbol{\Lambda} = \text{diag}(\lambda_1, \ldots, \lambda_{p'})$ et $\boldsymbol{P}\boldsymbol{P}' = \boldsymbol{P}'\boldsymbol{P} = \boldsymbol{I}_{p'}$, on peut alors montrer que

$$\text{tr}(\boldsymbol{X}^{*'}\boldsymbol{X}^*) = \text{tr}(\boldsymbol{P}\boldsymbol{\Lambda}\boldsymbol{P}') = \text{tr}(\boldsymbol{P}'\boldsymbol{P}\boldsymbol{\Lambda}) = \text{tr}(\boldsymbol{\Lambda}) = \sum_{j=1}^{p'} \lambda_j = p'. \tag{9.2}$$

En présence de multicolinéarité, le déterminant de $\boldsymbol{X}^{*'}\boldsymbol{X}^{*}$, qui est égal à $\prod_{j=1}^{p'} \lambda_j$, aura une valeur proche de 0.

Ainsi, en présence de multicolinéarité l'équation 9.2 indique que la somme des valeurs propres doit être égale à p', mais que leur produit sera proche de 0. Puisque les valeurs propres sont toutes positives, cela implique qu'en présence de multicolinéarité, il y aura à la fois des valeurs propres de grandes et de faibles valeurs. Le nombre de valeurs propres proches de zéro indique le nombre de directions presque linéairement dépendantes. Dans cette situation, le rapport de la plus grande valeur propre sur la plus faible sera donc élevé.

Les **indices de conditionnement** notés η_j pour $j = 1, 2, \cdots, p'$ sont définis comme les racines carrées des rapports entre la plus grande valeur propre de la matrice $\boldsymbol{X}^{*'}\boldsymbol{X}^{*}$ et chacune de ses autres valeurs propres, c'est-à-dire

$$\eta_j = \sqrt{\frac{\lambda_{max}}{\lambda_j}}.$$

Plusieurs auteurs semblent s'entendre pour dire qu'une valeur de $\eta_j > 30$ indique une multicolinéarité dont il faut se soucier.

La plus grande valeur de η_j est égale à

$$\kappa = \sqrt{\frac{\lambda_{max}}{\lambda_{min}}}.$$

κ est parfois appelée **facteur de conditionnement**.

Soit $\boldsymbol{p}_j$, le vecteur propre correspondant à la valeur propre λ_j. Pour les coefficients associés aux colonnes normalisées,

$$\mathbb{V}\text{ar}[\hat{\beta}_{k-1}] = \sigma^2(\boldsymbol{X}^{*'}\boldsymbol{X}^{*})^{-1}_{kk} = \sigma^2 \sum_{j=1}^{p'} p_{kj}^2/\lambda_j,$$

la portion de variance de $\hat{\beta}_{k-1}$ expliquée par la j^e dépendance linéaire peut se mesurer comme suit :

$$v_{kj} = \frac{p_{kj}^2/\lambda_j}{\sum_{l=1}^{p'} p_{kl}^2/\lambda_l}.$$

Pour détecter la multicolinéarité on suit donc la procédure suivante :

1. Calculer les indices de conditionnement η_j et vérifier si certains d'entre eux possèdent une valeur supérieure à 30.
2. Pour chaque η_j dont la valeur excède 30, calculer les proportions de la variance $v_{1j}, v_{2j}, \cdots, v_{p'j}$.
3. Les variables exogènes correspondant aux coefficents avec des valeurs de v_{kj} élevées (en général nettement supérieures à 60 %) sont multicolinéaires.

9.3 Les solutions possibles à la multicolinéarité

La solution la plus simple est de retirer une ou plusieurs variables exogènes. Typiquement, on retranchera les variables ayant le plus grand VIF, une à la fois. Dans la pratique, ce retrait des variables doit se faire en collaboration étroite avec le client, car dans le choix des variables, c'est d'abord l'interprétation qui compte. Il est parfois possible de combiner des variables exogènes redondantes, par exemple pour calculer un score à partir de plusieurs variables exogènes.

Quelques autres solutions sont également disponibles.

9.3.1 La régression « ridge »

La régression ridge, présentée à la section 8.6.1 peut également être utilisée en cas de multicolinéarité, mais donne des estimateurs biaisés. Le paramètre de pénalisation se choisit, par exemple, par validation croisée.

9.3.2 La régression basée sur les composantes principales

On peut également faire une régression sur les composantes principales de la matrice d'incidence. Les facteurs dans une analyse en composantes principales sont donnés par les colonnes de la matrice $\boldsymbol{F}$ suivante : $\boldsymbol{F} = \boldsymbol{X}^*\boldsymbol{P}$, où $\boldsymbol{P}$ est la matrice des vecteurs propres de $\boldsymbol{X}^{*'}\boldsymbol{X}^*$. Cette matrice est telle que $\boldsymbol{P}'\boldsymbol{P} = \boldsymbol{P}\boldsymbol{P}' = \mathbb{I}$. En utilisant cette propriété matricielle, nous pouvons écrire le modèle de régression multiple comme

$$\begin{aligned}\boldsymbol{Y} &= \beta_0\mathbf{1} + \boldsymbol{X}^*\boldsymbol{\beta} + \boldsymbol{\varepsilon} \\ &= \beta_0\mathbf{1} + \boldsymbol{X}^*\boldsymbol{P}\boldsymbol{P}'\boldsymbol{\beta} + \boldsymbol{\varepsilon} \\ &= \beta_0\mathbf{1} + \boldsymbol{F}\boldsymbol{\gamma} + \boldsymbol{\varepsilon},\end{aligned}$$

où $\boldsymbol{\gamma} = \boldsymbol{P}'\boldsymbol{\beta}$ ou encore $\boldsymbol{\beta} = \boldsymbol{P}\boldsymbol{\gamma}$. Le théorème de Gauss-Markov implique que $\widehat{\boldsymbol{\beta}} = \boldsymbol{P}\hat{\boldsymbol{\gamma}}$. La multicolinéarité n'est plus présente, mais au prix d'un biais dans les estimateurs. Ce biais est présent si on ne retient dans la modélisation que les facteurs associés aux plus grandes valeurs propres de $\boldsymbol{X}^{*'}\boldsymbol{X}^*$.

Le principal problème de la régression en composantes principales est son interprétation, qui peut être hasardeuse.