Observations aberrantes et influentes avec R

Cette fiche accompagne les notes du chapitre 10. Les noms des objets peuvent être adaptés à vos données. Les exemples utilisent des données incluses dans R ou des données simulées ; aucun fichier externe nest requis.

Calculer les diagnostics

Un grand levier concerne le profil explicatif ; un grand résidu concerne l'écart de réponse au modèle ; la distance de Cook mesure l'effet sur l'ajustement. Les seuils ci-dessous signalent des observations à examiner.

```
donnees <- mtcars
mod <- lm(mpg ~ wt + hp, data = donnees)
n <- nobs(mod)
pprime <- length(coef(mod))
diagnostic <- data.frame(
  voiture = rownames(model.frame(mod)),
  levier = hatvalues(mod),
  standardise = rstandard(mod),
  studentise = rstudent(mod),
  cook = cooks.distance(mod),
  dffits = dffits(mod),
  covratio = covratio(mod))
diagnostic$signal <- with(diagnostic,
  levier > 2 * pprime / n | abs(studentise) > 2 |
  cook > 4 / (n - pprime))
diagnostic[order(diagnostic$cook, decreasing = TRUE), ]
```

Changements des coefficients

dfbeta() donne les différences non standardisées ; dfbetas() donne les différences standardisées. Ces quantités ne sont pas interchangeables.

```
dfbeta(mod)
dfbetas(mod)
influence.measures(mod)
par(mfrow = c(1, 2))
plot(mod, which = 4)
plot(mod, which = 5)
par(mfrow = c(1, 1))
```

Analyse de sensibilité

Le retrait ci-dessous sert à mesurer l'effet de l'observation ayant la plus grande distance de Cook. Vérifiez la donnée et le contexte avant toute décision de retrait définitif.

```
i <- which.max(cooks.distance(mod))
rownames(donnees)[i]
mod_sans <- lm(mpg ~ wt + hp, data = donnees[-i, ])
cbind(avec = coef(mod), sans = coef(mod_sans))
profil <- data.frame(wt = 3, hp = 110)
rbind(avec = predict(mod, newdata = profil),
      sans = predict(mod_sans, newdata = profil))
```

Dépistage simultané des valeurs aberrantes

La correction de Bonferroni contrôle le seuil familial sous les postulats du modèle. Le résidu studentisé externe utilise une variance estimée après retrait, avec n-pprime-1 degrés de liberté.

```
alpha <- 0.05
seuil <- qt(1 - alpha / (2 * n), df = n - pprime - 1)
diagnostic[abs(diagnostic$studentise) > seuil, ]
```

Aide

Dans R, utilisez `?lm` et laide des fonctions présentées. Voir aussi la documentation des diagnostics dinfluence.