Chapitre 10

Observations aberrantes et influentes

Sommaire

10.1 Sources de l'influence 100
10.2 Mesures d'influence 101
10.2.1 Influence sur la prévision 102
10.2.2 Influence sur les estimations des paramètres 102
10.2.3 Influence sur la performance des estimateurs 103
10.3 Que faire avec les données influentes ? 103

On doit examiner les observations qui influencent fortement l'estimation des paramètres et documenter leur effet par une analyse de sensibilité. Avant de parler plus en détails de ces données influentes, il faut bien définir deux termes importants.

Définition 10.1. *Une observation est* ***aberrante*** *si elle ne cadre pas avec le modèle.*

Ce sera donc une observation qui a un résidu de grande taille. Une donnée aberrante n'est pas problématique en elle-même, mais elle peut indiquer une erreur dans la valeur d'une variable exogène ou de la variable endogène.

Définition 10.2. *Une donnée* ***influente*** *est une observation qui, à elle seule, peut avoir un impact sérieux sur les conclusions d'une analyse de régression.*

Parmi les exemples « d'impact sérieux », on peut citer des $\hat{\beta}$ négatifs quand on sait qu'ils devraient être positifs (ou vice-versa) ou encore une variable exogène qui devrait être importante mais qui est considérée non significative. Une ou des observations influentes peut également diminuer le pouvoir prédictif du modèle.

10.1 Sources de l'influence

L'influence d'une observation provient souvent d'une combinaison de deux sources :

Source 1 : L'observation a un grand levier, c'est-à-dire qu'elle a une grande capacité *a priori* à influencer les résultats de la régression.

Source 2 : L'observation a une valeur extrême de Y par rapport au modèle.

On peut facilement identifier les observations avec ces deux caractéristiques.

Levier d'une observation

Une observation a un grand levier si sa valeur de $\boldsymbol{x}_i$ est loin du centre (centroïde) de toutes les observations. La distance entre une observation et le centroïde de toutes les autres peut être calculée facilement à partir de la matrice d'incidence $\boldsymbol{X}$. Plus précisément, le levier de la i^e observation est le i^e élément diagonal de la matrice chapeau $\boldsymbol{H} = \boldsymbol{X}(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'$, qui peut s'exprimer comme $h_{ii} = \boldsymbol{x}_i'(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{x}_i$.

Qu'est-ce qu'une grande valeur de h_{ii} ? Il est difficile de répondre à cette question de façon générale. Cependant nous savons que $\text{tr}(\boldsymbol{H}) = \sum_{i=1}^{n} h_{ii} = p'$, où p' est le nombre de paramètres dans le modèle. Donc un h_{ii} moyen prend une valeur de p'/n et un h_{ii} qui se démarque nettement de cette valeur signifie une donnée à grand levier. Belsley et coll. (1980) suggèrent de retenir les valeurs de $h_{ii} > 2p'/n$.

Observation extrême

Une observation est extrême (ou aberrante) par rapport au modèle si son résidu est grand. On regardera plus précisément le résidu studentisé. On rappelle que celui-ci est donné par

En notant p' le nombre de coefficients, incluant l'ordonnée à l'origine,

$$s^2_{(i)} = \frac{(n-p')\hat{\sigma}^2 - \hat{\varepsilon}_i^2/(1-h_{ii})}{n-p'-1}, \qquad T_i = \frac{\hat{\varepsilon}_i}{s_{(i)}\sqrt{1-h_{ii}}}.$$

Sous les postulats normaux et si le modèle privé de l'observation i reste de plein rang, $T_i \sim \mathcal{T}_{n-p'-1}$. Un repère exploratoire courant est $|T_i| > 2$. Pour un dépistage simultané au seuil α, on peut comparer $|T_i|$ à $t_{n-p'-1;1-\alpha/(2n)}$. Ces repères ne constituent pas des règles automatiques de retrait.

Remarque 17. *Avoir un grand levier et être une observation extrême sont des indices qu'une observation pourrait avoir une influence démesurée sur les résultats de la régression. Pour tester si cela est effectivement le cas, on doit mesurer directement l'influence de l'observation sur la régression. Il est important de comprendre qu'une donnée avec un grand levier peut ne pas être influente. Il en est de même pour une observation extrême.*

10.2 Mesures d'influence

Pour mesurer si une donnée est influente ou non, on évalue son impact sur la prévision $\widehat{\boldsymbol{Y}}$ et sur l'estimation de $\boldsymbol{\beta}$. Les différentes statistiques utilisées sont présentées ici.

10.2.1 Influence sur la prévision

La statistique suivante mesure l'influence de la i^e donnée dans la prévision $\hat{Y}_i$ de Y_i (*Difference in Fit*) :

$$DFFIT_i = \frac{\hat{Y}_i - \hat{Y}_{i,-i}}{\hat{\sigma}_{-i}\sqrt{h_{ii}}} = T_i\sqrt{\frac{h_{ii}}{1-h_{ii}}},$$

où $\hat{Y}_{i,-i}$ désigne la valeur de la prévision de Y_i basée sur un jeu de données qui ne contient pas la i^e donnée, c'est-à-dire $\hat{Y}_{i,-i} = \boldsymbol{x}_i'\hat{\boldsymbol{\beta}}_{-i}$.

Il faut se rappeler ici que $\mathbb{V}\text{ar}[\hat{Y}_i] = \sigma^2 h_{ii}$. Les différences au numérateur de $DFFIT_i$ sont donc standardisées de sorte qu'elles s'expriment en multiples de l'écart-type de la prévision.

Nous analysons les $DFFIT_i$ de la même façon que nous nous penchons sur les T_i, c'est-à-dire que des grandes valeurs de $|DFFIT_i|$ constituent un signe que la i^e donnée possède une grande influence sur la valeur de la prévision. Belsley et coll. (1980) indiquent qu'il faut retenir les valeurs de $|DFFIT_i| > 2\sqrt{p'/n}$ alors que d'autres statisticiens proposent simplement de retenir les valeurs de $|DFFIT_i| > 2$.

10.2.2 Influence sur les estimations des paramètres

La statistique suivante mesure l'influence de la i^e observation sur la valeur de l'estimateur de β_j (*Difference in Beta*) :

$$DFBETAS_{ji} = \frac{\hat{\beta}_j - \hat{\beta}_{j,-i}}{\hat{\sigma}_{-i}\sqrt{(\boldsymbol{X}'\boldsymbol{X})^{-1}_{jj}}}.$$

Il faut se souvenir ici que $\mathbb{V}\text{ar}[\hat{\beta}_j] = \sigma^2(\boldsymbol{X}'\boldsymbol{X})^{-1}_{jj}$. Les différences au numérateur de la statistique sont à nouveau standardisées. Encore une fois, les grandes valeurs de $DFBETAS_{ji}$ indiquent que la i^e donnée possède une grande influence sur l'estimation de β_j. Belsley et coll. (1980) proposent de considérer les valeurs de $|DFBETAS_{ji}| > 2/\sqrt{n}$ alors que d'autres statisticiens suggèrent simplement de retenir les valeurs de $|DFBETAS_{ji}| > 2$.

Le signe de $DFBETAS_{ji}$ est un bon indicateur. En effet, si un certain $\hat{\beta}_j$ est négatif alors qu'on se serait attendu à une valeur positive, alors un $DFBETAS_{ji}$ très négatif indique que le « coupable »pourrait être l'observation i.

Comme nous obtenons $p\prime$ valeurs de $DFBETAS$ pour chaque observation, cette mesure devient peu pratique lorsque nous sommes en présence d'un jeu de données ayant plusieurs variables exogènes. Pour simplifier la recherche de valeurs influentes, Dennis Cook a proposé la statistique suivante, appelée

distance de Cook, qui permet de combiner les $DFBETAS$ d'une même observation :

$$\begin{aligned}\text{distance de Cook}_i \;=\; C_i \;&=\; \frac{(\hat{\boldsymbol{\beta}}-\hat{\boldsymbol{\beta}}_{-i})'(\boldsymbol{X}'\boldsymbol{X})(\hat{\boldsymbol{\beta}}-\hat{\boldsymbol{\beta}}_{-i})}{p'\hat{\sigma}^2}\\ &=\; \frac{\sum_{k=1}^{n}(\hat{Y}_k-\boldsymbol{x}_k'\hat{\boldsymbol{\beta}}_{-i})^2}{p'\hat{\sigma}^2}\\ &=\; \frac{\hat{\varepsilon}_i^2}{(1-h_{ii})^2}\frac{h_{ii}}{\hat{\sigma}^2 p'}\end{aligned}$$

Une grande valeur de C_i indique une observation ayant une influence prépondérante sur les β. Fox (1991) suggère de porter notre attention sur les valeurs de $C_i > \frac{4}{n-p'}$. Il s'agit par la suite d'examiner les $DFBETAS$ pour cette observation pour savoir quel(s) $\hat{\beta}$ est (sont) affecté(s).

10.2.3 Influence sur la performance des estimateurs

Une donnée peut aussi avoir un impact néfaste sur la variance des estimateurs. Soit $||Var(\hat{\boldsymbol{\beta}})|| = (\sigma^2)^{p'}||(\boldsymbol{X}'\boldsymbol{X})^{-1}||$, le déterminant de la matrice de variance de $\hat{\boldsymbol{\beta}}$, parfois appelé variance généralisée. L'influence de la i^e donnée sur la variance de $\hat{\boldsymbol{\beta}}$ peut être calculée comme suit :

$$\begin{aligned}COVRATIO_i \;&=\; \frac{||(\boldsymbol{X}'_{-i}\boldsymbol{X}_{-i})^{-1}\hat{\sigma}^2_{-i}||}{||(\boldsymbol{X}'\boldsymbol{X})^{-1}\hat{\sigma}^2||}\\ &=\; \left(\frac{\hat{\sigma}^2_{-i}}{\hat{\sigma}^2}\right)^{p'}\frac{1}{1-h_{ii}}.\end{aligned}$$

Comme la seconde ligne l'illustre, une donnée possédant beaucoup de levier donnera en général un $COVRATIO > 1$, et une donnée aberrante un $COVRATIO < 1$.

Belsley et coll. (1980) proposent de porter notre attention sur les valeurs telles que $|COVRATIO - 1| > 3p'/n$, c'est-à-dire sur les observations telles que
$COVRATIO < 1 - 3p'/n$ ou $COVRATIO > 1 + 3p'/n$.

10.3 Que faire avec les données influentes ?

Si une donnée est influente, il faut prendre tous les moyens possibles pour essayer de comprendre comment cette donnée a été obtenue et s'assurer qu'il n'y a pas d'erreur qui aurait pu survenir lors de la mesure, collecte ou saisie des données.

Si l'influence provient d'un grand levier, alors il serait souhaitable d'aller chercher d'autres données afin de combler le vide entre le centroïde des données et la donnée influente.

En général, on doit s'abstenir d'éliminer les données influentes d'un jeu de données. Quelques exceptions :

— Erreur de mesure ou de saisie (corriger la donnée est préférable à son élimination).

— Valeurs mesurées scientifiquement peu plausibles.

— Donnée très peu représentative du reste des données et de la population en général.

Il est à noter que souvent, une transformation de variable peut grandement réduire l'influence de certaines données.