Chapitre 11

Techniques plus avancées

Sommaire

11.1 Régression polynomiale **105**
11.2 Régression non linéaire **108**
11.3 Régression pondérée **110**
11.4 Modélisation de la dépendance **112**
11.5 Autres **112**

Figures

11.1 Données d'une expérience sur des rats de laboratoire avec la fonction de régression estimée 109

On présente ici quelques techniques de régression plus avancées. Elles peuvent entre autres être utilisées si les postulats de la RLM ne sont pas vérifiés.

11.1 Régression polynomiale

L'idée derrière la régression linéaire est que le modèle linéaire est une bonne approximation de la « vraie »relation entre la variable endogène et les variables exogènes

$$Y = f(x_1, x_2, \ldots, x_k) + \varepsilon.$$

Dans plusieurs cas, le modèle de régression linéaire sera une approximation suffisamment bonne de $f(x_1, \ldots, x_k)$. Par contre dans certaines situations, il arrive que l'approximation linéaire ne soit pas assez proche de $f(x_1, \ldots, x_k)$ pour donner un modèle approprié. Dans ces cas, nous pouvons utiliser le principe disant que la plupart des fonctions peuvent être approchées aussi bien que l'on veut par une expansion polynomiale. Plus il y a de la « courbure »dans $f(x_1, \ldots, x_k)$, plus le polynôme utilisé pour approcher $f(x_1, \ldots, x_k)$ doit être de degré élevé pour que l'approximation soit suffisamment précise.

En régression, ceci se traduit par le résultat suivant :

$$\begin{aligned} Y_i &= f(x_{1i}, \ldots, x_{ki}) + \varepsilon_i \\ &\approx \beta_0 + \beta_1 x_{1i} + \cdots + \beta_k x_{ki} \\ &\quad + \beta_{11} x_{1i}^2 + \cdots + \beta_{kk} x_{ki}^2 + \beta_{12} x_{1i} x_{2i} + \cdots + \beta_{k-1,k} x_{k-1,i} x_{ki} \\ &\quad + \beta_{111} x_{1i}^3 + \cdots + \beta_{kk\cdots k} x_{ki}^d + \cdots + \varepsilon_i. \end{aligned}$$

En général, il est rarement nécessaire de dépasser un modèle du second degré :

$$\begin{aligned} Y_i &= \beta_0 + \beta_1 x_{1i} + \cdots + \beta_k x_{ki} \\ &\quad + \beta_{11} x_{1i}^2 + \cdots + \beta_{kk} x_{ki}^2 + \beta_{12} x_{1i} x_{2i} + \cdots + \beta_{k-1,k} x_{k-1,i} x_{ki}. \end{aligned}$$

Il est possible que l'on rencontre des problèmes numériques ou de multicolinéarité quand on utilise des modèles polynomiaux. Si l'objectif est de trouver un modèle faisant de bonnes prédictions, ce n'est pas vraiment un problème. Si on veut vraiment interpréter les valeurs des coefficients de chaque terme, alors on peut travailler avec les variables exogènes standardisées, c'est-à-dire de remplacer x_{ji} par

$$x_{ji}^* = \frac{(x_{ji} - \bar{x}_j)}{s_j}$$

où $\bar{x_j} = \sum_i x_{ji}/n$ et $s_j^2 = \sum_i (x_{ji} - \bar{x}_j)^2/(n-1)$.

Sélection de modèle

Comme c'était le cas avec les interactions, si un terme de degré d est inclus dans le modèle, alors en général on inclut les termes de degré inférieur à d.

Test de comparaison de modèle pour justifier un degré supérieur

Exemple 11.1. *Soit le modèle* $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$.

Ce modèle est-il aussi valide que celui contenant des termes de degré 2 ?

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{11} x_1^2 + \beta_{22} x_2^2 + \beta_{12} x_1 x_2 + \varepsilon.$$

Nous pouvons utiliser un test F *de comparaison de modèles pour les hypothèses*
H_0 : $\beta_{11} = \beta_{22} = \beta_{12} = 0$ *contre*
H_1 : *au moins un de ces* β *diffère de 0.*

Si nous ne rejetons pas H_0*, les données ne montrent pas d'amélioration significative par ces termes de second degré ; les autres diagnostics restent nécessaires. Si nous rejetons* H_0*, alors le modèle de premier degré n'est pas adéquat.*

On aurait pu vérifier l'ajout d'un seul terme à la fois, car il est fort possible qu'une relation quadratique soit souhaitable en x_1 mais pas en x_2.

11.2 Régression non linéaire

Si l'espérance de Y (ou de $g(Y)$) n'est pas une fonction linéaire des paramètres inconnus, mais qu'on a une idée de la vraie relation entre Y et les variables indépendantes, on peut néanmoins estimer les paramètres de cette relation non linéaire avec la méthode des moindres carrés. Il n'y a pas de solution analytique dans ce cas, mais des méthodes numériques peuvent minimiser la somme des carrés des erreurs.

Exemple 11.2. *Dans une expérience sur des rats, on trempe des portions du ventricule auriculaire gauche dans une solution de chlorure de calcium, puis on stimule électriquement le tissu et on mesure la longueur du rétrécissement de la bandelette de tissu. On s'intéresse à la relation entre*

x : la concentration de chlorure de calcium (en mM)

Y : le changement de longueur de la bandelette en réaction au choc (en mm)

La figure 11.1 illustre les données. Il est clair qu'un modèle linéaire n'est pas approprié.

Il se trouve toutefois qu'on a déjà une idée du modèle approprié pour les données :

$$Y_i = \alpha + \beta e^{-x_i/\theta} + \varepsilon_i$$

La régression non linéaire permet d'estimer les coefficients par la méthode des moindres carrés. On trouve $\hat{\theta} = 0,6082$, $\hat{\alpha} = 28,9633$ *et* $\hat{\beta} = -34,2274$. *La fonction de régression correspondante est également illustrée à la figure 11.1.*

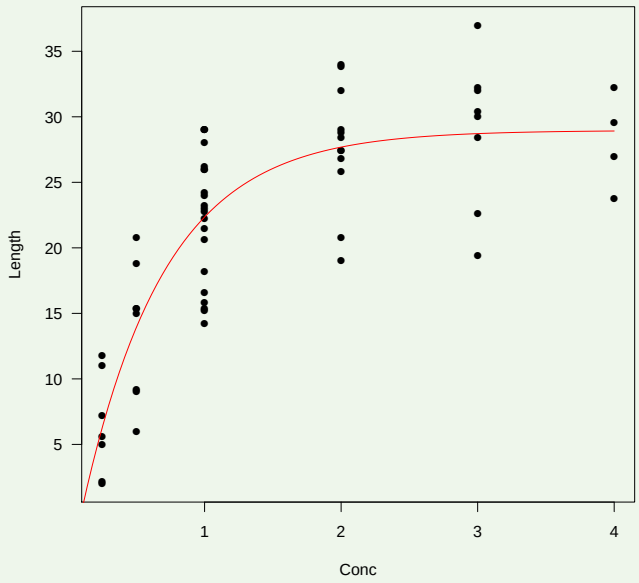


FIGURE 11.1 – Données d'une expérience sur des rats de laboratoire avec la fonction de régression estimée

11.3 Régression pondérée

La méthode des moindres carrés pondérés consiste à attribuer un poids différent à chaque observation, et donc à trouver $\hat{\boldsymbol{\beta}}$ tel que

$$\sum_{i=1}^{n} w_i (Y_i - \hat{Y}_i)^2$$

est minimale, où w_i est le poids associé à l'observation i.

Une application fréquente de la régression pondérée est lorsque l'hypothèse d'homoscédasticité n'est pas respectée, c'est-à-dire si le modèle est plutôt caractérisé par
$\boldsymbol{\varepsilon} \sim \mathcal{N}_n(\mathbf{0}, \text{diag}(\sigma_1^2, \ldots, \sigma_n^2))$, où les σ_i^2 ne sont pas nécessairement égaux.

Le choix des poids w_i n'est pas toujours facile à faire. Si chaque observation est en réalité la moyenne de n_i valeurs, on peut utiliser un poids égal $w_i = n_i$. Si la variance des erreurs est liée à une variable explicative, on peut faire un graphe des paires (x_i, t_i), et voir comment la variance des résidus studentisés évolue en fonction de x_i. Si le graphe est en forme d'entonnoir ouvert vers la droite, alors on pourra prendre $w_i = 1/x_i$, $w_i = 1/\sqrt{x_i}$, $w_i = 1/x_i^2$, etc. Si l'entonnoir ouvre vers la gauche, alors on peut prendre $w_i = x_i$, $w_i = \sqrt{x_i}$, $w_i = x_i^2$, etc. Il est toutefois recommandé d'essayer d'abord de régler le problème à l'aide d'une transformation de variable.

En régression linéaire multiple, il y a plusieurs variables explicatives, il faut donc trouver une stratégie plus globale en cas d'hétéroscédasticité. L'idéal serait d'identifier des poids de la forme $w_i \propto 1/\sigma_i^2$, où σ_i^2 est la variance de l'erreur pour l'observation i. On peut démontrer que dans ce cas,

$$\hat{\boldsymbol{\beta}} = (\boldsymbol{X}'\boldsymbol{V}^{-1}\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{V}^{-1}\boldsymbol{Y},$$

où $\boldsymbol{V} = \text{diag}(\sigma_1^2, \ldots, \sigma_n^2)$. La variance de $\hat{\boldsymbol{\beta}}$ est alors

$$\begin{aligned} \mathbb{V}\text{ar}(\hat{\boldsymbol{\beta}}) &= (\boldsymbol{X}'\boldsymbol{V}^{-1}\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{V}^{-1}\ \boldsymbol{V}\ \boldsymbol{V}^{-1}\boldsymbol{X}(\boldsymbol{X}'\boldsymbol{V}^{-1}\boldsymbol{X})^{-1} \\ &= (\boldsymbol{X}'\boldsymbol{V}^{-1}\boldsymbol{X})^{-1}. \end{aligned}$$

Si $\boldsymbol{V}$ est connue, la statistique obtenue en divisant $\hat{\beta}_j - c$ par son écart-type connu suit une loi normale standard sous H_0. Si $\boldsymbol{V} = \sigma^2\boldsymbol{W}^{-1}$ avec $\boldsymbol{W}$ connue et σ^2 inconnue, on estime σ^2 par

$$s_W^2 = \frac{\sum_i w_i (Y_i - \hat{Y}_i)^2}{n - p'}.$$

Sous normalité, la statistique $(\hat{\beta}_j - c)/\{s_W\sqrt{(\boldsymbol{X}'\boldsymbol{W}\boldsymbol{X})^{-1}_{jj}}\}$ suit alors une loi de Student à $n - p'$ degrés de liberté. Si les poids sont estimés à partir des mêmes données, ces résultats sont généralement approchés.

Or, établir des estimations des σ_i n'est pas si évident. Voici quelques pistes de solutions (il faut d'abord ajuster une régression du modèle complet et s'assurer que la linéarité est respectée) :

— Si le graphique des $\hat{\varepsilon}_i$ en fonction des $\hat{Y}_i$ est en entonnoir, on ajuste une régression des $|\hat{\varepsilon}_i|$ sur les $\hat{Y}_i$. Les valeurs prédites de ce nouvel ajustement sont une estimation de σ_i. (Et les poids seront $w_i = 1/\hat{\sigma}_i^2$).

— Si le graphique des $\hat{\varepsilon}_i^2$ en fonction des $\hat{Y}_i$ montre une tendance à la hausse, on ajuste une régression des $\hat{\varepsilon}_i^2$ sur les $\hat{Y}_i$. Les valeurs prédites de ce nouvel ajustement sont une estimation de σ_i^2. (Et les poids seront $w_i = 1/\hat{\sigma}_i^2$).

Quelques remarques sur la régression pondérée :

— En général, les estimations des $\hat{\beta}_j$ ne seront pas dramatiquement changées par la régression pondérée.

— Les degrés de liberté ne sont pas affectés par l'insertion de poids.

— Les intervalles de confiance et les tests d'hypothèses sont affectés par les poids.

11.4 Modélisation de la dépendance

Lorsque l'hypothèse d'indépendance des observations n'est pas vérifiée, on peut modéliser directement la dépendance en ajoutant des paramètres à la matrice de covariance des erreurs. Alors que la régression pondérée permet des valeurs différentes sur la diagonale de la matrice de covariance des erreurs, on modélise la dépendance en remplaçant les zéros hors diagonale par des paramètres à estimer. Selon la dépendance que l'on souhaite modéliser, on paramétrisera la matrice de covariance différemment.

Une forme particulière de dépendance est l'autocorrélation, qui arrive lorsque le résidu d'une observation est relié à celui de l'observation précédente, par exemple dans une série temporelle. Un modèle dit autorégressif peut alors être utilisé pour ajuster un modèle de régression.

Mathématiquement, on écrit

$$\varepsilon_i = \rho\varepsilon_{i-1} + u_i, \tag{11.1}$$

où les innovations u_i sont i.i.d. $\mathcal{N}(0, \sigma_u^2)$. Le paramètre ρ dans (11.1) est nommé paramètre d'autocorrélation, et sa valeur doit être dans l'intervalle (-1,1).

En supposant le processus stationnaire, avec $\varepsilon_1 \sim \mathcal{N}(0, \sigma_u^2/(1-\rho^2))$ indépendant des innovations futures, à partir de (11.1), nous pouvons calculer directement que

$$\begin{aligned}
\varepsilon_i &= \sum_{j=0}^{\infty} \rho^j u_{i-j} \\
\mathbb{E}[\varepsilon_i] &= \sum_{j=0}^{\infty} \rho^j \mathbb{E}[u_{i-j}] = 0 \\
\mathbb{V}\text{ar}[\varepsilon_i] &= \sigma_u^2 \sum_{j=0}^{\infty} \rho^{2j} = \frac{\sigma_u^2}{1-\rho^2} \\
\mathbb{C}\text{ov}(\varepsilon_i, \varepsilon_{i+j}) &= \rho^{|j|} \frac{\sigma_u^2}{1-\rho^2}.
\end{aligned}$$

Comme on peut le voir, une autocorrélation positive entre ε_i et ε_{i+1} est obtenue lorsque $\rho > 0$, tandis que $\rho < 0$ donne une autocorrélation négative. Il n'y a pas d'autocorrélation lorsque $\rho = 0$.

11.5 Autres

Il existe plusieurs autres modèles de régression plus complexes, notamment la régression linéaire mixte, la régression linéaire locale, la régression non-paramétrique, les arbres de régression, etc.