STT-2100

Régression

Université Laval

Document collaboratif de :
Anne-Sophie Charest
Thierry Duchesne
Anne-Catherine Favre
Christian Genest
Emmanuelle Reny-Nolin
Véronique Tremblay
Audrey-Anne Vallée

Octobre, 2026

Table des matières

1 Introduction **6**

1.1 Un peu d'histoire . . . 6

1.2 Modèle de régression . . . 7

1.3 Régression linéaire . . . 8

1.4 Objectifs de la régression . . . 8

2 Ajustement d'un modèle de régression linéaire simple (RLS) **10**

2.1 Le modèle de régression linéaire simple . . . 10

2.1.1 Postulats du modèle de RLS . . . 11

2.1.2 Interprétation de β_0 et β_1 . . . 12

2.2 Estimation des paramètres . . . 13

2.2.1 Méthode des moindres carrés . . . 13

2.2.2 Méthode du maximum de vraisemblance . . . 15

2.3 Exemple . . . 16

3 Inférence pour la RLS **19**

3.1 Inférence sur les paramètres . . . 19

3.1.1 Distribution des estimateurs . . . 19

3.1.2 Intervalles de confiance pour β_0 et β_1 . . . 22

3.1.3 Tests d'hypothèses . . . 24

3.2 Prévision . . . 25

3.2.1 Prévision de la valeur moyenne $\mathbb{E}[Y|x = x_0]$ . . . 25

3.2.2 Prévision d'une observation Y_0^* lorsque $x = x_0$ . . . 26

3.3 Décomposition de la variance . . . 28

3.3.1 Coefficient de détermination . . . 29

4 Notions pour la statistique multivariée **30**

4.1 Notions d'algèbre linéaire . . . 30

4.1.1 Définitions et opérations sur les matrices . . . 30

4.1.2 Propriétés du calcul matriciel . . . 31
4.1.3 Propriétés de la transposition et de l'inversion . . . 32
4.1.4 Projection orthogonale . . . 32
4.1.5 Dériver une fonction d'un vecteur . . . 32
4.2 Espérance et variance de variables aléatoires . . . 34
4.3 La loi normale multivariée . . . 35

5 Ajuster un modèle de régression linéaire multiple (RLM) 38
5.1 Le modèle de régression linéaire multiple . . . 38
5.1.1 Postulats du modèle de RLM . . . 40
5.1.2 Interprétation des paramètres . . . 40
5.2 Estimation des coefficients . . . 40
5.2.1 Méthode des moindres carrés . . . 41
5.2.2 Argument géométrique . . . 43
5.3 Exemple . . . 45

6 Inférence pour la RLM 48
6.1 Distribution de l'estimateur . . . 49
6.2 Matrice chapeau et implications . . . 50
6.2.1 La matrice chapeau . . . 50
6.2.2 Distribution de $\widehat{\boldsymbol{Y}}$ et $\widehat{\boldsymbol{\varepsilon}}$ . . . 51
6.2.3 Estimation de σ^2 . . . 51
6.3 Intervalle de confiance et test d'hypothèse pour un coefficient . . . 52
6.4 Prévision . . . 53
6.4.1 Inférence pour $\boldsymbol{a}^\top \boldsymbol{\beta}$ . . . 54
6.4.2 Inférence sur $\mathbb{E}(Y|\boldsymbol{x})$ . . . 54
6.4.3 Inférence sur une valeur de Y étant donné $\boldsymbol{x}$ . . . 55
6.4.4 Théorème de Gauss-Markov . . . 56
6.5 Analyse de la variance . . . 57
6.5.1 Test global de la régression . . . 57
6.6 Test de réduction du modèle . . . 59
6.6.1 Cas particuliers simples . . . 60
6.6.2 Point de vue géométrique . . . 62
6.7 Test d'une hypothèse linéaire générale . . . 63

7 Variables catégoriques et interactions 64
7.1 Variables exogènes catégoriques . . . 64
7.1.1 Inférence avec des variables catégoriques . . . 69

7.2 Interactions . . . 69

8 Choix de modèle pour la RLM **72**

8.1 Vérification des postulats et transformations . . . 73
8.1.1 Les résidus . . . 73
8.1.2 Vérification de la linéarité . . . 73
8.1.3 Homogénéité des variances . . . 75
8.1.4 Normalité des erreurs . . . 75
8.1.5 Transformation de Box-Cox . . . 75
8.1.6 Indépendance des erreurs . . . 75
8.1.7 Test pour manque d'ajustement (lack-of-fit) . . . 76
8.2 Importance de la sélection de variables . . . 78
8.3 Critères basés sur l'ajustement du modèle . . . 80
8.3.1 Coefficient de détermination . . . 80
8.3.2 Coefficient de détermination ajusté . . . 80
8.3.3 Critère d'information d'Akaike (AIC) . . . 80
8.3.4 Critère BIC ou SBC . . . 81
8.4 Méthodes basées sur la puissance de prévision . . . 81
8.4.1 Utilisation d'un jeu de validation . . . 82
8.4.2 La validation croisée . . . 82
8.4.3 Le C_p de Mallows . . . 83
8.5 Méthodes algorithmiques . . . 85
8.6 Régularisation (ou régression pénalisée) . . . 89
8.6.1 La régression « ridge » . . . 89
8.6.2 Le LASSO . . . 90
8.7 Le cas des variables catégoriques et interactions . . . 93
8.7.1 Sélection de modèle avec variables catégoriques . . . 93
8.7.2 Sélection de modèle en présence d'interactions . . . 93

9 Multicolinéarité **94**

9.1 Introduction et définition . . . 94
9.2 Détection de la multicolinéarité . . . 95
9.2.1 La matrice de corrélations . . . 95
9.2.2 Le facteur d'inflation de la variance (VIF) . . . 96
9.2.3 L'indice de conditionnement . . . 97
9.3 Les solutions possibles à la multicolinéarité . . . 99
9.3.1 La régression « ridge » . . . 99

9.3.2 La régression basée sur les composantes principales 99

10 Observations aberrantes et influentes **100**

10.1 Sources de l'influence 100

10.2 Mesures d'influence 101

10.2.1 Influence sur la prévision 102

10.2.2 Influence sur les estimations des paramètres 102

10.2.3 Influence sur la performance des estimateurs 103

10.3 Que faire avec les données influentes ? 103

11 Techniques plus avancées **105**

11.1 Régression polynomiale 105

11.2 Régression non linéaire 108

11.3 Régression pondérée 110

11.4 Modélisation de la dépendance 112

11.5 Autres 112

Table des figures

2.1 Illustration du modèle de régression linéaire simple 12
2.2 Diagramme de dispersion du rendement en fonction de la température 17
2.3 Diagramme de dispersion du rendement en fonction de la température avec la droite de régression estimée superposée 18

5.1 Représentation géométrique du modèle de régression linéaire multiple. 41
5.2 Représentation géométrique de la régression dans le cas où $p = 1$ et $n = 3$. 44

6.1 Illustration de l'analyse de la variance généralisée 57
6.2 Illustration de l'analyse de la variance généralisée 62

7.1 Espérance de la variable endogène Y en fonction de la variable exogène x_2 pour chacun des groupes 1 à 4. 68
7.2 Espérance de la variable endogène Y en fonction de la variable exogène x_2 pour chacune des valeurs de x_{1i}. 70

8.1 Illustration de la différence entre le LASSO et la régression ridge. 91

11.1 Données d'une expérience sur des rats de laboratoire avec la fonction de régression estimée 109

Chapitre 1

Introduction

Sommaire

1.1 Un peu d'histoire 6
1.2 Modèle de régression 7
1.3 Régression linéaire 8
1.4 Objectifs de la régression 8

1.1 Un peu d'histoire

L'origine du mot *régression* vient de Sir Francis Galton (1822–1911), un scientifique britannique. Cousin de Charles Darwin, Galton était un touche-à-tout intuitif qui fut anthropologue, explorateur, géographe, inventeur, météorologue, généticien, psychométricien et statisticien. En 1886, en travaillant sur l'hérédité, il s'est intéressé à la taille des enfants par rapport à celle de leurs parents. Il constata que lorsque les parents étaient plus grands que la moyenne, leurs enfants avaient tendance à être plus petits qu'eux et que, inversement, lorsque les parents étaient plus petits que la moyenne leurs enfants tendaient à être plus grands qu'eux. Il publia sa découverte dans l'article *Regression towards mediocrity in hereditary stature* (Galton, 1886). Il utilisa le terme régression dans le sens où les parents de taille extrême (petits et grands) voient en moyenne la taille de leurs enfants régresser vers la moyenne.

Par extension, on utilise maintenant le terme **analyse de régression** pour désigner l'étude des relations qui existent entre des variables mesurables à partir dobservations (données) prises sur ces variables.

L'analyse de la relation entre plusieurs variables est toutefois bien plus ancienne et remonte au milieu du XVIIIème siècle. En 1757, Ruđer Josip Bošcović (1711–1787) exposa une méthode minimisant la somme des valeurs absolues entre un modèle et les observations. Plus tard Adrien-Marie Legendre (1752–1833), célèbre mathématicien français, développa dans son mémoire *Nouvelles méthodes pour la détermination des orbites des comètes* (Legendre, 1805), la méthode d'estimation par moindres carrés

des paramètres d'un tel modèle, donnant le nom à cette méthode. Parallèlement, Carl Friedrich Gauss (1777-1855) publia en 1809 le développement de la méthode des moindres carrés (Gauss, 1809).

1.2 Modèle de régression

La régression est l'étude des relations qui existent entre des variables mesurables. C'est en fait une technique de modélisation qui vise à expliquer une variable Y en fonction d'une ou de plusieurs variables $x_1, \ldots, x_p$. Cela peut s'exprimer mathématiquement par

$$Y = f(x_1, \ldots, x_p). \tag{1.1}$$

La variable Y est appelée **variable endogène**. Ce terme signifie, selon le Larousse, « qui est produit par la structure elle-même en dehors de tout apport extérieur ». On appelle également la variable Y variable réponse ou variable dépendante. À l'opposé, les variables $x_1, \ldots, x_p$ ne sont pas expliquées par le modèle et on les nomme donc **variables exogènes**, qui signifie « qui provient du dehors, de l'extérieur du phénomène, par opposition à endogène ». On utilise également les termes variables explicatives, facteurs, covariables et variables indépendantes pour faire référence aux variables $x_1, \ldots, x_p$.

Dans certains cas, la relation entre les variables est exacte et donc la valeur de Y est uniquement déterminée par les valeurs de $x_1, \ldots, x_p$. Le modèle de régression est alors un modèle dit **déterministe**. On peut imaginer par exemple que la variable exogène soit la longueur de l'arête d'un carré, et que la variable endogène soit l'aire de ce carré. Un grand nombre de lois physiques sont également déterministes.

Exemple 1.1. *Le modèle d'atmosphère standard de l'Organisation de l'aviation civile internationale (OACI), couvrant les altitudes jusqu'à 80 km et ne prenant pas en compte la vapeur d'eau, exprime la relation entre la pression et l'altitude de la manière suivante :*

$$p = p_0(1 - 2,26 \times 10^{-5} h),$$

où p_0 désigne la pression au niveau de la mer en hPa ($p_0 = 1013,25\, hPa$) et h note l'altitude en m. Dans un modèle déterministe comme celui-ci, la valeur de la (ou des) variable(s) exogène(s) détermine exactement celle de la variable endogène.

Dans d'autres situations, il est possible que les données soient entachées d'une erreur de mesure (expérimentale) ou encore, que les facteurs utilisés dans le modèle ne permettent pas d'expliquer complètement la variable réponse. Les valeurs de $x_1, \ldots, x_p$ expliquent dans ce cas une partie de Y, alors que l'autre partie demeure inexpliquée. On parle alors de modèle **stochastique**. Par exemple, on peut vouloir prédire le poids d'un bébé à la naissance en fonction du nombre de jours de gestation. Bien qu'il y ait une relation entre ces deux variables, deux bébés nés avec la même durée de gestation n'auront pas nécessairement exactement le même poids à la naissance.

Dans plusieurs domaines où on s'intéresse à l'effet des variables les unes sur les autres, le modèle stochastique est le plus approprié. Pensons par exemple à l'effet de la pollution par l'ozone (O_3) sur la santé, au lien entre le revenu moyen d'un pays et l'espérance de vie de sa population, ou encore à l'effet de la température en hiver sur l'achalandage dans une station de ski. Dans ce cours, on s'intéressera uniquement aux modèles de régression stochastique.

1.3 Régression linéaire

Avec un nombre fini d'observations, on doit faire des hypothèses sur la fonction de régression $f(x_1, \ldots, x_p)$ pour pouvoir l'estimer. Dans ce cours nous nous intéressons principalement aux modèles de régression linéaire. Dans un tel modèle la valeur de la variable endogène est une fonction linéaire des paramètres :

$$Y = \beta_0 + \beta_1 f_1(x_1) + \beta_2 f_2(x_2) + \cdots + \beta_p f_p(x_p) + \text{fluctuation}, \tag{1.2}$$

où

- Y dénote la variable endogène,
- $x_1, \ldots, x_p$ représentent les variables exogènes,
- $f_1, \ldots, f_p$ sont des transformations connues des variables exogènes et
- $\beta_0, \ldots, \beta_p$ sont des paramètres de valeur inconnue qu'on estimera à l'aide des données.

La fluctuation indique que le modèle est stochastique, et non déterministe.

La contrainte de linéarité limite le type de relations pouvant être modélisées entre les variables d'intérêt. La régression linéaire est toutefois suffisante pour plusieurs situations, et largement utilisée en pratique pour sa simplicité et son interprétation accessible. Nous décrirons tout de même brièvement au chapitre 11 quelques méthodes qui peuvent être utilisées si la régression linéaire n'est pas appropriée.

Notons que dans le cas où une seule variable explicative (exogène) est considérée, le modèle est appelé **régression linéaire simple**. Ce modèle fait l'objet des premiers chapitres de ces notes de cours. Les chapitres suivants présentent le modèle de **régression linéaire multiple**, lorsque plusieurs variables explicatives sont utilisées pour modéliser la variable réponse.

1.4 Objectifs de la régression

Le but d'une analyse de régression est d'étudier les relations qui existent entre des variables mesurables sur des observations (données). Quatre objectifs spécifiques peuvent être identifiés pour une analyse de régression.

1. **La spécification d'un modèle**

   L'objectif consiste à décrire le lien entre les variables. On peut également vouloir tester si un modèle de régression linéaire est approprié.

Exemple 1.2. *Comment la température de fonctionnement d'un procédé influence-t-elle le rendement du produit ? La relation est-elle linéaire ?*

2. **L'estimation de paramètres**

   Cet objectif va souvent de pair avec le premier, mais on peut aussi vouloir estimer les paramètres d'un modèle déjà connu.

   Exemple 1.3. *La relation de Faber-Jackson est une loi empirique qui relie la luminosité L à la dispersion des vitesses σ des étoiles centrales des galaxies elliptiques. Mathématiquement, elle s'exprime comme $L = k\sigma^{\gamma}$, où γ est un indice approximativement égal à 4, selon la catégorie de galaxies considérées, et k est un paramètre du modèle. Il est facile de linéariser la relation en prenant le logarithme à gauche et à droite de l'égalité : $\log L = \gamma \log \sigma + \log k$. Le but consiste à estimer k et γ puis à tester si γ est significativement différent de 4 avec nos données.*

3. **La sélection de variables**

   On veut identifier la ou les variables exogènes qui expliquent la variable réponse.

   Exemple 1.4. *Parmi des variables météorologiques comme la température, l'humidité, le vent, etc., lesquelles ont une influence significative sur les pics d'ozone ?*

4. **La prévision**

   L'objectif est de prédire la variable réponse pour certaines valeurs des variables explicatives. Pour ce faire, il est en général nécessaire de spécifier le modèle, en estimer les paramètres et associer une marge d'erreur à ces estimations.

   Exemple 1.5. *Étant donné la température du mois de décembre 2010, quelle sera la consommation totale en électricité à Québec pour l'hiver 2010–2011 ?*

   Une analyse de régression permet souvent de répondre à plusieurs de ces objectifs. Nous verrons tout au long des notes de multiples outils pour ce faire.

Chapitre 2

Ajustement d'un modèle de régression linéaire simple (RLS)

Sommaire

2.1 Le modèle de régression linéaire simple 10
2.1.1 Postulats du modèle de RLS 11
2.1.2 Interprétation de β_0 et β_1 12
2.2 Estimation des paramètres 13
2.2.1 Méthode des moindres carrés 13
2.2.2 Méthode du maximum de vraisemblance 15
2.3 Exemple 16

Figures

2.1 Illustration du modèle de régression linéaire simple 12
2.2 Diagramme de dispersion du rendement en fonction de la température 17
2.3 Diagramme de dispersion du rendement en fonction de la température avec la droite de régression estimée superposée 18

2.1 Le modèle de régression linéaire simple

Le modèle de régression linéaire simple est un modèle dans lequel on cherche à expliquer une variable endogène Y en fonction d'une seule variable exogène x. Il s'exprime comme suit

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \tag{2.1}$$

où

— Y_i est une variable aléatoire représentant la réponse de l'unité i ;

— x_i est la valeur (connue) de la variable explicative de l'unité i ;

— β_0 est le paramètre associé à l'ordonnée à l'origine de la droite ;

— β_1 est le paramètre associé à la pente de la droite ;

— ε_i est une variable aléatoire représentant le terme d'erreur de l'unité i.

Il est important de comprendre quelles quantités sont supposées constantes ou aléatoires dans le modèle (2.1), à savoir

— $Y_1, \ldots, Y_n$ sont des variables aléatoires ;

— $x_1, \ldots, x_n$ sont des valeurs considérées constantes ;

— β_0 et β_1, les paramètres du modèle, sont constants ;

— $\varepsilon_1, \ldots, \varepsilon_n$ sont des variables aléatoires.

Les paramètres du modèle (2.1) sont inconnus et doivent être estimés. Pour les estimer, nous disposons de n réalisations, soit les couples (x_i, y_i), pour $i = 1, \ldots, n$. À noter que y_i est la réalisation de la variable aléatoire Y_i, pour $i = 1, \ldots, n$.

2.1.1 Postulats du modèle de RLS

Pour développer la théorie de la régression linéaire, il est nécessaire de formuler certains postulats sur le modèle défini en (2.1). Ces postulats peuvent être énoncés mathématiquement en termes d'hypothèses sur les termes d'erreur ε_i du modèle :

$\mathcal{P}_1$. La linéarité de la relation entre la variable réponse et la variable explicative :
$\mathbb{E}[\varepsilon_i] = 0$ pour $1 \leq i \leq n$.

$\mathcal{P}_2$. L'homoscédasticité (variance constante) des observations de la variable réponse :
$\mathbb{V}\text{ar}[\varepsilon_i] = \sigma^2$ pour $1 \leq i \leq n$.

$\mathcal{P}_3$. L'indépendance des observations de la variable réponse :
$\mathbb{C}\text{ov}(\varepsilon_i, \varepsilon_j) = 0$ pour $i \neq j$.

$\mathcal{P}_4$. La normalité des termes d'erreur :
$\varepsilon_1, \cdots, \varepsilon_n \sim \mathcal{N}(0, \sigma^2)$.

Le premier postulat est nécessaire pour l'interprétation des paramètres du modèle, et indique simplement que le modèle linéaire est approprié pour modéliser la relation entre les variables d'intérêt. Les deux postulats suivants permettent d'estimer la variance des estimateurs de β_0 et β_1. Obtenir une telle mesure de précision des estimateurs ponctuels est très important en pratique. À ces trois postulats, on doit souvent ajouter le quatrième postulat sur l'hypothèse de normalité des termes d'erreur. Il s'agit d'un postulat plus fort généralement utilisé parce qu'il permet de construire des intervalles de confiance

et de faire des tests d'hypothèses aisément [1]. On verra également que ce postulat est nécessaire à la mise en œuvre de la méthode du maximum de vraisemblance pour l'estimation des paramètres.

Il est évidemment possible que ces 4 postulats ne soient pas vérifiés en pratique. Nous verrons dans ce cours comment tester si chacun des postulats est vérifié et comment modifier le modèle au besoin. Nous verrons aussi brièvement d'autres modèles de régression qui peuvent être utilisés si une ou plusieurs des conditions d'application de la RLS ne sont pas vérifiées.

2.1.2 Interprétation de β_0 et β_1

La figure 2.1 illustre le modèle de régression linéaire simple. La ligne droite représente la valeur moyenne de Y en fonction de la valeur de x. Les variables Y_i sont distribuées de façon aléatoire autour de cette droite. Les termes d'erreur sont les différences entre les Y_i et la droite. Comme la variance de ces termes est constante en x, la distance moyenne des points à la droite est la même pour toute valeur de x. Finalement, l'absence de corrélation entre les termes d'erreur signifie que la valeur d'un terme d'erreur n'est pas influencée par la valeur des autres termes d'erreur.

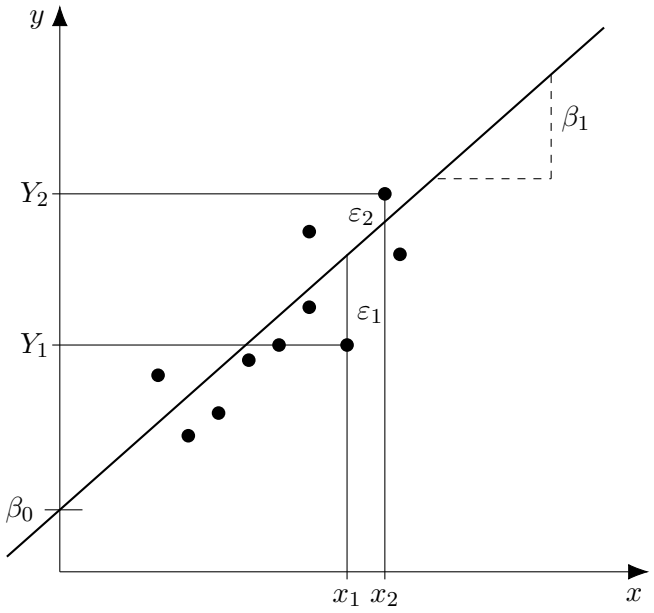


FIGURE 2.1 – Illustration du modèle de régression linéaire simple.

On interprète β_0 comme la valeur moyenne de Y lorsque x vaut zéro et β_1 comme l'accroissement moyen de Y lorsque x augmente d'une unité. Si $\beta_0 = 0$, l'espérance de Y est nulle lorsque x vaut zéro, et le modèle ne comporte pas d'ordonnée à l'origine. Si $\beta_1 = 0$, l'espérance de Y ne dépend pas de x, du moins pas de façon linéaire.

1. Il est également possible d'obtenir des intervalles de confiance et des tests d'hypothèses sans poser le postulat de normalité des erreurs, en utilisant par exemple la méthode du bootstrap.

Modèle centré

Il arrive que la valeur moyenne de Y lorsque x vaut zéro soit difficile ou inutile à interpréter. On peut alors utiliser une version centrée du modèle,

$$\begin{aligned} Y_i &= \beta_0 + \beta_1 x_i + \varepsilon_i \\ &= \beta_0^* + \beta_1(x_i - \overline{x}) + \varepsilon_i \text{ (version centrée).} \end{aligned}$$

Dans la version centrée du modèle, l'interprétation de β_1 est inchangée, mais β_0^* s'interprète comme étant la valeur moyenne de Y lorsque x vaut $\overline{x}$. On remarque que $\beta_0^* = \beta_0 + \beta_1\overline{x}$.

2.2 Estimation des paramètres

Dans le modèle de régression linéaire simple, on doit estimer trois paramètres : β_0 et β_1, qui décrivent la droite de régression, ainsi que σ^2, la variance des termes d'erreur. Deux approches communes pour estimer les paramètres d'un modèle de régression sont la méthode des moindres carrés et celle du maximum de vraisemblance. Dans les sections suivantes, on explique comment estimer les paramètres de régression à l'aide de ces deux approches, et on démontre qu'elles sont équivalentes sous le postulat de normalité $\mathcal{P}_4$.

2.2.1 Méthode des moindres carrés

Tel que mentionné au chapitre 1, on attribue généralement la méthode des moindres carrés au mathématicien français Adrien-Marie Legendre (1752-1833). Plusieurs autres mathématiciens de l'époque ont aussi publié des travaux sur le sujet, notamment Carl Friedrich Gauss (1777-1855) et Robert Adrain (1775-1843).

Soit $\widehat{Y}_i$ la prévision du modèle pour l'observation i. On appelle résidu la différence entre Y_i, la variable réponse, et cette prévision $\widehat{Y}_i$. On le dénote $\widehat{\varepsilon}_i$, puisque c'est une estimation du terme d'erreur ε_i.

Avec la méthode des moindres carrés, on cherche à choisir les estimateurs $\widehat{\beta}_0$ et $\widehat{\beta}_1$ de façon à minimiser la somme des carrés des erreurs. On veut donc minimiser la fonction

$$g(\beta_0, \beta_1) = \sum_{i=1}^{n} \varepsilon_i^2 = \sum_{i=1}^{n} \{Y_i - (\beta_0 + \beta_1 x_i)\}^2 . \tag{2.2}$$

Puisque la fonction à minimiser possède de bonnes propriétés (entre autres lisse et convexe), elle peut être minimisée en la dérivant par rapport à β_0 et β_1, puis en posant ces dérivées égales à zéro. On doit donc résoudre le système d'équations à deux inconnues suivant :

$$\left\{ \begin{array}{rcl} \frac{\partial}{\partial\beta_0} \sum\limits_{i=1}^{n} (Y_i - \beta_0 - \beta_1 x_i)^2 &=& 0, \\ \frac{\partial}{\partial\beta_1} \sum\limits_{i=1}^{n} (Y_i - \beta_0 - \beta_1 x_i)^2 &=& 0. \end{array} \right. \tag{2.3}$$

Estimation de β_0

On dérive d'abord par rapport à β_0 :

$$\begin{aligned}\frac{\partial}{\partial\beta_0}\left\{\sum_{i=1}^{n}(Y_i-\beta_0-\beta_1x_i)^2\right\} &= \sum_{i=1}^{n}2(Y_i-\beta_0-\beta_1x_i)(-1)\\ &= -2(n\overline{Y}-n\beta_0-n\beta_1\overline{x}).\end{aligned}$$

On pose ensuite cette dérivée égale à zéro, et elle est évaluée au point $\left(\widehat{\beta}_0,\widehat{\beta}_1\right)$. Il s'agit du point critique de la fonction $g(\beta_0,\,\beta_1)$:

$$\begin{aligned}-2(n\overline{Y}-n\widehat{\beta}_0-n\widehat{\beta}_1\overline{x}) &= 0,\\ \overline{Y}-\widehat{\beta}_0-\widehat{\beta}_1\overline{x} &= 0,\\ \widehat{\beta}_0 &= \overline{Y}-\widehat{\beta}_1\overline{x}.\end{aligned} \tag{2.4}$$

Remarque 1. *Il est à noter que l'équation* (2.4) *signifie que la droite de régression passe nécessairement par le point de coordonnées* $(\overline{x},\overline{Y})$ *:*

$$\overline{Y}=\widehat{\beta}_0+\widehat{\beta}_1\overline{x}. \tag{2.5}$$

Estimation de β_1

On dérive ensuite par rapport à β_1 :

$$\begin{aligned}\frac{\partial}{\partial\beta_1}\left\{\sum_{i=1}^{n}(Y_i-\beta_0-\beta_1x_i)^2\right\} &= \sum_{i=1}^{n}2(Y_i-\beta_0-\beta_1x_i)(-x_i)\\ &= -2\left(\sum_{i=1}^{n}x_iY_i-\sum_{i=1}^{n}\beta_0x_i-\sum_{i=1}^{n}\beta_1x_i^2\right).\end{aligned}$$

En posant cette dérivée égale à zéro, en l'évaluant au point $\left(\widehat{\beta}_0,\widehat{\beta}_1\right)$ et en utilisant (2.4), on a

$$\begin{aligned}-2\left(\sum_{i=1}^{n}x_iY_i-\sum_{i=1}^{n}\widehat{\beta}_0x_i-\sum_{i=1}^{n}\widehat{\beta}_1x_i^2\right) &= 0\\ \sum_{i=1}^{n}x_iY_i &= \widehat{\beta}_0\sum_{i=1}^{n}x_i+\widehat{\beta}_1\sum_{i=1}^{n}x_i^2\\ \sum_{i=1}^{n}x_iY_i &= (\overline{Y}-\widehat{\beta}_1\overline{x})\sum_{i=1}^{n}x_i+\widehat{\beta}_1\sum_{i=1}^{n}x_i^2\\ \sum_{i=1}^{n}x_iY_i &= \overline{Y}\sum_{i=1}^{n}x_i+\widehat{\beta}_1\left(\sum_{i=1}^{n}x_i^2-\overline{x}\sum_{i=1}^{n}x_i\right).\end{aligned}$$

On obtient l'estimateur

$$\widehat{\beta}_1=\frac{\sum\limits_{i=1}^{n}x_iY_i-\overline{Y}\sum\limits_{i=1}^{n}x_i}{\sum\limits_{i=1}^{n}x_i^2-\overline{x}\sum\limits_{i=1}^{n}x_i}. \tag{2.6}$$

Il est possible de réécrire $\widehat{\beta}_1$ sous les formes équivalentes suivantes :

$$\widehat{\beta}_1 = \frac{\sum_{i=1}^{n} x_i Y_i - n\overline{x}\,\overline{Y}}{\sum_{i=1}^{n} x_i^2 - n\overline{x}^2} = \frac{\sum_{i=1}^{n}(x_i - \overline{x})(Y_i - \overline{Y})}{\sum_{i=1}^{n}(x_i - \overline{x})^2} = \frac{\sum_{i=1}^{n}(x_i - \overline{x})Y_i}{\sum_{i=1}^{n}(x_i - \overline{x})^2}.$$

Ces différentes formes peuvent être utiles pour calculer $\widehat{\beta_1}$ selon le type d'information que nous avons sur les données. On simplifie parfois davantage la notation en écrivant

$$\widehat{\beta}_1 = \frac{S_{xy}}{S_{xx}}, \tag{2.7}$$

où

$$S_{xy} = \sum_{i=1}^{n}(x_i - \overline{x})\, Y_i = \sum_{i=1}^{n} x_i Y_i - \frac{1}{n}\left(\sum_{i=1}^{n} x_i\right)\left(\sum_{i=1}^{n} Y_i\right), \tag{2.8}$$

$$S_{xx} = \sum_{i=1}^{n}(x_i - \overline{x})^2 = \sum_{i=1}^{n} x_i^2 - \frac{1}{n}\left(\sum_{i=1}^{n} x_i\right)^2. \tag{2.9}$$

Il est à noter que S_{xy} et S_{xx} sont appelés respectivement la somme des produits croisés corrigée de x et Y et la somme des carrés corrigée de x. En somme, les estimateurs des moindres carrés pour la RLS sont

$$\widehat{\beta}_1 = \frac{S_{xy}}{S_{xx}}, \qquad \widehat{\beta}_0 = \overline{Y} - \widehat{\beta}_1\overline{x}. \tag{2.10}$$

2.2.2 Méthode du maximum de vraisemblance

La méthode du maximum de vraisemblance nécessite de spécifier la distribution exacte de $Y_1, \ldots, Y_n$. Celle-ci est connue sous l'hypothèse des quatre postulats établis à la section 2.1.1. Avec ceux-ci, on peut écrire le modèle sous la forme

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad \varepsilon_i \overset{iid}{\sim} N(0, \sigma^2),$$

ou, de façon équivalente,

$$Y_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2), \tag{2.11}$$

pour $i = 1, \ldots, n$. La vraisemblance s'exprime donc

$$\begin{aligned} L(\beta_0, \beta_1, \sigma^2) &= \prod_{i=1}^{n} f(Y_i) \\ &= \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2}\left(\frac{Y_i - \beta_0 - \beta_1 x_i}{\sigma}\right)^2\right\}. \end{aligned}$$

Pour simplifier les calculs, plutôt que de maximiser la vraisemblance $L(\beta_0, \beta_1)$, il est possible de maximiser son logarithme

$$\begin{aligned} l(\beta_0, \beta_1, \sigma^2) &= \sum_{i=1}^{n} \left\{ -\frac{1}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}(Y_i - \beta_0 - \beta_1 x_i)^2 \right\} \\ &= -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(Y_i - \beta_0 - \beta_1 x_i)^2. \end{aligned} \tag{2.12}$$

Les estimateurs $\widehat{\beta}_0$, $\widehat{\beta}_1$ et $\widehat{\sigma}^2$ sont les valeurs qui minimisent $l(\beta_0, \beta_1, \sigma^2)$ obtenues en dérivant respectivement par rapport à β_0, β_1 et σ^2 puis en posant les dérivées égales à zéro.

Dans l'équation (2.12), on remarque que le premier terme ne contient ni β_0, ni β_1. Maximiser la log-vraisemblance par rapport à β_0 et β_1 revient donc à maximiser le second terme. Ce dernier étant négatif, cela équivaut à minimiser $\sum_{i=1}^{n}(Y_i - \beta_0 - \beta_1 x_i)^2$, ce qui correspond exactement à la méthode des moindres carrés de Legendre. Ainsi, les estimateurs de la méthode du maximum de vraisemblance de β_0 et β_1 sont les mêmes que ceux obtenus avec la méthode des moindres carrés.

La méthode du maximum de vraisemblance présente toutefois certains avantages par rapport à la méthode des moindres carrés. Elle permet notamment d'estimer σ^2 de façon directe. Ceci permet de trouver la distribution des paramètres et des prévisions et de faire des tests d'hypothèse, comme on verra dans les sections suivantes.

Estimation de σ^2

On estime σ^2 de la même manière que β_0 et β_1 en dérivant le logarithme de la vraisemblance par rapport à σ^2,

$$\begin{aligned} \frac{\partial}{\partial\sigma^2}\left\{ -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(Y_i - \beta_0 - \beta_1 x_i)^2 \right\} &= -\frac{n}{2}\frac{1}{2\pi\sigma^2}2\pi + \frac{1}{\sigma^4}\frac{1}{2}\sum_{i=1}^{n}(Y_i - \beta_0 - \beta_1 x_i)^2 \\ &= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}\sum_{i=1}^{n}(Y_i - \beta_0 - \beta_1 x_i)^2. \end{aligned}$$

En posant la dérivée égale à zéro et en évaluant au point $\left(\widehat{\beta}_0, \widehat{\beta}_1, \widehat{\sigma}^2_{MV}\right)$, on a

$$\widehat{\sigma}^2_{MV} = \frac{1}{n}\sum_{i=1}^{n}(Y_i - \widehat{\beta_0} - \widehat{\beta_1} x_i)^2 = \frac{1}{n}\sum_{i=1}^{n}\widehat{\varepsilon_i}^2. \tag{2.13}$$

Rappelons que $\widehat{\varepsilon_i}$ désigne la différence entre la prédiction $\widehat{Y_i}$ et la variable Y_i.

2.3 Exemple

Le petit exemple qui va servir de fil conducteur pour les chapitres sur la régression linéaire simple est tiré de Hines et coll. (2012). Un ingénieur chimiste a analysé l'effet de la température de fonctionnement d'un procédé sur le rendement du produit. Les valeurs obtenues sont résumées ci-dessous.

TABLE 2.1 – 10 mesures du rendement en % en fonction de la température en °C

Température [°C]	100	110	120	130	140	150	160	170	180	190
Rendement [%]	45	51	54	61	66	70	74	78	85	89

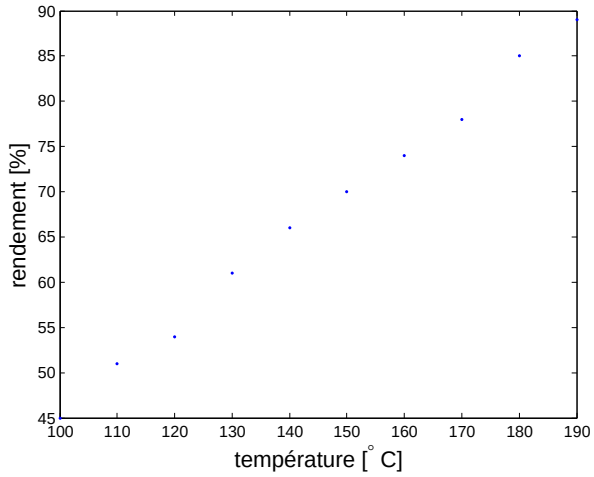


FIGURE 2.2 – Diagramme de dispersion du rendement en fonction de la température

On peut constater sur la figure 2.2 qu'il existe une relation forte entre le rendement et la température. Supposons que cette relation est linéaire, il est possible de modéliser ces données à l'aide de l'équation (2.1). On calcule d'abord

$$\sum_{i=1}^{10} x_i = 1450, \qquad \overline{x} = \frac{1}{10}\sum_{i=1}^{10} x_i = 145, \qquad \sum_{i=1}^{10} x_i^2 = 218\ 500,$$
$$\sum_{i=1}^{10} y_i = 673, \qquad \overline{y} = \frac{1}{10}\sum_{i=1}^{10} y_i = 67,3, \qquad \sum_{i=1}^{10} Y_i x_i = 101\ 570.$$

On obtient

$$S_{xx} = 218\ 500 - (1450)^2/10 = 8250,$$
$$S_{xy} = 101\ 570 - 1450 \times 673/10 = 3985.$$

Et donc

$$\widehat{\beta_1} = 3985/8250 = 0,483,$$
$$\widehat{\beta_0} = 67,3 - 0,483 \times 145 = -2,739.$$

Le modèle de régression linéaire simple ajusté est $\widehat{Y}_i = -2,739 + 0,483x_i$. Ainsi, une augmentation de un degré Celsius de la température du procédé est associée à une augmentation moyenne de $0,483$ point de pourcentage du rendement du produit. Le modèle indique aussi qu'à une température nulle, le rendement attendu est de $-2,739\%$.

La figure 2.3 montre l'ajustement obtenu sous forme d'une droite. Dans ce cas-ci la relation linéaire semble très appropriée pour modéliser la relation entre les variables.

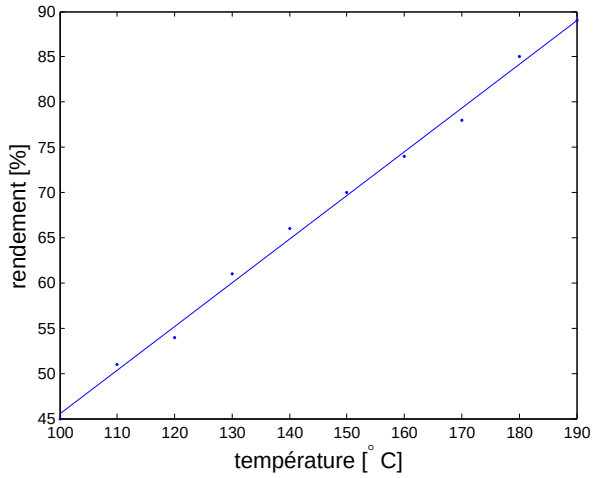


FIGURE 2.3 – Diagramme de dispersion du rendement en fonction de la température avec la droite de régression estimée superposée

On peut également estimer σ^2 à partir des données. Il faut d'abord calculer la valeur prédite et le résidu pour chacune des observations, comme au Tableau 2.2. L'équation (2.13) mène à

$$\widehat{\sigma}^2_{MV} = \frac{1}{10}\{(-0,561)^2 + \cdots + (-0,0301)^2\} = \frac{7,224}{10} = 0,7224.$$

TABLE 2.2 – Tableau résumant x_i, Y_i, $\hat{Y}_i$ et $\widehat{\varepsilon}_i$, $i = 1, \ldots, 10$ pour le calcul de $\widehat{\sigma}^2_{MV}$ dans l'exemple de la section 2.3

i	x_i	Y_i	$\hat{Y}_i$	$\widehat{\varepsilon}_i$
1	100	45	45,561	-0,561
2	110	51	50,391	0,609
3	120	54	55,221	-1,221
4	130	61	60,051	0,949
5	140	66	64,881	1,119
6	150	70	69,711	0,289
7	160	74	74,541	-0,541
8	170	78	79,371	-1,371
9	180	85	84,201	0,799
10	190	89	89,031	-0,031

Chapitre 3

Inférence pour la RLS

Sommaire

3.1 Inférence sur les paramètres 19
3.1.1 Distribution des estimateurs 19
3.1.2 Intervalles de confiance pour β_0 et β_1 22
3.1.3 Tests d'hypothèses 24
3.2 Prévision 25
3.2.1 Prévision de la valeur moyenne $\mathbb{E}[Y|x = x_0]$ 25
3.2.2 Prévision d'une observation Y_0^* lorsque $x = x_0$ 26
3.3 Décomposition de la variance 28
3.3.1 Coefficient de détermination 29

3.1 Inférence sur les paramètres

On a montré comment obtenir des estimations pour les différents paramètres du modèle de régression linéaire simple. Généralement, on souhaite également faire de l'inférence sur les vraies valeurs des paramètres β_0, β_1 et σ^2. Pour ce faire, on utilise la distribution des estimateurs.

3.1.1 Distribution des estimateurs

Distribution de $\widehat{\beta}_1$

On note d'abord que $\widehat{\beta}_1$ est une combinaison linéaire des Y_i. En effet,

$$\widehat{\beta}_1 = \frac{\sum_{i=1}^{n}(x_i - \overline{x})Y_i}{\sum_{i=1}^{n}(x_i - \overline{x})^2} = \sum_{i=1}^{n} a_i Y_i,$$

où

$$a_i = \frac{x_i - \overline{x}}{\sum_{i=1}^{n}(x_i - \overline{x})^2} = \frac{x_i - \overline{x}}{S_{xx}}.$$

Étant donné qu'une combinaison linéaire de variables aléatoires normales suit également une distribution normale, il s'ensuit que $\widehat{\beta}_1$ est distribué selon une loi normale. Il faut déterminer l'espérance et la variance de $\widehat{\beta}_1$. Notons d'abord que

$$\begin{aligned}
\sum_{i=1}^{n} a_i &= \frac{\sum_{i=1}^{n}(x_i - \overline{x})}{S_{xx}} = 0, \\
\sum_{i=1}^{n} a_i x_i &= \frac{\sum_{i=1}^{n}(x_i - \overline{x})x_i}{S_{xx}} = \frac{\sum_{i=1}^{n}(x_i - \overline{x})(x_i - \overline{x})}{S_{xx}} = \frac{S_{xx}}{S_{xx}} = 1.
\end{aligned}$$

Calculons l'espérance de β_1,

$$\begin{aligned}
\mathbb{E}\left(\widehat{\beta}_1\right) &= \sum_{i=1}^{n} a_i \mathbb{E}\left(Y_i\right) \\
&= \sum_{i=1}^{n} a_i \left(\beta_0 + \beta_1 x_i\right) \\
&= \beta_0 \sum_{i=1}^{n} a_i + \beta_1 \sum_{i=1}^{n} a_i x_i \\
&= \beta_1.
\end{aligned}$$

Ainsi, l'estimateur $\widehat{\beta}_1$ est un estimateur sans biais de β_1 puisque $\mathbb{E}\left(\widehat{\beta}_1\right) - \beta_1 = 0$. Calculons la variance de $\widehat{\beta}_1$,

$$\begin{aligned}
\mathbb{V}\mathsf{ar}\left(\widehat{\beta}_1\right) &= \mathbb{V}\mathsf{ar}\left(\sum_{i=1}^{n} a_i Y_i\right) \\
&= \sum_{i=1}^{n} a_i^2 \, \mathbb{V}\mathsf{ar}\left(Y_i\right) \\
&= \sum_{i=1}^{n} \frac{(x_i - \overline{x})^2}{S_{xx}^2} \, \mathbb{V}\mathsf{ar}\left(Y_i\right) \\
&= \frac{1}{S_{xx}^2} \sum_{i=1}^{n} (x_i - \overline{x})^2 \, \mathbb{V}\mathsf{ar}\left(Y_i\right) \\
&= \frac{S_{xx}}{S_{xx}^2} \sigma^2 \\
&= \frac{\sigma^2}{S_{xx}}.
\end{aligned}$$

Ainsi, la distribution de $\widehat{\beta}_1$ est

$$\widehat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{S_{xx}}\right). \tag{3.1}$$

Remarque 2. *Seulement certaines hypothèses de la RLS ont été nécessaires pour calculer cette distribution. Lesquelles ? Et que nous indique la forme de cette distribution sur l'estimation de la pente dans un modèle de régression linéaire simple ?*

Distribution de $\widehat{\beta}_0$

L'estimateur $\widehat{\beta}_0$ peut également s'exprimer comme une combinaison linéaire des Y_i,

$$\begin{aligned}\widehat{\beta}_0 &= \overline{Y} - \widehat{\beta}_1 \overline{x} \\ &= \sum_{i=1}^{n} \frac{Y_i}{n} - \overline{x} \sum_{i=1}^{n} a_i Y_i \\ &= \sum_{i=1}^{n} \left(\frac{1}{n} - a_i \overline{x} \right) Y_i.\end{aligned}$$

Par le même raisonnement que pour $\widehat{\beta}_1$, on a donc que $\widehat{\beta}_0$ est distribué selon une loi normale. On peut calculer l'espérance et la variance de $\widehat{\beta}_1$. Pour l'espérance, on a que

$$\begin{aligned}\mathbb{E}\left(\widehat{\beta}_0\right) &= \mathbb{E}\left(\overline{Y} - \widehat{\beta}_1 \overline{x}\right) \\ &= \frac{1}{n} \sum_{i=1}^{n} \mathbb{E}\left(Y_i\right) - \overline{x}\, \mathbb{E}\left(\widehat{\beta}_1\right) \\ &= \frac{1}{n} \sum_{i=1}^{n} \left(\beta_0 + \beta_1 x_i\right) - \overline{x} \beta_1 \\ &= \beta_0 + \beta_1 \overline{x} - \beta_1 \overline{x} \\ &= \beta_0.\end{aligned}$$

Pour la variance, on a

$$\begin{aligned}\mathbb{V}\mathsf{ar}\left(\widehat{\beta}_0\right) &= \mathbb{V}\mathsf{ar}\left(\overline{Y} - \widehat{\beta}_1 \overline{x}\right) \\ &= \mathbb{V}\mathsf{ar}\left(\frac{1}{n} \sum_{i=1}^{n} Y_i\right) + \overline{x}^2\, \mathbb{V}\mathsf{ar}\left(\widehat{\beta}_1\right) - 2\overline{x}\, \mathbb{C}\mathsf{ov}\left(\overline{Y}, \widehat{\beta}_1\right) \\ &= \frac{\sigma^2}{n} + \overline{x}^2 \frac{\sigma^2}{S_{xx}} \\ &= \sigma^2 \left(\frac{1}{n} + \frac{\overline{x}^2}{S_{xx}} \right).\end{aligned}$$

Pour obtenir l'expression finale pour cette variance, il faut démontrer que $\mathbb{C}\mathsf{ov}[\overline{Y}, \widehat{\beta}_1] = 0$, ce qui est laissé en exercice. On obtient ainsi la loi pour $\widehat{\beta}_0$,

$$\widehat{\beta}_0 \sim \mathcal{N}\left\{ \beta_0, \left(\frac{1}{n} + \frac{\overline{x}^2}{S_{xx}} \right) \sigma^2 \right\}. \tag{3.2}$$

Exemple 3.1. *Calculons la variance de $\widehat{\beta}_0$ et $\widehat{\beta}_1$ de l'exemple de la section 2.3. On doit pour ce faire connaître la valeur de la variance des termes d'erreur. Supposons ici que $\sigma^2 = 1$. On sait déjà que $n = 10, \overline{x} = 145$ et $S_{xx} = 8250$. Par conséquent on a*

$$\mathbb{V}ar[\widehat{\beta}_0] = \left(\frac{1}{10} + \frac{145^2}{8250}\right)(1) = 2,648,$$
$$\mathbb{V}ar[\widehat{\beta}_1] = \frac{1^2}{8250} = 1,212 \times 10^{-4}.$$

3.1.2 Intervalles de confiance pour β_0 et β_1

On peut utiliser les distributions de $\widehat{\beta}_0$ et $\widehat{\beta}_1$ pour construire des intervalles de confiance pour β_0 et β_1. Pour déterminer l'intervalle de confiance pour β_1, on centre et réduit la variable aléatoire pour obtenir

$$\frac{\widehat{\beta}_1 - \beta_1}{\sqrt{\sigma^2/S_{xx}}} \sim \mathcal{N}(0,1). \tag{3.3}$$

Si σ^2 était connue, un intervalle de confiance de niveau $100(1-\alpha)\%$ serait donné par

$$\left[\widehat{\beta}_1 \pm z_{1-\alpha/2}\frac{\sigma}{\sqrt{S_{xx}}}\right].$$

Or, σ^2 n'est généralement pas connue et on doit l'estimer. L'estimateur du maximum de vraisemblance de cette quantité est

$$\widehat{\sigma}^2_{MV} = \sum_{i=1}^{n}\frac{\widehat{\varepsilon}_i^2}{n},$$

mais ce dernier est biaisé. On utilisera donc plutôt l'estimateur non biaisé défini par

$$\widehat{\sigma}^2 = \frac{1}{n-2}\sum_{i=1}^{n}\widehat{\varepsilon}_i^2.$$

Remplacer σ^2 par $\widehat{\sigma}^2$ dans le terme de gauche de (3.3) a toutefois pour conséquence que cette variable aléatoire ne suit plus une loi normale. On peut néanmoins montrer, en utilisant des notions de statistique mathématique, que

$$\frac{\dfrac{\widehat{\beta}_1 - \beta_1}{\sigma/\sqrt{S_{xx}}}}{\sqrt{\dfrac{\widehat{\sigma}^2}{\sigma^2}}} \sim \mathcal{T}_{n-2}. \tag{3.4}$$

On peut alors déduire un intervalle de confiance de niveau $100(1-\alpha)\%$ pour β_1,

$$\left[\widehat{\beta}_1 \pm t_{n-2;1-\alpha/2}\left(\frac{\widehat{\sigma}}{\sqrt{S_{xx}}}\right)\right], \tag{3.5}$$

où $t_{n-2;1-\alpha/2}$ dénote le $(1-\alpha/2)$-ième quantile d'une loi $\mathcal{T}$ à $(n-2)$ degrés de liberté.

Il est possible de construire de la même manière un intervalle de confiance pour β_0. On obtient l'intervalle de confiance

$$\left[\widehat{\beta}_0 \pm t_{n-2;1-\alpha/2}\,\widehat{\sigma}\sqrt{\frac{1}{n}+\frac{\overline{x}^2}{S_{xx}}}\right]. \tag{3.6}$$

Remarque 3. *Pour arriver à (3.4), on note que*

$$\frac{\dfrac{\widehat{\beta}_1-\beta_1}{\sigma/\sqrt{S_{xx}}}}{\sqrt{\dfrac{\sum_{i=1}^{n}\widehat{\varepsilon}_i^2}{\sigma^2(n-2)}}}=\frac{U}{\sqrt{V/\nu}},$$

où $U=\left(\widehat{\beta}_1-\beta_1\right)/\left(\sigma/\sqrt{S_{xx}}\right)$ *est distribué selon une loi normale centrée réduite et* $V=\left(\sum_{i=1}^{n}\widehat{\varepsilon}_i^2\right)/\sigma^2$ *suit une loi du khi-carré à* $\nu=(n-2)$ *degrés de liberté, puisque c'est une somme du carré de variables aléatoires normales. Comme il s'agit d'un rapport entre une variable aléatoire normale centrée réduite et la racine carrée d'une variable khi-carré divisée par son degré de liberté* $(n-2)$*, on obtient la distribution d'une loi* $\mathcal{T}$ *de Student à* $(n-2)$ *degrés de liberté (*$\mathcal{T}_{n-2}$*),*

$$\frac{\dfrac{\widehat{\beta}_1-\beta_1}{\sigma/\sqrt{S_{xx}}}}{\sqrt{\dfrac{\sum_{i=1}^{n}\widehat{\varepsilon}_i^2}{\sigma^2(n-2)}}}\sim\frac{\mathcal{N}(0,1)}{\sqrt{\chi^2_{n-2}/(n-2)}}\sim\mathcal{T}_{n-2}.$$

Exemple 3.2. *Calculons un intervalle de confiance pour* β_0 *et* β_1 *de l'exemple 2.3. La plupart des quantités nécessaires ont déjà été calculées. Il ne manque que*

$$\widehat{\sigma}=\sqrt{\frac{1}{10-2}\sum_{i=1}^{10}\widehat{\varepsilon}_i^2}=\sqrt{\frac{7,224}{8}}=0,950.$$

Si on fixe $\alpha=5\%$*, il faut calculer* $t_{n-2;0,975}$*. On peut trouver dans une table que ce quantile est* $t_{8;0,975}=2,306$*. On obtient alors les intervalles suivants :*

$$\left[\widehat{\beta}_0\pm 2,306\times 0,950\sqrt{1/10+145^2/8250}\right]=\left[\widehat{\beta}_0\pm 3,566\right]=[-6,305;0,827]\,,$$

$$\left[\widehat{\beta}_1\pm 2,306\times 0,950/\sqrt{8250}\right]=\left[\widehat{\beta}_1\pm 0,024\right]=[0,459;0,507].$$

3.1.3 Tests d'hypothèses

On peut également se baser sur les distributions déterminées à la section 3.1.1 pour mettre en œuvre des tests d'hypothèses sur la valeur des coefficients. Considérons le test bilatéral

$$\begin{aligned}\mathcal{H}_0 &: \ \beta_j = c,\\ \mathcal{H}_1 &: \ \beta_j \neq c.\end{aligned}$$

Notons

$$\begin{aligned}\widehat{\mathrm{Var}}\left(\widehat{\beta}_0\right) &= \widehat{\sigma}^2\left(\frac{1}{n} + \frac{\overline{x}^2}{S_{xx}}\right),\\ \widehat{\mathrm{Var}}\left(\widehat{\beta}_1\right) &= \frac{\widehat{\sigma}^2}{S_{xx}}.\end{aligned}$$

Sous $\mathcal{H}_0$,

$$\frac{\widehat{\beta}_j - c}{\widehat{\mathrm{Var}}\left(\widehat{\beta}_j\right)} \sim \mathcal{T}_{n-2}.$$

Soit $t_{obs} = \left(\widehat{\beta}_j - c\right)/\widehat{\mathrm{Var}}\left(\widehat{\beta}_j\right)$ la statistique observée du test. La décision du test d'hypothèses au seuil α peut être prise de trois façons.

(i) Valeur critique : Soit le quantile théorique $t_{n-2;1-\alpha/2}$. Si $|t_{obs}| > t_{n-2;1-\alpha/2}$, l'hypothèse nulle $\mathcal{H}_0 : \ \beta_j = c$ est rejetée.

(ii) Valeur-p : Soit $\alpha^* = \mathbb{P}(|t_{n-2}| > |t_{\text{obs}}|) = 2\mathbb{P}(t_{n-2} > |t_{\text{obs}}|)$ la valeur-p. Si $\alpha^* < \alpha$, l'hypothèse nulle $\mathcal{H}_0 : \ \beta_j = c$ est rejetée.

(iii) Intervalle de confiance : Si la valeur c n'est pas comprise dans l'intervalle de confiance pour β_j de niveau $1-\alpha$, l'hypothèse nulle $\mathcal{H}_0 : \ \beta_j = c$ est rejetée.

Il est aussi possible de faire des test unilatéraux. Pour le test

$$\begin{aligned}\mathcal{H}_0 &: \ \beta_j = c,\\ \mathcal{H}_1 &: \ \beta_j < c,\end{aligned}$$

les règles de décisions sont

(i) Valeur critique : Si $t_{obs} < -t_{n-2;1-\alpha}$, l'hypothèse nulle $\mathcal{H}_0 : \ \beta_j = c$ est rejetée.

(ii) Valeur-p : Si $\alpha^* = \mathbb{P}(t_{n-2} < t_{\text{obs}}) < \alpha$, l'hypothèse nulle $\mathcal{H}_0 : \ \beta_j = c$ est rejetée.

Pour le test

$$\begin{aligned}\mathcal{H}_0 &: \ \beta_j = c,\\ \mathcal{H}_1 &: \ \beta_j > c,\end{aligned}$$

les règles de décisions sont

(i) Valeur critique : Si $t_{obs} > t_{n-2;1-\alpha}$, l'hypothèse nulle $\mathcal{H}_0 : \beta_j = c$ est rejetée.

(ii) Valeur-p : Si $\alpha^* = \mathbb{P}(t_{n-2} > t_{\text{obs}}) < \alpha$, l'hypothèse nulle $\mathcal{H}_0 : \beta_j = c$ est rejetée.

Un cas particulier, souvent d'intérêt, est le test bilatéral avec $c = 0$. Pour la pente, ceci correspond aux hypothèses $\mathcal{H}_0 : \beta_1 = 0$, $\mathcal{H}_1 : \beta_1 \neq 0$. Si l'hypothèse nulle de ce test est rejetée, le lien linéaire entre Y et x n'est pas significatif et le modèle se réduit à $Y_i = \beta_0 + \varepsilon_i$. Pour l'ordonnée à l'origine, on a $\mathcal{H}_0 : \beta_0 = 0$, $\mathcal{H}_1 : \beta_0 \neq 0$. Si l'hypothèse nulle de ce test est rejetée, l'ordonnée à l'origine n'est pas significativement différente de 0 et le modèle se réduit à $Y_i = \beta_1 x_i + \varepsilon_i$.

Exemple 3.3. *Toujours avec les données de la section 2.3, on a*

$$t_{obs} = \frac{\widehat{\beta}_1}{\widehat{\sigma}/\sqrt{S_{xx}}} = \frac{0,483}{0,950/\sqrt{8250}} = 46,17.$$

Un logiciel nous permet d'obtenir 5.35×10^{-11} *comme valeur de* p *correspondante. On rejette donc l'hypothèse d'une pente nulle au seuil* $\alpha = 0,05$*. Notez qu'on aurait pu arriver à la même conclusion simplement à l'aide de l'intervalle de confiance construit à l'exemple 3.2. En effet, l'intervalle de confiance à 95% pour* β_1 *ne contient pas la valeur* 0*, ce qui permet de rejeter l'hypothèse que* $\beta_1 = 0$ *au seuil* $\alpha = 0,05$*.*

3.2 Prévision

On a déjà défini $\widehat{Y}_i = \widehat{\beta}_0 + \widehat{\beta}_1 x_i$, la prévision du modèle en x_i. Avant de définir un intervalle de confiance, deux intérêts doivent être distingués :

(i) l'estimation de $\mathbb{E}[Y|x = x_0]$, la valeur moyenne de Y pour une valeur $x = x_0$ de la variable explicative.

(ii) l'estimation de Y_0^*, soit la valeur d'une observation/réalisation de Y lorsque la variable explicative prend la valeur x_0.

Dans le premier cas, on souhaite estimer la valeur de la droite en x_0, alors que dans le deuxième cas, on s'intéresse à une réalisation de la variable réponse, qui n'est pas nécessairement sur la droite. L'intervalle de confiance sera plus grand dans le deuxième cas, pour tenir compte de la variabilité additionnelle causée par la fluctuation aléatoire autour de la droite.

3.2.1 Prévision de la valeur moyenne $\mathbb{E}[Y|x = x_0]$

Soit $\mathbb{E}[Y|x = x_0]$, la valeur moyenne de Y lorsque $x = x_0$. Cette quantité est estimée par $\widehat{Y}_0 = \widehat{\beta}_0 + \widehat{\beta}_1 x_0$. On utilise le fait que $Y_i \sim \mathcal{N}(\beta_0 + \beta_1 x_i, \sigma^2)$ pour déterminer la distribution de $\widehat{Y}_0$. On

exprime d'abord $\widehat{Y}_0$ sous la forme d'une combinaison linéaire des Y_i,

$$\begin{aligned}\widehat{Y}_0 &= \widehat{\beta}_0 + \widehat{\beta}_1 x_0 \\ &= \sum_{i=1}^{n} \left(\frac{1}{n} - a_i\overline{x}\right) Y_i + \left(\sum_{i=1}^{n} a_i Y_i\right) x_0 \\ &= \sum_{i=1}^{n} \left(\frac{1}{n} - a_i\overline{x} + a_i x_0\right) Y_i \\ &= \sum_{i=1}^{n} c_i Y_i,\end{aligned}$$

où

$$c_i = \frac{1}{n} - a_i\overline{x} + a_i x_0.$$

On peut montrer que $\sum_{i=1}^{n} c_i = 1$, que $\sum_{i=1}^{n} c_i x_i = x_0$ et que $\sum_{i=1}^{n} c_i^2 = 1/n + (\overline{x} - x_0)^2/S_{xx}$. On peut ensuite en déduire que

$$\mathbb{E}\left(\widehat{Y}_0\right) = \sum_{i=1}^{n} c_i \mathbb{E}\left(Y_i\right) = \sum_{i=1}^{n} c_i(\beta_0 + \beta_1 x_i) = \beta_0 + \beta_1 x_0, \tag{3.7}$$

$$\mathbb{V}\text{ar}\left(\widehat{Y}_0\right) = \sum_{i=1}^{n} c_i^2 \mathbb{V}\text{ar}\left(Y_i\right) = \left\{\frac{1}{n} + \frac{(\overline{x} - x_0)^2}{S_{xx}}\right\}\sigma^2. \tag{3.8}$$

Puisque $\widehat{Y}_0$ est une combinaison linéaire des Y_i, qui suivent une loi normale, $\widehat{Y}_0$ suit aussi une loi normale. On a donc

$$\widehat{Y}_0 \sim \mathcal{N}\left\{\beta_0 + \beta_1 x_0, \left(1/n + \frac{(\overline{x} - x_0)^2}{S_{xx}}\right)\sigma^2\right\}. \tag{3.9}$$

À partir de ce résultat, il est possible de calculer un intervalle de confiance autour de la valeur moyenne de Y en $x = x_0$ en remplaçant σ^2 par son estimateur $\widehat{\sigma}^2$. En utilisant le même raisonnement qu'à la section 3.1.2, on obtient l'intervalle de confiance de niveau $1 - \alpha$ pour $\mathbb{E}[Y|x = x_0]$,

$$\left[\left(\widehat{\beta}_0 + \widehat{\beta}_1 x_0\right) \pm t_{n-2;1-\alpha/2}\, \widehat{\sigma}\, \sqrt{\frac{1}{n} + \frac{(\overline{x} - x_0)^2}{S_{xx}}}\right]. \tag{3.10}$$

3.2.2 Prévision d'une observation Y_0^* lorsque $x = x_0$

Il est important de comprendre que l'intervalle de confiance défini à l'équation (3.10) concerne la moyenne de Y au point $x = x_0$. Pour construire ce qu'on appelle un intervalle de prévision, il faut considérer à la fois la variance liée à l'estimation des paramètres et la variance liée à la variabilité naturelle du phénomène, c'est-à-dire la variance du terme d'erreur ε. Or, l'équation (3.8) ne tient pas compte de la variance du terme d'erreur σ^2.

Désignons la prévision de la moyenne de Y en x_0 par $\widehat{Y}_0 = \widehat{\beta}_0 + \widehat{\beta}_1 x_0$ et la prévision d'une observation individuelle par $\widehat{Y}_0^* = \widehat{\beta}_0 + \widehat{\beta}_1 x_0 + \varepsilon$. L'espérance de $\widehat{Y}_0$ et celle de $\widehat{Y}_0^*$ sont égales parce que l'espérance des termes d'erreur est nulle. Ce n'est pas le cas des variances. On a que

$$\begin{aligned} \mathbb{V}\text{ar}\left(\widehat{Y}_0^*\right) &= \mathbb{V}\text{ar}\left(\widehat{Y}_0\right) + \mathbb{V}\text{ar}\left(\varepsilon\right) \\ &= \left\{\frac{1}{n} + \frac{(\overline{x} - x_0)^2}{S_{xx}}\right\}\sigma^2 + \sigma^2 \\ &= \left\{1 + \frac{1}{n} + \frac{(\overline{x} - x_0)^2}{S_{xx}}\right\}\sigma^2. \end{aligned} \tag{3.11}$$

Le méthode de calcul de l'intervalle de prévision de niveau $1-\alpha$ pour Y_0^* est similaire à celle de l'intervalle de confiance pour $\mathbb{E}[Y|x = x_0]$. On obtient donc

$$\left[\left(\widehat{\beta}_0 + \widehat{\beta}_1 x_0\right) \pm t_{n-2;1-\alpha/2}\, \widehat{\sigma}\, \sqrt{1 + \frac{1}{n} + \frac{(\overline{x} - x_0)^2}{S_{xx}}}\right]. \tag{3.12}$$

En analysant les expressions (3.8) et (3.11), nous constatons que les variances diminuent lorsque n augmente ou que S_{xx} augmente. Cela signifie que plus la taille de l'échantillon est grande et/ou plus il y a de la variabilité dans les valeurs de la variable indépendante, plus les estimations seront précises. Au contraire, plus le point x_0 pour lequel une prévision est requise est éloigné du centre de la variable explicative $(\overline{x})$, plus la prévision sera imprécise. Il est important de prendre ces remarques en considération lors de la planification des expériences.

Remarque 4. *L'intervalle de prévision pour Y_0^* sera toujours plus large que l'intervalle de confiance pour $\mathbb{E}[Y|x = x_0]$. Pour cette raison, il peut arriver dans la pratique qu'un client préfère présenter l'intervalle de confiance plutôt que l'intervalle de prévision. Il est important de bien comprendre et de bien expliquer la distinction entre les deux intervalles pour éviter une mauvaise interprétation des résultats.*

Exemple 3.4. *On désire calculer un intervalle de confiance au niveau 95 % pour le rendement moyen du produit ($\mathbb{E}[Y|x = x_0]$) lorsque la température de fonctionnement est de 150 °C et pour le rendement d'un produit spécifique (Y_0^*) lorsque la température est de 150 °C. Dans les deux cas, la prévision est $\widehat{Y}_0 = \widehat{\beta}_0 + \widehat{\beta}_1 \times 150 = -2,739 + 0,483 \times 150 = 69,711\%$.*

La plupart des quantités nécessaires au calcul des deux intervalles ont été déjà calculées auparavant. On tire de la section 2.3 que $\overline{x} = 145, S_{xx} = 8250$ et de l'exemple 3.2 que $\widehat{\sigma} = 0,950$ et que $t_{8;0,975} = 2,306$. Il nous reste seulement à calculer $(x_0 - \overline{x})^2 = (150 - 145)^2 = 25$. En utilisant l'équation (3.10), on obtient l'intervalle de confiance du rendement moyen :

$$\left[69,711 \pm 2,306 \times 0,950 \times \sqrt{1/10 + 25/8250}\right] = [69,711 \pm 0,703] = [69,008; 70,414].$$

L'intervalle de prévision du rendement d'un produit quelconque, appelé également intervalle de

prévision, se calcule à l'aide de l'équation (3.12) :

$$\left[69,711 \pm 2,306 \times 0,950 \times \sqrt{1+1/10+25/8250}\right] = [69,711 \pm 2,301] = [67,410; 72,012].$$

Comme mentionné, l'intervalle de prévision est plus large que l'intervalle de confiance pour $\mathbb{E}[Y|x = 150]$.

3.3 Décomposition de la variance

Une partie de la différence entre les Y_i peut être expliquée par la différence entre les x_i, puisque selon le modèle de régression la variable réponse est expliquée en partie par la variable explicative. Il reste une partie de la variabilité des Y_i qui n'est pas expliquée par les différences dans les valeurs de x_i. On peut écrire

$$Y_i - \overline{Y} = \left(\widehat{Y}_i - \overline{Y}\right) + \left(Y_i - \widehat{Y}_i\right).$$

On a aussi que

$$\begin{aligned}
\sum_{i=1}^{n}\left(Y_i - \overline{Y}\right)^2 &= \sum_{i=1}^{n}\left(Y_i - \widehat{Y}_i + \widehat{Y}_i - \overline{Y}\right)^2 \\
&= \sum_{i=1}^{n}\left(Y_i - \widehat{Y}_i\right)^2 + \sum_{i=1}^{n}\left(\widehat{Y}_i - \overline{Y}\right)^2 + 2\sum_{i=1}^{n}\left(Y_i - \widehat{Y}_i\right)\left(\widehat{Y}_i - \overline{Y}\right) \\
&= \sum_{i=1}^{n}\left(Y_i - \widehat{Y}_i\right)^2 + \sum_{i=1}^{n}\left(\widehat{Y}_i - \overline{Y}\right)^2.
\end{aligned}$$

Notons

$$SC_{tot} = SC_{reg} + SC_{res}, \tag{3.13}$$

où

- $SC_{tot} = \sum_{i=1}^{n}(Y_i - \overline{Y})^2$, la somme des carrés totale, quantifie la variabilité des Y_i autour de leur valeur moyenne ;
- $SC_{reg} = \sum_{i=1}^{n}(\widehat{Y}_i - \overline{Y})^2$, la somme des carrés de la régression, quantifie la variabilité des prévisions $\widehat{Y}_i$. Les $\widehat{Y}_i$ ne varient qu'avec les x_i, cette somme de carrés est donc la partie de la variabilité des Y_i expliquée par le fait que toutes les observations n'ont pas la même valeur de x_i ;
- $SC_{res} = \sum_{i=1}^{n}(Y_i - \widehat{Y}_i)^2$, la somme des carrés résiduelle, quantifie la variabilité dans les $(Y_i - \widehat{Y}_i)$. Cette variabilité est induite par le fait que la valeur de Y_i n'est pas expliquée parfaitement par le modèle de régression.

Exemple 3.5. *Toujours dans l'exemple du rendement d'un produit en fonction de la température*

de fonctionnement du procédé, on peut calculer

$$SC_{tot} = \sum_{i=1}^{n}(Y_i - \overline{Y})^2 = 1931,2,$$
$$SC_{res} = \sum_{i=1}^{n}(Y_i - \widehat{Y}_i)^2 = (n-2) * \widehat{\sigma}^2 = 7,224,$$
$$SC_{reg} = \sum_{i=1}^{n}(\widehat{Y}_i - \overline{Y})^2 = 1924,876.$$

On vérifie alors que $SC_{tot} = SC_{reg} + SC_{res}$. On note que la température à elle seule ne peut pas expliquer en totalité le fait que toutes les expériences ne possèdent pas le même rendement.

3.3.1 Coefficient de détermination

La décomposition de la variance permet de quantifier la qualité du modèle de régression linéaire à l'aide du coefficient de détermination,

$$R^2 = \frac{SC_{reg}}{SC_{tot}}. \tag{3.14}$$

Notons que $0 \leq R^2 \leq 1$. Le coefficient de détermination s'interprète comme la proportion de la variance des Y_i expliquée par le modèle. Lorsque $R^2 = 0$, le modèle n'explique absolument pas la variabilité des Y_i. Quand $R^2 = 1$, tous les points sont alignés sur la droite de régression, c'est-à-dire que l'ajustement du modèle est parfait et que la valeur de Y_i est une fonction exacte de x_i. Ainsi, une valeur élevée du R^2 indique que le modèle est bon. Le seuil à partir duquel on considère que le R^2 est élevé est très variable et assez subjectif. Il dépend notamment des objectifs de la régression et du domaine d'application.

Le coefficient de détermination correspond au carré de la corrélation entre les valeurs observées et les valeurs prédites

$$R^2 = \frac{SC_{reg}}{SC_{tot}} = \mathbb{C}\text{orr}^2(Y, \widehat{Y}) = \left(\frac{\sum_{i=1}^{n}(Y_i - \overline{Y})(\widehat{Y}_i - \overline{Y})}{\sqrt{\sum_{i=1}^{n}(Y_i - \overline{Y})^2 \sum_{i=1}^{n}(\widehat{Y}_i - \overline{Y})^2}} \right)^2.$$

Exemple 3.6. *Dans notre exemple,*

$$R^2 = \frac{1924,876}{1931,1} = 0,9967,$$

ce qui indique que la température prédit presque parfaitement le rendement de l'expérience. Des valeurs aussi grandes sont plutôt rares en pratique.

Chapitre 4

Notions pour la statistique multivariée

Sommaire

4.1 Notions d'algèbre linéaire 30
4.1.1 Définitions et opérations sur les matrices 30
4.1.2 Propriétés du calcul matriciel 31
4.1.3 Propriétés de la transposition et de l'inversion 32
4.1.4 Projection orthogonale 32
4.1.5 Dériver une fonction d'un vecteur 32
4.2 Espérance et variance de variables aléatoires 34
4.3 La loi normale multivariée 35

4.1 Notions d'algèbre linéaire

4.1.1 Définitions et opérations sur les matrices

Définition 4.1. *Une **matrice** réelle $m \times n$ est un tableau ordonné de nombres réels arrangés en m lignes et n colonnes. On appelle ce tableau matrice de dimension $m \times n$. Une matrice $\boldsymbol{A}$ et ses éléments a_{ij}, $i = 1, \ldots, m$ et $j = 1, \ldots, n$, peuvent s'écrire*

$$\boldsymbol{A} = \begin{bmatrix} a_{11} & \cdots & a_{1j} & \cdots & a_{1n} \\ \vdots & & \vdots & & \vdots \\ a_{i1} & \cdots & a_{ij} & \cdots & a_{in} \\ \vdots & & \vdots & & \vdots \\ a_{m1} & \cdots & a_{mj} & \cdots & a_{mn} \end{bmatrix}.$$

Définition 4.2. *Soit $\boldsymbol{A}$ une matrice de dimension $m \times n$ quelconque, alors la **matrice transposée** de $\boldsymbol{A}$, notée $\boldsymbol{A}^\top$ ou $\boldsymbol{A}'$, est de dimension $n \times m$ et comprend les éléments $\alpha_{ji} = a_{ij}$, $i = 1, \ldots, m$; $j = 1, \ldots, n$.*

Définition 4.3. *Une matrice carrée (de dimension $n \times n$) $\boldsymbol{A}$ est **symétrique** si ses éléments sont tels que*

$$a_{ij} = a_{ji}$$

pour $i, j = 1, \ldots, n$. Une matrice symétrique est égale à sa transposée, $\boldsymbol{A} = \boldsymbol{A}^\top$.

Définition 4.4. *Soit une matrice $\boldsymbol{A}$ carrée de dimension $n \times n$. La **matrice inverse** de $\boldsymbol{A}$, notée $\boldsymbol{A}^{-1}$ est la matrice qui satisfait*

$$\boldsymbol{A}\boldsymbol{A}^{-1} = \boldsymbol{A}^{-1}\boldsymbol{A} = \mathbf{I}_n,$$

où $\mathbf{I}_n$ est la matrice identité de dimension n.

Définition 4.5. *Soit une matrice $\boldsymbol{A}$ carrée de dimension $n \times n$. La matrice $\boldsymbol{A}$ est **idempotente** si la multiplication par elle-même ne la modifie pas, $\boldsymbol{A}\boldsymbol{A} = \boldsymbol{A}$.*

Définition 4.6. *La **somme matricielle** $\mathbf{C} = \boldsymbol{A} + \mathbf{B}$ de deux matrices $\boldsymbol{A}$ $(m \times n)$ et $\mathbf{B}$ $(m \times n)$ est la matrice C (de même dimension que $\boldsymbol{A}$ et $\mathbf{B}$) dont les éléments sont*

$$c_{ij} = a_{ij} + b_{ij} \qquad i = 1, \ldots, m;\ j = 1, \ldots, n.$$

Définition 4.7. *Le produit du scalaire $k, k \in \mathbb{R}$, et de la matrice $\boldsymbol{A}$ de dimension $m \times n$ est la matrice $\mathbf{C}$ de dimension $m \times n$, $\mathbf{C} = k\boldsymbol{A}$, dont les éléments sont*

$$c_{ij} = ka_{ij} \ \ i = 1, \ldots, m;\ j = 1, \ldots, n.$$

Définition 4.8. *Soient $\boldsymbol{A}$ et $\mathbf{B}$ deux matrices de dimensions respectives $m \times r$ et $r \times n$. Le **produit matriciel** $\mathbf{C} = \mathbf{AB}$ correspond à la matrice $\mathbf{C}$ de dimension $m \times n$ dont les éléments sont*

$$c_{ij} = \sum_{k=1}^{r} a_{ik} b_{kj}, \quad i = 1, \ldots, m;\ j = 1, \ldots, n.$$

Il est à noter que le produit matriciel n'est défini que si le nombre de colonnes de $\boldsymbol{A}$ est égal au nombre de lignes de $\mathbf{B}$. L'élément c_{ij} correspond au produit scalaire euclidien du $i^{\text{ème}}$ vecteur ligne de $\boldsymbol{A}$ par le $j^{\text{ème}}$ vecteur colonne de $\mathbf{B}$.

4.1.2 Propriétés du calcul matriciel

En supposant des matrices compatibles pour les opérations en question, on a que

(i) Commutativité de la somme : $\boldsymbol{A} + \mathbf{B} = \mathbf{B} + \mathbf{A}$

(ii) Associativité de la somme : $(\mathbf{A} + \mathbf{B}) + \mathbf{C} = \mathbf{A} + (\mathbf{B} + \mathbf{C})$

(iii) Associativité du produit : $(\mathbf{AB})\mathbf{C} = \mathbf{A}(\mathbf{BC})$

(iv) Divers types de distributivité :

$$\begin{aligned}\mathbf{A}(\mathbf{B}+\mathbf{C}) &= \mathbf{AB}+\mathbf{AC}\\ (\mathbf{A}+\mathbf{B})\mathbf{C} &= \mathbf{AC}+\mathbf{BC}\\ k(\mathbf{A}+\mathbf{B}) &= k\mathbf{A}+k\mathbf{B}\\ (k_1+k_2)\mathbf{A} &= k_1\mathbf{A}+k_2\mathbf{A}\end{aligned}$$

(v) Divers types d'associativité :

$$\begin{aligned}k_1(k_2\mathbf{C}) &= k_1k_2\mathbf{C}\\ k(\mathbf{AB}) &= (k\mathbf{A})\mathbf{B}=\mathbf{A}(k\mathbf{B})\end{aligned}$$

4.1.3 Propriétés de la transposition et de l'inversion

(i) $(\mathbf{A}+\mathbf{B})^\top = \mathbf{A}^\top + \mathbf{B}^\top$

(ii) $(k\mathbf{A})^\top = k\mathbf{A}^\top$

(iii) $(\mathbf{AB})^\top = \mathbf{B}^\top\mathbf{A}^\top$

(iv) $(\mathbf{A}^\top)^\top = \mathbf{A}$

(v) $(\mathbf{A}^{-1})^{-1} = \mathbf{A}$

(vi) $(\mathbf{A}^\top)^{-1} = (\mathbf{A}^{-1})^\top$

(vii) $(\mathbf{AB})^{-1} = \mathbf{B}^{-1}\mathbf{A}^{-1}$

4.1.4 Projection orthogonale

Soit $\mathbf{V}$ un sous-espace vectoriel de $\mathbb{R}^n$ et une matrice $\mathbf{X}$ dont les colonnes forment une base de $\mathbf{V}$. La **matrice de projection orthogonale** sur l'espace engendré par les colonnes de $\mathbf{X}$ est

$$\mathbf{P}_\mathbf{X} = \boldsymbol{X}\left(\boldsymbol{X}^\top\boldsymbol{X}\right)^{-1}\boldsymbol{X}^\top.$$

Cette matrice de projection est idempotente et symétrique. Ainsi, $\mathbf{P}_{\boldsymbol{X}} = \mathbf{P}_{\boldsymbol{X}}^\top = \mathbf{P}_{\boldsymbol{X}}\mathbf{P}_{\boldsymbol{X}}$.

Soit un vecteur $\mathbf{y} \in \mathbb{R}^n$. Sa projection sur $\mathbf{V}$ est obtenue le multipliant à la matrice de projection, soit $\mathbf{P}_{\boldsymbol{X}}\mathbf{y}$.

4.1.5 Dériver une fonction d'un vecteur

Soit une fonction scalaire $f : \mathbb{R}^n \to \mathbb{R}$ et un vecteur $\boldsymbol{x} = (x_1, \ldots, x_n)^\top$. Pour dériver $f(\boldsymbol{x})$ par rapport à $\boldsymbol{x}$, il faut appliquer la dérivée partielle à $f(\boldsymbol{x})$ par rapport à chaque composante du vecteur

$\boldsymbol{x}$. Ainsi,

$$\frac{\partial f(\boldsymbol{x})}{\partial \boldsymbol{x}} = \begin{pmatrix} \dfrac{\partial f(\boldsymbol{x})}{\partial x_1} \\ \dfrac{\partial f(\boldsymbol{x})}{\partial x_2} \\ \vdots \\ \dfrac{\partial f(\boldsymbol{x})}{\partial x_n} \end{pmatrix}.$$

Exemple 4.1. *Soit un vecteur* $\boldsymbol{x} = (x_1, \ldots, x_n)^\top$*, un vecteur* $\boldsymbol{u} = (u_1, \ldots, u_n)^\top$ *et une matrice symétrique* $\boldsymbol{A}$ *de dimension* $n \times n$*.*

(i) Calculons $\partial \boldsymbol{x}^\top \boldsymbol{u}/\partial \boldsymbol{x}$*. On a*

$$\boldsymbol{x}^\top \boldsymbol{u} = \begin{pmatrix} x_1 & \cdots & x_n \end{pmatrix} \begin{pmatrix} u_1 \\ \vdots \\ u_n \end{pmatrix} = x_1 u_1 + \ldots x_n u_n$$

et

$$\frac{\partial \boldsymbol{x}^\top \boldsymbol{u}}{\partial x_1} = u_1, \quad \ldots, \quad \frac{\partial \boldsymbol{x}^\top \boldsymbol{u}}{\partial x_n} = u_n.$$

Ainsi,

$$\frac{\partial \boldsymbol{x}^\top \boldsymbol{u}}{\partial \boldsymbol{x}} = \begin{pmatrix} \dfrac{\partial \boldsymbol{x}^\top \boldsymbol{u}}{\partial x_1} \\ \vdots \\ \dfrac{\partial \boldsymbol{x}^\top \boldsymbol{u}}{\partial x_n} \end{pmatrix} = \begin{pmatrix} u_1 \\ \vdots \\ u_n \end{pmatrix} = \boldsymbol{u}.$$

(ii) Calculons $\partial \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}/\partial \boldsymbol{x}$*. On a*

$$\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x} = \begin{pmatrix} x_1 & \cdots & x_n \end{pmatrix} \begin{pmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{pmatrix} \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} = \sum_{i=1}^{n} \sum_{j=1}^{n} x_i x_j a_{ij}$$

qui peut s'écrire

$$\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x} = \sum_{i=1}^{n}\sum_{\substack{j=1\\ i\neq j}}^{n} x_i x_j a_{ij} + \sum_{i=1}^{n} x_i^2 a_{ii}.$$

Alors

$$\begin{aligned}\frac{\partial \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}}{\partial x_1} &= \sum_{i=2}^{n} x_i a_{i1} + \sum_{j=2}^{n} x_j a_{1j} + 2x_1 a_{11}\\ &= \sum_{i=1}^{n} x_i a_{i1} + \sum_{j=1}^{n} x_j a_{1j}\\ &= 2\sum_{j=1}^{n} x_j a_{1j} \quad \textit{puisque } A \textit{ est symétrique.}\end{aligned}$$

Ainsi,

$$\frac{\partial \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}}{\partial \boldsymbol{x}} = \begin{pmatrix} \dfrac{\partial \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}}{\partial x_1} \\ \vdots \\ \dfrac{\partial \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}}{\partial x_n} \end{pmatrix} = 2\begin{pmatrix} \sum_{j=1}^{n} x_j a_{1j} \\ \vdots \\ \sum_{j=1}^{n} x_j a_{nj} \end{pmatrix} = 2\boldsymbol{A}\boldsymbol{x}.$$

4.2 Espérance et variance de variables aléatoires

Soit $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)^\top$, un vecteur de n variables aléatoires et $\boldsymbol{A}$ et $\boldsymbol{B}$, des matrices de constantes. L'espérance de $\boldsymbol{X}$ est

$$\mathbb{E}(\boldsymbol{X}) = \begin{pmatrix} \mathbb{E}(X_1) \\ \mathbb{E}(X_2) \\ \vdots \\ \mathbb{E}(X_n) \end{pmatrix}$$

et la variance de $\boldsymbol{X}$ est

$$\mathbb{V}\text{ar}\left(\boldsymbol{X}\right) = \begin{pmatrix} \mathbb{V}\text{ar}(X_1) & \mathbb{C}\text{ov}(X_1, X_2) & \cdots & \mathbb{C}\text{ov}(X_1, X_n) \\ \mathbb{C}\text{ov}(X_2, X_1) & \mathbb{V}\text{ar}(X_2) & \cdots & \mathbb{C}\text{ov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \mathbb{C}\text{ov}(X_n, X_1) & \mathbb{C}\text{ov}(X_n, X_2) & \cdots & \mathbb{V}\text{ar}(X_n) \end{pmatrix}.$$

Les propriétés de l'espérance et de la variance sous forme matricielle sont

(i) $\mathbb{E}\left(\boldsymbol{AX} + \boldsymbol{B}\right) = \boldsymbol{A}\mathbb{E}\left(\boldsymbol{X}\right) + \boldsymbol{B}$

(ii) $\mathbb{V}\text{ar}\left(\boldsymbol{AX}\right) = \boldsymbol{A}\mathbb{V}\text{ar}\left(\boldsymbol{X}\right)\boldsymbol{A}'$

(iii) $\mathbb{V}\text{ar}\left(\boldsymbol{AX} + \boldsymbol{B}\right) = \boldsymbol{A}\mathbb{V}\text{ar}\left(\boldsymbol{X}\right)\boldsymbol{A}'$.

4.3 La loi normale multivariée

Dans le cas d'une variable aléatoire Z distribuée selon une loi normale centrée réduite, $Z \sim \mathcal{N}(0,1)$, la densité de Z s'écrit

$$f_Z(z) = \frac{1}{\sqrt{2\pi}} \exp\left(\frac{-z^2}{2}\right).$$

Une variable aléatoire X de distribution normale avec une moyenne μ et une variance σ^2 peut s'écrire $X = \sigma Z + \mu$. On dit dans ce cas que $X \sim \mathcal{N}(\mu, \sigma^2)$. La densité de cette variable X s'écrit

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right\}.$$

On considère maintenant la généralisation pour $n \geq 1$. Posons $\boldsymbol{Z} = (Z_1, \ldots, Z_n)^\top$, un vecteur de variables aléatoires indépendantes et identiquement distribuées suivant chacune une loi $\mathcal{N}(0,1)$. On a que la densité conjointe des Z_i peut s'écrire comme

$$\begin{aligned} f(\boldsymbol{Z}) = f(Z_1, ..., Z_n) &= \prod_{i=1}^{p} f(Z_i) \\ &= \left(\frac{1}{\sqrt{2\pi}}\right)^n \exp\left(-\sum_{i=1}^{n} \frac{z_i^2}{2}\right) \\ &= \left(\frac{1}{\sqrt{2\pi}}\right)^n \exp\left(-\frac{1}{2}\boldsymbol{Z}'\boldsymbol{Z}\right). \end{aligned} \tag{4.1}$$

Cette densité conjointe est celle d'une loi normale multivariée de dimension n, dont le vecteur des espérances est $\mathbf{0}$, un vecteur $n \times 1$ de zéros, et dont la matrice de variances-covariances est $\mathbb{I}_n$, la

matrice identité de dimension $(n \times n)$. On peut écrire

$$\begin{pmatrix} Z_1 \\ Z_2 \\ \vdots \\ Z_n \end{pmatrix} \sim \mathcal{N}_n(\mathbf{0}, \mathbb{I}_n) \quad \text{ou encore, } \boldsymbol{Z} \sim \mathcal{N}_n(\mathbf{0}, \mathbb{I}_n).$$

Considérons la transformation de variables $\boldsymbol{X} = \boldsymbol{\mu} + \boldsymbol{\Sigma}^{(1/2)}\boldsymbol{Z}$, où $\boldsymbol{\mu}$ désigne le vecteur contenant les espérances des n variables et $\boldsymbol{\Sigma}$ dénote la matrice de variances-covariances de $\boldsymbol{X}$ (de dimension $n \times n$). La densité conjointe des X_i est alors donnée par

$$\begin{aligned} f(\boldsymbol{X}) = f(X_1, ..., X_n) &= \left(\frac{1}{\sqrt{2\pi}}\right)^n \frac{1}{|\boldsymbol{\Sigma}|^{1/2}} \exp\left\{-\frac{1}{2}(\boldsymbol{X}-\boldsymbol{\mu})'(\boldsymbol{\Sigma}^{-1/2})'\boldsymbol{\Sigma}^{-1/2}(\boldsymbol{X}-\boldsymbol{\mu})\right\} \\ &= \left(\frac{1}{\sqrt{2\pi}}\right)^n \frac{1}{|\boldsymbol{\Sigma}|^{1/2}} \exp\left\{-\frac{1}{2}(\boldsymbol{X}-\boldsymbol{\mu})'\boldsymbol{\Sigma}^{-1}(\boldsymbol{X}-\boldsymbol{\mu})\right\}. \end{aligned} \tag{4.2}$$

Cette densité est celle d'une loi normale multivariée de dimension n, et on peut écrire

$$\begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{pmatrix} \sim \mathcal{N}_n(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \quad \text{ou encore, } \boldsymbol{X} \sim \mathcal{N}_n(\boldsymbol{\mu}, \boldsymbol{\Sigma}).$$

Remarque 5. *On a posé $\boldsymbol{X} = \boldsymbol{\mu} + \boldsymbol{\Sigma}^{(1/2)}\boldsymbol{Z}$. On peut déterminer l'espérance et la variance de $\boldsymbol{X}$ à partir de celles de $\boldsymbol{Z}$.*

$$\begin{aligned} \mathbb{E}[\boldsymbol{X}] &= \mathbb{E}[\boldsymbol{\mu} + \boldsymbol{\Sigma}^{1/2}\boldsymbol{Z}] \\ &= \mathbb{E}[\boldsymbol{\mu}] + \boldsymbol{\Sigma}^{1/2}\mathbb{E}[\boldsymbol{Z}] \\ &= \boldsymbol{\mu}, \end{aligned}$$

$$\begin{aligned} \mathbb{V}ar[\boldsymbol{X}] &= \mathbb{V}ar[\boldsymbol{\Sigma}^{1/2}\boldsymbol{Z}] \\ &= (\boldsymbol{\Sigma}^{1/2})'\mathbb{V}ar[\boldsymbol{Z}]\boldsymbol{\Sigma}^{1/2} \\ &= (\boldsymbol{\Sigma}^{1/2})'\mathbb{I}_p\boldsymbol{\Sigma}^{1/2} \\ &= \boldsymbol{\Sigma}. \end{aligned}$$

Remarque 6. *On pourrait appliquer la transformation inverse et déduire le vecteur des variables aléatoires centrées réduites comme suit :*

$$\boldsymbol{Z} = \boldsymbol{\Sigma}^{(-1/2)}(\boldsymbol{X} - \boldsymbol{\mu}).$$

Finalement, il est possible de transformer une variable aléatoire normale. Voici un cas particulier d'intérêt pour le cours.

Théorème 1. *Si $\boldsymbol{X} \sim \mathcal{N}_n(\mathbf{0}, \mathbb{I}_n)$ et $\boldsymbol{A}$ est une matrice symétrique, alors $\boldsymbol{X}^\top \boldsymbol{A}\boldsymbol{X} \sim \chi^2_r$ si et seulement si $\boldsymbol{A}$ est idempotente de rang r.*

Chapitre 5

Ajuster un modèle de régression linéaire multiple (RLM)

Sommaire

5.1 Le modèle de régression linéaire multiple 38
5.1.1 Postulats du modèle de RLM 40
5.1.2 Interprétation des paramètres 40
5.2 Estimation des coefficients 40
5.2.1 Méthode des moindres carrés 41
5.2.2 Argument géométrique 43
5.3 Exemple 45

Figures

5.1 Représentation géométrique du modèle de régression linéaire multiple. 41
5.2 Représentation géométrique de la régression dans le cas où $p = 1$ et $n = 3$. 44

5.1 Le modèle de régression linéaire multiple

Le modèle de régression linéaire multiple constitue une généralisation du modèle de régression linéaire simple permettant d'étudier la relation une variable réponse Y avec p variables explicatives $x_1, x_2, ..., x_p$. L'équation du modèle de régression linéaire multiple s'exprime de la manière suivante

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \ldots + \beta_p x_{ip} + \varepsilon_i, \qquad i = 1, \ldots, n; \quad j = 1, \ldots, p, \tag{5.1}$$

où

— Y_i est une variable aléatoire représentant la réponse de l'unité i ;

— x_{ij} est la valeur (connue) de la j-ème variable explicative de l'unité i ;

— β_0 et β_j, $j = 1, \ldots, p$, sont les paramètres du modèle ;

— ε_i est une variable aléatoire représentant le terme d'erreur de l'unité i.

Notons

— n, le nombre d'observations ;

— p, le nombre de variables explicatives ;

— $p' = p + 1$, le nombre de paramètres à estimer ;

— $\boldsymbol{Y} = \begin{pmatrix} Y_1 & \cdots & Y_n \end{pmatrix}^\top$, le vecteur $n \times 1$ contenant les n observations à venir (pas encore observées) de la variable réponse ;

— $\boldsymbol{\beta} = \begin{pmatrix} \beta_0 & \beta_1 & \cdots & \beta_p \end{pmatrix}^\top$, le vecteur $p' \times 1$ contenant les p' coefficients de régression ;

— $\boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 & \cdots & \varepsilon_n \end{pmatrix}^\top$, le vecteur $n \times 1$ des termes d'erreur ;

— $\boldsymbol{X}$, la matrice de design (ou d'incidence) $n \times p'$ contenant les observations des p variables explicatives (incluant une colonne de 1 associée à β_0),

$$\boldsymbol{X} = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}.$$

Le modèle de régression linéaire multiple peut s'écrire à l'aide d'une notation matricielle,

$$\underbrace{\begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}}_{n \times 1} = \underbrace{\begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}}_{n \times (p+1)} \underbrace{\begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}}_{(p+1) \times 1} + \underbrace{\begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}}_{n \times 1},$$

que l'on écrit

$$\boldsymbol{Y} = \boldsymbol{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}. \tag{5.2}$$

Exemple 5.1. *Dans le cas de la régression linéaire simple, $p = 1$ et on peut écrire*

$$\boldsymbol{Y} = \underbrace{\begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}}_{n \times 1}, \quad \boldsymbol{X} = \underbrace{\begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}}_{n \times 2}, \quad \boldsymbol{\beta} = \underbrace{\begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}}_{2 \times 1}, \quad \boldsymbol{\varepsilon} = \underbrace{\begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}}_{n \times 1},$$

On a alors

$$\begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix} = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix} = \begin{pmatrix} \beta_0 + \beta_1 x_1 + \varepsilon_1 \\ \beta_0 + \beta_1 x_2 + \varepsilon_2 \\ \vdots \\ \beta_0 + \beta_1 x_n + \varepsilon_n \end{pmatrix},$$

et le modèle de régression linéaire simple défini à l'équation (2.1) peut s'exprimer

$$\boldsymbol{Y} = \boldsymbol{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}.$$

5.1.1 Postulats du modèle de RLM

Les postulats émis sur le modèle de régression linéaire multiple sont les mêmes que ceux émis sur le modèle de régression linéaire simple. Pour $i, j = 1, \ldots, n$, on a

$\mathcal{P}_1$. La linéarité de la relation entre la variable réponse et les variables explicatives, $\mathbb{E}[\varepsilon_i] = 0$;

$\mathcal{P}_2$. L'homoscédasticité (variance constante) des observations de la variable réponse, $\mathbb{V}\text{ar}[\varepsilon_i] = \sigma^2$;

$\mathcal{P}_3$. L'indépendance des observations de la variable réponse, $\mathbb{C}\text{ov}(\varepsilon_i, \varepsilon_j) = 0$ pour $i \neq j$;

$\mathcal{P}_4$. La normalité des termes d'erreur, $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$.

5.1.2 Interprétation des paramètres

Dans le modèle de RLM défini à l'équation (5.1), et sous le postulat $\mathcal{P}_1$. $\mathbb{E}[\varepsilon_i] = 0$ pour $i = 1, \ldots, n$, le coefficient β_0 représente la valeur moyenne de Y_i lorsque $x_{i1}, \ldots, x_{ip}$ prennent toutes simultanément la valeur 0. Le coefficient β_j, $j = 1, \ldots, p$, représente la variation dans la moyenne de Y_i lorsque x_j augmente d'une unité et que la valeur de toutes les autres variables explicatives reste constante.

Dans le modèle de régression linéaire simple, les points Y sont situés autour d'une droite, alors que dans le modèle de régression linéaire multiple, ils sont dispersés autour d'un hyperplan. Le coefficient β_j représente la pente de l'hyperplan dans la direction de la variable explicative j. Voir la figure 5.1.

5.2 Estimation des coefficients

Les coefficients de régression β_0, β_1, ..., β_p doivent être estimés. Nous présentons dans cette section la méthode des moindres carrés et une approche géométrique. Il est aussi possible d'utiliser la méthode du maximum de vraisemblance pour obtenir des estimateurs des coefficients, ce qui ne sera pas présenté dans le cadre de la RLM.

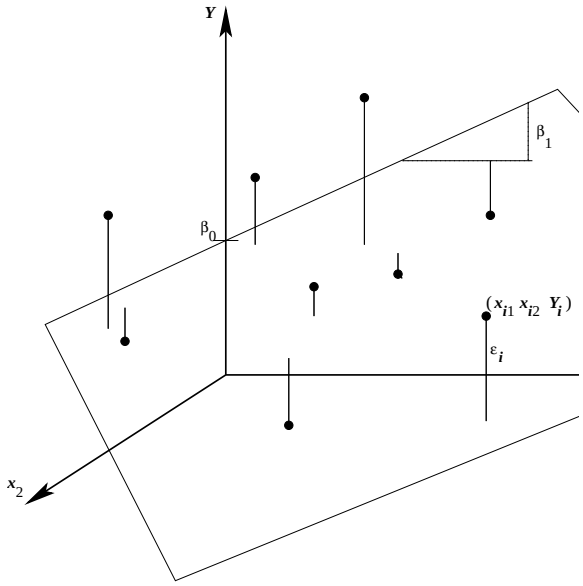


FIGURE 5.1 – Représentation géométrique du modèle de régression linéaire multiple.

5.2.1 Méthode des moindres carrés

Comme dans le cas de la régression linéaire simple, on adopte à nouveau le principe des moindres carrés de Legendre. On cherche par conséquent le vecteur $\boldsymbol{\beta}$ qui minimise la somme des carrés des résidus ($\sum_{i=1}^{n} \widehat{\varepsilon}_i^2$). Le vecteur des résidus s'exprime

$$\boldsymbol{\varepsilon} = (\varepsilon_1, \varepsilon_2, ..., \varepsilon_n)^\top = \boldsymbol{Y} - \boldsymbol{X}\boldsymbol{\beta},$$

on a alors

$$\sum_{i=1}^{n} \varepsilon_i^2 = \boldsymbol{\varepsilon}^\top \boldsymbol{\varepsilon} = (\boldsymbol{Y} - \boldsymbol{X}\boldsymbol{\beta})^\top (\boldsymbol{Y} - \boldsymbol{X}\boldsymbol{\beta}) = f(\boldsymbol{\beta}).$$

La fonction $f(\widehat{\boldsymbol{\beta}})$ s'écrit comme

$$\begin{aligned} f(\boldsymbol{\beta}) &= \left[\boldsymbol{Y}^\top - (\boldsymbol{X}\boldsymbol{\beta})^\top\right](\boldsymbol{Y} - \boldsymbol{X}\boldsymbol{\beta}) \\ &= \boldsymbol{Y}^\top\boldsymbol{Y} - \boldsymbol{Y}^\top\boldsymbol{X}\boldsymbol{\beta} - (\boldsymbol{X}\boldsymbol{\beta})^\top\boldsymbol{Y} + (\boldsymbol{X}\boldsymbol{\beta})^\top(\boldsymbol{X}\boldsymbol{\beta}) \\ &= \boldsymbol{Y}^\top\boldsymbol{Y} - 2\boldsymbol{\beta}^\top\boldsymbol{X}^\top\boldsymbol{Y} + \boldsymbol{\beta}^\top\boldsymbol{X}^\top\boldsymbol{X}\boldsymbol{\beta}. \end{aligned}$$

Dans la dernière égalité on a que $\boldsymbol{Y}^\top\boldsymbol{X}\boldsymbol{\beta} = (\boldsymbol{X}\boldsymbol{\beta})^\top\boldsymbol{Y} = \boldsymbol{\beta}^\top\boldsymbol{X}^\top\boldsymbol{Y}$ puisque ces trois quantités sont des scalaires.

Ainsi, pour minimiser $\sum_{i=1}^{n} \widehat{\varepsilon}_i^2$, il faut dériver $f(\boldsymbol{\beta})$ par rapport à $\boldsymbol{\beta}$, puis évaluer la dérivée au point $\widehat{\boldsymbol{\beta}}$ et égaler à 0. En utilisant les notions de la section 4.1.5, on obtient

$$\frac{\partial f(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} = -2\boldsymbol{X}^\top\boldsymbol{Y} + 2\boldsymbol{X}^\top\boldsymbol{X}\boldsymbol{\beta}.$$

On a ensuite

$$\begin{aligned} -2\boldsymbol{X}^\top\boldsymbol{Y} + 2\boldsymbol{X}^\top\boldsymbol{X}\widehat{\boldsymbol{\beta}} &= 0 \\ \boldsymbol{X}^\top\boldsymbol{X}\widehat{\boldsymbol{\beta}} &= \boldsymbol{X}^\top\boldsymbol{Y} \\ \widehat{\boldsymbol{\beta}} &= \left(\boldsymbol{X}^\top\boldsymbol{X}\right)^{-1}\boldsymbol{X}^\top\boldsymbol{Y}, \end{aligned} \tag{5.3}$$

si $\boldsymbol{X}^\top\boldsymbol{X}$ est inversible (de plein rang). Notons que

$$\underbrace{\widehat{\boldsymbol{\beta}}}_{p'\times 1} = \underbrace{(\boldsymbol{X}^\top\boldsymbol{X})^{-1}}_{p'\times p'}\underbrace{\boldsymbol{X}^\top}_{p'\times n}\underbrace{\boldsymbol{Y}}_{n\times 1}.$$

Remarque 7. *La matrice $\boldsymbol{X}^\top\boldsymbol{X}$ n'est pas inversible si le nombre d'observations n est inférieur au nombre de paramètres à estimer p', ou si une ligne de cette matrice est une combinaison linéaire des autres. Dans le premier cas, une méthode d'estimation de modèle plus complexe peut être utilisée, comme présenté à la section 8.6.2. Dans le second cas, une variable peut être retirée du modèle, voir le chapitre 9 sur la multicolinéarité.*

Exemple 5.2. Application au cas $p = 1$

Comme vu dans l'exemple 5.1, le modèle de RLS est un cas particulier du modèle de RLM. Vérifions que l'équation (5.3) mène aux estimateurs obtenus au Chapitre 2. En reprenant la notation de l'exemple 5.1, on a que

$$\boldsymbol{X}^\top\boldsymbol{X} = \begin{pmatrix} 1 & 1 & \cdots & 1 \\ x_1 & x_2 & \cdots & x_n \end{pmatrix}\begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix} = \begin{pmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{pmatrix} = \begin{pmatrix} n & n\overline{x} \\ n\overline{x} & \sum_{i=1}^n x_i^2 \end{pmatrix}$$

On calcule l'inverse de cette matice 2×2. Le déterminant est

$$\det(\boldsymbol{X}^\top\boldsymbol{X}) = n\sum_{i=1}^n x_i^2 - n^2\overline{x}^2 = n\left(\sum_{i=1}^n x_i^2 - \sum_{i=1}^n \overline{x}^2\right) = n\sum_{i=1}^n (x_i^2 - \overline{x}^2) = n\sum_{i=1}^n (x_i - \overline{x})^2 = nS_{xx}.$$

Alors

$$\left(\boldsymbol{X}^\top\boldsymbol{X}\right)^{-1} = \frac{1}{nS_{xx}}\begin{pmatrix} \sum_{i=1}^n x_i^2 & -n\overline{x} \\ -n\overline{x} & n \end{pmatrix}.$$

Calculons $\widehat{\boldsymbol{\beta}}$,

$$
\begin{aligned}
\widehat{\boldsymbol{\beta}} &= (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \boldsymbol{Y} \\
&= \frac{1}{nS_{xx}} \begin{pmatrix} \sum_{i=1}^n x_i^2 & -n\overline{x} \\ -n\overline{x} & n \end{pmatrix} \begin{pmatrix} 1 & 1 & \cdots & 1 \\ x_1 & x_2 & \cdots & x_n \end{pmatrix} \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix} \\
&= \frac{1}{nS_{xx}} \begin{pmatrix} \sum_{i=1}^n x_i^2 & -n\overline{x} \\ -n\overline{x} & n \end{pmatrix} \begin{pmatrix} \sum_{i=1}^n Y_i \\ \sum_{i=1}^n x_i Y_i \end{pmatrix} \\
&= \frac{1}{nS_{xx}} \begin{pmatrix} n\overline{Y} \sum_{i=1}^n x_i^2 - n\overline{x} \sum_{i=1}^n x_i Y_i \\ -n\overline{x} \sum_{i=1}^n Y_i + n \sum_{i=1}^n x_i Y_i \end{pmatrix} \\
&= \begin{pmatrix} \dfrac{\overline{Y}\left(\sum_{i=1}^n x_i^2 - n\overline{x}^2\right) - \overline{x}\left(\sum_{i=1}^n x_i Y_i - n\overline{x}\overline{Y}\right)}{S_{xx}} \\ \dfrac{\sum_{i=1}^n x_i Y_i - n\overline{x}\overline{Y}}{S_{xx}} \end{pmatrix} \\
&= \begin{pmatrix} \dfrac{\overline{Y} S_{xx} - \overline{x} S_{xy}}{S_{xx}} \\ \dfrac{S_{xy}}{S_{xx}} \end{pmatrix} = \begin{pmatrix} \overline{Y} - \overline{x}\widehat{\beta}_1 \\ \dfrac{S_{xy}}{S_{xx}} \end{pmatrix} = \begin{pmatrix} \widehat{\beta}_0 \\ \widehat{\beta}_1 \end{pmatrix}.
\end{aligned}
$$

On obtient les mêmes résultats qu'en (2.4) et (2.6).

5.2.2 Argument géométrique

Il est possible d'obtenir l'estimateur (5.3) à partir d'une approche géométrique. Le vecteur $\boldsymbol{Y}$ peut s'écrire comme une combinaison linéaire des colonnes de $\boldsymbol{X}$, plus une erreur $\boldsymbol{\varepsilon}$:

$$
\begin{aligned}
\boldsymbol{Y} &= \boldsymbol{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \\
&= \begin{pmatrix} \mathbf{1} & \mathbf{x}_1 & \cdots & \mathbf{x}_p \end{pmatrix} \begin{pmatrix} \beta_0 \\ \vdots \\ \beta_p \end{pmatrix} + \boldsymbol{\varepsilon} \\
&= \beta_0 \mathbf{1} + \beta_1 \mathbf{x}_1 + \cdots + \beta_p \mathbf{x}_p + \boldsymbol{\varepsilon},
\end{aligned}
$$

avec $\mathbf{1} = (1, \ldots, 1)^\top$ $\mathbf{x}_j = (x_{1j}, \ldots, x_{nj})^\top$.

Soit le sous-espace vectoriel formé par les colonnes de $\boldsymbol{X}$. Si $\boldsymbol{X}$ est de plein rang (inversible), cet espace aura $p' = p + 1$ dimensions. Pour estimer les paramètres du modèle de régression linéaire multiple, on peut projeter $\boldsymbol{Y}$ dans le sous-espace vectoriel engendré par les colonnes $\boldsymbol{X}$. Cette projection orthogonale permet d'obtenir la partie de $\boldsymbol{Y}$ qui est linéairement expliquées par les colonnes de $\boldsymbol{X}$.

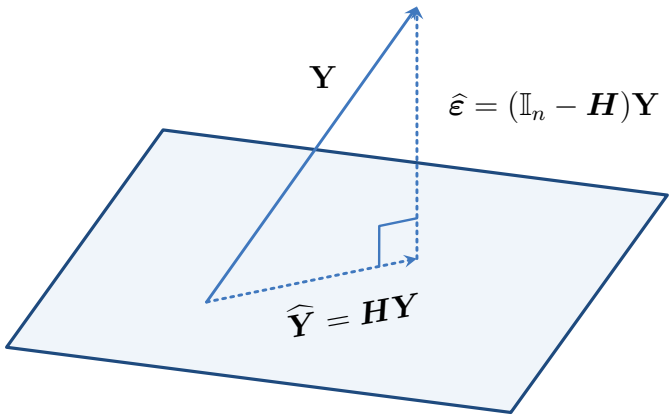


FIGURE 5.2 – Représentation géométrique de la régression dans le cas où $p = 1$ et $n = 3$.

Soit $\boldsymbol{H}$ la matrice chapeau, c'est-à-dire la matrice de projection orthogonale dans l'espace engendré par les colonnes de $\boldsymbol{X}$ (voir la section 6.2 pour plus de détails sur cette matrice). Le vecteur $\widehat{\boldsymbol{Y}}$ est le vecteur de valeurs prédites et correspond à la projection orthogonale de $\boldsymbol{Y}$ sur le sous-espace engendré par les colonnes de $\boldsymbol{X}$,

$$\widehat{\boldsymbol{Y}} = \boldsymbol{H}\boldsymbol{Y}.$$

Ainsi, $\widehat{\boldsymbol{Y}}$ s'exprime comme une combinaison linéaire des vecteurs $\mathbf{1}$ et $\mathbf{x}_j$, $j = 1, \ldots, p$. Le vecteur de résidus $\widehat{\boldsymbol{\varepsilon}}$ s'écrit

$$\widehat{\boldsymbol{\varepsilon}} = \boldsymbol{Y} - \widehat{\boldsymbol{Y}} = (\mathbb{I}_n - \boldsymbol{H})\boldsymbol{Y}.$$

Ainsi, le vecteur $\widehat{\boldsymbol{\varepsilon}}$ est perpendiculaire au sous-espace engendré par les colonnes de $\boldsymbol{X}$, il est une projection de $\boldsymbol{Y}$ dans le sous-espace perpendiculaire à celui engendré par les colonnes de $\boldsymbol{X}$. Toujours en considérant $\boldsymbol{X}$ de plein rang, ce sous-espace est de dimension $(n - p')$. La projection orthogonale permet de minimiser la somme des résidus au carré, c'est-à-dire $\widehat{\boldsymbol{\varepsilon}}'\widehat{\boldsymbol{\varepsilon}}$. L'orthogonalité de $\widehat{\boldsymbol{Y}}$ et $\widehat{\boldsymbol{\varepsilon}}$ revient à dire que $\mathbb{C}\text{ov}[\widehat{\boldsymbol{\varepsilon}}, \widehat{\boldsymbol{Y}}] = 0$. En effet, des vecteurs orthogonaux sont des vecteurs non corrélés. Dans le cas gaussien, ceci implique de plus que ces vecteurs sont indépendants. La figure 5.2 représente géométriquement le cas où $n = 3$ $p' = 2$.

Pour obtenir $\widehat{\boldsymbol{\beta}}$ sous cette approche, on peut utiliser le fait que l'on veut écrire $\widehat{\boldsymbol{Y}} = \boldsymbol{X}\widehat{\boldsymbol{\beta}}$ et que $\widehat{\boldsymbol{Y}}$ est perpendiculaire à $\widehat{\boldsymbol{\varepsilon}}$,

$$\begin{aligned}
\widehat{\boldsymbol{Y}}^\top \widehat{\boldsymbol{\varepsilon}} &= 0 \\
\left(\boldsymbol{X}\widehat{\boldsymbol{\beta}}\right)^\top \widehat{\boldsymbol{\varepsilon}} &= 0 \\
\widehat{\boldsymbol{\beta}}^\top \boldsymbol{X}^\top \widehat{\boldsymbol{\varepsilon}} &= 0,
\end{aligned}$$

ainsi

$$\begin{aligned}
\boldsymbol{X}^\top \widehat{\boldsymbol{\varepsilon}} &= 0 \\
\boldsymbol{X}^\top (\boldsymbol{Y} - \boldsymbol{X}\widehat{\boldsymbol{\beta}}) &= 0 \\
\boldsymbol{X}^\top \boldsymbol{Y} - \boldsymbol{X}^\top \boldsymbol{X}\widehat{\boldsymbol{\beta}} &= 0 \\
\boldsymbol{X}^\top \boldsymbol{Y} &= \boldsymbol{X}^\top \boldsymbol{X}\widehat{\boldsymbol{\beta}} \\
\left(\boldsymbol{X}^\top \boldsymbol{X}\right)^{-1} \boldsymbol{X}^\top \boldsymbol{Y} &= \widehat{\boldsymbol{\beta}}
\end{aligned}$$

et on retrouve les résultats obtenus avec les moindres carrés, soit l'équation (5.3).

5.3 Exemple

Cet exemple est tiré de Hines et coll. (2012, Exemple 14.1). Des expériences en laboratoire ont montré que le diamètre des meurtrissures (en mm) peut être expliqué en fonction de la hauteur de chute (en mm) et de la masse volumique des fruits (en g/cm^3). Le Tableau 5.1 présente des données typiques de ce type d'expérience.

Le modèle de régression linéaire multiple s'exprime sous forme matricielle comme

$$\underbrace{\begin{pmatrix} 3,62 \\ 7,27 \\ 2,66 \\ 1,53 \\ \vdots \\ 5,23 \end{pmatrix}}_{20\times 1} = \underbrace{\begin{pmatrix} 1 & 303,7 & 0,9 \\ 1 & 366,7 & 1,04 \\ 1 & 336,8 & 1,01 \\ 1 & 304,5 & 0,95 \\ \vdots & \vdots & \vdots \\ 1 & 351,4 & 0,96 \end{pmatrix}}_{20\times 3} \underbrace{\begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix}}_{3\times 1} + \underbrace{\begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \varepsilon_3 \\ \varepsilon_4 \\ \vdots \\ \varepsilon_{20} \end{pmatrix}}_{20\times 1}$$

Selon l'équation (5.3), on sait que $\widehat{\boldsymbol{\beta}} = (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \boldsymbol{Y}$. La matrice $\boldsymbol{X}^\top \boldsymbol{X}$ est

$$\begin{aligned}
\boldsymbol{X}^\top \boldsymbol{X} &= \begin{pmatrix} 1 & 1 & \cdots & 1 \\ 303,7 & 366,7 & \cdots & 351,4 \\ 0,90 & 1,04 & \cdots & 0,96 \end{pmatrix} \begin{pmatrix} 1 & 303,7 & 0,90 \\ 1 & 366,7 & 1,04 \\ \vdots & \vdots & \vdots \\ 1 & 351,4 & 0,96 \end{pmatrix} \\
&= \begin{pmatrix} 20 & 7767,8 & 19,33 \\ 7767,8 & 3201646 & 7791,878 \\ 19,93 & 7791,878 & 19,9077 \end{pmatrix}.
\end{aligned}$$

Le vecteur $\boldsymbol{X}^\top \boldsymbol{Y}$ s'exprime comme

$$\begin{pmatrix} 1 & 1 & \cdots & 1 \\ 303,7 & 366,7 & \cdots & 351,4 \\ 0,90 & 1,04 & \cdots & 0,96 \end{pmatrix} \begin{pmatrix} 3,62 \\ 7,27 \\ \vdots \\ 5,23 \end{pmatrix} = \begin{pmatrix} 120,79 \\ 51129,17 \\ 122,70 \end{pmatrix}.$$

On en déduit donc que

$$\begin{aligned} \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} &= \begin{pmatrix} 20 & 7767,8 & 19,33 \\ 7767,8 & 3201646 & 7791,878 \\ 19,93 & 7791,878 & 19,9077 \end{pmatrix}^{-1} \begin{pmatrix} 120,79 \\ 51129,17 \\ 122,70 \end{pmatrix} \\ &= \begin{pmatrix} 24,63666 & 0,005321 & -26,74679 \\ 0,005321 & 0,0000077 & -0,008353 \\ -26,74679 & -0,008353 & 30,096389 \end{pmatrix} \begin{pmatrix} 120,79 \\ 51129,17 \\ 122,70 \end{pmatrix} \\ &= \begin{pmatrix} -33,8310 \\ 0,0134 \\ 34,8900 \end{pmatrix}. \end{aligned}$$

Par conséquent, le modèle de régression ajusté s'écrit

$$\hat{Y} = -33,831 + 0,0134x_1 + 34,890x_2.$$

L'espérance du diamètre moyen des meurtrissures d'une pêche de masse volumique nulle lancée d'une hauteur nulle (très hypothétique comme valeur !) est de $-33,831$ mm. L'augmentation d'un mm de la hauteur de la chute est associée à une augmentation attendue de 0,0134 mm du diamètre moyen des meurtrissures, pour une masse volumique constante. De même, l'augmentation d'un g/cm^3 de la masse volumique d'une pêche est associée à une augmentation attendue de $34,890$ mm du diamètre moyen des meurtrissures, pour une hauteur de chute constante.

TABLE 5.1 – Données pour l'exemple des meurtrissures de pêches

numéro	diamètre des meurtrissures [mm] Y_i	hauteur de chute [mm] x_{i1}	masse volumique [g/cm^3] x_{i2}
1	3,62	303,7	0,90
2	7,27	366,7	1,04
3	2,66	336,8	1,01
4	1,53	304,5	0,95
5	4,91	346,8	0,98
6	10,36	600,0	1,04
7	5,26	369,0	0,96
8	6,09	418,0	1,00
9	6,57	269,0	1,01
10	4,24	323,0	0,94
11	8,04	562,2	1,01
12	3,46	284,2	0,97
13	8,50	558,6	1,03
14	9,34	415,0	1,01
15	5,55	349,5	1,04
16	8,11	462,8	1,02
17	7,32	333,1	1,05
18	12,58	502,1	1,10
19	0,15	311,4	0,91
20	5,23	351,4	0,96

Chapitre 6

Inférence pour la RLM

Sommaire

6.1 Distribution de l'estimateur 49
6.2 Matrice chapeau et implications 50
6.2.1 La matrice chapeau 50
6.2.2 Distribution de $\widehat{\boldsymbol{Y}}$ et $\widehat{\boldsymbol{\varepsilon}}$ 51
6.2.3 Estimation de σ^2 51
6.3 Intervalle de confiance et test d'hypothèse pour un coefficient 52
6.4 Prévision 53
6.4.1 Inférence pour $\boldsymbol{a}^\top \boldsymbol{\beta}$ 54
6.4.2 Inférence sur $\mathbb{E}(Y|\boldsymbol{x})$ 54
6.4.3 Inférence sur une valeur de Y étant donné $\boldsymbol{x}$ 55
6.4.4 Théorème de Gauss-Markov 56
6.5 Analyse de la variance 57
6.5.1 Test global de la régression 57
6.6 Test de réduction du modèle 59
6.6.1 Cas particuliers simples 60
6.6.2 Point de vue géométrique 62
6.7 Test d'une hypothèse linéaire générale 63

Figures

6.1 Illustration de l'analyse de la variance généralisée 57
6.2 Illustration de l'analyse de la variance généralisée 62

6.1 Distribution de l'estimateur

Déterminons la distribution des estimateurs pour faire de l'inférence sur les paramètres. Pour trouver la loi des estimateurs, on doit faire l'hypothèse que le vecteur des termes d'erreurs $\boldsymbol{\varepsilon}$ est distribuée selon une loi normale multivariée de dimension égale au nombre d'observations n. On peut écrire cette hypothèse sous la forme

$$\boldsymbol{\varepsilon} = (\varepsilon_1, \varepsilon_2, ..., \varepsilon_n)^\top \sim \mathcal{N}_n(\mathbf{0}, \sigma^2 \mathbf{I}_n)$$

où $\mathbf{I}_n$ dénote la matrice identité de dimension $n \times n$. On a donc que

$$\boldsymbol{Y} \sim \mathcal{N}_n(\boldsymbol{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n).$$

Afin de déterminer l'espérance et la variance de $\widehat{\boldsymbol{\beta}}$, on suit la même approche que pour la régression linéaire simple et on exprime $\widehat{\boldsymbol{\beta}}$ comme une combinaison linéaire des Y_i. On a vu que

$$\widehat{\boldsymbol{\beta}} = (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \boldsymbol{Y}.$$

On a donc que $\widehat{\boldsymbol{\beta}} \sim \mathcal{N}_{p'}\left(\mathbb{E}[\widehat{\boldsymbol{\beta}}], \mathbb{V}\text{ar}[\widehat{\boldsymbol{\beta}}]\right)$ car une combinaison linéaire de variables aléatoires normales est également normalement distribuée. Il reste à calculer $\mathbb{E}[\widehat{\boldsymbol{\beta}}]$ et $\mathbb{V}\text{ar}[\widehat{\boldsymbol{\beta}}]$ afin de déterminer la loi complètement. On peut d'abord montrer que l'estimateur est non biaisé :

$$\begin{aligned}
\mathbb{E}\left[\widehat{\boldsymbol{\beta}}\right] &= \mathbb{E}\left[(\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \boldsymbol{Y}\right] \\
&= (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \mathbb{E}\left[\boldsymbol{Y}\right] \\
&= (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{\beta} \\
&= \boldsymbol{\beta}
\end{aligned}$$

On calcule ensuite la variance :

$$\begin{aligned}
\mathbb{V}\text{ar}\left[\widehat{\boldsymbol{\beta}}\right] &= \mathbb{V}\text{ar}\left[(\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \boldsymbol{Y}\right] \\
&= (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \mathbb{V}\text{ar}\left[\boldsymbol{Y}\right] \left\{(\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top\right\}^\top \\
&= (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \sigma^2 \mathbf{I}_n \left\{(\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top\right\}^\top \\
&= \sigma^2 (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \boldsymbol{X} (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \\
&= \sigma^2 (\boldsymbol{X}^\top \boldsymbol{X})^{-1}
\end{aligned}$$

Ainsi,

$$\widehat{\boldsymbol{\beta}} \sim \mathcal{N}_{p'}\{\boldsymbol{\beta}, \sigma^2 (\boldsymbol{X}^\top \boldsymbol{X})^{-1}\}. \tag{6.1}$$

Exemple 6.1. Application au cas $p = 1$

On a déjà vu que dans le cas où $p = 1$,

$$(\boldsymbol{X}^\top \boldsymbol{X})^{-1} = \frac{1}{nS_{xx}} \begin{pmatrix} \sum_{i=1}^{n} x_i^2 & -n\overline{x} \\ -n\overline{x} & n \end{pmatrix}. \tag{6.2}$$

À partir de (6.1) et (6.2), on peut calculer les variances et la covariance de $\widehat{\beta}_0$ et de $\widehat{\beta}_1$,

$$\begin{aligned} \mathbb{V}ar\left(\widehat{\beta}_1\right) &= \frac{\sigma^2 n}{nS_{xx}} = \frac{\sigma^2}{S_{xx}} \\ \mathbb{V}ar\left(\widehat{\beta}_0\right) &= \frac{\sigma^2 \sum_{i=1}^{n} x_i^2}{nS_{xx}} = \frac{S_{xx} + n\overline{x}^2}{nS_{xx}}\sigma^2 \\ \mathbb{C}ov\left(\widehat{\beta}_1, \widehat{\beta}_0\right) &= \frac{-n\overline{x}\sigma^2}{nS_{xx}} = \frac{-\overline{x}\sigma^2}{S_{xx}} \end{aligned}$$

On obtient les quantités déjà connues. Remarquez que la covariance entre $\widehat{\beta}_0$ et $\widehat{\beta}_1$ est de signe contraire de $\overline{x}$ et que cette covariance est nulle si $\overline{x} = 0$.

6.2 Matrice chapeau et implications

On a introduit la matrice chapeau, à la section 5.2.2. Dans cette section, on explore plus en détails la matrice chapeau, et on obtient quelques résultats utiles pour l'inférence à partir de ses propriétés.

6.2.1 La matrice chapeau

La matrice chapeau $\boldsymbol{H}$ (ńhat matrixż) tire son nom du fait qu'elle permet de transformer $\boldsymbol{Y}$ en $\widehat{\boldsymbol{Y}}$ ("Y chapeau"). Selon l'équation (5.2), la régression linéaire multiple s'exprime sous format matriciel comme $\boldsymbol{Y} = \boldsymbol{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$. L'estimateur de $\boldsymbol{\beta}$ peut s'écrire selon l'équation (5.3) comme $\widehat{\boldsymbol{\beta}} = (\boldsymbol{X}^\top \boldsymbol{X})^{-1}\boldsymbol{X}^\top \boldsymbol{Y}$. On peut écrire

$$\begin{aligned} \widehat{\boldsymbol{Y}} &= \boldsymbol{X}\widehat{\boldsymbol{\beta}} \\ &= \boldsymbol{X}(\boldsymbol{X}^\top \boldsymbol{X})^{-1}\boldsymbol{X}^\top \boldsymbol{Y} \\ &= \boldsymbol{H}\boldsymbol{Y} \end{aligned}$$

La matrice chapeau correspond donc à la matrice $\boldsymbol{H} = \boldsymbol{X}(\boldsymbol{X}^\top \boldsymbol{X})^{-1}\boldsymbol{X}^\top$. Il est également possible d'exprimer les résidus en fonction de la matrice chapeau,

$$\widehat{\boldsymbol{\varepsilon}} = \boldsymbol{Y} - \widehat{\boldsymbol{Y}} = \left[\mathbf{I}_n - \boldsymbol{X}(\boldsymbol{X}^\top \boldsymbol{X})^{-1}\boldsymbol{X}^\top\right] \boldsymbol{Y} = (\mathbf{I}_n - \boldsymbol{H})\boldsymbol{Y}.$$

La matrice chapeau peut être vue comme une matrice de transformation. Il s'agit d'un opérateur linéaire, de même que $(\mathbf{I}_n - \boldsymbol{H})$. Ces deux opérateurs possèdent plusieurs propriétés intéressantes, à savoir :

1. $\boldsymbol{H}^\top = \boldsymbol{H}$ (symétrie) ;
2. $\boldsymbol{H}\boldsymbol{H} = \boldsymbol{H}$ (idempotence) ;
3. $\boldsymbol{H}\boldsymbol{X} = \boldsymbol{X}$;
4. $(\mathbf{I}_n - \boldsymbol{H})^\top = (\mathbf{I}_n - \boldsymbol{H})$ (symétrie) ;
5. $(\mathbf{I}_n - \boldsymbol{H})(\mathbf{I}_n - \boldsymbol{H}) = (\mathbf{I}_n - \boldsymbol{H})$ (idempotence) ;
6. $(\mathbf{I}_n - \boldsymbol{H})\boldsymbol{X} = 0$.

De plus, tous les éléments de la matrice ont une interprétation précise et utile pour étudier la robustesse d'un modèle de RLM. Nous y reviendrons à la section 10.

6.2.2 Distribution de $\widehat{\boldsymbol{Y}}$ et $\widehat{\boldsymbol{\varepsilon}}$

Les propriétés de la matrice chapeau permettent de calculer la variance de $\widehat{\boldsymbol{Y}}$ et $\widehat{\boldsymbol{\varepsilon}}$. En effet,

$$\mathbb{V}\text{ar}\left(\widehat{\boldsymbol{Y}}\right) = \mathbb{V}\text{ar}\left(\boldsymbol{H}\boldsymbol{Y}\right) = \boldsymbol{H}\mathbb{V}\text{ar}\left(\boldsymbol{Y}\right)\boldsymbol{H}^\top = \boldsymbol{H}\boldsymbol{H}^\top\sigma^2 = \boldsymbol{H}\sigma^2$$

et

$$\mathbb{V}\text{ar}\left(\widehat{\boldsymbol{\varepsilon}}\right) = \mathbb{V}\text{ar}\left((\mathbf{I}_n - \boldsymbol{H})\boldsymbol{Y}\right) = (\mathbf{I}_n - \boldsymbol{H})\sigma^2.$$

On a donc que les lois de $\widehat{\boldsymbol{Y}}$ et $\widehat{\boldsymbol{\varepsilon}}$ sont respectivement

$$\widehat{\boldsymbol{Y}} \sim \mathcal{N}_n(\boldsymbol{X}\boldsymbol{\beta}, \sigma^2\boldsymbol{H})$$

$$\widehat{\boldsymbol{\varepsilon}} \sim \mathcal{N}_n(\mathbf{0}, \sigma^2(\mathbf{I}_n - \boldsymbol{H})). \tag{6.3}$$

6.2.3 Estimation de σ^2

La méthode du maximum de vraisemblance permet de trouver un estimateur pour σ^2, mais celui-ci est biaisé. On utilise plutôt l'estimateur suivant :

$$\widehat{\sigma}^2 = \frac{\widehat{\boldsymbol{\varepsilon}}^\top\widehat{\boldsymbol{\varepsilon}}}{n - p'}, \tag{6.4}$$

où $p' = p + 1$. Montrons que l'estimateur donné en (6.4) est sans biais pour σ^2, c'est-à-dire, montrons que

$$E\left(\frac{\widehat{\boldsymbol{\varepsilon}}^\top\widehat{\boldsymbol{\varepsilon}}}{n - p'}\right) = \sigma^2.$$

Commençons par étudier $\widehat{\varepsilon}$ et $\widehat{\varepsilon}^\top\widehat{\varepsilon}$. Par le résultat (6.3), $\widehat{\varepsilon} \sim \mathcal{N}_n\left(\mathbf{0}, \sigma^2(\mathbf{I}_n - \boldsymbol{H})\right)$, et on peut écrire

$$\frac{\widehat{\varepsilon}}{\sigma} \sim \mathcal{N}_n\left(\mathbf{0}, (\mathbf{I}_n - \boldsymbol{H})\right).$$

Soit un vecteur $\boldsymbol{Z} \sim \mathcal{N}_n(\mathbf{0}, \mathbf{I}_n)$. On a que $(\mathbf{I}_n - \boldsymbol{H})\boldsymbol{Z} \sim \mathcal{N}_n\left(\mathbf{0}, (\mathbf{I}_n - \boldsymbol{H})\right)$. Ainsi, on peut écrire

$$\frac{\widehat{\varepsilon}}{\sigma} = (\mathbf{I}_n - \boldsymbol{H})\boldsymbol{Z} \sim \mathcal{N}_n\left(\mathbf{0}, (\mathbf{I}_n - \boldsymbol{H})\right).$$

Cette forme nous permet d'utiliser le théorème 1 du Chapitre 4. On a

- $\boldsymbol{Z} \sim \mathcal{N}_n(\mathbf{0}, \mathbf{I}_n)$,
- $(\mathbf{I}_n - \boldsymbol{H})$ une matrice symétrique,
- $(\mathbf{I}_n - \boldsymbol{H})$ une matrice idempotente idempotente.

Avec le Théorème 1,

$$\boldsymbol{Z}^\top(\mathbf{I}_n - \boldsymbol{H})\boldsymbol{Z} \sim \chi^2_r,$$

avec $r = \text{rang}(\mathbf{I}_n - \boldsymbol{H}) = n - p'$. Or,

$$\begin{aligned}
\boldsymbol{Z}^\top(\mathbf{I}_n - \boldsymbol{H})\boldsymbol{Z} &= \boldsymbol{Z}^\top(\mathbf{I}_n - \boldsymbol{H})^\top(\mathbf{I}_n - \boldsymbol{H})\boldsymbol{Z} \\
&= ((\mathbf{I}_n - \boldsymbol{H})\boldsymbol{Z})^\top(\mathbf{I}_n - \boldsymbol{H})\boldsymbol{Z} \\
&= \frac{\widehat{\varepsilon}^\top}{\sigma}\frac{\widehat{\varepsilon}}{\sigma} \\
&= \frac{\widehat{\varepsilon}^\top\widehat{\varepsilon}}{\sigma^2}.
\end{aligned}$$

Ainsi,

$$\frac{\widehat{\varepsilon}^\top\widehat{\varepsilon}}{\sigma^2} \sim \chi^2_{n-p'}.$$

On peut finalement montrer que l'estimateur donné en (6.4) est sans biais pour σ^2,

$$\begin{aligned}
E\left(\frac{\widehat{\varepsilon}^\top\widehat{\varepsilon}}{\sigma^2}\right) &= n - p' \\
E\left(\widehat{\varepsilon}^\top\widehat{\varepsilon}\right) &= \sigma^2(n - p') \\
E\left(\frac{\widehat{\varepsilon}^\top\widehat{\varepsilon}}{n - p'}\right) &= \sigma^2.
\end{aligned}$$

6.3 Intervalle de confiance et test d'hypothèse pour un coefficient

On a utilisé le postulat de normalité $\varepsilon \sim \mathcal{N}_n(0, \sigma^2\mathbf{I}_n)$, pour montrer que $\widehat{\boldsymbol{\beta}} \sim \mathcal{N}_{p'}\left(\boldsymbol{\beta}, \sigma^2(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\right)$. Si on s'intéresse à un β_j en particulier, on a alors que

$$\frac{\widehat{\beta}_j - \beta_j}{\sigma\sqrt{v_{j+1,j=1}}} \sim \mathcal{N}(0, 1),$$

où $v_{j+1,j=1}$ est l'élément $(j+1, j+1)$ de la matrice $(\boldsymbol{X}^\top \boldsymbol{X})^{-1}$, pour $j = 0, \ldots, p$.

On a montré que $\widehat{\sigma}^2 = \widehat{\boldsymbol{\varepsilon}}^\top \widehat{\boldsymbol{\varepsilon}}/(n-p')$ est un estimateur sans biais de σ^2. Par conséquent,

$$\frac{\dfrac{\widehat{\beta}_j - \beta_j}{\sigma\sqrt{v_{j+1,j+1}}}}{\sqrt{\dfrac{\widehat{\boldsymbol{\varepsilon}}^\top \widehat{\boldsymbol{\varepsilon}}}{\sigma^2(n-p')}}} \sim \frac{\mathcal{N}(0,1)}{\sqrt{\chi^2_{n-p'}/(n-p')}} \sim \mathcal{T}_{n-p'}, \tag{6.5}$$

où $\mathcal{T}_{n-p'}$ note la loi de Student à $n-p'$ degrés de liberté. On peut alors utiliser (6.5) pour construire un intervalle de confiance pour β_j ou pour effectuer des tests d'hypothèses. L'intervalle de confiance de niveau $(1-\alpha)$ pour β_j s'exprime comme

$$\left[\widehat{\beta}_j \pm t_{n-p';1-\alpha/2}\sqrt{\widehat{\sigma}^2 v_{j+1,j+1}}\right] \tag{6.6}$$

Exemple 6.2. *Construisons un intervalle de confiance à 95 % pour le paramètre β_1 de l'exemple de la section 5.1. Nous avons déjà calculé que $\widehat{\beta}_1 = 0,01314$. L'élément diagonal de la matrice $(\boldsymbol{X}^\top \boldsymbol{X})^{-1}$ correspondant à β_1 est $v_{22} = 0,0000077$. L'estimation non biaisée de σ^2 est $\widehat{\sigma}^2 = 2,247$. Le quantile à 97,5 % d'une loi $\mathcal{T}$ de Student à $n-p' = 20-3 = 17$ degrés de liberté est égal à 2,110. On obtient donc selon (6.6) l'intervalle de confiance suivant :*

$$\begin{aligned}\left[\widehat{\beta}_1 \pm t_{n-p';1-\alpha/2}\sqrt{\widehat{\sigma}^2 v_{22}}\right] &= \left[0,01314 \pm 2,110\sqrt{2,247 \times 0,0000077}\right] \\ &= [0,00436; 0,0219]\end{aligned}$$

On note que l'intervalle n'inclut pas la valeur 0. On peut donc rejeter l'hypothèse nulle $H_0 : \beta_1 = 0$ et conclure que la hauteur de la chute est significativement associée au diamètre moyen des meurtrissures, en tenant compte de la présence des autres variables explicatives dans le modèle.

6.4 Prévision

Quand on veut faire une prévision, on s'intéresse à une combinaison linéaire des coefficients. Considérons donc le problème général d'estimer une combinaison linéaire de $\boldsymbol{\beta}$:

$$\sum_{i=0}^{p} a_i \beta_i = \boldsymbol{a}^\top \boldsymbol{\beta}, \qquad \text{où} \quad \boldsymbol{a}^\top = (a_0 \; a_1 \; \ldots \; a_p)\,. \tag{6.7}$$

On peut utiliser $\boldsymbol{a}^\top \widehat{\boldsymbol{\beta}}$ pour estimer $\boldsymbol{a}^\top \boldsymbol{\beta}$, puisque

$$\boldsymbol{a}^\top \widehat{\boldsymbol{\beta}} \sim \mathcal{N}(\boldsymbol{a}^\top \boldsymbol{\beta}, \quad \sigma^2 \boldsymbol{a}^\top (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{a}). \tag{6.8}$$

6.4.1 Inférence pour $\boldsymbol{a}^\top\boldsymbol{\beta}$

On peut utiliser (6.8) pour faire de l'inférence sur une combinaison linéaire des coefficients. Si on connaissait σ^2, on pourrait construire des intervalles de confiance et des tests d'hypothèses pour $\boldsymbol{a}^\top\boldsymbol{\beta}$ à partir de

$$\frac{\boldsymbol{a}^\top\widehat{\boldsymbol{\beta}} - \boldsymbol{a}^\top\boldsymbol{\beta}}{\sqrt{\sigma^2\boldsymbol{a}^\top(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{a}}} \sim \mathcal{N}(0,1). \tag{6.9}$$

Toutefois, comme on ne connaît pas σ^2, on l'estime par $\widehat{\sigma}^2 = \widehat{\boldsymbol{\varepsilon}}^\top\widehat{\boldsymbol{\varepsilon}}/(n-p')$ et on a que

$$\frac{\boldsymbol{a}^\top\widehat{\boldsymbol{\beta}} - \boldsymbol{a}^\top\boldsymbol{\beta}}{\sqrt{\widehat{\sigma}^2\boldsymbol{a}^\top(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{a}}} \sim \mathcal{T}_{n-p'}. \tag{6.10}$$

On peut utiliser ce résultat pour construire un intervalle de confiance ou pour faire un test pour $\boldsymbol{a}^\top\boldsymbol{\beta}$.

Remarque 8. *Il y a plusieurs circonstances dans lesquelles on voudrait faire de l'inférence sur une combinaison linéaire des coefficients. On pourrait se demander si une variable a un effet aussi grand qu'une autre (on s'intéresse alors à $\beta_i - \beta_j$), ou si une variable a un effet deux fois plus grand qu'une autre ($\beta_i - 2\beta_j$), par exemple. Dans les prochaines sections, le résultat (6.10) est appliqué au cas de la prévision pour de nouvelles observations.*

6.4.2 Inférence sur $\mathbb{E}(Y|\boldsymbol{x})$

On désire dans ce cas estimer la valeur moyenne de la variable réponse pour une combinaison de valeurs $\mathbf{x}^{*\top} = (1, x_1^*, \ldots, x_p^*)$ spécifiées des variables explicatives. On veut donc estimer $\mathbb{E}(Y|\mathbf{x}^*) = \mathbb{E}\left(\mathbf{x}^{*\top}\boldsymbol{\beta} + \boldsymbol{\varepsilon}\right) = \mathbf{x}^{*\top}\boldsymbol{\beta}$. Cela revient à estimer une combinaison linéaire de $\boldsymbol{\beta}$ et il suffit de remplacer $\mathbf{x}^{*\top}$ par $\boldsymbol{a}^\top$ dans la section précédente afin d'obtenir un intervalle de confiance au niveau $100(1-\alpha)\%$ pour $\mathbb{E}(Y|\mathbf{x}^*)$. Celui-ci est donné par

$$\left[\mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}} \pm t_{n-p';1-\alpha/2}\sqrt{\widehat{\sigma}^2\mathbf{x}^{*\top}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\mathbf{x}^*}\right]. \tag{6.11}$$

Exemple 6.3. *Les scientifiques œuvrant sur l'expérimentation des pêches meurtries de l'exemple 5.1 désirent construire un intervalle de confiance à 95 % pour la moyenne des meurtrissures d'une pêche qui tombe d'une hauteur de $x_1 = 325$ mm et qui possède une masse volumique de $x_2 = 0,98$ g/cm^3. On a dans ce cas que*

$$\mathbf{x}^* = \begin{pmatrix} 1 \\ 325 \\ 0,98 \end{pmatrix}.$$

Notre estimation est

$$\mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}} = \begin{pmatrix} 1 & 325 & 0,98 \end{pmatrix} \begin{pmatrix} -33,831 \\ 0,01314 \\ 34,890 \end{pmatrix} = 4,63.$$

La variance de $\mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}}$ *est estimée par*

$$\begin{aligned} &\widehat{\sigma}^2 \mathbf{x}^{*\top}(\boldsymbol{X}^\top \boldsymbol{X})^{-1}\mathbf{x}^* \\ &\quad = 2,247 \begin{pmatrix} 1 & 325 & 0,98 \end{pmatrix} \begin{pmatrix} 24,63666 & 0,005321 & -26,74679 \\ 0,005321 & 0,0000077 & -0,008353 \\ -26,74679 & -0,008353 & 30,096389 \end{pmatrix} \begin{pmatrix} 1 \\ 325 \\ 0,98 \end{pmatrix} \\ &\quad = 2,247 \times 0,0718 \\ &\quad = 0,1613. \end{aligned}$$

Avec l'équation (6.11)*, l'intervalle de confiance à 95 % pour la moyenne des meurtrissures au point* $\mathbf{x}^*$ *est donné par*

$$\left[4,63 \pm 2,110\sqrt{0,1613}\right] = [3,78; 5,48]\,.$$

6.4.3 Inférence sur une valeur de Y étant donné x

Nous cherchons maintenant à prédire la valeur même d'une réalisation de la variable réponse pour une combinaison de valeurs $\mathbf{x}^*$ fixées des variables explicatives. On cherche donc à estimer $Y = \mathbf{x}^{*\top}\boldsymbol{\beta} + \varepsilon$. On estime de nouveau $\mathbf{x}^{*\top}\boldsymbol{\beta}$ par $\mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}}$. Comme $\mathbb{E}(\varepsilon) = 0$, la meilleure estimation d'une réalisation de ε est 0. L'estimateur ponctuel de Y pour une valeur $\mathbf{x}^*$ donnée est donc $\mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}} + 0 = \mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}}$.

Afin d'utiliser un résultat similaire à (6.5), nous devons calculer

$$\begin{aligned} \mathbb{V}\text{ar}[\widehat{Y} - Y] = \mathbb{V}\text{ar}[\mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}} - (\mathbf{x}^{*\top}\boldsymbol{\beta} + \varepsilon)] &= \mathbb{V}\text{ar}[\mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}}] + \mathbb{V}\text{ar}[\varepsilon] \\ &= \sigma^2 \mathbf{x}^{*\top}(\boldsymbol{X}^\top \boldsymbol{X})^{-1}\mathbf{x}^* + \sigma^2 \\ &= \sigma^2 \left(1 + \mathbf{x}^{*\top}(\boldsymbol{X}^\top \boldsymbol{X})^{-1}\mathbf{x}^*\right). \end{aligned}$$

On a donc que

$$\frac{\mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}} - (\mathbf{x}^{*\top}\boldsymbol{\beta} + \varepsilon)}{\sqrt{\widehat{\sigma}^2\left(1 + \mathbf{x}^{*\top}(\boldsymbol{X}^\top \boldsymbol{X})^{-1}\mathbf{x}^*\right)}} \sim \mathcal{T}_{n-p'}. \tag{6.12}$$

Un intervalle de prévision à $100(1-\alpha)\%$ pour une observation de Y étant donné $\mathbf{x}^*$ est donc donné par

$$\left[\mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}} \pm t_{n-p';1-\alpha/2}\sqrt{\widehat{\sigma}^2\left(1 + \mathbf{x}^{*\top}(\boldsymbol{X}^\top \boldsymbol{X})^{-1}\mathbf{x}^*\right)}\right]. \tag{6.13}$$

Comme on a déjà remarqué pour la RLS, l'intervalle de prévision pour une valeur précise sera plus grand que celui pour $\mathbb{E}[Y|\boldsymbol{x}]$.

Exemple 6.4. *Supposons que les scientifiques de l'exemple 5.1 désirent construire un intervalle de prévision à 95 % sur les meurtrissures subies par une pêche tombant d'une hauteur $x_1 = 325$ mm et de masse volumique $x_2 = 0,98$ g/cm^3. Comme dans l'exemple 6.3 on a que $\mathbf{x}^{*\top} = \begin{pmatrix} 1 & 325 & 0,98 \end{pmatrix}$ et que l'estimation ponctuelle des meurtrissures est égale à $\mathbf{x}^{*\top}\widehat{\boldsymbol{\beta}} = 4,63$ mm. De plus on a que $\mathbf{x}^{*\top}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\mathbf{x}^* = 0,0718$. Donc, selon l'équation (6.13), l'intervalle de prévision s'obtient comme*

$$\left[4,63 \pm 2,110\sqrt{2,247(1+0,0718)}\right] = [1,36; 7,90]\,.$$

6.4.4 Théorème de Gauss-Markov

On conclut cette section en présentant un théorème important qui montre que l'inférence présentée aux sections 6.4.1, 6.4.2 et 6.4.3 est optimale.

Théorème 2. ***(Théorème de Gauss-Markov)***
Le théorème de Gauss-Markov stipule que $\boldsymbol{a}^\top\widehat{\boldsymbol{\beta}} = \boldsymbol{a}^\top(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{X}^\top\boldsymbol{Y}$ est le meilleur estimateur linéaire non biaisé de $\boldsymbol{a}^\top\boldsymbol{\beta}$, c'est-à-dire qu'il est l'estimateur linéaire sans biais dont la variance est la plus petite.

Démonstration. Supposons que $\boldsymbol{c}^\top\boldsymbol{Y}$ est un autre estimateur linéaire quelconque sans biais de $\boldsymbol{a}^\top\boldsymbol{\beta}$. Nous montrerons que $\mathbb{V}\text{ar}[\boldsymbol{c}^\top\boldsymbol{Y}] \geq \mathbb{V}\text{ar}[\boldsymbol{a}^\top\widehat{\boldsymbol{\beta}}]$.

On a que

$$\mathbb{E}[\boldsymbol{c}^\top\boldsymbol{Y}] = \boldsymbol{c}^\top\mathbb{E}[\boldsymbol{Y}] = \boldsymbol{c}^\top\boldsymbol{X}\boldsymbol{\beta} = \boldsymbol{a}^\top\boldsymbol{\beta},$$

la dernière égalité provenant du fait qu'on veut un estimateur sans biais. On a donc que $\boldsymbol{a}^\top = \boldsymbol{c}^\top\boldsymbol{X}$.

Si on calcule la variance de $\boldsymbol{c}^\top\boldsymbol{Y}$, on obtient

$$\mathbb{V}\text{ar}[\boldsymbol{c}^\top\boldsymbol{Y}] = \boldsymbol{c}^\top\mathbb{V}\text{ar}[\boldsymbol{Y}]\boldsymbol{c} = \boldsymbol{c}^\top\sigma^2\mathbb{I}_n\boldsymbol{c} = \sigma^2\boldsymbol{c}^\top\boldsymbol{c}.$$

La variance de $\boldsymbol{a}^\top\widehat{\boldsymbol{\beta}}$ est

$$\mathbb{V}\text{ar}[\boldsymbol{a}^\top\widehat{\boldsymbol{\beta}}] = \boldsymbol{a}^\top\mathbb{V}\text{ar}[\widehat{\boldsymbol{\beta}}]\boldsymbol{a} = \sigma^2\boldsymbol{a}^\top(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{a}.$$

Si on calcule $\mathbb{V}\text{ar}[\boldsymbol{c}^\top\boldsymbol{Y}] - \mathbb{V}\text{ar}[\boldsymbol{a}^\top\widehat{\boldsymbol{\beta}}]$, on obtient un terme nécessairement positif. En effet

$$\begin{aligned}
\mathbb{V}\text{ar}[\boldsymbol{c}^\top\boldsymbol{Y}] - \mathbb{V}\text{ar}[\boldsymbol{a}^\top\widehat{\boldsymbol{\beta}}] &= \sigma^2[\boldsymbol{c}^\top\boldsymbol{c} - \boldsymbol{a}^\top(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{a}] \\
&= \sigma^2[\boldsymbol{c}^\top\boldsymbol{c} - \boldsymbol{c}^\top\boldsymbol{X}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{X}^\top\boldsymbol{c}] \\
&= \sigma^2\boldsymbol{c}^\top[\mathbf{1}_n - \boldsymbol{X}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{X}^\top]\boldsymbol{c} \\
&= \sigma^2\boldsymbol{c}^\top[\mathbf{1}_n - \boldsymbol{H}]\boldsymbol{c},
\end{aligned}$$

où $\boldsymbol{H}$ désigne la matrice chapeau. D'après les propriétés de cette matrice, $\mathbf{1}_n - \boldsymbol{H}$ est une matrice semi-définie positive, ce qui implique que $\sigma^2\boldsymbol{c}^\top(\mathbb{I}_n - \boldsymbol{H})\boldsymbol{c} \geq 0$. Ainsi, $\mathbb{V}\text{ar}[\boldsymbol{c}^\top\boldsymbol{Y}] \geq \mathbb{V}\text{ar}[\boldsymbol{a}^\top\widehat{\boldsymbol{\beta}}]$. □

6.5 Analyse de la variance

Tout comme pour la RLS, on peut décomposer la variabilité de la variable réponse en une part expliquée linéairement par les variables explicatives et une part résiduelle. On peut écrire la décomposition sous forme matricielle,

$$\begin{aligned}
\sum_{i=1}^{n}(Y_i-\overline{Y})^2 &= \sum_{i=1}^{n}(\widehat{Y}_i-\overline{Y})^2+\sum_{i=1}^{n}(Y_i-\widehat{Y}_i)^2\\
\boldsymbol{Y}^\top\boldsymbol{Y}-n\overline{Y}^2 &= \widehat{\boldsymbol{Y}}^\top\widehat{\boldsymbol{Y}}-n\overline{Y}^2+(\boldsymbol{Y}-\widehat{\boldsymbol{Y}})^\top(\boldsymbol{Y}-\widehat{\boldsymbol{Y}})\\
&= \left(\widehat{\boldsymbol{\beta}}^\top\boldsymbol{X}^\top\boldsymbol{X}\widehat{\boldsymbol{\beta}}-n\overline{Y}^2\right)+\widehat{\boldsymbol{\varepsilon}}^\top\widehat{\boldsymbol{\varepsilon}}\\
SC_{tot} &= SC_{reg}+SC_{res}.
\end{aligned}$$

Cette décomposition peut également être obtenue par un argument géométrique. La figure 6.1 montre cette géométrie.

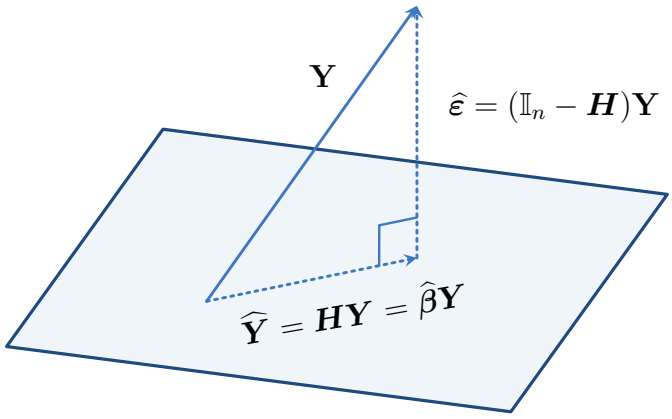


FIGURE 6.1 – Illustration de l'analyse de la variance généralisée

Le théorème de Pythagore donne

$$||\boldsymbol{Y}||^2 = ||\boldsymbol{X}\widehat{\boldsymbol{\beta}}||^2 + ||\widehat{\boldsymbol{\varepsilon}}||^2,$$

où $||\cdot||$ représente la norme (longueur) du vecteur. Ainsi on retrouve la décomposition,

$$\begin{aligned}
\boldsymbol{Y}^\top\boldsymbol{Y} &= (\boldsymbol{X}\widehat{\boldsymbol{\beta}})^\top\boldsymbol{X}\widehat{\boldsymbol{\beta}}+\widehat{\boldsymbol{\varepsilon}}^\top\widehat{\boldsymbol{\varepsilon}}\\
\Rightarrow \boldsymbol{Y}^\top\boldsymbol{Y}-n\overline{Y}^2 &= \widehat{\boldsymbol{\beta}}^\top\boldsymbol{X}^\top\boldsymbol{X}\widehat{\boldsymbol{\beta}}+\widehat{\boldsymbol{\varepsilon}}^\top\widehat{\boldsymbol{\varepsilon}}-n\overline{Y}_n^2\\
&= \widehat{\boldsymbol{\beta}}^\top\boldsymbol{X}^\top\boldsymbol{X}\widehat{\boldsymbol{\beta}}-n\overline{Y}^2+\widehat{\boldsymbol{\varepsilon}}^\top\widehat{\boldsymbol{\varepsilon}}.
\end{aligned}$$

6.5.1 Test global de la régression

La somme des carrés de la régression (SC_{reg}) constitue la portion de la variance expliquée par le modèle, alors que la somme des carrés résiduelle (SC_{res}) représente la partie que le modèle n'explique pas.

Intuitivement, on comprend que si la proportion de la variance expliquée par le modèle (SC_{reg}/SC_{tot}) est élevée, le modèle est bon.

L'analyse de la variance utilise cette idée pour effectuer un test global de la régression. On désire tester les hypothèses suivantes

$$\begin{aligned} H_0 : &\quad \beta_1 = \beta_2 = \cdots = \beta_p = 0 \\ H_1 : &\quad \text{au moins un des coefficients n'est pas nul.} \end{aligned} \tag{6.14}$$

L'idée consiste à comparer SC_{reg} à SC_{res} pour évaluer si les variables explicatives explique une partie significative de SC_{tot}. Afin de construire un test, il faut en premier lieu déterminer la statistique à utiliser et sa distribution sous H_0. Il se trouve qu'il est plus simple de trouver cette distribution si on standardise les sommes des carrés pour construire la statistique de test. On obtient alors

— CM_{res}, le carré moyen pour les résidus,

— CM_{reg}, le carré moyen pour la régression.

La statistique de test des hypothèses 6.14 est le rapport $F_{obs} = CM_{reg}/CM_{res}$. Le tableau 6.1 présente les principaux éléments de l'analyse de la variance et montre comment calculer cette statistique de test.

TABLE 6.1 – Tableau d'analyse de la variance dans le cas de la régression linéaire multiple

Source	Degrés de liberté	Sommes des carrés	Carrés moyens	F_{obs}	$\alpha*$
Modèle	$ddl_1 = p$	$SC_{reg} = \sum_{i=1}^{n} (\widehat{Y}_i - \overline{Y})^2$	$CM_{reg} = \frac{SC_{reg}}{ddl_1}$	$\frac{CM_{reg}}{CM_{res}}$	$P(F > F_{obs})$
Erreur	$ddl_2 = n - p'$	$SC_{res} = \sum_{i=1}^{n} (Y_i - \widehat{Y}_i)^2$	$CM_{res} = \frac{SC_{res}}{ddl_2}$		
Totale	$n - 1 = p + n - p'$	$SC_{tot} = \sum_{i=1}^{n} (Y_i - \overline{Y})^2$			

Une grande valeur de la statistique F_{obs} indique que la régression explique une bonne partie de la variabilité, et suggère de rejeter l'hypothèse nulle. Sous H_0, la statistique F_{obs} suit une loi $\mathcal{F}$ de Fisher-Snedecor avec p degrés de liberté au numérateur et $n-p'$ degrés de liberté au dénominateur. On rejette donc H_0 au seuil α lorsque la statistique $F_{obs} > F_{p,n-p';1-\alpha}$. On peut rejeter H_0 au seuil α si la valeur p du test est inférieure au seuil,

$$\alpha^* = P\left(F > F_{obs}\right),$$

avec F une variable de loi $\mathcal{F}_{p,n-p'}$.

Remarque 9. *Il est à souligner que le carré moyen de l'erreur résiduelle (CM_{res}) correspond à l'estimation de la variance des termes d'erreur. En effet*

$$CM_{res} = \frac{SC_{res}}{ddl_2} = \frac{\sum_{i=1}^{n} (Y_i - \widehat{Y}_i)^2}{n - p'} = \frac{\sum_{i=1}^{n} \widehat{\varepsilon}_i^2}{n - p'} = \widehat{\sigma}^2.$$

Exemple 6.5. *Pour l'exemple 5.1, on peut calculer* $SC_{res} = \widehat{\boldsymbol{\varepsilon}}^\top \widehat{\boldsymbol{\varepsilon}} = \widehat{\sigma}^2(n-p') = 38,21$, $SC_{tot} = \boldsymbol{Y}'\boldsymbol{Y} - n\overline{Y}^2 = 904,60 - 20\left(\frac{120,79}{20}\right)^2 = 175,089$ *et* $SC_{reg} = SC_{tot} - SC_{res} = 136,88$. *On obtient donc le tableau d'analyse de la variance 6.2.*

Pour tester $H_0 : \beta_1 = \beta_2 = 0$, *on compare* $F = 30,46$ *au quantile* $F_{p,n-p'}(1-\alpha) = F_{2,17}(0,95) = 3,59$. *Comme* $30,46 > 3,59$, *on rejette l'hypothèse nulle. On en conclut donc que les meurtrissures de pêche sont liées soit à la hauteur de chute, soit à la masse volumique, soit aux deux.*

TABLE 6.2 – Tableau d'analyse de la variance pour l'exemple 5.1

Source	Degrés de liberté	Sommes des carrés	Carrés moyens	F
Modèle	$ddl_1 = 2$	$136,88$	$136,88/2 = 68,44$	$68,44/2,247 = 30,46$
Erreur résiduelle	$ddl_2 = 17$	$38,21$	$38,21/17 = 2,247$	
Totale	19	$175,09$		

6.6 Test de réduction du modèle

Il est plutôt rare en pratique que le test $\mathcal{F}$ de Fisher global ne rejette pas l'hypothèse H_0 donnée par (6.14) que le modèle de régression est totalement inutile. Cependant, on veut souvent tester si le modèle peut être réduit. Cela revient à tester si un sous-modèle plus simple explique une partie suffisamment grande de la variabilité dans les Y_i pour qu'il ne soit pas nécessaire d'utiliser le modèle plus complexe. Il s'agit donc de mesurer si la différence entre les sommes de carrés résiduels des deux modèles est faible ou élevée.

Cette idée se traduit mathématiquement de la manière suivante. Supposons le modèle de régression multiple standard

$$Y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i.$$

On désire tester si un modèle comprenant seulement $k < p$ variables exogènes suffit à expliquer la variabilité dans les Y_i. Par souci de simplicité, on suppose que les k variables explicatives en question sont $x_1, \ldots, x_k$. Alors on veut tester

$$\begin{aligned} H_0 : \ Y_i &= \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik} + \varepsilon_i \\ H_1 : \ Y_i &= \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik} + \beta_{k+1} x_{i,k+1} + \cdots + \beta_p x_{ip} + \varepsilon_i. \end{aligned} \tag{6.15}$$

Le modèle donné par H_0 est appelé modèle réduit, alors que le modèle présenté en H_1 se nomme modèle complet.

Soit $SC_{res}^{(0)}$ la somme des carrés résiduels obtenue avec le modèle réduit et $SC_{res}^{(1)}$ la somme des carrés résiduels obtenue avec le modèle complet. Alors il est toujours vrai que $SC_{res}^{(1)} \leq SC_{res}^{(0)}$. Cependant, sous H_0, la différence entre $SC_{res}^{(0)}$ et $SC_{res}^{(1)}$ est faible, alors que cette même différence est élevée sous H_1.

On standardise le rapport $(SC_{res}^{(0)} - SC_{res}^{(1)})/SC_{res}^{(1)}$ afin d'obtenir une statistique avec une distribution connue sous H_0. On obtient

$$F = \frac{SC_{res}^{(0)} - SC_{res}^{(1)}}{\Delta_{dl}\widehat{\sigma}^2_{H_1}}, \tag{6.16}$$

où Δ_{dl} note la différence entre les degrés de liberté de $SC_{res}^{(0)}$ et les degrés de liberté de $SC_{res}^{(1)}$. Sous l'hypothèse nulle H_0 donnée par (6.15), la statistique F en (6.16) suit une distribution $\mathcal{F}$ de Fisher avec Δ_{dl} degrés de liberté au numérateur et $n - p'$ degrés de liberté au dénominateur. On rejette donc H_0 au niveau de confiance α lorsque $F \geq F_{\Delta_{dl}, n-p'}(1-\alpha)$.

On note qu'il existe plusieurs manières de calculer Δ_{dl} :

1. $\Delta_{dl} = dl(SC_{res}^{(0)}) - dl(SC_{res}^{(1)})$;
2. Δ_{dl} =(nbr de paramètres du modèle H_1)- (nbr de paramètres du modèle H_0) ;
3. Δ_{dl} = nbr de contraintes sur les paramètres du modèle complet pour arriver au modèle réduit.

Ainsi, dans le cas présenté en (6.15), on aurait

1. $dl(SC_{res}^{(0)}) = n - (k+1) = n - k - 1$
   $dl(SC_{res}^{(1)}) = n - p'$
   Donc, $\Delta_{dl} = n - k - 1 - n + p' = p' - k - 1 = p - k$.
2. Paramètres sous H_1 : $p' = p + 1$
   Paramètres sous H_0 : $k + 1$
   Donc, $\Delta_{dl} = p + 1 - k - 1 = p - k$.
3. Les contraintes pour réduire le modèle H_1 au modèle H_0 sont

$$\beta_{k+1} = 0, \ldots, \beta_p = 0,$$

   c'est-à-dire $p - k$ égalités (contraintes) sur les paramètres du modèle complet afin d'obtenir le modèle réduit. Donc $\Delta_{dl} = p - k$.

6.6.1 Cas particuliers simples

La très grande majorité des tests d'hypothèses que nous aurons à effectuer dans ce cours pourrons être exprimés sous la forme H_0 : modèle réduit contre H_1 : modèle complet. Trois cas particuliers ont des noms spécifiques et méritent d'être étudiés.

Test global de la régression

La statistique F_{obs} de la table 6.1 d'ANOVA constitue en fait un test de réduction de modèle dans lequel le modèle complet contient toutes les variables explicatives disponibles et le modèle réduit s'écrit simplement comme $Y_i = \beta_0 + \varepsilon_i$. Dans ce cas, on peut facilement voir que la statistique F donnée en (6.16) est égale à la statistique F_{obs} de la table d'ANOVA. De plus, on déduit aussi facilement que $\Delta_{dl} = p$.

Tests de F séquentiels

Il s'agit de tests de réduction de modèles séquentiels pour toutes les variables du jeu de données. On commence avec le modèle nul comme modèle simple et on ajoute séquentiellement chaque variable en testant si elle permet de réduire significativement la somme des carrés résiduelle.

On présente souvent les valeurs de F et valeurs de p associées pour les tests de F séquentiels de toutes les variables d'un jeu de données dans un seul tableau. Les résultats dépendront de l'ordre dans lequel on ajoute les variables.

Remarque 10. *Dans certains livres et logiciels on parle dans ce cas de sommes de carrés de type I.*

Tests de F ajustés

On parle de tests de F ajustés quand on teste l'effet de l'ajout de chaque variable, en tenant compte de toutes les autres variables présentes dans le modèle. On dit qu'on ajuste pour toutes les autres variables présentes dans le modèle.

Un test de F ajusté pour la variable j teste donc

$$\begin{aligned} H_0 : Y_i &= \beta_0 + \beta_1 x_{i1} + \cdots + \beta_{j-1} x_{i(j-1)} + \beta_{j+1} x_{i(j+1)} + \beta_k x_{ik} + \varepsilon_i, \\ H_1 : Y_i &= \beta_0 + \beta_1 x_{i1} + \cdots + \beta_{j-1} x_{i(j-1)} + \beta_j x_{ij} + \beta_{j+1} x_{i(j+1)} + \beta_k x_{ik} + \varepsilon_i. \end{aligned}$$

Ici aussi on présente souvent dans un seul tableau les résultats des tests de F ajustés de toutes les variables d'un jeu de données. Puisqu'on ajuste à chaque fois sur toutes les variables disponibles, les résultats ne dépendront pas de l'ordre dans lequel les variables sont testées.

Remarque 11. *On parle parfois dans ce cas de sommes de carrés de type II.*

Remarque 12. *Dans un test de F ajusté pour la variable j, on teste en fait $H_0 : \beta_j = 0$ vs $H_1 : \beta_j \neq 0$. On peut d'ailleurs montrer que ce test est équivalent au test t de l'hypothèse $H_0 : \beta_j = 0$ basé sur la distribution de $\widehat{\beta}$ et mentionné à la section 6.3.*

6.6.2 Point de vue géométrique

On peut également comprendre les tests de réduction de modèle d'un point de vue géométrique. La statistique F du test est alors construite en standardisant les longueurs des vecteurs appropriés en les divisant par la dimension de l'espace dans lesquels ils vivent (leurs degrés de liberté). La figure 6.2 montre toutes les quantités impliquées.

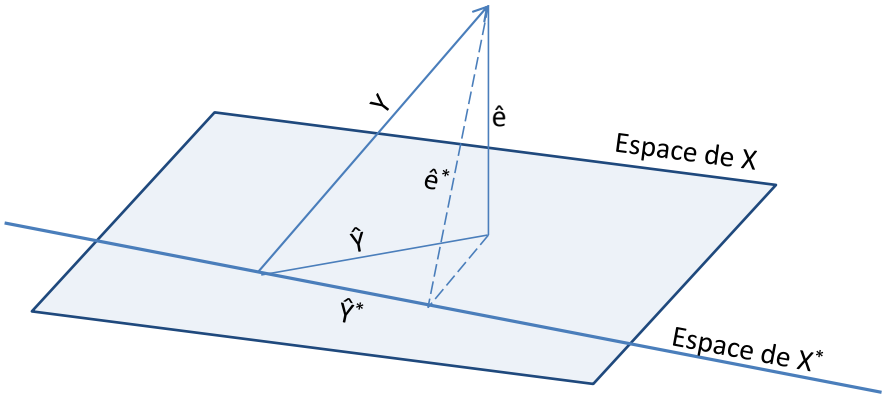


FIGURE 6.2 – Illustration de l'analyse de la variance généralisée

- Le plan Espace de X est l'espace colonne de la matrice d'incidence sous H_1.
- La droite Espace de X^* est l'espace colonne de la matrice d'incidence sous H_0.
- Le vecteur $\widehat{\boldsymbol{Y}}$ est $\boldsymbol{X}\widehat{\boldsymbol{\beta}}$ sous le modèle complet et se situe dans un espace de dimension p'. Ce vecteur constitue la projection orthogonale du vecteur $\boldsymbol{Y}$ sur le plan nommé Espace de X.
- Le vecteur $\boldsymbol{\varepsilon}$ est constitué des résidus sous le modèle complet et vit dans un espace de dimension $n - p'$.
- Le vecteur $\widehat{\boldsymbol{Y}}^*$ représente le vecteur $\mathbf{x}^*\widehat{\boldsymbol{\beta}}$ sous le modèle réduit et évolue dans un espace de dimension $p' - \Delta_{dl}$. Ce vecteur est la projection orthogonale du vecteur $\boldsymbol{Y}$ sur la droite Espace de X.
- Le vecteur $\boldsymbol{\varepsilon}^*$ est formé des résidus sous le modèle réduit et vit dans un espace de dimension $n - p' + \Delta_{dl}$.

Le vecteur égal à la différence entre les vecteurs de résidus des deux modèles est important. Notons C sa longueur. C^2 est donc la différence entre les sommes de carrés résiduels. Ce vecteur vit dans un espace de dimension Δ_{dl}. La statistique du test F du principe de somme de carrés résiduels additionnelle est tout simplement égale à $(C^2/\Delta_{dl})/(B^2/(n-p'))$ où B dénote la longueur du vecteur des résidus sous le modèle complet.

6.7 Test d'une hypothèse linéaire générale

Plusieurs tests en régression linéaire peuvent être exprimés comme une liste de contraintes linéaires sur les valeurs des paramètres. Soit $\boldsymbol{C}$, une matrice de dimension $r \times p'$, et $\boldsymbol{d}$, un vecteur de dimension $r \times 1$. Un test d'hypothèse linéaire générale s'écrit comme

$$\begin{aligned} H_0 : \boldsymbol{C\beta} &= \boldsymbol{d} \\ H_1 : \boldsymbol{C\beta} &\neq \boldsymbol{d}. \end{aligned} \tag{6.17}$$

On peut ré-écrire ce test d'hypothèse sous la forme d'un modèle réduit et d'un modèle complet de la manière suivante :

$$\begin{aligned} H_0 : \boldsymbol{Y} &= \boldsymbol{Z\alpha} + \boldsymbol{\varepsilon} \\ H_1 : \boldsymbol{Y} &= \boldsymbol{X\beta} + \boldsymbol{\varepsilon}, \end{aligned}$$

où l'équation en H_0 est obtenue en (i) résolvant le système d'équations $\boldsymbol{C\beta} = \boldsymbol{d}$ pour β et (ii) en substituant la solution trouvée en (i) dans le modèle $\boldsymbol{Y} = \boldsymbol{X\beta} + \boldsymbol{\varepsilon}$.

Il est possible de montrer (voir par e.g. Sen et Srivastava, 1990, pp. 44–45 et pp. 60–64) que

$$SC_{res}^{(0)} - SC_{res}^{(1)} = (\boldsymbol{C}\widehat{\boldsymbol{\beta}} - \boldsymbol{d})'[\boldsymbol{C}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{C}^\top]^{-1}(\boldsymbol{C}\widehat{\boldsymbol{\beta}} - \boldsymbol{d}).$$

Notez que $\sigma^2[\boldsymbol{C}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{C}^\top]$ est la variance de $\boldsymbol{C}\widehat{\boldsymbol{\beta}} - \boldsymbol{d}$. Donc la différence des sommes de carrés résiduels peut être vue comme la longueur du vecteur qui sépare $\boldsymbol{C}\widehat{\boldsymbol{\beta}}$ et $\boldsymbol{d}$, standardisée par sa variance. Si la distance entre $\boldsymbol{C}\widehat{\boldsymbol{\beta}}$ et $\boldsymbol{d}$ est faible, alors H_0 constitue une hypothèse raisonnable, $SC_{res}^{(0)} - SC_{res}^{(1)}$ prend une petite valeur et on ne rejette donc pas H_0. Si H_0 n'est pas réaliste, alors $\boldsymbol{C}\widehat{\boldsymbol{\beta}}$ sera éloignée de $\boldsymbol{d}$, $SC_{res}^{(0)} - SC_{res}^{(1)}$ prendra une grande valeur et on rejettera l'hypothèse nulle H_0.

On peut maintenant construire la statistique F en utilisant l'équation (6.16) :

$$F = \frac{(\boldsymbol{C}\widehat{\boldsymbol{\beta}} - \boldsymbol{d})^\top[\boldsymbol{C}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{C}^\top]^{-1}(\boldsymbol{C}\widehat{\boldsymbol{\beta}} - \boldsymbol{d})/r}{SC_{res}^{(1)}/(n-p')} = \frac{(\boldsymbol{C}\widehat{\boldsymbol{\beta}} - \boldsymbol{d})^\top[\boldsymbol{C}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{C}^\top]^{-1}(\boldsymbol{C}\widehat{\boldsymbol{\beta}} - \boldsymbol{d})}{r\widehat{\sigma}^2_{H_1}},$$

où r note le nombre de lignes de la matrice $\boldsymbol{C}$. Le fait que $\Delta_{dl} = r$ dans ce cas est facile à comprendre si on utilise la troisième manière de le calculer, soit le nombre de contraintes sur les paramètres du modèle complet pour obtenir le modèle réduit. Sous l'hypothèse H_0, F suit une loi de Fisher $\mathcal{F}_{r,n-p'}$.

Chapitre 7

Variables catégoriques et interactions

Sommaire

7.1 Variables exogènes catégoriques 64

7.1.1 Inférence avec des variables catégoriques 69

7.2 Interactions 69

Figures

7.1 Espérance de la variable endogène Y en fonction de la variable exogène x_2 pour chacun des groupes 1 à 4. 68

7.2 Espérance de la variable endogène Y en fonction de la variable exogène x_2 pour chacune des valeurs de x_{1i}. 70

Une grande différence quand on utilise un modèle de RLM au lieu de la RLS, c'est qu'on peut créer des modèles plus complexes. On verra ici deux façons pour ce faire, soit inclure des variables catégoriques et inclure des interactions.

7.1 Variables exogènes catégoriques

Jusqu'à maintenant, nous n'avons considéré que des variables exogènes continues. Il arrive pourtant souvent en pratique que les variables exogènes ne puissent prendre des valeurs que dans un ensemble de

valeurs possibles, et que ces valeurs n'impliquent pas un ordre entre les mesures. Quelques exemples :

$$x_{1i} = \begin{cases} H, & \text{si } i \text{ est un homme} \\ F, & \text{si } i \text{ est une femme} \end{cases}$$

$$x_{1i} = \begin{cases} 1, & \text{si } i \text{ est une ville} \\ -1, & \text{si } i \text{ est un village} \end{cases}$$

$$x_{1i} = \begin{cases} 1, & \text{si } i \text{ est à ON} \\ 0, & \text{si } i \text{ est à OFF} \end{cases}$$

On peut simplement ajouter une variable catégorique linéairement dans le modèle de RLM. La valeur de cette variable modifiera l'ordonnée à l'origine de la régression. Il faut toutefois faire attention à la façon avec laquelle on code les variables catégoriques pour s'assurer que le modèle soit facile à interpréter.

Variable dichotomique

Dans le cas d'une variable dichotomique, il est toujours plus prudent de coder x_i sous la forme d'une variable indicatrice, c'est-à-dire sous la forme

$$x_i = \begin{cases} 1, & \text{si ...} \\ 0, & \text{sinon} \end{cases}$$

Si ce type de codage n'est pas utilisé, alors les β peuvent être difficiles à interpréter.

Par exemple si

$$x_i = \begin{cases} -5, & \text{si } i \text{ est un homme} \\ 5, & \text{si } i \text{ est une femme} \end{cases}$$

Alors le modèle $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ nous donne

$$\begin{aligned} \mathbb{E}[Y_i | i \text{ est un homme}] &= \beta_0 - 5\beta_1 \\ \mathbb{E}[Y_i | i \text{ est une femme}] &= \beta_0 + 5\beta_1 \end{aligned}$$

On a donc que β_0 est la moyenne des espérances de Y pour les hommes et les femmes, et β_1 représente 0.1 fois la différence entre la valeur moyenne de Y pour les hommes et celle pour les femmes.

Si on prend plutôt

$$x_i = \begin{cases} 1, & \text{si } i \text{ est un homme} \\ 0, & \text{si } i \text{ est une femme} \end{cases}$$

alors on a

$$\begin{aligned} \mathbb{E}[Y_i | i \text{ est un homme}] &= \beta_0 + \beta_1 \\ \mathbb{E}[Y_i | i \text{ est une femme}] &= \beta_0 \end{aligned}$$

et maintenant β_0 est simplement la valeur moyenne de Y pour les femmes et β_1 représente exactement la différence entre la valeur moyenne de Y pour les hommes et celle pour les femmes.

Un autre codage souvent utilisé durant la collecte de données est de la forme

$$x_i = \begin{cases} 1, & \text{si } i \text{ est un homme} \\ 2, & \text{si } i \text{ est une femme} \end{cases}$$

Dans ce cas, β_1 s'interprète de la même façon qu'avec la variable indicatrice, mais β_0 est plus complexe à interpréter.

Variable polytomique

Si x est une variable polytomique, c'est-à-dire que x_i peut prendre une parmi $C \geq 2$ valeurs possibles, la façon prudente de procéder est de définir $C - 1$ variables indicatrices. Ainsi, si

$$x_{1i} = \begin{cases} 1, & \text{si } i \text{ est bleu} \\ 2, & \text{si } i \text{ est rouge} \\ 3, & \text{si } i \text{ est jaune} \\ 4, & \text{si } i \text{ est vert} \end{cases}$$

alors on définit

$$x_{Bi} = \begin{cases} 1, & \text{si } i \text{ est bleu} \\ 0, & \text{sinon} \end{cases} \qquad x_{Ri} = \begin{cases} 1, & \text{si } i \text{ est rouge} \\ 0, & \text{sinon} \end{cases}$$

$$x_{Ji} = \begin{cases} 1, & \text{si } i \text{ est jaune} \\ 0, & \text{sinon} \end{cases}$$

Dans ce cas

$$\begin{aligned} x_{1i} = \text{bleu} &\Rightarrow (x_{Bi}, x_{Ri}, x_{Ji}) = (1,0,0) \\ x_{1i} = \text{rouge} &\Rightarrow (x_{Bi}, x_{Ri}, x_{Ji}) = (0,1,0) \\ x_{1i} = \text{jaune} &\Rightarrow (x_{Bi}, x_{Ri}, x_{Ji}) = (0,0,1) \\ x_{1i} = \text{vert} &\Rightarrow (x_{Bi}, x_{Ri}, x_{Ji}) = (0,0,0) \end{aligned}$$

Ainsi, si $Y_i = \beta_0 + \beta_B x_{Bi} + \beta_R x_{Ri} + \beta_J x_{Ji} + \varepsilon_i$,

$$\begin{aligned} \mathbb{E}[Y_i | i \text{ est bleu}] &= \beta_0 + \beta_B \\ \mathbb{E}[Y_i | i \text{ est rouge}] &= \beta_0 + \beta_R \\ \mathbb{E}[Y_i | i \text{ est jaune}] &= \beta_0 + \beta_J \\ \mathbb{E}[Y_i | i \text{ est vert}] &= \beta_0. \end{aligned}$$

Remarque 13. *Si une variable exogène ne prend que très peu de valeurs différentes, il est important de déterminer s'il s'agit d'une variable continue pour laquelle on a peu de mesures ou s'il s'agit d'une variable polytomique. Selon la façon avec laquelle la variable est incluse dans le modèle, l'interprétation sera différente, ainsi que l'information qu'on pourra retirer du modèle.*

Exemple 7.1. *Soit x_{1i}, le numéro de lot du produit i, x_{2i}, la concentration de sel dans le produit i et Y_i, l'indice de qualité du produit i. Les variables Y_i et x_{2i} sont des variables continues, alors que x_{1i} est un variable polytomique prenant une des valeurs $\{1, 2, 3, 4\}$.*

On ajuste le modèle

$$Y_i = \beta_0 + \beta_{11}x_{11i} + \beta_{12}x_{12i} + \beta_{13}x_{13i} + \beta_2 x_{2i} + \varepsilon_i,$$

où

$$x_{11i} = \begin{cases} 1, & x_{1i} = 1 \\ 0, & x_{1i} \neq 1 \end{cases} \qquad x_{12i} = \begin{cases} 1, & x_{1i} = 2 \\ 0, & x_{1i} \neq 2 \end{cases}$$

$$x_{13i} = \begin{cases} 1, & x_{1i} = 3 \\ 0, & x_{1i} \neq 3. \end{cases}$$

La figure 7.1 illustre graphiquement ce modèle. Notez qu'on suppose dans la figure que tous les coefficients sont positifs, mais ce n'est absolument pas nécessaire en pratique.

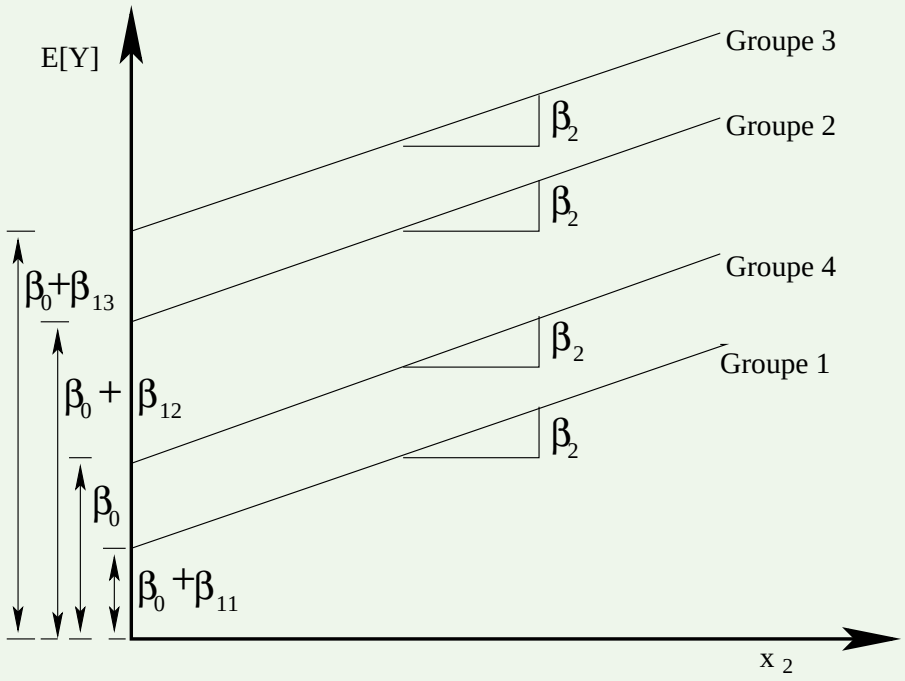


FIGURE 7.1 – Espérance de la variable endogène Y en fonction de la variable exogène x_2 pour chacun des groupes 1 à 4. Comme on peut le voir, les β_0 et β_{1j} déterminent les ordonnées à l'origine, tandis que β_2 détermine la pente des droites de régression.

7.1.1 Inférence avec des variables catégoriques

On peut en général faire de l'inférence sur les coefficients des variables indicatrices exactement comme pour les coefficients des variables continues.

Tester l'utilité globale d'une variable polytomique

Il faut toutefois faire attention si on veut tester si une variable polytomique possède un effet significatif sur la valeur moyenne de la variable endogène. On doit alors tester si plusieurs coefficients sont simultanément égaux à zéro à l'aide d'un test F de réduction de modèle. En général, pour tester si une variable polytomique prenant C valeurs possibles a un effet significatif, il faut tester si $C-1$ coefficients sont simultanément égaux à zéro.

Exemple 7.2. *Supposons que dans le modèle de l'exemple 7.1 on souhaite tester si le groupe d'où provient l'item i a un effet sur la variable dépendante. Il faut alors tester $H_0 : \beta_{11} = \beta_{12} = \beta_{13} = 0$. Notez que ceci revient à tester si la droite de régression est la même pour les 4 groupes, c'est-à-dire que sur la figure 7.1, les 4 lignes sont superposées.*

Tester une hypothèse plus complexe sur les différents niveaux d'une variable

Notons aussi que plusieurs hypothèses intéressantes dans un modèle avec variables polytomiques peuvent être vues comme des hypothèses linéaires sur les β, ce qui nous permet d'utiliser nos résultats de la section 6.7.

Exemple 7.3. *Toujours pour le modèle de l'exemple 7.1, supposons qu'on veut tester que la valeur moyenne de Y_i est la même pour les lots 1 et 3. Ceci revient à tester si $\beta_{11} = \beta_{13}$. On peut donc utiliser un test d'hypothèse linéaire générale avec*

$$\boldsymbol{C} = (0, 1, 0, -1, 0).$$

On pourrait aussi vouloir tester si on peut diviser les lots en deux : les lots 1 et 3 ayant la même moyenne, et les lots 2 et 4 ayant la même moyenne. Ici encore, c'est un test d'hypothèse linéaire générale, mais avec deux contraintes simultanées. La matrice C appropriée est alors :

$$\boldsymbol{C} = \begin{bmatrix} 0 & 1 & 0 & -1 & 0 \\ 0 & 0 & 1 & 0 & 0 \end{bmatrix}.$$

7.2 Interactions

Une interaction entre deux variables exogènes x_{1i} et x_{2i} est un terme de la forme

$$\beta_{12} x_{1i} x_{2i}.$$

On inclut une interaction dans un modèle lorsque l'effet d'une des variables sur la moyenne de Y dépend de la valeur d'une autre variable. En effet, supposons le modèle

$$Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_{12} x_{1i} x_{2i} + \varepsilon_i.$$

On a alors

$$\mathbb{E}[Y_i | x_{1i} + 1] = \beta_0 + \beta_1 (x_{1i} + 1) + \beta_2 x_{2i} + \beta_{12} (x_{1i} + 1) x_{2i} \quad (7.1)$$

$$\mathbb{E}[Y_i | x_{1i}] = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_{12} x_{1i} x_{2i}. \quad (7.2)$$

L'effet d'une augmentation d'une unité de x_{1i} sur $\mathbb{E}[Y_i]$ est $\beta_1 + \beta_{12} x_{2i}$, c'est-à-dire que l'effet d'une augmentation de x_{1i} d'une unité sur $\mathbb{E}[Y_i]$ **dépend de la valeur de** x_{2i}.

Exemple 7.4. *Soit x_{1i} une variable polytomique pouvant prendre les valeurs $\{1, 2, 3\}$ et soient x_{11i} l'indicatrice que $x_{1i} = 1$ et x_{12i} l'indicatrice que $x_{1i} = 2$. Le modèle*

$$Y_i = \beta_0 + \beta_{11} x_{11i} + \beta_{12} x_{12i} + \beta_2 x_{2i} + \beta_{112} x_{11i} x_{2i} + \beta_{122} x_{12i} x_{2i} + \varepsilon_i.$$

est illustré à la figure 7.2.

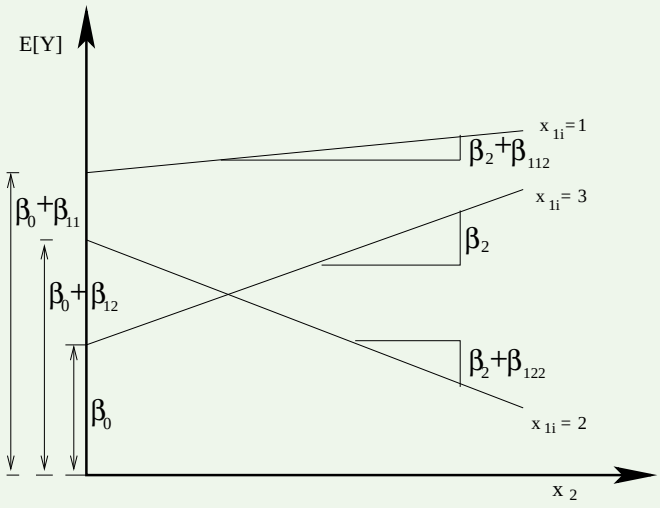


FIGURE 7.2 – Espérance de la variable endogène Y en fonction de la variable exogène x_2 pour chacune des valeurs de x_{1i}.

L'exemple 7.4 illustre une interaction entre une variable catégorique et une variable continue, ce qui s'illustre aisément. On peut également inclure une interaction entre deux variables catégoriques, ce qui crée en quelque sorte une nouvelle variable catégorique avec plus de catégories. Ou entre deux variables continues, ce qui implique une pente de régression pour une première variable qui diffère pour chaque valeur d'une autre variable.

De plus, les termes d'interaction ne sont pas limités à seulement deux variables. En effet, si nous mesurons 4 variables $x_1, \ldots, x_4$ il se pourrait que le modèle approprié soit

$$\begin{aligned} Y_i &= \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_{12} x_{1i} x_{2i} + \beta_{13} x_{1i} x_{3i} \\ &\quad + \beta_{14} x_{1i} x_{4i} + \beta_{23} x_{2i} x_{3i} + \beta_{24} x_{2i} x_{4i} + \beta_{34} x_{3i} x_{4i} \\ &\quad + \beta_{123} x_{1i} x_{2i} x_{3i} + \cdots + \beta_{1234} x_{1i} x_{2i} x_{3i} x_{4i} + \varepsilon_i. \end{aligned}$$

Mais à moins de posséder vraiment beaucoup de données, les interactions impliquant plus de deux variables sont rarement utilisées. Elles sont en outre plus complexes à interpréter.

Test de linéarité

Pour tester si un modèle est adéquat, on peut y ajouter des termes d'interaction et tester si ces termes sont significatifs.

Exemple 7.5. *Soit le modèle*

$$Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \varepsilon_i.$$

Nous pouvons tester si $H_0 : \ \beta_{12} = 0$ *contre* $H_1 : \ \beta_{12} \neq 0$ *à partir du modèle*

$$Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_{12} x_{1i} x_{2i} + \varepsilon_i.$$

Si nous ne rejetons pas H_0*, les données ne fournissent pas de preuve suffisante en faveur de cette interaction ; cela ne démontre pas que le modèle est adéquat. Si nous rejetons* H_0*, alors le modèle sans interaction n'est pas adéquat.*

Remarque 14. *Un cas particulier d'interaction est si on inclut une interaction entre une variable* x_j *et elle-même, ce qui crée un terme de la forme* x_j^2 *dans l'équation de régression. Ce peut être utile si la relation entre les variables est quadratique plutôt que linéaire. On y reviendra à la section 11.1.*

Chapitre 8

Choix de modèle pour la RLM

Sommaire

8.1 Vérification des postulats et transformations 73
8.1.1 Les résidus 73
8.1.2 Vérification de la linéarité 73
8.1.3 Homogénéité des variances 75
8.1.4 Normalité des erreurs 75
8.1.5 Transformation de Box-Cox 75
8.1.6 Indépendance des erreurs 75
8.1.7 Test pour manque d'ajustement (lack-of-fit) 76
8.2 Importance de la sélection de variables 78
8.3 Critères basés sur l'ajustement du modèle 80
8.3.1 Coefficient de détermination 80
8.3.2 Coefficient de détermination ajusté 80
8.3.3 Critère d'information d'Akaike (AIC) 80
8.3.4 Critère BIC ou SBC 81
8.4 Méthodes basées sur la puissance de prévision 81
8.4.1 Utilisation d'un jeu de validation 82
8.4.2 La validation croisée 82
8.4.3 Le C_p de Mallows 83
8.5 Méthodes algorithmiques 85
8.6 Régularisation (ou régression pénalisée) 89
8.6.1 La régression « ridge » 89
8.6.2 Le LASSO 90
8.7 Le cas des variables catégoriques et interactions 93
8.7.1 Sélection de modèle avec variables catégoriques 93
8.7.2 Sélection de modèle en présence d'interactions 93

Figures

8.1 Illustration de la différence entre le LASSO et la régression ridge. 91

Comme pour la RLS, il est important lors du choix de modèle de s'assurer que les postulats sont bien respectés. Une autre difficulté de la RLM est qu'il faut choisir les variables à inclure dans le modèle parmi toutes celles à notre disposition. Nous abordons ces deux étapes dans ce chapitre.

8.1 Vérification des postulats et transformations

L'analyse des résidus pour la RLM est très similaire à celle des résidus pour la RLS. Nous révisons ici brièvement les diagnostics de régression, et introduisons quelques nouvelles procédures.

8.1.1 Les résidus

Comme pour la RLS, le résidu est l'outil de base pour la vérification des postulats. On a déjà vu à la section 6.2.2 que $\widehat{\boldsymbol{\varepsilon}} = \boldsymbol{Y} - \widehat{\boldsymbol{Y}} = (\mathbb{I}_n - \boldsymbol{H})\boldsymbol{Y}$ et que

$$\widehat{\boldsymbol{\varepsilon}} \sim \mathcal{N}_n(0, \sigma^2(\mathbb{I}_n - \boldsymbol{H})).$$

Tout comme pour la RLS, les résidus suivent une loi normale de moyenne $\mathbf{0}$, mais ne sont pas indépendants et n'ont pas des variances homogènes.

Les résidus standardisés et studentisés sont définis exactement comme pour la RLS :

$$r_i = \frac{\hat{\varepsilon}_i}{\sqrt{\hat{\sigma}^2(1-h_{ii})}} \qquad t_i = \frac{\hat{\varepsilon}_i}{\hat{\sigma}_{(i)}\sqrt{1-h_{ii}}}$$

8.1.2 Vérification de la linéarité

On peut utiliser les mêmes graphiques que pour la RLS. On doit notamment observer le graphique de $\widehat{\boldsymbol{\varepsilon}}$ *versus* x_j pour toutes les variables explicatives. On pourra alors identifier la ou les variables pour lesquelles la relation avec Y n'est pas linéaire, et corriger le problème par une transformation appropriée.

Toutefois, **les graphiques à variable ajoutée** sont mieux adaptés au contexte de la régression multiple pour détecter le manque de linéarité. Un graphique à variable ajoutée est un nuage de points de $\widehat{\boldsymbol{\varepsilon}}_{\boldsymbol{Y}|\boldsymbol{X}_{-j}}$ vs $\widehat{\boldsymbol{\varepsilon}}_{x_j|\boldsymbol{X}_{-j}}$. Ici $\widehat{\boldsymbol{\varepsilon}}_{\boldsymbol{Y}|\boldsymbol{X}_{-j}}$ représente le vecteur des résidus obtenu en régressant $\boldsymbol{Y}$ sur toutes les variables exogènes du modèle **excepté** x_j. Il s'agit donc de la partie des Y_i qui n'est pas expliquée par l'ensemble des variables exogènes, sauf la variable d'intérêt. On veut ensuite savoir si ajouter la variable x_j permet d'expliquer davantage les Y_i. On pourrait tout simplement regarder la relation entre x_j et $\widehat{\boldsymbol{\varepsilon}}_{\boldsymbol{Y}|\boldsymbol{X}_{-j}}$, mais puisque x_j peut lui-même être expliqué par les autres variables exogènes, il faut être un peu plus rusé. On utilise donc $\widehat{\boldsymbol{\varepsilon}}_{x_j|\boldsymbol{X}_{-j}}$, soit le vecteur des résidus de la régression avec x_j comme

variable endogène et toutes les variables explicatives sauf x_j comme variables exogènes. On l'obtient en ajustant le modèle suivant :

$$x_{ij} = \delta_0 + \delta_1 x_{i1} + ... + \delta_p x_{ip} + \varepsilon_{i\,[x_j|\boldsymbol{X}_{-j}]}.$$

Plus les résidus de cette régression sont grands, plus x_j ajoute de l'information importante au modèle.

Le nuage de points de $\widehat{\boldsymbol{\varepsilon}}_{\boldsymbol{Y}|\boldsymbol{X}_{-j}}$ vs $\widehat{\boldsymbol{\varepsilon}}_{x_j|\boldsymbol{X}_{-j}}$ tombera dans un des trois cas suivants :

— Si x_j est vraiment une variable qui entre linéairement dans le modèle,
le graphique devrait donner une droite de pente β_j passant par l'origine.

— Si x_j est « inutile »,
le graphique devrait ressembler à un graphique de résidus ordinaires.

— Si x_j est utile mais entre dans le modèle de façon non linéaire,
le graphique devrait avoir l'allure d'une courbe plutôt que d'une droite. On pourra donc détecter le manque de linéarité en x_j de la moyenne de $\boldsymbol{Y}$.

Dans certains cas, il est également possible de tester la linéarité d'un modèle à l'aide d'un test de manque d'ajustement. Nous présentons celui-ci à la section 8.1.7.

8.1.3 Homogénéité des variances

On teste l'homogénéité des variances avec le graphique r_i vs $\hat{Y}_i$ comme pour la RLS. S'il y a un problème, on tentera souvent de le régler en transformant la variable endogène.

Notons également qu'il existe un test formel de l'homogénéité des variances, soit le test de White (1980). La statistique du test de White s'exprime comme suit

$$\chi^2_{\text{White}} = nR^2 \overset{a}{\sim} \chi^2_{p(p+3)/2}$$

où R^2 est le coefficient de détermination (R^2) de la régression de $\hat{\varepsilon}_i^2$ sur toutes les variables explicatives x_j, de même que sur tous les produits croisés entre ces variables, incluant le carré de chacune des variables. On rejette l'hypothèse d'homogénéité des variances au seuil α lorsque $\chi^2_{\text{White}} > \chi^2_{p(p+3)/2;1-\alpha}$.

8.1.4 Normalité des erreurs

Les mêmes outils que pour la RLS peuvent être utilisés pour tester la normalité des erreurs. Quand le postulat de normalité n'est pas rencontré, il peut être souhaitable d'utiliser la technique de transformation de Box-Cox (voir section 8.1.5) pour déterminer la meilleure transformation de la variable endogène.

Il vaut la peine de noter que le test de Shapiro-Wilk est très puissant et que pour de gros échantillons, il rejettera très souvent la normalité. Comme les seuils des tests t de Student et F de Fisher ne sont pas sérieusement affectés si la distribution des résidus est près de la normalité sans l'atteindre exactement, alors il est toujours bon d'accompagner le test de normalité d'un diagramme quantile-quantile pour s'assurer que la non-normalité est vraiment sérieuse.

8.1.5 Transformation de Box-Cox

Pour une réponse strictement positive, on peut considérer la famille

$$g_\lambda(Y) = \begin{cases} (Y^\lambda - 1)/\lambda, & \lambda \neq 0, \\ \log(Y), & \lambda = 0. \end{cases}$$

On choisit une transformation en tenant compte de la vraisemblance avec son jacobien, de l'interprétation et des diagnostics du modèle transformé. Une transformation ne corrige pas automatiquement tous les problèmes. L'inverse de la moyenne prédite sur l'échelle transformée n'est généralement pas la moyenne sur l'échelle originale. Il faut tenir compte de ce biais lorsqu'on souhaite prédire une moyenne sur l'échelle originale.

8.1.6 Indépendance des erreurs

On vérifie l'indépendance des erreurs exactement de la même façon que pour la RLS. Si les données sont chronologiques, on peut utiliser un graphique des résidus versus le temps. Sinon, il faut se fier à la description de la collecte de données.

8.1.7 Test pour manque d'ajustement (lack-of-fit)

Ce test permet de vérifier si le modèle proposé s'ajuste bien aux données. Il constitue un bon complément à l'analyse des résidus. Toutefois, ce test ne peut être utilisé que lorsque nous avons plusieurs observations dont la (les) variable(s) exogène(s) a (ont) exactement la (les) même(s) valeur(s).

Exemple 8.1. *Le tableau 8.1 montre un jeu de données où les observations 2 et 3, 4 et 5 et 7 et 8 ont les mêmes combinaisons de valeurs pour leurs variables exogènes. Un test de manque d'ajustement est donc possible dans ce cas.*

Obs	Y_i	x_1	x_2	Obs	Y_i	x_1	x_2
1	8.74	2	1				
2	7.10	2	0	3	9.85	2	0
4	12.1	5	1	5	13.1	5	1
6	14.1	5	0				
7	18.6	8	1	8	15.0	8	1
9	16.9	8	0				

TABLE 8.1 – Jeu de données pour lequel le test de manque d'ajustement s'applique.

Le test de manque d'ajustement se base sur le fait qu'on peut estimer σ^2 (l'erreur pure) grâce à la variabilité de la variable endogène parmi les observations ayant une même combinaison de variables exogènes. On peut ainsi séparer notre somme de carrés résiduels en une partie due à l'erreur pure et une partie due au manque d'ajustement du modèle. Mathématiquement, on écrira

$$\underbrace{\sum_{k=1}^{m}\sum_{j=1}^{n_k}(Y_{kj}-\hat{Y}_k)^2}_{SC_{res}} = \underbrace{\sum_{k=1}^{m}\sum_{j=1}^{n_k}(Y_{kj}-\overline{Y}_k)^2}_{SC_{pure}} + \underbrace{\sum_{k=1}^{m} n_k(\overline{Y}_k-\hat{Y}_k)^2}_{SC_{ajust.}}.$$

où

- m est le nombre de combinaisons distinctes des valeurs des variables exogènes
- n_k, le nombre d'observations de la k^e combinaison de variables exogènes
- Y_{kj} la j^e observation de la variable endogène pour la k^e combinaison de variables exogènes
- $\overline{Y}_k = \sum_j Y_{kj}/n_k$, la valeur moyenne de la variable endogène pour la k^e combinaison de variables exogènes

Si le modèle de régression est adéquat, alors $\hat{Y}_k$ sera une bonne estimation de la vraie moyenne de Y pour la k^e combinaison de variables exogènes. Dans ce cas, $\overline{Y}_k$ sera proche de la valeur prédite $\hat{Y}_k$ et la $SC_{ajust.}$ sera petite. On compare $SC_{ajust.}$ à SC_{pure} pour tester l'adéquation du modèle.

On teste donc les hypothèses

$H_0 : E(Y_i) = \beta_0 + \beta_1 x_1 + \ldots \beta_p x_p$

$H_1 : E(Y_i) \neq \beta_0 + \beta_1 x_1 + \ldots \beta_p x_p$

On procède alors à une analyse de variance, résumée au tableau 8.2.

	dl	SC	CM	F
Manque d'ajustement	$m - p'$	$SC_{ajust.}$	$\frac{SC_{ajust.}}{m-p'}$	$\frac{SC_{ajust.}/(m-p')}{SC_{pure}/(n-m)}$
Erreur pure	$n - m$	SC_{pure}	$\frac{SC_{pure}}{n-m}$	
Erreur totale	$n - p'$	SC_{res}		

TABLE 8.2 – Table d'ANOVA pour un test de manque d'ajustement

On rejette H_0 si $F \geq F_{m-p',n-m,\,1-\alpha}$. On peut également obtenir une valeur de p en comparant notre statistique F à la distribution $F_{m-p',n-m}$.

Exemple 8.2. *Dans les données de l'exemple 8.1, on a $m = 6$ combinaisons de valeurs différentes pour (x_{1i}, x_{2i}) : $\{(2,1),(2,0),(5,1),(5,0),(8,1),(8,0)\}$.*
On a par exemple $n_2 = 2$ observations avec $(x_{1i}, x_{2i}) = (2,0)$, et $\overline{Y}_2 = 8.475$.
On peut calculer les 5 autres moyennes pour obtenir SC_{pure}.

On ajuste également le modèle $Y_{ij} = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \varepsilon_{ij}$, et on obtient alors $\hat{Y}_1, \ldots, \hat{Y}_6$, ce qui permet de calculer SC_{res} et $SC_{ajust.}$. On trouve :

	dl	*SC*	*CM*	*F*	$Pr > F$
Manque ajustement	*3*	*1.598029*	*0.53267*	*0.1484*	*0.9242*
Erreur pure	*3*	*10.76125*	*3.58708*		
Erreur totale	*6*	*12.3598*	*2.0599*		

Il ne semble pas y avoir de problème de manque d'ajustement dans notre exemple. Bien entendu, avec le très petit nombre de données observé, très peu d'hypothèses peuvent être rejetées !

8.2 Importance de la sélection de variables

Pour la RLM, la vérification des postulats n'est pas le seul élément important dans le choix du modèle. Il faut aussi sélectionner les variables à inclure dans le modèle.

En effet, il se peut que certaines variables dans notre jeu de données de soient pas associées à la variable réponse. En présence d'un grand nombre de variables exogènes, on court deux dangers : enlever une variable qui est utile pour expliquer la variable endogène, et conserver dans le modèle une variable qui n'est pas utile.

Conserver une variable inutile

Si on conserve trop de variables, on va augmenter inutilement la variance des estimations. Par conséquent, certains effets importants risquent d'être jugés non significatifs.

Plus précisément, supposons que le bon modèle soit :

$$Y_i = \beta_0 + \beta_1 x_{1i} + ... + \beta_k x_{ki} + \varepsilon_i. \tag{8.1}$$

Si on ajoute la variable x_{k+1} et qu'on ajuste le modèle :

$$Y_i = \beta_0^* + \beta_1^* x_{1i} + ... + \beta_k^* x_{ki} + \beta_{k+1}^* x_{(k+1)i} + \varepsilon_i \tag{8.2}$$

on obtiendra que

$$\mathbb{V}\text{ar}[\hat{\beta}_j^*] \geq \mathbb{V}\text{ar}[\hat{\beta}_j], \qquad \text{pour } \; j = 1, ..., k.$$

De plus, la prévision faite pour Y en un $\boldsymbol{x}^*$ donné sera moins précise avec le modèle superflu de l'équation (8.2) qu'avec le modèle simple de l'équation (8.1).

Enlever une variable utile

À l'opposé, si on enlève trop de variables, le modèle sera biaisé. Pour illustrer le biais, prenons par exemple les deux modèles suivants exprimés sous forme matricielle :

$$\boldsymbol{Y} = \boldsymbol{X}_1\boldsymbol{\beta}_1 + \boldsymbol{\varepsilon}, \tag{8.3}$$

$$\boldsymbol{Y} = \boldsymbol{X}_1\boldsymbol{\beta}_1 + \boldsymbol{X}_2\boldsymbol{\beta}_2 + \boldsymbol{\varepsilon}, \tag{8.4}$$

où $\boldsymbol{\beta}_1$ comporte $p' = p + 1$ paramètres et $\boldsymbol{\beta}_2$ inclut $m - p'$ paramètres.

Supposons que le bon modèle soit celui de l'équation (8.4) et qu'on choisisse plutôt le modèle de l'équation (8.3), on aura alors

$$\begin{aligned}
\mathbb{E}[\widehat{\boldsymbol{\beta}}_1] &= (\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{X}_1'\mathbb{E}[\boldsymbol{Y}] \\
&= (\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{X}_1'(\boldsymbol{X}_1\boldsymbol{\beta}_1 + \boldsymbol{X}_2\boldsymbol{\beta}_2) \\
&= \boldsymbol{\beta}_1 + (\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{X}_1'\boldsymbol{X}_2\boldsymbol{\beta}_2.
\end{aligned}$$

On a donc que $\widehat{\boldsymbol{\beta}}_1$ est un estimateur biaisé.

Si l'on s'intéresse plutôt à la prévision au point $\boldsymbol{x}^* = \begin{bmatrix} \boldsymbol{x}_1^* \\ \boldsymbol{x}_2^* \end{bmatrix}$, le modèle à p' paramètres nous donnerait

$$\begin{aligned} \widehat{\boldsymbol{Y}}(\boldsymbol{x}_1^*) &= \boldsymbol{x}_1^{*'}\widehat{\boldsymbol{\beta}}_1 \\ \mathbb{E}[\widehat{\boldsymbol{Y}}(\boldsymbol{x}_1^*)] &= \boldsymbol{x}_1^{*'}\mathbb{E}[\widehat{\boldsymbol{\beta}}_1] \\ &= \boldsymbol{x}_1^{*'}\{\boldsymbol{\beta}_1 + (\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{X}_1'\boldsymbol{X}_2\boldsymbol{\beta}_2\} \end{aligned}$$

alors que le modèle à m paramètres conduirait à

$$\begin{aligned} \widehat{\boldsymbol{Y}}(\boldsymbol{x}^*) &= \boldsymbol{x}_1^{*'}\widehat{\boldsymbol{\beta}}_1^* + \boldsymbol{x}_2^{*'}\widehat{\boldsymbol{\beta}}_2^* \\ \mathbb{E}[\widehat{\boldsymbol{Y}}(\boldsymbol{x}^*)] &= \boldsymbol{x}_1^{*'}\boldsymbol{\beta}_1 + \boldsymbol{x}_2^{*'}\boldsymbol{\beta}_2. \end{aligned}$$

Le biais dans la prévision serait donc

$$\begin{aligned} \text{biais}[\widehat{\boldsymbol{Y}}(\boldsymbol{x}^*)] &= \mathbb{E}[\widehat{\boldsymbol{Y}}(\boldsymbol{x}_1^*)] - \mathbb{E}[\widehat{\boldsymbol{Y}}(\boldsymbol{x}^*)] \\ &= \boldsymbol{x}_1^{*'}\{\boldsymbol{\beta}_1 + (\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{X}_1'\boldsymbol{X}_2\boldsymbol{\beta}_2\} - \boldsymbol{x}_1^{*'}\boldsymbol{\beta}_1 - \boldsymbol{x}_2^{*'}\boldsymbol{\beta}_2 \\ &= [\boldsymbol{x}_1^{*'}(\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{X}_1'\boldsymbol{X}_2 - \boldsymbol{x}_2^{*'}]\boldsymbol{\beta}_2. \end{aligned}$$

En somme

En résumé, un trop grand nombre de variables mène à une variance trop grande et un trop petit nombre de variables conduit à une estimation biaisée. Il est donc important de chercher un ensemble de variables permettant d'atteindre un compromis entre ces deux critères. Pour ce faire, on a souvent recours à l'une des techniques de sélection de variables pour choisir un sous-ensemble raisonnable de variables.

8.3 Critères basés sur l'ajustement du modèle

Pour sélectionner les bonnes variables dans le modèle, plusieurs techniques sont disponibles. Voyons d'abord quelques critères basés sur l'ajustement du modèle.

8.3.1 Coefficient de détermination

Comme pour la RLS, le coefficient de détermination est défini comme

$$R^2 = \frac{SC_{reg}}{SC_{tot}} = 1 - \frac{SC_{res}}{SC_{tot}}. \tag{8.5}$$

C'est une mesure d'ajustement du modèle facile à calculer et à interpréter, mais il est problématique pour la RLM puisque sa valeur ne peut jamais diminuer si on ajoute une variable dans le modèle, même si celle-ci est inutile.

En effet, si on ajoute un terme à un modèle de régression, SC_{reg} ne peut pas diminuer. Comme SC_{tot} ne dépend pas du modèle, elle reste inchangée. Donc l'ajout d'un terme au modèle se traduit forcément par un R^2 plus grand. L'ajout de termes superflus réduit en général la précision dans les prévisions, ce qu'on souhaite éviter. Le coefficient de détermination n'est donc pas utile pour la RLM.

8.3.2 Coefficient de détermination ajusté

Il s'agit d'un coefficient de détermination qui pénalise pour l'ajout d'un trop grand nombre de variables. Plus précisément, il est défini comme :

$$R_a^2 = 1 - \frac{CM_{res}}{CM_{tot}} = 1 - \frac{SC_{res}/(n-p')}{SC_{tot}/(n-1)} = 1 - \frac{(n-1)\hat{\sigma}^2}{SC_{tot}}. \tag{8.6}$$

Avec R_a^2, l'ajout d'une variable exogène peut aussi résulter en une diminution de la statistique. Comme on peut le voir dans la dernière égalité de l'équation (8.6), comparer deux modèles sur la base de leur R_a^2 est équivalent à comparer deux modèles sur la base de leur estimation de la variance des termes d'erreur $\hat{\sigma}^2$, puisque SC_{tot} et n ne dépendent pas du modèle choisi.

Notez que peu importe si on utilise R^2 ou R_a^2, on ne peut pas vraiment se fier sur ces statistiques pour comparer des modèles employant des transformations différentes de la variable endogène, ou un modèle avec et un modèle sans ordonnée à l'origine.

8.3.3 Critère d'information d'Akaike (AIC)

Le critère d'information d'Akaike a été proposé par Hirotsugu Akaike (1974), un statisticien japonais. Ce critère est assez utilisé dans la pratique et permet d'évaluer la qualité de l'ajustement d'un modèle. Il est défini de plusieurs façons dans la littérature, mais il est toujours basé sur la log-vraisemblance

maximisée :

$$\begin{aligned} -2\ln L(\widehat{\boldsymbol{\beta}}, \hat{\sigma}^2_{\mathsf{ML}}) &= \sum_{i=1}^{n} \frac{(Y_i - \hat{Y}_i)^2}{\hat{\sigma}^2_{\mathsf{ML}}} + n\ln(2\pi\hat{\sigma}^2_{\mathsf{ML}}) \\ &= n + n\ln(2\pi\hat{\sigma}^2_{\mathsf{ML}}) \\ &= n + n\ln(2\pi) + n\ln(SC_{res}/n), \end{aligned}$$

car $\hat{\sigma}^2_{\mathsf{ML}} = \sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2/n = SC_{res}/n$.

Les différentes définitions du AIC varient par une constante additive dépendant de n. Puisque tous les modèles sont basés sur les mêmes observations (donc le même n), on sélectionnera les mêmes variables avec n'importe laquelle de ces versions :

Critère	Procédure SAS	Fonction R
$AIC_1 = n\ln(SC_{res}/n) + 2p'$	REG	`extractAIC, stepAIC`
$AIC_2 = n\ln(SC_{res}/n) + 2p' + n + 2$	GLMSELECT	
$AIC_3 = n\ln(SC_{res}/n) + 2(p'+1) + n + n\ln(2\pi)$		`AIC`

L'AIC prend en compte à la fois la qualité des prédictions du modèle et sa complexité. En effet, un modèle qui s'ajuste bien sur les observations est associé à une faible valeur de SC_{res} et donc à une faible valeur de $n\ln(SC_{res}/n)$. La complexité du modèle est prise en compte en ajoutant le double du nombre de paramètres ($2p'$) à cette dernière quantité. Un bon modèle est donc associé à une faible valeur d'AIC.

8.3.4 Critère BIC ou SBC

Le BIC, pour Bayesian Information Criterion, souvent appelé SBC pour Schwarz Bayesian Criterion, est un critère semblable à l'AIC. Il est aussi défini de différentes façons :

Critère	Procédure SAS	Fonction R
$BIC_1 = n\ln(SC_{res}/n) + \ln(n)p'$	REG	`extractAIC(...,k=log(n))`
	GLMSELECT	`stepAIC(...,k=log(n))`
$BIC_2 = n\ln(SC_{res}/n) + \ln(n)(p'+1) + n + n\ln(2\pi)$		`BIC`
		`AIC(...,k=log(n))`

La seule différence avec l'AIC est que la pénalité pour le nombre de variables grandit avec le nombre d'observations. En général, la pénalité du BIC sera supérieure à celle de l'AIC. Le BIC tend donc à sélectionner des modèles moins complexes que l'AIC.

8.4 Méthodes basées sur la puissance de prévision

Si on se préoccupe beaucoup de la capacité prédictive de notre modèle, on peut utiliser certains critères qui mesurent directement la prévision du modèle plutôt que son ajustement. On pourrait simple-

ment regarder la taille des résidus du modèle puisqu'un meilleur modèle devrait mener à de plus petits résidus. Toutefois, on risque de sous-estimer l'erreur de prévision du modèle puisqu'on triche en quelque sorte en testant la prévision de notre modèle sur les données qui ont été utilisées pour l'estimer. On présente ici quelques alternatives.

8.4.1 Utilisation d'un jeu de validation

Une méthode simple et efficace pour mesurer la capacité de prévision d'un modèle est de séparer notre jeu de données en deux au tout début de l'analyse. Avec la première partie, nommée jeu de données d'entraînement, on estime les paramètres du modèle. On prédit ensuite la valeur de la variable dépendante pour les observations dans la deuxième partie du jeu de données, appelé jeu de validation. On choisit le modèle pour lequel l'erreur quadratique moyenne de prévision, soit la moyenne des carrés des erreurs sur le jeu de validation, est la plus petite.

L'avantage ici est que puisque les observations du jeu de validation n'ont pas été utilisées pour estimer les paramètres du modèle, on a une meilleure estimation de l'erreur de prévision réelle. Toutefois, cela fait moins d'observations pour ajuster le modèle, et donc des estimations moins précises. L'utilisation d'un jeu de validation est donc en général limité aux situations où la taille du jeu de données originale est très grande.

8.4.2 La validation croisée

Si notre jeu de données n'est pas assez grand pour utiliser un jeu de validation, on peut avoir recours à la validation croisée. L'idée est la même que pour le jeu de validation, soit de tester le modèle sur des données qui n'ont pas été utilisées pour l'ajuster, mais ici les données font tour à tour partie du jeu de données d'entraînement et du jeu de données de validation. L'algorithme est le suivant :

1. Diviser les données en k échantillons.
2. Ajuster un modèle sur $k-1$ des échantillons et l'utiliser pour prédire les valeurs dans le dernier échantillon. Calculer l'erreur quadratique moyenne.
3. Répéter k fois l'étape 2 avec un échantillon différent pour le test à chaque fois.
4. Calculer la moyenne des k erreurs quadratiques moyennes.

Cet algorithme permet de bien estimer l'erreur de prévision du modèle pour un choix approprié de k, mais peut être assez demandant en temps de calcul.

Critère PRESS

Une alternative efficace pour la RLM consiste à utiliser la validation croisée avec $k = n$ échantillons de validation, c'est-à-dire à enlever chacune des observations une à une du jeu d'entraînement.

Soit $\hat{Y}_{i,-i}$ la prévision pour l'observation i obtenue à l'aide d'un modèle de régression estimé sans l'observation i. On définit alors le i^e résidu $PRESS$ (pour PREdiction Sum of Squares) comme étant

$$\hat{\varepsilon}_{i,-i} = Y_i - \hat{Y}_{i,-i}.$$

À première vue, cela semble allonger le temps de calcul, mais il est en fait possible de calculer l'erreur quadratique moyenne de façon analytique dans ce cas.

Théorème 3. *Le i^e résidu $PRESS$ peut être obtenu à l'aide du i^e résidu ordinaire et de l'élément en position i, i de la matrice chapeau grâce à la relation*

$$\hat{\varepsilon}_{i,-i} = \frac{\hat{\varepsilon}_i}{1 - h_{ii}}.$$

Pour comparer des modèles, on peut donc calculer le critère

$$PRESS = \sum_{i=1}^{n} \hat{\varepsilon}_{i,-i}^2 = \sum_{i=1}^{n} (Y_i - \hat{Y}_{i,-i})^2 = \sum_{i=1}^{n} \left(\frac{\hat{\varepsilon}_i}{1 - h_{ii}} \right)^2.$$

Le critère $PRESS$ permet de comparer entre eux tous les modèles utilisant la même transformation pour la variable endogène. Évidemment, plus le critère $PRESS$ est faible, plus le modèle prédit bien.

Le critère $PRESS$ peut aussi servir à définir un *coefficient de détermination de prévision* de la manière suivante :

$$R_p^2 = 1 - \frac{PRESS}{SC_{tot}} = 1 - \frac{\sum_{i=1}^{n} (Y_i - \hat{Y}_{i,-i})^2}{\sum_{i=1}^{n} (Y_i - \overline{Y})^2}. \tag{8.7}$$

Encore une fois, une valeur de R_p^2 approchant 1 est signe d'un modèle qui prédit bien, tandis qu'une valeur approchant 0 indique un modèle qui prédit mal.

Remarque 15. *Il est bon d'examiner également chaque résidu $PRESS$ de façon individuelle. En effet, un modèle précis dont une seule des prévisions est mauvaise pourrait être indûment pénalisé par la somme $PRESS$.*

8.4.3 Le C_p de Mallows

Il existe également un autre critère de comparaison de modèle basé sur la prévision du modèle, soit le C_p de Mallows. Il est maintenant peu utilisé en pratique, mais nous le décrivons tout de même ici car il s'agit d'un critère classique de sélection de modèle.

Idée

On a vu précédemment qu'un trop grand nombre de variables cause un problème de variance et qu'un nombre insuffisant de variables induit un problème de biais. Un compromis serait de tenter de minimiser

l'erreur quadratique moyenne (EQM) de prévision d'un modèle à p variables lorsque m variables sont disponibles.

$$\begin{aligned}\mathsf{EQM}[\hat{Y}(\boldsymbol{x}^*)] &= \mathbb{V}\mathsf{ar}[\hat{Y}(\boldsymbol{x}^*)] + \mathsf{biais}^2[\hat{Y}(\boldsymbol{x}^*)] \\ &= \sigma^2 \boldsymbol{x}_{\boldsymbol{1}}^{*\prime}(\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{x}_{\boldsymbol{1}}^* + \left\{[\boldsymbol{x}_{\boldsymbol{1}}^{*\prime}(\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{X}_1'\boldsymbol{X}_2 - \boldsymbol{x}_{\boldsymbol{2}}^{*\prime}]\boldsymbol{\beta}_2\right\}^2\end{aligned}$$

Pour minimiser l'EQM, on fait face à deux difficultés : premièrement, on ne sait pas quel $\boldsymbol{x}^*$ choisir ; deuxièmement, l'EQM dépend de $\boldsymbol{\beta}_2$, que l'on ne connaît pas. Mallows a donc proposé un autre critère, qui permet de régler le premier problème : on minimise

$$\sum_{i=1}^{n} \frac{\mathsf{EQM}[\hat{Y}(x_i)]}{\sigma^2}.$$

La division par σ^2 permettra une simplification commode.

Calcul de la portion variance de l'EQM

$$\begin{aligned}\sum_{i=1}^{n} \frac{\mathbb{V}\mathsf{ar}[\hat{Y}(\boldsymbol{x}_i)]}{\sigma^2} &= \sum_{i=1}^{n} \frac{\boldsymbol{x}_{1i}'\mathbb{V}\mathsf{ar}[\widehat{\boldsymbol{\beta}}_1]\boldsymbol{x}_{1i}}{\sigma^2} \\ &= \sum_{i=1}^{n} \boldsymbol{x}_{1i}'(\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{x}_{1i} \\ &= \sum_{i=1}^{n} \mathsf{tr}[\boldsymbol{x}_{1i}'(\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{x}_{1i}] \\ &= \sum_{i=1}^{n} \mathsf{tr}[\boldsymbol{x}_{1i}\boldsymbol{x}_{1i}'(\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}] \\ &= \mathsf{tr}\left[(\sum_{i=1}^{n} \boldsymbol{x}_{1i}\boldsymbol{x}_{1i}')(\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\right] \\ &= \mathsf{tr}\left[(\boldsymbol{X}_1'\boldsymbol{X}_1)(\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\right] \\ &= \mathsf{tr}(I_p') = p'\end{aligned}$$

Dans le développement ci-dessus, nous avons utilisé le fait que la trace d'un nombre réel est le nombre lui-même et que $\mathsf{tr}(AB) = \mathsf{tr}(BA)$.

Calcul de la portion biais de l'EQM La portion biais peut être estimée facilement une fois que l'on réalise que

$$\mathbb{E}[\hat{\sigma}_p^2] = \sigma^2 + \frac{\sum_{i=1}^{n} \mathsf{biais}[\hat{Y}(x_i)]^2}{n - p'}$$

où $\hat{\sigma}_p^2$ est la variance calculée dans le modèle à p variables. Si σ^2 était connu, on pourrait estimer $\sum_{i=1}^{n} \mathsf{biais}[\hat{Y}(x_i)]^2$ par $(\hat{\sigma}_p^2 - \sigma^2)(n - p')$. Puisque σ^2 est inconnu, on l'estime par $\hat{\sigma}_{toutes}^2$, la variance

calculée dans le modèle incluant toutes les variables disponibles. Le critère proposé par Mallows est donc le suivant :

$$C_p \quad = \quad p' + \frac{(\hat{\sigma}_p^2 - \hat{\sigma}_{toutes}^2)(n-p')}{\hat{\sigma^2}_{toutes}}.$$

En pratique, un modèle pour lequel $C_p \approx p'$ (ou $C_p - p' \approx 0$) est un bon modèle. Une façon simple de choisir un modèle lorsque k variables exogènes sont disponibles est de calculer le C_p des 2^{k+1} modèles possibles et de prendre celui pour lequel $C_p - p'$ est le plus faible. Mais en général, on utilise C_p pour cerner un petit ensemble de modèles raisonnables, et ensuite on utilise d'autres critères ($PRESS$, R_a^2, etc.) pour départager ces modèles. On peut réécrire le C_p de la façon suivante, où SC_{res} est associée au modèle à p variables :

$$C_p \quad = \quad \frac{SC_{res}}{\hat{\sigma^2}_{toutes}} + 2p' - n$$

8.5 Méthodes algorithmiques

On a beau avoir des critères pour comparer les modèles 2 à 2, encore faut-il savoir quels modèles comparer. En effet, le nombre de modèles possibles à comparer augmente très rapidement avec le nombre de variables et si p est grand il peut être impossible de tester tous les modèles possibles. Certaines méthodes algorithmiques ont été proposées pour tenter de trouver le meilleur modèle par une série d'optimisations.

L'utilisation de ces méthodes est toutefois de moins en moins conseillée, pour plusieurs raisons

- Il n'y a aucune garantie de trouver le modèle optimal. Le modèle final est un peu trop adapté à l'échantillon.
- Les procédures sont difficiles à appliquer en présence d'interactions.
- L'inférence à partir du modèle final n'est pas exacte. Les valeurs p sont sous-estimées, car on fait de l'inférence conditionnelle et de multiples tests non indépendants.
- Les données dictent la théorie, alors qu'on voudrait confronter la théorie à des données.

Nous décrivons toutefois les 3 méthodes algorithmiques les plus connues. :

— **Méthode d'inclusion** : on entre les variables une à une tant qu'elles sont significatives.

— **Méthode d'exclusion** : on entre toutes les variables, puis on les retire une à une tant qu'il reste des coefficients non significatifs.

— **Méthode pas-à-pas** : On entre une variable, puis à chaque étape on vérifie s'il est justifié d'ajouter ou de retirer une variable.

À chaque étape de ces méthodes, il faut choisir un critère objectif qui déterminera s'il est utile d'entrer ou de retirer une variable du modèle. Ce peut être un seuil de test si on procède par statistique de Fisher, ou encore un des critères d'ajustement de modèle vus précédemment.

Méthode d'inclusion (*forward*)

1. Commencer avec $Y_i = \beta_0 + \varepsilon_i$.
2. Identifier la variable j qui améliore le plus le modèle d'après le critère de sélection.
3. Si elle est significative (ou si le critère est amélioré), ajouter cette variable au modèle : $Y_i = \beta_0 + \beta_j X_{ij} + \varepsilon_i$
4. Répéter les étapes 2 et 3 jusqu'à qu'aucune variable n'améliore le modèle.

On peut utiliser tout critère de notre choix : R^2_a, $PRESS$, C_p, AIC, BIC ou test F de réduction de modèle (puisqu'on compare des modèles emboîtés).

Méthode d'exclusion (*backward*)

1. Commencer avec le modèle complet (toutes les variables).
2. Identifier, si elle existe, la variable j qui améliore le plus le modèle si on l'enlève (ou qui apporte un gain non significatif une fois les autres prises en compte)
3. Enlever cette variable du modèle.
4. Répéter les étapes 2 et 3 jusqu'à ce qu'aucune variable ne puisse être enlevée pour améliorer le modèle.

Méthode pas à pas (*stepwise*)

Cette méthode combine les deux premières.

1. Commencer avec uniquement l'ordonnée à l'origine : $Y_i = \beta_0 + \varepsilon_i$.
2. Faire un pas avec la méthode d'inclusion.
3. Faire un pas avec la méthode d'exclusion.
4. Répéter les étapes 2 et 3 jusqu'à ce qu'aucune variable ne puisse être enlevée ou ajoutée pour améliorer le modèle.

On peut spécifier des seuils différents pour l'inclusion et l'exclusion des variables.

Exemple 8.3. *Prenons un cas avec trois variables et $n = 10$ observations pour illustrer les méthodes de sélection de variables dites algorithmiques (inclusion, exclusion et pas à pas). On utilisera ici le test F de réduction de modèle comme critère d'inclusion et d'exclusion, à l'aide de l'information dans le tableau ci-dessous.*

Variables du modèle	SC_{res}
aucune	*30*
x_1	*25*
x_2	*24*
x_3	*20*
x_1, x_2	*6*
x_1, x_3	*15*
x_2, x_3	*12*
x_1, x_2, x_3	*4*

- *Si on procède par inclusion, avec un seuil d'entrée de $\alpha_E = 0,25$:*

1. *On commence avec la variable x_3 (la plus importante baisse de SC_{res}). On compare le modèle nul et (x_3) avec un test F. On obtient $F = \frac{30-20}{20/(10-2)} = 4 > F_{0,25;1;8} = 1,54$ donc on inclut la variable x_3.*
2. *On essaie ensuite d'inclure la variable x_2 (la plus importante baisse de SC_{res} une fois que x_3 est prise en compte). On compare les modèles (x_3) et (x_2, x_3). On obtient $F = \frac{20-12}{12/(10-3)} = 4,67 > F_{0,25;1;7} = 1,57$ donc on inclut la variable x_2.*
3. *Enfin on essaie la variable x_1. On compare les modèles (x_2, x_3) et (x_1, x_2, x_3). On obtient $F = \frac{12-4}{4/(10-4)} = 12 > F_{0,25;1;6} = 1,62$ donc on inclut la variable x_1.*

Le modèle final avec la méthode d'inclusion est $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \varepsilon$.

- *Si on procède par exclusion, avec un seuil de sortie de $\alpha_S = 0,10$:*

1. *On retire x_3 (son retrait cause la plus petite hausse de SC_{res}) et on compare les modèles (x_1, x_2) et (x_1, x_2, x_3). On obtient $F = \frac{6-4}{4/(10-4)} = 3 < F_{0,10;1;6} = 3,78$. On rejette la variable x_3 du modèle.*
2. *On retire x_1 et on compare les modèles (x_1, x_2) et (x_2). On obtient $F = \frac{24-6}{6/(10-3)} = 21 > F_{0,10;1;7} = 3,58$. On ne rejette pas la variable x_1.*

Le modèle final avec la méthode d'exclusion est $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$.

• *Si on utilise la méthode pas à pas avec* $\alpha_E = 0,25$ *et* $\alpha_S = 0,10$*, on vérifie à chaque étape si une des variables peut entrer, puis si une des variables doit sortir :*

1. • *La meilleure candidate pour entrer est la variable* x_3*. Comme dans la méthode d'inclusion, on obtient* $F = \frac{30-20}{20/(10-2)} = 4 > F_{0,25;1;8} = 1,54$ *donc on inclut la variable* x_3*.*

   • *Comme* x_3 *est la seule dans le modèle, c'est la seule candidate pour sortir. Puisque* $F = 4 > F_{0.10,1,8} = 3,46$*, on la garde dans le modèle.*

   Le modèle à cette étape est $Y = \beta_0 + \beta_3\, x_3 + \varepsilon$*.*

2. • *La meilleure candidate pour entrer est la variable* x_2*. On compare les modèles* (x_3) *et* $(x_2,\, x_3)$*. On obtient* $F = \frac{20-12}{12/(10-3)} = 4,67 > F_{0,25;1;7} = 1,57$ *donc on inclut la variable* x_2*.*

   • *On vérifie si* x_2 *et* x_3 *sont toujours pertinentes avec l'arrivée de* x_2*. Comme retirer* x_2 *mène au* SC_{res} *le plus bas, on compare les modèles* (x_3) *et* $(x_2,\, x_3)$ *au seuil de 10%. Puisque* $F = 4,67 > F_{0,10;1;7} = 3,58$ *, on garde* x_2 *dans le modèle.*

   Le modèle à cette étape est $Y = \beta_0 + \beta_2\, x_2 + \beta_3\, x_3 + \varepsilon$*.*

3. • *Enfin on essaie la variable* x_1*. On compare les modèles* $(x_2,\, x_3)$ *et* $(x_1,\, x_2,\, x_3)$*. On obtient* $F = \frac{12-4}{4/(10-4)} = 12 > F_{0,25;1;6} = 1,62$ *donc on inclut la variable* x_1*.*

   • *On vérifie si les 3 variables sont toujours pertinentes individuellement. Comme retirer* x_3 *mène au* SC_{res} *le plus bas à deux variables, on compare les modèles* $(x_1,\, x_2)$ *et* $(x_1,\, x_2,\, x_3)$ *au seuil de 10%.* $F = \frac{6-4}{4/(10-4)} = 3 < F_{0,10;1;6} = 3,78$*. On rejette la variable* x_3 *du modèle.*

Le modèle final avec la méthode pas à pas est $Y = \beta_0 + \beta_1\, x_1 + \beta_2\, x_2 + \varepsilon$*.*

8.6 Régularisation (ou régression pénalisée)

La régularisation est une technique statistique très générale qui fait référence au fait d'ajouter une pénalité à un modèle pour pénaliser les modèles trop complexes et éviter le sur-ajustement, particulièrement en présence d'un grand nombre de variables explicatives. La méthode de régularisation qui nous intéresse dans cette section est le LASSO, qui peut être utilisé pour la sélection de variables. Nous présentons d'abord la régression ridge, qui est une méthode de régularisation voisine du LASSO. On introduit un biais dans les estimateurs dans le but de diminuer la variance des prédictions.

8.6.1 La régression « ridge »

La régression ridge fut très populaire dans les années 1970-80. Elle consiste à estimer les paramètres de régression en ajoutant une petite constante $k > 0$ à la diagonale de la matrice $\boldsymbol{X}'\boldsymbol{X}$ avant de calculer son inverse. Dans les formules suivantes, les prédicteurs sont centrés et réduits, la réponse est centrée, et $\boldsymbol{X}$ ne contient pas de colonne de 1. La constante est récupérée séparément et n'est pas pénalisée. On obtient alors

$$\begin{aligned}
\widehat{\boldsymbol{\beta}}(k) &= (\boldsymbol{X}'\boldsymbol{X} + k\mathbb{I})^{-1}\boldsymbol{X}'\boldsymbol{Y} \\
&= \{(\boldsymbol{X}'\boldsymbol{X})\left[\mathbb{I} + k(\boldsymbol{X}'\boldsymbol{X})^{-1}\right]\}^{-1}\boldsymbol{X}'\boldsymbol{Y} \\
&= \{\mathbb{I} + k(\boldsymbol{X}'\boldsymbol{X})^{-1}\}^{-1}(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{Y} \\
&= \{\mathbb{I} + k(\boldsymbol{X}'\boldsymbol{X})^{-1}\}^{-1}\widehat{\boldsymbol{\beta}}.
\end{aligned}$$

L'estimateur $\widehat{\boldsymbol{\beta}}(k)$ est un estimateur biaisé pour β, ce qui peut sembler problématique. L'intérêt de l'estimateur réside dans sa variance, qui est donnée par

$$\mathbb{V}\text{ar}[\widehat{\boldsymbol{\beta}}(k)] = (\boldsymbol{X}'\boldsymbol{X} + k\mathbb{I})^{-1}(\boldsymbol{X}'\boldsymbol{X})(\boldsymbol{X}'\boldsymbol{X} + k\mathbb{I})^{-1}\sigma^2.$$

Dans certains cas, $\widehat{\boldsymbol{\beta}}(k)$ a une variance largement inférieure à celle de $\widehat{\boldsymbol{\beta}}$, ce qui compense le gain en biais en terme d'erreur quadratique moyenne. On peut d'ailleurs choisir k dans le but de minimiser cette erreur quadratique moyenne.

La régression ridge peut être utile en particulier en présence de multicolinéarité (voir la section 9.3) ou lorsque $p > n$.

Il est dur d'interpréter la valeur de k dans l'estimateur ridge, mais elle est reliée à une contrainte fixée sur la longueur du vecteur $\widehat{\boldsymbol{\beta}}(k)$, i.e. sur $\widehat{\boldsymbol{\beta}}(k)'\widehat{\boldsymbol{\beta}}(k)$. Une formulation équivalente de l'estimateur met en évidence cette interprétation.

Formulation équivalente

On peut voir la régression ridge autrement. Elle est équivalente à ajuster une régression linéaire normale mais en ajoutant une pénalité à la somme des carrés. On minimise ainsi

$$Q_{Ridge}(\beta) = \sum_{i=1}^{n}(Y_i - (\beta_1 x_{i1} + ... + \beta_p x_{ip}))^2 + \lambda \sum_{j=1}^{p} \beta_j^2$$

Nous n'irons pas dans ces détails ici, mais notez qu'on peut écrire le k de la formulation précédente en fonction du λ de cette formulation.

En comparaison avec la méthode des moindres carrés originale, cette pénalité force les coefficients estimés à être plus proches de 0 qu'avec le critère des moindres carrés. L'estimateur est toutefois une fonction de λ, qu'on doit choisir. On choisit en général λ à l'aide d'un estimateur du risque de prévision, par exemple la validation croisée.

L'idée d'ajouter une pénalité au critère des moindres carrés pour faire un compromis entre le biais et la variance de l'estimateur est plus générale que la simple régression ridge. En particulier, différentes pénalités peuvent être utilisées pour régulariser. La méthode LASSO utilise une pénalité particulièrement utile pour la sélection de variables.

8.6.2 Le LASSO

Le LASSO (*Least Absolute Shrinkage and Selection Operator*) a été proposé par Tibshirani en 1995. On minimise dans ce cas

$$Q_{Lasso}(\beta) = \sum_{i=1}^{n}(Y_i - (\beta_1 x_{i1} + ... + \beta_p x_{ip}))^2 + \lambda \sum_{i=1}^{p} |\beta_j|$$

Notez que la seule différence avec la régression ridge est qu'on somme les valeurs absolues des coefficients estimés dans la pénalité, et non les carrés de ces mêmes coefficients. L'avantage du LASSO est que cette pénalité ne fait pas que biaiser les estimations vers 0, elle force certains coefficients à valoir exactement 0. On a donc directement une sélection de modèle ! La figure 8.1 illustre pourquoi c'est le cas.

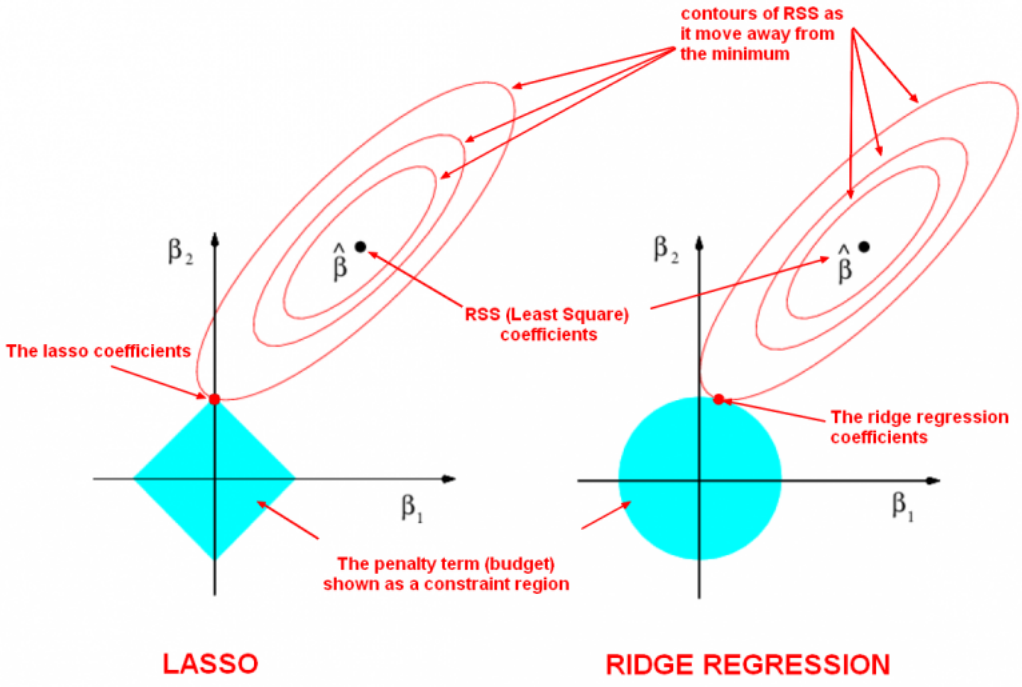


FIGURE 8.1 – Illustration de la différence entre le LASSO et la régression ridge.

Source : http://gerardnico.com/wiki/data_mining/lasso

Tel qu'indiqué plus haut, il faut choisir le paramètre λ pour obtenir une estimation avec le LASSO. Celui-ci est généralement choisi pour minimiser l'erreur de prévision, telle qu'estimée par une méthode comme la validation croisée.

Notons que sous certaines hypothèses, on peut montrer que le LASSO identifie correctement les coefficients qui ne valent pas 0 avec une grande probabilité. Toutefois, les estimateurs sont en général biaisés vers 0, et pas nécessairement convergents. En pratique, on utilise donc parfois le LASSO pour faire une sélection de variables, et on estime ensuite les coefficients avec la méthode des moindres carrés sans pénalité.

Enfin, un autre avantage de la régression LASSO est qu'elle permet d'ajuster un modèle dans le cas où le nombre de paramètres à estimer p' est supérieur au nombre d'observations n.

8.7 Le cas des variables catégoriques et interactions

Dans le cas de modèles de régression contenant des variables catégoriques et des interactions, il faut être un peu plus prudent dans la sélection de modèle.

8.7.1 Sélection de modèle avec variables catégoriques

La sélection se fait comme à l'habitude en présence de variables dichotomiques.

Avec des variables polytomiques, la règle utilisée en sélection de modèle, quel que soit le critère de sélection, est que les β correspondant à une même variable polytomique soient ou bien tous exclus du modèle, ou bien tous inclus dans le modèle. On peut aussi décider de fusionner certaines catégories de la variable polytomique si c'est suggéré par la forme du modèle sélectionné.

Exemple 8.4. *Considérons de nouveau l'exemple 7.1. Si un critère de sélection indique que le meilleur modèle est* $Y_i = \beta_0 + \beta_{11}x_{11i} + \beta_{13}x_{13i} + \varepsilon_i$*, alors on ajoutera* $\beta_{12}x_{12i}$ *à ce modèle car* β_{11}*,* β_{12} *et* β_{13} *sont tous reliés à la variable « lot »et doivent donc ou tous être inclus dans le modèle, ou tous être exclus du modèle, et comme au moins un de ces* β *semble important, nous les incluons tous. On pourrait aussi décider de fusionner les lots 1 et 2 pour créer une nouvelle variable à trois catégories.*

8.7.2 Sélection de modèle en présence d'interactions

Si une interaction entre plusieurs variables exogènes est incluse dans un modèle, on laisse en général les effets plus simples correspondants dans le modèle. Ceci facilitera l'interprétation des différents coefficients du modèle.

Exemple 8.5. *Supposons que le modèle complet est*

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_{12} x_1 x_2 + \beta_{13} x_1 x_3 + \beta_{23} x_2 x_3 + \varepsilon,$$

mais que les procédures de sélection de variables indiquent que seulement les coefficients β_1 *et* β_{23} *semblent importants. Nous utiliserions alors le modèle*

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_{23} x_2 x_3 + \varepsilon$$

car avec la présence de β_{23} *dans le modèle, il est recommandé d'y inclure* β_2 *et* β_3*.*

Chapitre 9

Multicolinéarité

Sommaire

9.1 Introduction et définition 94
9.2 Détection de la multicolinéarité 95
9.2.1 La matrice de corrélations 95
9.2.2 Le facteur d'inflation de la variance (VIF) 96
9.2.3 L'indice de conditionnement 97
9.3 Les solutions possibles à la multicolinéarité 99
9.3.1 La régression « ridge » 99
9.3.2 La régression basée sur les composantes principales 99

9.1 Introduction et définition

Depuis le début du cours, nous avons supposé que la matrice $\boldsymbol{X}$ est une matrice de plein rang, c'est-à-dire qu'il existe une unique inverse à la matrice $\boldsymbol{X}'\boldsymbol{X}$, et donc qu'il n'existe qu'un seul vecteur $\widehat{\boldsymbol{\beta}}$ qui minimise la somme des carrés résiduels SC_{res}. Toutefois, en pratique certaines colonnes de $\boldsymbol{X}$ peuvent être reliées linéairement entre elles. C'est ce qu'on nomme la multicolinéarité.

La définition mathématique formelle de la multicolinéarité est la suivante.

Définition 9.1. *Il y a **multicolinéarité exacte** lorsqu'une variable est la combinaison linéaire d'une ou de plusieurs autres variables, c'est-à-dire lorsqu'il existe une combinaison de constantes $d_1, \ldots, d_p$ (pas toutes égales à zéro) telle que*

$$\sum_{j=1}^{p} d_j X_j = \mathbf{0}.$$

Définition 9.2. *La **multicolinéarité** au sens large se produit lorsqu'il existe une combinaison de*

constantes $d_1, \ldots, d_p$ (pas toutes égales à zéro) telle que

$$\sum_{j=1}^{p} d_j X_j \approx \mathbf{0}.$$

Dans le cas de multicolinéarité exacte, la matrice $\boldsymbol{X}'\boldsymbol{X}$ n'est pas inversible et les coefficients ne sont pas tous identifiables de façon unique. Les valeurs ajustées restent définies comme la projection de $\boldsymbol{Y}$ sur l'espace engendré par les colonnes de $\boldsymbol{X}$. La multicolinéarité exacte ne représente pas un problème : elle se détecte facilement et il suffit d'enlever la ou les variables en cause pour régler le problème. La multicolinéarité au sens large est plus fréquente et plus difficile à détecter.

La multicolinéarité au sens large pose plusieurs problèmes :

1. Instabilité de $(\boldsymbol{X}'\boldsymbol{X})^{-1}$, ce qui entraîne qu'une petite variation en $\boldsymbol{Y}$ peut se traduire par de très grands changements en $\widehat{\boldsymbol{\beta}}$. Les valeurs ajustées aux profils observés peuvent toutefois rester stables.
2. On observe des $\hat{\beta}_i$ de signe inattendu ou contre-intuitif.
3. Les variances de certains $\hat{\beta}_i$ peuvent être grandes. Les prédictions à des profils éloignés du domaine observé peuvent également être peu précises.
4. Les méthodes de sélection de variables ne concordent pas.
5. Certains paramètres peuvent se révéler non-significatifs alors que la corrélation des variables correspondantes avec Y est très grande.

Le problème, au fond, est que les variables s'expliquent entre elles. Si on s'imagine l'espace d'une régression à deux variables, c'est comme si les points étaient alignés en ńpiquets de clôtureż. Ce phénomène n'est pas facile à détecter dans un espace à haute dimension. Nous présenterons ici quelques outils de détection de la multicolinéarité.

9.2 Détection de la multicolinéarité

9.2.1 La matrice de corrélations

À première vue, on pourrait être tenté de calculer la matrice des corrélations entre les variables exogènes pour détecter la multicolinéarité.

Le coefficient de corrélation échantillonnal entre la variable x_j et la variable x_k est donné par

$$r_{jk} = \frac{1}{n-1} \sum_{i=1}^{n} \frac{(x_{ji} - \overline{x}_j)(x_{ki} - \overline{x}_k)}{s_j s_k},\ j \in \{1, \ldots, p\}, k \in \{1, \ldots, p\}$$

où $\overline{x}_j = \sum_{i=1}^{n} x_{ji}/n$ et $s_j = \sqrt{\sum_{i=1}^{n}(x_{ji} - \overline{x}_j)^2/(n-1)}$, et de même pour $\overline{x}_k$ et s_k.

On peut aussi écrire la matrice des coefficients de corrélation échantillonnaux (en excluant la colonne de 1) comme

$$\boldsymbol{X}_c^{*'}\boldsymbol{X}_c^* = \begin{pmatrix} 1 & r_{12} & \cdots & r_{1p} \\ r_{21} & 1 & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & 1 \end{pmatrix}$$

où

$$\boldsymbol{X}_c^* = \left(\frac{\boldsymbol{x}_1 - \overline{\boldsymbol{x}}_1}{\sqrt{\sum_i (x_{1i} - \overline{x}_1)^2}} \quad \frac{\boldsymbol{x}_2 - \overline{\boldsymbol{x}}_2}{\sqrt{\sum_i (x_{2i} - \overline{x}_2)^2}} \ldots \frac{\boldsymbol{x}_p - \overline{\boldsymbol{x}}_p}{\sqrt{\sum_i (x_{pi} - \overline{x}_p)^2}} \right) \quad \text{et} \quad \overline{\boldsymbol{x}}_j = (\overline{x}_j, \ldots, \overline{x}_j)'.$$

Si deux variables exogènes sont linéairement reliées, leur coefficient de corrélation devrait être élevé. Cependant deux problèmes majeurs empêchent les coefficients de corrélation d'être des bons outils de diagnostic :

(i) il est difficile de dire ce qu'est une grande valeur de la corrélation

(ii) la multicolinéarité est souvent induite par une dépendance linéaire entre plus de deux variables.

Pour voir que le point (ii) constitue un problème, il est possible de créer des exemples où p variables sont parfaitement linéairement dépendantes, mais où les coefficients de corrélation de toutes les paires de variables sont égaux en valeur absolue à $1/(p-1)$. Ainsi, même si la corrélation entre deux variables est indésirable, cela ne représente qu'un cas particulier de la multicolinéarité.

9.2.2 Le facteur d'inflation de la variance (VIF)

Une approche plus sensible consiste à évaluer le degré de dépendance linéaire de chaque variable exogène sur les autres variables exogènes. Ainsi pour la j^e variable exogène, on peut mesurer ce niveau de dépendance en effectuant une régression linéaire avec la j^e variable exogène comme variable réponse et les $p-1$ variables exogènes restantes comme variables explicatives. Le coefficient de détermination de cette régression, noté R_j^2, mesurera la proportion de la variabilité de la j^e variable exogène qui est expliquée de façon linéaire par les autres variables exogènes. Si R_j^2 est grand, on a vraisemblablement un problème.

Cette idée se matérialise dans le facteur d'inflation de la variance (en anglais, VIF pour Variance Inflation Factor). Celui-ci est défini de la façon suivante :

$$\text{VIF}_j \quad = \quad \frac{1}{1 - R_j^2} \tag{9.1}$$

Si $R_j^2 \to 1$, alors $VIF_j \to \infty$. Ainsi, une grande valeur de VIF_j signifie une valeur proche de 1 de R_j^2, et donc une forte dépendance linéaire des variables exogènes.

Le nom « facteur d'inflation de la variance » vient du fait que la variance de $\hat{\beta}_j$ s'exprime en fonction du VIF comme suit :

$$\mathbb{V}\text{ar}[\hat{\beta}_j] \quad = \quad \frac{\sigma^2}{(\boldsymbol{X}'\boldsymbol{X})_{jj}}\text{VIF}_j$$

On voit donc l'effet de cette multicolinéarité sur la variance des estimateurs des coefficients.

Plusieurs auteurs suggèrent un VIF > 10 comme point où l'on doit commencer à considérer la présence de multicolinéarité aux conséquences importantes. Cependant, les VIF à eux seuls ne sont pas un diagnostic complet. Parmi les points faibles des VIF on dénote

(i) l'incapacité de détecter des multicolinéarités impliquant la colonne de 1 de la matrice d'incidence

(ii) l'incapacité de cerner le nombre de quasi dépendances linéaires présentes dans les données

(iii) le fait qu'on a jamais réussi à cerner une valeur précise pour le VIF où l'on doit vraiment commencer à s'inquiéter (10 est une valeur *ad hoc*).

Remarque 16. *Une mesure équivalente au facteur d'inflation de la variance est la tolérance définie comme suit :*

$$TOL_j = 1 - R_j^2 = 1/VIF_j.$$

La tolérance TOL_j est donc la partie de la variabilité dans la $j^{ème}$ variable exogène qui n'est pas expliquée par les autres variables exogènes. Ainsi, si on définit un cas problématique comme un cas où $VIF > 10$, ceci est équivalent à définir les cas problématiques comme ceux ayant une $TOL < 10\%$, c'est-à-dire ceux pour qui au moins 90 % de la variabilité est expliquée par les autres variables exogènes.

9.2.3 L'indice de conditionnement

L'approche la plus efficace afin de détecter les causes de multicolinéarité est basée sur les valeurs propres de la matrice des coefficients de corrélation échantillonnaux $\boldsymbol{X}_c^{*'}\boldsymbol{X}_c^*$, ou sur la matrice des valeurs réduites, mais non centrées $\boldsymbol{X}^*$ (qui permet l'inclusion de la colonne de 1), où

$$\boldsymbol{X}^* = \left(\frac{\boldsymbol{x}_1}{\sqrt{\sum_i x_{1i}^2}} \quad \frac{\boldsymbol{x}_2}{\sqrt{\sum_i x_{2i}^2}} \cdots \frac{\boldsymbol{x}_p}{\sqrt{\sum_i x_{pi}^2}} \right).$$

En se servant de la décomposition en valeurs propres de $\boldsymbol{X}^{*'}\boldsymbol{X}^*$, i.e.

$$\boldsymbol{X}^{*'}\boldsymbol{X}^* = \boldsymbol{P}\boldsymbol{\Lambda}\boldsymbol{P}'$$

avec $\boldsymbol{\Lambda} = \text{diag}(\lambda_1, \ldots, \lambda_{p'})$ et $\boldsymbol{P}\boldsymbol{P}' = \boldsymbol{P}'\boldsymbol{P} = \boldsymbol{I}_{p'}$, on peut alors montrer que

$$\text{tr}(\boldsymbol{X}^{*'}\boldsymbol{X}^*) = \text{tr}(\boldsymbol{P}\boldsymbol{\Lambda}\boldsymbol{P}') = \text{tr}(\boldsymbol{P}'\boldsymbol{P}\boldsymbol{\Lambda}) = \text{tr}(\boldsymbol{\Lambda}) = \sum_{j=1}^{p'} \lambda_j = p'. \tag{9.2}$$

En présence de multicolinéarité, le déterminant de $\boldsymbol{X}^{*'}\boldsymbol{X}^{*}$, qui est égal à $\prod_{j=1}^{p'} \lambda_j$, aura une valeur proche de 0.

Ainsi, en présence de multicolinéarité l'équation 9.2 indique que la somme des valeurs propres doit être égale à p', mais que leur produit sera proche de 0. Puisque les valeurs propres sont toutes positives, cela implique qu'en présence de multicolinéarité, il y aura à la fois des valeurs propres de grandes et de faibles valeurs. Le nombre de valeurs propres proches de zéro indique le nombre de directions presque linéairement dépendantes. Dans cette situation, le rapport de la plus grande valeur propre sur la plus faible sera donc élevé.

Les **indices de conditionnement** notés η_j pour $j = 1, 2, \cdots, p'$ sont définis comme les racines carrées des rapports entre la plus grande valeur propre de la matrice $\boldsymbol{X}^{*'}\boldsymbol{X}^{*}$ et chacune de ses autres valeurs propres, c'est-à-dire

$$\eta_j = \sqrt{\frac{\lambda_{max}}{\lambda_j}}.$$

Plusieurs auteurs semblent s'entendre pour dire qu'une valeur de $\eta_j > 30$ indique une multicolinéarité dont il faut se soucier.

La plus grande valeur de η_j est égale à

$$\kappa = \sqrt{\frac{\lambda_{max}}{\lambda_{min}}}.$$

κ est parfois appelée **facteur de conditionnement**.

Soit $\boldsymbol{p}_j$, le vecteur propre correspondant à la valeur propre λ_j. Pour les coefficients associés aux colonnes normalisées,

$$\mathbb{V}\text{ar}[\hat{\beta}_{k-1}] = \sigma^2(\boldsymbol{X}^{*'}\boldsymbol{X}^{*})^{-1}_{kk} = \sigma^2 \sum_{j=1}^{p'} p_{kj}^2/\lambda_j,$$

la portion de variance de $\hat{\beta}_{k-1}$ expliquée par la j^e dépendance linéaire peut se mesurer comme suit :

$$v_{kj} = \frac{p_{kj}^2/\lambda_j}{\sum_{l=1}^{p'} p_{kl}^2/\lambda_l}.$$

Pour détecter la multicolinéarité on suit donc la procédure suivante :

1. Calculer les indices de conditionnement η_j et vérifier si certains d'entre eux possèdent une valeur supérieure à 30.
2. Pour chaque η_j dont la valeur excède 30, calculer les proportions de la variance $v_{1j}, v_{2j}, \cdots, v_{p'j}$.
3. Les variables exogènes correspondant aux coefficents avec des valeurs de v_{kj} élevées (en général nettement supérieures à 60 %) sont multicolinéaires.

9.3 Les solutions possibles à la multicolinéarité

La solution la plus simple est de retirer une ou plusieurs variables exogènes. Typiquement, on retranchera les variables ayant le plus grand VIF, une à la fois. Dans la pratique, ce retrait des variables doit se faire en collaboration étroite avec le client, car dans le choix des variables, c'est d'abord l'interprétation qui compte. Il est parfois possible de combiner des variables exogènes redondantes, par exemple pour calculer un score à partir de plusieurs variables exogènes.

Quelques autres solutions sont également disponibles.

9.3.1 La régression « ridge »

La régression ridge, présentée à la section 8.6.1 peut également être utilisée en cas de multicolinéarité, mais donne des estimateurs biaisés. Le paramètre de pénalisation se choisit, par exemple, par validation croisée.

9.3.2 La régression basée sur les composantes principales

On peut également faire une régression sur les composantes principales de la matrice d'incidence. Les facteurs dans une analyse en composantes principales sont donnés par les colonnes de la matrice $\boldsymbol{F}$ suivante : $\boldsymbol{F} = \boldsymbol{X}^*\boldsymbol{P}$, où $\boldsymbol{P}$ est la matrice des vecteurs propres de $\boldsymbol{X}^{*'}\boldsymbol{X}^*$. Cette matrice est telle que $\boldsymbol{P}'\boldsymbol{P} = \boldsymbol{P}\boldsymbol{P}' = \mathbb{I}$. En utilisant cette propriété matricielle, nous pouvons écrire le modèle de régression multiple comme

$$\begin{aligned}\boldsymbol{Y} &= \beta_0\mathbf{1} + \boldsymbol{X}^*\boldsymbol{\beta} + \boldsymbol{\varepsilon} \\ &= \beta_0\mathbf{1} + \boldsymbol{X}^*\boldsymbol{P}\boldsymbol{P}'\boldsymbol{\beta} + \boldsymbol{\varepsilon} \\ &= \beta_0\mathbf{1} + \boldsymbol{F}\boldsymbol{\gamma} + \boldsymbol{\varepsilon},\end{aligned}$$

où $\boldsymbol{\gamma} = \boldsymbol{P}'\boldsymbol{\beta}$ ou encore $\boldsymbol{\beta} = \boldsymbol{P}\boldsymbol{\gamma}$. Le théorème de Gauss-Markov implique que $\widehat{\boldsymbol{\beta}} = \boldsymbol{P}\hat{\boldsymbol{\gamma}}$. La multicolinéarité n'est plus présente, mais au prix d'un biais dans les estimateurs. Ce biais est présent si on ne retient dans la modélisation que les facteurs associés aux plus grandes valeurs propres de $\boldsymbol{X}^{*'}\boldsymbol{X}^*$.

Le principal problème de la régression en composantes principales est son interprétation, qui peut être hasardeuse.

Chapitre 10

Observations aberrantes et influentes

Sommaire

10.1 Sources de l'influence 100
10.2 Mesures d'influence 101
10.2.1 Influence sur la prévision 102
10.2.2 Influence sur les estimations des paramètres 102
10.2.3 Influence sur la performance des estimateurs 103
10.3 Que faire avec les données influentes ? 103

On doit examiner les observations qui influencent fortement l'estimation des paramètres et documenter leur effet par une analyse de sensibilité. Avant de parler plus en détails de ces données influentes, il faut bien définir deux termes importants.

Définition 10.1. *Une observation est* ***aberrante*** *si elle ne cadre pas avec le modèle.*

Ce sera donc une observation qui a un résidu de grande taille. Une donnée aberrante n'est pas problématique en elle-même, mais elle peut indiquer une erreur dans la valeur d'une variable exogène ou de la variable endogène.

Définition 10.2. *Une donnée* ***influente*** *est une observation qui, à elle seule, peut avoir un impact sérieux sur les conclusions d'une analyse de régression.*

Parmi les exemples « d'impact sérieux », on peut citer des $\hat{\beta}$ négatifs quand on sait qu'ils devraient être positifs (ou vice-versa) ou encore une variable exogène qui devrait être importante mais qui est considérée non significative. Une ou des observations influentes peut également diminuer le pouvoir prédictif du modèle.

10.1 Sources de l'influence

L'influence d'une observation provient souvent d'une combinaison de deux sources :

Source 1 : L'observation a un grand levier, c'est-à-dire qu'elle a une grande capacité *a priori* à influencer les résultats de la régression.

Source 2 : L'observation a une valeur extrême de Y par rapport au modèle.

On peut facilement identifier les observations avec ces deux caractéristiques.

Levier d'une observation

Une observation a un grand levier si sa valeur de $\boldsymbol{x}_i$ est loin du centre (centroïde) de toutes les observations. La distance entre une observation et le centroïde de toutes les autres peut être calculée facilement à partir de la matrice d'incidence $\boldsymbol{X}$. Plus précisément, le levier de la i^e observation est le i^e élément diagonal de la matrice chapeau $\boldsymbol{H} = \boldsymbol{X}(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'$, qui peut s'exprimer comme $h_{ii} = \boldsymbol{x}_i'(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{x}_i$.

Qu'est-ce qu'une grande valeur de h_{ii} ? Il est difficile de répondre à cette question de façon générale. Cependant nous savons que $\text{tr}(\boldsymbol{H}) = \sum_{i=1}^{n} h_{ii} = p'$, où p' est le nombre de paramètres dans le modèle. Donc un h_{ii} moyen prend une valeur de p'/n et un h_{ii} qui se démarque nettement de cette valeur signifie une donnée à grand levier. Belsley et coll. (1980) suggèrent de retenir les valeurs de $h_{ii} > 2p'/n$.

Observation extrême

Une observation est extrême (ou aberrante) par rapport au modèle si son résidu est grand. On regardera plus précisément le résidu studentisé. On rappelle que celui-ci est donné par

En notant p' le nombre de coefficients, incluant l'ordonnée à l'origine,

$$s^2_{(i)} = \frac{(n-p')\hat{\sigma}^2 - \hat{\varepsilon}_i^2/(1-h_{ii})}{n-p'-1}, \qquad T_i = \frac{\hat{\varepsilon}_i}{s_{(i)}\sqrt{1-h_{ii}}}.$$

Sous les postulats normaux et si le modèle privé de l'observation i reste de plein rang, $T_i \sim \mathcal{T}_{n-p'-1}$. Un repère exploratoire courant est $|T_i| > 2$. Pour un dépistage simultané au seuil α, on peut comparer $|T_i|$ à $t_{n-p'-1;1-\alpha/(2n)}$. Ces repères ne constituent pas des règles automatiques de retrait.

Remarque 17. *Avoir un grand levier et être une observation extrême sont des indices qu'une observation pourrait avoir une influence démesurée sur les résultats de la régression. Pour tester si cela est effectivement le cas, on doit mesurer directement l'influence de l'observation sur la régression. Il est important de comprendre qu'une donnée avec un grand levier peut ne pas être influente. Il en est de même pour une observation extrême.*

10.2 Mesures d'influence

Pour mesurer si une donnée est influente ou non, on évalue son impact sur la prévision $\widehat{\boldsymbol{Y}}$ et sur l'estimation de $\boldsymbol{\beta}$. Les différentes statistiques utilisées sont présentées ici.

10.2.1 Influence sur la prévision

La statistique suivante mesure l'influence de la i^e donnée dans la prévision $\hat{Y}_i$ de Y_i (*Difference in Fit*) :

$$DFFIT_i = \frac{\hat{Y}_i - \hat{Y}_{i,-i}}{\hat{\sigma}_{-i}\sqrt{h_{ii}}} = T_i\sqrt{\frac{h_{ii}}{1-h_{ii}}},$$

où $\hat{Y}_{i,-i}$ désigne la valeur de la prévision de Y_i basée sur un jeu de données qui ne contient pas la i^e donnée, c'est-à-dire $\hat{Y}_{i,-i} = \boldsymbol{x}_i'\hat{\boldsymbol{\beta}}_{-i}$.

Il faut se rappeler ici que $\mathbb{V}\text{ar}[\hat{Y}_i] = \sigma^2 h_{ii}$. Les différences au numérateur de $DFFIT_i$ sont donc standardisées de sorte qu'elles s'expriment en multiples de l'écart-type de la prévision.

Nous analysons les $DFFIT_i$ de la même façon que nous nous penchons sur les T_i, c'est-à-dire que des grandes valeurs de $|DFFIT_i|$ constituent un signe que la i^e donnée possède une grande influence sur la valeur de la prévision. Belsley et coll. (1980) indiquent qu'il faut retenir les valeurs de $|DFFIT_i| > 2\sqrt{p'/n}$ alors que d'autres statisticiens proposent simplement de retenir les valeurs de $|DFFIT_i| > 2$.

10.2.2 Influence sur les estimations des paramètres

La statistique suivante mesure l'influence de la i^e observation sur la valeur de l'estimateur de β_j (*Difference in Beta*) :

$$DFBETAS_{ji} = \frac{\hat{\beta}_j - \hat{\beta}_{j,-i}}{\hat{\sigma}_{-i}\sqrt{(\boldsymbol{X}'\boldsymbol{X})^{-1}_{jj}}}.$$

Il faut se souvenir ici que $\mathbb{V}\text{ar}[\hat{\beta}_j] = \sigma^2(\boldsymbol{X}'\boldsymbol{X})^{-1}_{jj}$. Les différences au numérateur de la statistique sont à nouveau standardisées. Encore une fois, les grandes valeurs de $DFBETAS_{ji}$ indiquent que la i^e donnée possède une grande influence sur l'estimation de β_j. Belsley et coll. (1980) proposent de considérer les valeurs de $|DFBETAS_{ji}| > 2/\sqrt{n}$ alors que d'autres statisticiens suggèrent simplement de retenir les valeurs de $|DFBETAS_{ji}| > 2$.

Le signe de $DFBETAS_{ji}$ est un bon indicateur. En effet, si un certain $\hat{\beta}_j$ est négatif alors qu'on se serait attendu à une valeur positive, alors un $DFBETAS_{ji}$ très négatif indique que le « coupable »pourrait être l'observation i.

Comme nous obtenons $p\prime$ valeurs de $DFBETAS$ pour chaque observation, cette mesure devient peu pratique lorsque nous sommes en présence d'un jeu de données ayant plusieurs variables exogènes. Pour simplifier la recherche de valeurs influentes, Dennis Cook a proposé la statistique suivante, appelée

distance de Cook, qui permet de combiner les $DFBETAS$ d'une même observation :

$$\begin{aligned}\text{distance de Cook}_i \;=\; C_i \;&=\; \frac{(\hat{\boldsymbol{\beta}}-\hat{\boldsymbol{\beta}}_{-i})'(\boldsymbol{X}'\boldsymbol{X})(\hat{\boldsymbol{\beta}}-\hat{\boldsymbol{\beta}}_{-i})}{p'\hat{\sigma}^2}\\ &=\; \frac{\sum_{k=1}^{n}(\hat{Y}_k-\boldsymbol{x}_k'\hat{\boldsymbol{\beta}}_{-i})^2}{p'\hat{\sigma}^2}\\ &=\; \frac{\hat{\varepsilon}_i^2}{(1-h_{ii})^2}\frac{h_{ii}}{\hat{\sigma}^2 p'}\end{aligned}$$

Une grande valeur de C_i indique une observation ayant une influence prépondérante sur les β. Fox (1991) suggère de porter notre attention sur les valeurs de $C_i > \frac{4}{n-p'}$. Il s'agit par la suite d'examiner les $DFBETAS$ pour cette observation pour savoir quel(s) $\hat{\beta}$ est (sont) affecté(s).

10.2.3 Influence sur la performance des estimateurs

Une donnée peut aussi avoir un impact néfaste sur la variance des estimateurs. Soit $||Var(\hat{\boldsymbol{\beta}})|| = (\sigma^2)^{p'}||(\boldsymbol{X}'\boldsymbol{X})^{-1}||$, le déterminant de la matrice de variance de $\hat{\boldsymbol{\beta}}$, parfois appelé variance généralisée. L'influence de la i^e donnée sur la variance de $\hat{\boldsymbol{\beta}}$ peut être calculée comme suit :

$$\begin{aligned}COVRATIO_i \;&=\; \frac{||(\boldsymbol{X}'_{-i}\boldsymbol{X}_{-i})^{-1}\hat{\sigma}^2_{-i}||}{||(\boldsymbol{X}'\boldsymbol{X})^{-1}\hat{\sigma}^2||}\\ &=\; \left(\frac{\hat{\sigma}^2_{-i}}{\hat{\sigma}^2}\right)^{p'}\frac{1}{1-h_{ii}}.\end{aligned}$$

Comme la seconde ligne l'illustre, une donnée possédant beaucoup de levier donnera en général un $COVRATIO > 1$, et une donnée aberrante un $COVRATIO < 1$.

Belsley et coll. (1980) proposent de porter notre attention sur les valeurs telles que $|COVRATIO - 1| > 3p'/n$, c'est-à-dire sur les observations telles que
$COVRATIO < 1 - 3p'/n$ ou $COVRATIO > 1 + 3p'/n$.

10.3 Que faire avec les données influentes ?

Si une donnée est influente, il faut prendre tous les moyens possibles pour essayer de comprendre comment cette donnée a été obtenue et s'assurer qu'il n'y a pas d'erreur qui aurait pu survenir lors de la mesure, collecte ou saisie des données.

Si l'influence provient d'un grand levier, alors il serait souhaitable d'aller chercher d'autres données afin de combler le vide entre le centroïde des données et la donnée influente.

En général, on doit s'abstenir d'éliminer les données influentes d'un jeu de données. Quelques exceptions :

— Erreur de mesure ou de saisie (corriger la donnée est préférable à son élimination).

— Valeurs mesurées scientifiquement peu plausibles.

— Donnée très peu représentative du reste des données et de la population en général.

Il est à noter que souvent, une transformation de variable peut grandement réduire l'influence de certaines données.

Chapitre 11

Techniques plus avancées

Sommaire

11.1 Régression polynomiale **105**
11.2 Régression non linéaire **108**
11.3 Régression pondérée **110**
11.4 Modélisation de la dépendance **112**
11.5 Autres **112**

Figures

11.1 Données d'une expérience sur des rats de laboratoire avec la fonction de régression estimée 109

On présente ici quelques techniques de régression plus avancées. Elles peuvent entre autres être utilisées si les postulats de la RLM ne sont pas vérifiés.

11.1 Régression polynomiale

L'idée derrière la régression linéaire est que le modèle linéaire est une bonne approximation de la « vraie »relation entre la variable endogène et les variables exogènes

$$Y = f(x_1, x_2, \ldots, x_k) + \varepsilon.$$

Dans plusieurs cas, le modèle de régression linéaire sera une approximation suffisamment bonne de $f(x_1, \ldots, x_k)$. Par contre dans certaines situations, il arrive que l'approximation linéaire ne soit pas assez proche de $f(x_1, \ldots, x_k)$ pour donner un modèle approprié. Dans ces cas, nous pouvons utiliser le principe disant que la plupart des fonctions peuvent être approchées aussi bien que l'on veut par une expansion polynomiale. Plus il y a de la « courbure »dans $f(x_1, \ldots, x_k)$, plus le polynôme utilisé pour approcher $f(x_1, \ldots, x_k)$ doit être de degré élevé pour que l'approximation soit suffisamment précise.

En régression, ceci se traduit par le résultat suivant :

$$\begin{aligned} Y_i &= f(x_{1i}, \ldots, x_{ki}) + \varepsilon_i \\ &\approx \beta_0 + \beta_1 x_{1i} + \cdots + \beta_k x_{ki} \\ &\quad + \beta_{11} x_{1i}^2 + \cdots + \beta_{kk} x_{ki}^2 + \beta_{12} x_{1i} x_{2i} + \cdots + \beta_{k-1,k} x_{k-1,i} x_{ki} \\ &\quad + \beta_{111} x_{1i}^3 + \cdots + \beta_{kk\cdots k} x_{ki}^d + \cdots + \varepsilon_i. \end{aligned}$$

En général, il est rarement nécessaire de dépasser un modèle du second degré :

$$\begin{aligned} Y_i &= \beta_0 + \beta_1 x_{1i} + \cdots + \beta_k x_{ki} \\ &\quad + \beta_{11} x_{1i}^2 + \cdots + \beta_{kk} x_{ki}^2 + \beta_{12} x_{1i} x_{2i} + \cdots + \beta_{k-1,k} x_{k-1,i} x_{ki}. \end{aligned}$$

Il est possible que l'on rencontre des problèmes numériques ou de multicolinéarité quand on utilise des modèles polynomiaux. Si l'objectif est de trouver un modèle faisant de bonnes prédictions, ce n'est pas vraiment un problème. Si on veut vraiment interpréter les valeurs des coefficients de chaque terme, alors on peut travailler avec les variables exogènes standardisées, c'est-à-dire de remplacer x_{ji} par

$$x_{ji}^* = \frac{(x_{ji} - \bar{x}_j)}{s_j}$$

où $\bar{x_j} = \sum_i x_{ji}/n$ et $s_j^2 = \sum_i (x_{ji} - \bar{x}_j)^2/(n-1)$.

Sélection de modèle

Comme c'était le cas avec les interactions, si un terme de degré d est inclus dans le modèle, alors en général on inclut les termes de degré inférieur à d.

Test de comparaison de modèle pour justifier un degré supérieur

Exemple 11.1. *Soit le modèle* $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$.

Ce modèle est-il aussi valide que celui contenant des termes de degré 2 ?

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{11} x_1^2 + \beta_{22} x_2^2 + \beta_{12} x_1 x_2 + \varepsilon.$$

Nous pouvons utiliser un test F *de comparaison de modèles pour les hypothèses*
H_0 : $\beta_{11} = \beta_{22} = \beta_{12} = 0$ *contre*
H_1 : *au moins un de ces* β *diffère de 0.*

Si nous ne rejetons pas H_0*, les données ne montrent pas d'amélioration significative par ces termes de second degré ; les autres diagnostics restent nécessaires. Si nous rejetons* H_0*, alors le modèle de premier degré n'est pas adéquat.*

On aurait pu vérifier l'ajout d'un seul terme à la fois, car il est fort possible qu'une relation quadratique soit souhaitable en x_1 mais pas en x_2.

11.2 Régression non linéaire

Si l'espérance de Y (ou de $g(Y)$) n'est pas une fonction linéaire des paramètres inconnus, mais qu'on a une idée de la vraie relation entre Y et les variables indépendantes, on peut néanmoins estimer les paramètres de cette relation non linéaire avec la méthode des moindres carrés. Il n'y a pas de solution analytique dans ce cas, mais des méthodes numériques peuvent minimiser la somme des carrés des erreurs.

Exemple 11.2. *Dans une expérience sur des rats, on trempe des portions du ventricule auriculaire gauche dans une solution de chlorure de calcium, puis on stimule électriquement le tissu et on mesure la longueur du rétrécissement de la bandelette de tissu. On s'intéresse à la relation entre*

x : la concentration de chlorure de calcium (en mM)

Y : le changement de longueur de la bandelette en réaction au choc (en mm)

La figure 11.1 illustre les données. Il est clair qu'un modèle linéaire n'est pas approprié.

Il se trouve toutefois qu'on a déjà une idée du modèle approprié pour les données :

$$Y_i = \alpha + \beta e^{-x_i/\theta} + \varepsilon_i$$

La régression non linéaire permet d'estimer les coefficients par la méthode des moindres carrés. On trouve $\hat{\theta} = 0,6082$, $\hat{\alpha} = 28,9633$ *et* $\hat{\beta} = -34,2274$. *La fonction de régression correspondante est également illustrée à la figure 11.1.*

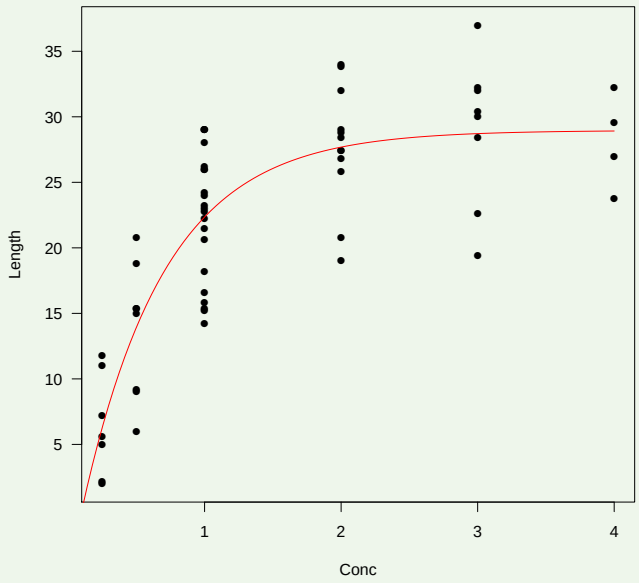


FIGURE 11.1 – Données d'une expérience sur des rats de laboratoire avec la fonction de régression estimée

11.3 Régression pondérée

La méthode des moindres carrés pondérés consiste à attribuer un poids différent à chaque observation, et donc à trouver $\hat{\boldsymbol{\beta}}$ tel que

$$\sum_{i=1}^{n} w_i (Y_i - \hat{Y}_i)^2$$

est minimale, où w_i est le poids associé à l'observation i.

Une application fréquente de la régression pondérée est lorsque l'hypothèse d'homoscédasticité n'est pas respectée, c'est-à-dire si le modèle est plutôt caractérisé par
$\boldsymbol{\varepsilon} \sim \mathcal{N}_n(\mathbf{0}, \text{diag}(\sigma_1^2, \ldots, \sigma_n^2))$, où les σ_i^2 ne sont pas nécessairement égaux.

Le choix des poids w_i n'est pas toujours facile à faire. Si chaque observation est en réalité la moyenne de n_i valeurs, on peut utiliser un poids égal $w_i = n_i$. Si la variance des erreurs est liée à une variable explicative, on peut faire un graphe des paires (x_i, t_i), et voir comment la variance des résidus studentisés évolue en fonction de x_i. Si le graphe est en forme d'entonnoir ouvert vers la droite, alors on pourra prendre $w_i = 1/x_i$, $w_i = 1/\sqrt{x_i}$, $w_i = 1/x_i^2$, etc. Si l'entonnoir ouvre vers la gauche, alors on peut prendre $w_i = x_i$, $w_i = \sqrt{x_i}$, $w_i = x_i^2$, etc. Il est toutefois recommandé d'essayer d'abord de régler le problème à l'aide d'une transformation de variable.

En régression linéaire multiple, il y a plusieurs variables explicatives, il faut donc trouver une stratégie plus globale en cas d'hétéroscédasticité. L'idéal serait d'identifier des poids de la forme $w_i \propto 1/\sigma_i^2$, où σ_i^2 est la variance de l'erreur pour l'observation i. On peut démontrer que dans ce cas,

$$\hat{\boldsymbol{\beta}} = (\boldsymbol{X}'\boldsymbol{V}^{-1}\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{V}^{-1}\boldsymbol{Y},$$

où $\boldsymbol{V} = \text{diag}(\sigma_1^2, \ldots, \sigma_n^2)$. La variance de $\hat{\boldsymbol{\beta}}$ est alors

$$\begin{aligned} \mathbb{V}\text{ar}(\hat{\boldsymbol{\beta}}) &= (\boldsymbol{X}'\boldsymbol{V}^{-1}\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{V}^{-1}\ \boldsymbol{V}\ \boldsymbol{V}^{-1}\boldsymbol{X}(\boldsymbol{X}'\boldsymbol{V}^{-1}\boldsymbol{X})^{-1} \\ &= (\boldsymbol{X}'\boldsymbol{V}^{-1}\boldsymbol{X})^{-1}. \end{aligned}$$

Si $\boldsymbol{V}$ est connue, la statistique obtenue en divisant $\hat{\beta}_j - c$ par son écart-type connu suit une loi normale standard sous H_0. Si $\boldsymbol{V} = \sigma^2\boldsymbol{W}^{-1}$ avec $\boldsymbol{W}$ connue et σ^2 inconnue, on estime σ^2 par

$$s_W^2 = \frac{\sum_i w_i (Y_i - \hat{Y}_i)^2}{n - p'}.$$

Sous normalité, la statistique $(\hat{\beta}_j - c)/\{s_W\sqrt{(\boldsymbol{X}'\boldsymbol{W}\boldsymbol{X})^{-1}_{jj}}\}$ suit alors une loi de Student à $n - p'$ degrés de liberté. Si les poids sont estimés à partir des mêmes données, ces résultats sont généralement approchés.

Or, établir des estimations des σ_i n'est pas si évident. Voici quelques pistes de solutions (il faut d'abord ajuster une régression du modèle complet et s'assurer que la linéarité est respectée) :

— Si le graphique des $\hat{\varepsilon}_i$ en fonction des $\hat{Y}_i$ est en entonnoir, on ajuste une régression des $|\hat{\varepsilon}_i|$ sur les $\hat{Y}_i$. Les valeurs prédites de ce nouvel ajustement sont une estimation de σ_i. (Et les poids seront $w_i = 1/\hat{\sigma}_i^2$).

— Si le graphique des $\hat{\varepsilon}_i^2$ en fonction des $\hat{Y}_i$ montre une tendance à la hausse, on ajuste une régression des $\hat{\varepsilon}_i^2$ sur les $\hat{Y}_i$. Les valeurs prédites de ce nouvel ajustement sont une estimation de σ_i^2. (Et les poids seront $w_i = 1/\hat{\sigma}_i^2$).

Quelques remarques sur la régression pondérée :

— En général, les estimations des $\hat{\beta}_j$ ne seront pas dramatiquement changées par la régression pondérée.

— Les degrés de liberté ne sont pas affectés par l'insertion de poids.

— Les intervalles de confiance et les tests d'hypothèses sont affectés par les poids.

11.4 Modélisation de la dépendance

Lorsque l'hypothèse d'indépendance des observations n'est pas vérifiée, on peut modéliser directement la dépendance en ajoutant des paramètres à la matrice de covariance des erreurs. Alors que la régression pondérée permet des valeurs différentes sur la diagonale de la matrice de covariance des erreurs, on modélise la dépendance en remplaçant les zéros hors diagonale par des paramètres à estimer. Selon la dépendance que l'on souhaite modéliser, on paramétrisera la matrice de covariance différemment.

Une forme particulière de dépendance est l'autocorrélation, qui arrive lorsque le résidu d'une observation est relié à celui de l'observation précédente, par exemple dans une série temporelle. Un modèle dit autorégressif peut alors être utilisé pour ajuster un modèle de régression.

Mathématiquement, on écrit

$$\varepsilon_i = \rho\varepsilon_{i-1} + u_i, \tag{11.1}$$

où les innovations u_i sont i.i.d. $\mathcal{N}(0, \sigma_u^2)$. Le paramètre ρ dans (11.1) est nommé paramètre d'autocorrélation, et sa valeur doit être dans l'intervalle (-1,1).

En supposant le processus stationnaire, avec $\varepsilon_1 \sim \mathcal{N}(0, \sigma_u^2/(1-\rho^2))$ indépendant des innovations futures, à partir de (11.1), nous pouvons calculer directement que

$$\begin{aligned}
\varepsilon_i &= \sum_{j=0}^{\infty} \rho^j u_{i-j} \\
\mathbb{E}[\varepsilon_i] &= \sum_{j=0}^{\infty} \rho^j \mathbb{E}[u_{i-j}] = 0 \\
\mathbb{V}\text{ar}[\varepsilon_i] &= \sigma_u^2 \sum_{j=0}^{\infty} \rho^{2j} = \frac{\sigma_u^2}{1-\rho^2} \\
\mathbb{C}\text{ov}(\varepsilon_i, \varepsilon_{i+j}) &= \rho^{|j|} \frac{\sigma_u^2}{1-\rho^2}.
\end{aligned}$$

Comme on peut le voir, une autocorrélation positive entre ε_i et ε_{i+1} est obtenue lorsque $\rho > 0$, tandis que $\rho < 0$ donne une autocorrélation négative. Il n'y a pas d'autocorrélation lorsque $\rho = 0$.

11.5 Autres

Il existe plusieurs autres modèles de régression plus complexes, notamment la régression linéaire mixte, la régression linéaire locale, la régression non-paramétrique, les arbres de régression, etc.

Bibliographie

Belsley, D. A., Kuh, E. et Welsch, R. E. (1980). *Regression diagnostics : identifying influential data and sources of collinearity*. John Wiley & Sons, New York-Chichester-Brisbane. Wiley Series in Probability and Mathematical Statistics.

Fox, J. (1991). *Regression Diagnostics*. Sage Publications, Newbury Park, California. Quantitative Applications in the Social Sciences Series No. 79.

Galton, F. (1886). Regression towards mediocrity in heriditary stature. *The Journal of the Anthropological Institute of Great Britain and Ireland*, **15**, 246–263. URL http://galton.org/essays/1880-1889/galton-1886-jaigi-regression-stature.pdf.

Gauss, C. F. (1809). *Theoria motus corporum coelestium in sectionibus conicis solem ambientium auctore Carolo Friderico Gauss*. sumtibus Frid. Perthes et IH Besser.

Hines, W., Montgomery, D., Goldsman, D. et Borror, C. (2012). *Probabilités et statistique pour ingénieurs*. Montréal (QC), Canada : Chenelière Éducation. Adaptation par Emmanuelle Reny-Nolin et Luc Adjengue.

Legendre, A. M. (1805). *Nouvelles méthodes pour la détermination des orbites des comètes*. No. 1. F. Didot.

Sen, A. et Srivastava, M. (1990). *Regression Analysis. Theory, Methods, and Applications*. Springer texts in statistics. New York, USA : Springer-Verlag.

White, H. (1980). A heteroskedasticity-consistent covariance matrix estimator and a direct test for heteroskedasticity. *Econometrica*, **48**, 817–838. URL http://dx.doi.org/10.2307/1912934.